

Elastic Attention: 面向高效 Transformer 的测试时自适应稀疏率

Zecheng Tang^{*1,2} Quantong Qiu^{*1,2} Yi Yang^{1,2} Zhiyi Hong^{1,2} Haiya Xiang^{1,2} Kebin Liu³
Qingqing Dang³ Juntao Li^{1,2} Min Zhang¹

Abstract

标准注意力机制的二次复杂度，在长上下文场景中为大语言模型（LLM）带来了显著的可扩展性瓶颈。尽管在同一模型中结合稀疏注意力与全注意力的混合策略是一条可行路径，但现有方法通常采用静态计算比例（即固定的稀疏/全注意力占比），无法在推理时适应不同下游任务对稀疏性的敏感差异。为此，我们提出 **Elastic Attention**，使模型能够根据输入动态调整整体稀疏度。具体而言，我们在现有预训练模型中集成了一个轻量级的 **Attention Router**，用于动态地将每个注意力头分配到不同计算模式。在仅使用 8×A800 GPU 训练 12 小时的条件下，我们的方法即可同时获得较强性能与高效推理（见图 1）。在 3 个主流长上下文基准上的实验结果表明，该方法具有显著优势。

1. 引言

大语言模型（LLM）在长上下文序列处理上已展现出显著能力（Liu et al., 2025a,b; Mei et al., 2025）。然而，标准全注意力（FA）机制（Vaswani et al., 2017）的二次计算与内存复杂度，会随着上下文窗口扩大而迅速成为可扩展性的核心瓶颈。稀疏注意力（SA）机制（Child, 2019; Zaheer et al., 2020）通过仅关注关键 token 子集来有效缓解这一问题，从而显著降低计算开销并提升推理吞吐。

为平衡计算成本与模型质量（即接近 FA 的性能），现有方法通常采用混合建模策略，在单个模型中同时集成 SA 与 FA（Zhang et al., 2025a; Xiao et al., 2025）。但下游任务性能对两种注意力计算模式的占比非常敏感（见 § 2.2 的预分析），而寻找合适占比通常需要大量任务特定验证或调参，这严重限制了方法的鲁棒性与通用性（Peng et al., 2025a）。

本文首先发现，下游任务可自然归纳为两类：（1）稀疏鲁棒型任务（如摘要），在较宽稀疏范围内性能基本稳定；（2）稀疏敏感型任务（如问答），当稀疏度超




Figure 1. Elastic Attention（我们的方法）与现有方法在 LongBench-V2（Bai et al., 2025）上的对比。“(XA+SSA)”与“(FA+SSA)”表示我们的不同配置。

过阈值后性能显著下降。这一观察意味着，模型无需为每个任务分别学习精细稀疏配置，而只需区分这两类任务并分配相应稀疏度。基于此，我们提出 **Elastic Attention**，使模型在 prefill 阶段能够自动调整整体稀疏度，以适配上述两类任务。我们方法的核心是集成到现有 Transformer 架构中的轻量 **Attention Router** 模块。

具体而言，Attention Router 的工作方式类似 Mixture-of-Experts（Shazeer et al., 2017）：它基于输入隐状态执行按头路由，动态将每个注意力头分配到 FA 或 SA 计算模式，从而动态调整模型整体稀疏度。Attention Router 的额外开销很小，在头维度为 128 时每层仅增加 0.27M 参数，兼顾了推理效率与计算成本。为优化该模块，我们采用基于 Gumbel-Softmax（Jang et al., 2016）的连续松弛方案，以缓解离散路由带来的训练-推理不一致问题。同时，为稳定优化过程，我们结合 straight-through estimator（STE）（Bengio et al., 2013）进行梯度传播。推理时，同一层内不同头可以被路由到不同计算模式。我们进一步设计了融合 kernel，使所有被路由的头能够在一次前向中并行处理。

我们在 3 个广泛使用且具有代表性的 LLM 上验证方法（Qwen3 系列（Yang et al., 2025）与 Llama-3.1-8B-Instruct（Grattafiori et al., 2024）），并同时考虑 Streaming（Xiao et al., 2024b）与 block-sparse（Guo

¹ 苏州大学，中国 ²LCM Laboratory ³ 百度公司，中国.
Correspondence to: Juntao Li <ljt@suda.edu.cn>.

et al., 2024) 两种 SA 模式。在覆盖真实任务、合成检索任务与长程推理任务的多类长上下文基准上, 我们的方法不仅能学习到任务相关的稀疏分配, 还在性能上稳定优于基线。值得注意的是, 这一提升在有限训练预算下即可实现: 无需修改骨干模型参数, 仅用 $8 \times A800$ GPU 训练 12 小时。此外, 我们还对 Attention Router 进行了深入分析, 包括架构设计、参数容量影响, 以及详细的训练监控指标。

2. 预备知识

2.1. 检索头与稀疏头

检索头与 FA 检索头是一类专门从长序列中捕获上下文相关 token 的注意力头, 使现代 LLM 能够有效处理长上下文任务 (Wu et al., 2024)。在实践中, 检索头通常采用标准全注意力 (FA) 计算模式。给定 Query (Q)、Key (K) 与 Value (V) 状态, FA 的计算为:

$$\mathcal{O}_r = \text{Softmax}(QK^\top)V, \quad (1)$$

其中为简化表达, 省略了缩放因子。

稀疏头与 SA 与检索头相比, 稀疏头通过采用 SA 模式降低计算成本, 仅保留最相关的一部分 K 与 V (例如仅保留 20% 的 key/value 状态)。SA 的计算可定义为:

$$\mathcal{O}_s = \text{Softmax}(Q\tilde{K}^\top)\tilde{V}, \quad (2)$$

其中 $\tilde{K}$ 与 $\tilde{V}$ 分别是 K 、 V 的子集。

混合头机制 尽管 SA 能显著降低计算量, 但其可能引入性能下降 (Lu et al., 2025b)。为平衡效率与性能, 近期方法提出在同一模型中混合检索头与稀疏头的 *hybrid heads* 设计 (Xiao et al., 2025; Yu et al., 2025; Bhaskar et al., 2025)。具体地, 对于一个包含 L 层、每层有 H 个 key-value 头的 Transformer¹, 第 ℓ 层第 h 个头被分配计算类型: $\pi^{(\ell,h)} \in \{\text{FA}, \text{SA}\}$, 该层最终输出 ($\mathbf{O}^{(\ell)}$) 可写为:

$$\begin{cases} \mathbf{O}^{(\ell)} = \text{Concat}(\mathcal{O}^{(\ell,1)}, \mathcal{O}^{(\ell,2)}, \dots, \mathcal{O}^{(\ell,H)}), \\ \mathcal{O}^{(\ell,h)} = \begin{cases} \mathcal{O}_r, & \pi^{(\ell,h)} = \text{FA}, \\ \mathcal{O}_s, & \pi^{(\ell,h)} = \text{SA}, \end{cases} \end{cases} \quad (3)$$

稀疏率计算 在混合头机制下, 给定模型 f_θ , 我们从两个视角定义两种模型稀疏率: (1) 稀疏注意力头占比; (2) 这些头实际关注 token 的比例。

定义 2.1 (模型稀疏率, Ω_{MSR}). Ω_{MSR} 衡量模型中稀疏

¹此处采用 grouped query attention (GQA) (Ainslie et al., 2023) 的定义而非 multi-head attention (MHA), 因为 GQA 在现代 LLM 架构中更常见。




Figure 2. 当混合模型稀疏率 (MSR) 提升时的性能变化趋势。性能以相对 FA 的百分比形式报告。

头所占比例:

$$\Omega_{\text{MSR}}(f_\theta) = \frac{1}{H} \frac{1}{L} \sum_{h=1}^H \sum_{l=1}^L \mathbb{I}[\pi^{(\ell,h)} = \text{SA}], \quad (4)$$

其中 $\mathbb{I}[\cdot]$ 为指示函数。

定义 2.2 (有效稀疏率, Ω_{ESR}). Ω_{ESR} 衡量整个模型的有效稀疏程度, 同时考虑稀疏头比例与其具体稀疏模式。其计算为:

$$\Omega_{\text{ESR}}(f_\theta) = \frac{1}{H} \frac{1}{L} \sum_{h=1}^H \sum_{l=1}^L \rho^{(\ell,h)}, \quad (5)$$

其中 $\rho^{(\ell,h)} \in [0, 1]$ 表示每个头的剪枝率; 若头采用 FA, 则 $\rho^{(\ell,h)} = 0$ (无 token 被剪枝); 若头采用 SA, 则 $\rho^{(\ell,h)} = \rho_{\text{SA}}$ ²。

2.2. MSR 对下游任务的影响

尽管现有混合头机制在性能-效率上取得了较好权衡, 但仍存在关键局限: MSR 在推理时固定不变, 且其与下游任务性能的关系尚未被系统探索。本节研究不同 Ω_{MSR} 取值对下游任务的影响。

设置 我们使用 Llama3.1-8B-Instruct (Grattafiori et al., 2024), 并遵循 Wu et al. (2024) 的方法识别模型中的检索头并按激活频率排序。基于该排序, 我们逐步将检索头替换为稀疏头, 从而提高 Ω_{MSR} 。我们在 LongBench (Bai et al., 2024) 上评估该过程产生的模型; 该基准包含 6 类长上下文下游任务。对不同 Ω_{MSR} , 我们报告相对于骨干模型 (全 FA) 的性能百分比。例如, 当 $\Omega_{\text{MSR}} = 20\%$ 时, 模型可能达到骨干模型 ($\Omega_{\text{MSR}} = 0\%$) 性能的 73.85%。关于检索头识别背景与实现细节见附录 C。

²不同 SA 策略对应不同 ρ_{SA} 。例如 SA 仅关注序列维度上 10% token 时, $\rho_{\text{SA}} = 0.9$, 表示 90% token 被剪枝。




Figure 3. 我们提出的 Elastic Attention 示意图。(a) 为冻结骨干参数后的模型块；(b) 展示通过 Attention Router 动态分配头；(c) 给出 Attention Router 的轻量化结构。




Figure 4. 我们融合 kernel 与基于 Torch 的逐层串行混合注意力实现的速度对比。

结果 如图 2 所示，任务可大致划分为两类。第一类为 **稀疏鲁棒型任务**，其性能对 Ω_{MSR} 变化不敏感。这类任务通常仅需较粗粒度上下文信息即可完成，例如摘要。第二类为 **稀疏敏感型任务**，当 Ω_{MSR} 超过某阈值后性能会快速下降。这类任务通常需要从上下文中检索细粒度证据以给出准确输出，问答任务即为典型。因此，无论任务类型数量多少，都可映射到上述两类之一。在该设定下，模型只需判断任务是否需要细粒度信息，并据此采用相应注意力计算模式。

3. Elastic Attention

我们的方法概览见图 3。子图 3(a) 展示了集成 Elastic Attention 模块后的整体结构，其核心为 Attention Router 机制。需要强调的是，除 Elastic Attention 相关组件外，训练过程中骨干模型参数全部冻结。

3.1. Attention Router 介绍

Attention Router 的信息流 如子图 3(b) 所示，Attention Router 的工作方式类似 Mixture-of-Experts (MoE) (Shazeer et al., 2017) 门控：它根据输入隐状态，为每个 key-value 头分配注意力计算模式 (FA 或 SA)。具体来说，Key 隐状态 ($\mathbf{x}_K \in \mathbb{R}^{s \times H \times d'}$ ，其中 s 表示序列长度， d' 表示头维度) 被送入 router。随后，router 为每个头输出一个硬二值决策 ($r_{\text{hard}}^{(\ell, h)} \in \{0, 1\}$)，表示该头采用 FA ($r_{\text{hard}}^{(\ell, h)} = 0$) 还是 SA ($r_{\text{hard}}^{(\ell, h)} = 1$)。每个头据此执行对应计算模式，最终在特征维拼接所有头输出，得到该层最终表示。

Attention Router 的结构设计 子图 3(c) 展示了 router 结构，由两个组件组成：**task MLP** 与 **router MLP**。task MLP 用于从输入隐状态中提取任务相关特征，router MLP 则基于该表示决定每个头的计算模式。更具体地，给定 Key 隐状态 ($\mathbf{x}_K$)，router 先沿序列维进行池化，得到任务表示 $\mathbf{x}'_K \in \mathbb{R}^{H \times d'}$ 。³ 再将池化后表示 $\mathbf{x}'_K$ 输入 task MLP 与 router MLP，得到按头路由 logits 矩阵 ($\mathbf{z} \in \mathbb{R}^{H \times 2}$)，并通过 softmax 分类器转换为每个头的二值决策 $r_{\text{hard}}^{(\ell, h)}$ 。

3.2. 基于优化的头识别

Attention Router 优化 为保证训练与推理一致 (推理使用硬路由，即二分类决策)，我们在训练时同样采用硬路由。这带来两个挑战：(i) 如何使 softmax 路由分布逼近硬路由由决策；(ii) 如何处理硬路由导致的不可导问题。针对第一个问题，我们采用带退火的 Gumbel-Softmax (Jang et al., 2016) 连续松弛策略，使路由分布分布在训练过程中逐步收敛到离散分配。具体地，将 $\mathbf{z}$ 输

³ 实际中我们不在完整序列上池化，因为超长上下文包含大量冗余，可能降低任务表示质量。相关分析见附录 H.5。

入 Gumbel-Softmax, 得到软路由矩阵 $r_{\text{soft}}^{(\ell)} \in \mathbb{R}^{H \times 2}$, 其中每列对应第 ℓ 层所有头的路由概率。然后在第二维执行 $\arg \max$ 得到硬路由:

$$r_{\text{hard}}^{(\ell, h)} = \arg \max_{c \in \{0, 1\}} r_{\text{soft}}^{(\ell, h, c)}, \quad \forall h \in \{1, \dots, H\}. \quad (6)$$

针对第二个问题, 由于 $\arg \max$ 不可导会阻断梯度, 我们使用 straight-through estimator (STE) (Bengio et al., 2013):

$$r_{\text{hard}}^{(\ell, h)} = r_{\text{hard}}^{(\ell, h)} + \left[r_{\text{soft}}^{(\ell, h)} - \text{gradient_detach} \left(r_{\text{soft}}^{(\ell, h)} \right) \right], \quad (7)$$

该写法使反向传播可通过软路由分布进行, 同时前向仍保持硬路由行为。更多细节与理论说明见附录 F。

训练目标 训练时我们使用 Ω_{MSR} 计算预测稀疏率, 并与任务目标稀疏度 t 进行比较。与为每个任务强制固定 t 不同, 我们采用预设上下界的任务相关非紧约束, 因为单任务最优稀疏度通常未知。为确保引入稀疏性后语言建模能力不下降, 我们在标准语言建模目标上构造了带稀疏正则项的 min-max 优化目标。给定输入 $\mathcal{X}$ 与标签 $\mathcal{Y}$, 目标函数为:

$$\begin{aligned} & \max_{\lambda_1, \lambda_2} \min \underbrace{L_{\text{language}}(\mathcal{X})}_{\text{language modeling}} + \underbrace{\lambda_1 L_{\text{diff}}(\mathcal{X}) + \lambda_2 L_{\text{diff}}^2(\mathcal{X})}_{\text{sparsity regularization}}, \\ \Rightarrow & \begin{cases} L_{\text{language}} = \text{CE_Loss}(\mathcal{Y} | f_{\theta}(\mathcal{X})), \\ L_{\text{diff}} = \Omega_{\text{MSR}}(f_{\theta}(\mathcal{X})) - t, \end{cases} \end{aligned} \quad (8)$$

其中 CE_Loss 是标准语言建模交叉熵损失, λ_1, λ_2 为任务相关可训练拉格朗日乘子, 通过梯度上升优化 (Bhaskar et al., 2025), 用于解耦不同任务间稀疏性能权衡并缓解优化冲突。

3.3. 高效部署

由于每层都采用混合头计算, 不同类型头在运行时难以高效并行, 我们实现了融合注意力 kernel, 以“同时”计算检索头与稀疏头。本文聚焦单 GPU 部署, 不引入设备间通信开销 (如按头并行)。在实现上, 注意力 kernel 在序列维、注意力头维与 batch 维构成的三维网格上启动。当输入序列足够长时, 序列维并行主导整体执行。由于并发 block 数受限于可用 streaming multiprocessor, GPU 实际上会先调度并执行某个头的大部分序列 block, 再处理下一个头。我们在图 4 中报告了相对基于 Torch 的串行逐层混合注意力实现的加速结果, 表明融合 kernel 在推理 prefill 阶段能够带来加速。更多细节见附录 E。

4. 实验

4.1. 实验设置

训练与数据 我们选择 Qwen3-(4B/8B) (Yang et al., 2025) 和 Llama-3.1-8B-Instruct (Grattafiori et al.,

2024) 作为骨干 LLM。训练数据由 5 个来源构建: ChatQA2-Long-SFT-data (Xu et al., 2024)、MuSiQue (Trivedi et al., 2022)、CoLT-132K (Li et al., 2025)、GovReport (Huang et al., 2021) 与 XSum (Narayan et al., 2018), 覆盖稀疏敏感任务 (单文档 QA、多跳 QA) 与稀疏鲁棒任务 (代码补全、摘要、上下文学习)。最终数据集序列长度范围为 8K 到 64K token, 总计约 0.74B token。针对稀疏鲁棒与稀疏敏感任务, 我们经验设置目标稀疏度分别为 $t = 1.0$ 与 $t = 0.7$ 。我们在 $8 \times \text{A800 GPU}$ 上训练, 每次实验可在 12 小时内完成。更多训练细节见附录 D, 超参数见表 6。

评测 我们将方法与代表性训练式稀疏方法比较, 包括 DuoAttention (Xiao et al., 2025)、PruLong (Bhaskar et al., 2025) 与 InfLLM-V2 (Zhao et al., 2025)。对于稀疏头的注意力计算模式, 我们考虑 Streaming Sparse Attention (SSA) (Xiao et al., 2024b) 与 XAttention (XA) (Xu et al., 2025)。在 XA 中设阈值 $\tau = 0.9$, 其余超参数采用默认值。我们使用“{检索头模式}-{稀疏头模式}”表示不同头配置, 例如 FA-SSA 表示检索头采用 FA、稀疏头采用 SSA。由于篇幅限制, MoBA (Lu et al., 2025a) 与 NSA (Yuan et al., 2025) 的实验, 以及更详细基线配置见附录 G。全部评测均在 LOOM-Eval 框架 (Tang et al., 2025) 上完成。

4.2. 评测结果

真实长上下文任务 我们首先在 LongBench-E (Bai et al., 2024) 上评估方法。该基准包含 6 类共 14 个真实长上下文任务。表 1 对比了 Elastic Attention 与其他基线。在每个比较组中, 所有方法使用相同骨干模型与相同训练数据。结果显示, 我们的方法在平均性能上持续最优, 能够在提升推理效率的同时达到或逼近骨干模型 (全 FA) 表现。在不同任务上, Elastic Attention 能动态分配不同稀疏水平, 例如在代码任务上平均 Ω_{MSR} 约为 0.85, 而在 QA 上约为 0.68。同时我们注意到, 在稀疏鲁棒任务 (如 Code、Summ) 上, 本方法有时弱于部分基线。其原因是我们采用更高稀疏度, 而 InfLLM-V2 在部分场景会使用 FA⁴。

长度外推能力测试 我们在 RULER (Hsieh et al., 2024) 上评测长度外推能力, 考察不同上下文长度区间下模型表现。训练时最大上下文长度为 64K token, 评测长度覆盖 8K 至 256K token。如表 2 (左半部分) 所示, 我们的方法在所有长度上均取得最佳性能, 同时保持较优稀疏水平, Ω_{MSR} 基本稳定在 0.65 ~ 0.7。此外我们观察到, 对于 8B 规模模型, 当上下文超过 64K token 时, FA-XA 配置通常表现最好。原因在于 FA-XA 的 Ω_{ESR} 低于其他配置, 可保留并利用更多有效信息。这种优势在超长上下文下尤为明显, 例如在 256K token 时 FA-XA 仍保持较强性能。

⁴InfLLM-V2 没有严格定义的 Ω_{MSR} , 因为其在上下文长度小于 8K 时使用 FA, 超过 8K 时切换为混合注意力模式。

Table 1. LongBench-E (Bai et al., 2024) 上的性能结果。我们报告各任务类别的平均性能 (Perf.) 与 Ω_{MSR} 。每个比较组中, 性能第 1 与第 2 的结果分别以加粗和下划线 标出。

方法	S-Doc QA		M-Doc QA		Summ		In-Context		Synthetic		Code		平均	
	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR
Qwen3-4B 骨干模型														
Qwen3-4B	43.69	-	38.48	-	28.46	-	66.21	-	49.59	-	54.38	-	48.45	-
+ InfLLM-V2	<u>43.30</u>	-	34.97	-	29.95	-	64.19	-	38.54	-	59.58	-	46.68	-
+ DuoAttention	41.73	0.70	35.72	0.70	28.47	0.70	64.59	0.70	47.17	0.70	53.91	0.70	46.95	0.70
+ PruLong	41.58	0.70	37.58	0.70	<u>28.53</u>	0.70	64.80	0.70	<u>47.23</u>	0.70	53.20	0.70	47.19	0.70
+ Elastic Attention (FA-SSA)	42.20	0.66	<u>38.86</u>	0.68	28.50	0.76	65.73	0.73	48.43	0.71	<u>54.34</u>	0.82	48.08	0.73
+ Elastic Attention (FA-XA)	44.40	0.68	39.42	0.71	28.49	0.82	<u>65.26</u>	0.76	44.35	0.74	54.29	0.87	<u>47.59</u>	0.76
Qwen3-8B 骨干模型														
Qwen3-8B	45.57	-	51.59	-	28.34	-	66.64	-	50.16	-	61.20	-	52.16	-
+ InfLLM-V2	42.20	-	42.33	-	29.58	-	64.55	-	45.87	-	59.58	-	49.03	-
+ DuoAttention	45.45	0.70	44.52	0.70	28.16	0.70	66.42	0.70	47.50	0.70	<u>62.38</u>	0.70	50.67	0.70
+ PruLong	<u>46.05</u>	0.70	<u>46.88</u>	0.70	<u>28.30</u>	0.70	<u>66.61</u>	0.70	<u>48.66</u>	0.70	62.24	0.70	51.34	0.70
+ Elastic Attention (FA-SSA)	46.15	0.64	46.54	0.65	28.19	0.72	67.52	0.71	48.07	0.65	62.95	0.78	<u>51.51</u>	0.69
+ Elastic Attention (FA-XA)	44.01	0.75	49.99	0.76	<u>28.30</u>	0.83	66.23	0.80	50.95	0.77	60.57	0.86	51.66	0.80
Llama-3.1-8B-Instruct 骨干模型														
Llama-3.1-8B-Instruct	48.75	-	51.85	-	30.26	-	68.16	-	56.00	-	55.81	-	53.28	-
+ InfLLM-V2	43.77	-	46.30	-	30.08	-	67.32	-	42.03	-	64.30	-	50.73	-
+ DuoAttention	48.65	0.70	45.21	0.70	29.93	0.70	67.35	0.70	54.56	0.70	56.47	0.70	51.82	0.70
+ PruLong	47.69	0.70	43.05	0.70	30.02	0.70	67.86	0.70	53.56	0.70	<u>61.07</u>	0.70	52.11	0.70
+ Elastic Attention (FA-SSA)	49.92	0.64	<u>48.92</u>	0.63	<u>30.14</u>	0.73	<u>67.99</u>	0.74	<u>54.00</u>	0.64	60.70	0.79	53.35	0.69
+ Elastic Attention (FA-XA)	<u>49.40</u>	0.71	52.94	0.69	30.30	0.80	68.55	0.79	49.66	0.72	56.49	0.87	<u>52.71</u>	0.77




Figure 5. 任务表示相似度可视化。(左) Task MLP 之前, 不同任务池化隐状态的两两余弦相似度较高; (右) 经过 Task MLP 后, 任务间相似度显著降低。

长程推理任务 我们进一步在 LongBench-V2 (Bai et al., 2025) 上评测, 该基准被广泛用于长上下文推理, 长度范围约为 8K 至 2M 词。如表 2 (右半部分) 所示, 我们的方法在 Easy 与 Hard 设置下都取得了稳定强结果, 并获得最佳平均性能 (FA-SSA 或 FA-XA 配置)。值得注意的是, FA-XA 在 Qwen3-8B 上未表现出同等优势, 这可能与该模型自身特性有关, 后续可通过更细粒度超参数调优进一步改进。

5. 消融研究

本节在 Qwen3-4B 与 Llama3.1-8B-Instruct 上对 Elastic Attention 进行分析。我们重点研究其核心组件 Attention Router 的设计 (§ 5.1)、不同目标稀疏度 t 的影响 (§ 5.2)、方法在性能与推理效率间的权衡 (§ 5.3), 以及 Elastic Attention 的可扩展性 (§ 5.4)。




Figure 6. Qwen3-4B 中各头路由激活频率概览。红色表示在 LongBench-E 全部 6 个任务中始终被路由到 FA 的头 (即检索头), 蓝色表示始终被路由到 SA 的头。

5.1. Attention Router 设计

Task MLP 的作用 我们分析 Attention Router 中 Task MLP 的作用。具体地, 我们取模型第一层的 Task MLP, 计算任务隐状态 (x_K) 在通过 Task MLP 前后的两两余弦相似度。余弦相似度越低, 说明任务表示分离度越高, 任务区分能力越强。如图 5 所示, 我们在三类任务上比较后发现, 经过 Task MLP 后任务间相似度明显下降。这表明 Task MLP 能有效解耦任务特征, 为后续 Router MLP 的路由决策提供更具判别性的表示。更多细节及其他模型结果见附录 H.1。

Table 2. RULER (Hsieh et al., 2024) 与 LongBench-v2 (Bai et al., 2025) 上的模型性能。我们报告平均性能 (Perf.) 与 Ω_{MSR} 。

模型	RULER								LongBench-v2			
	8K	16K	32K	64K	128K	256K	性能	MSR	Easy	Hard	性能	MSR
Qwen3-4B 骨干模型												
Qwen3-4B	87.49	86.82	60.05	70.98	53.19	43.27	66.00	-	32.67	22.18	25.96	-
+ InfLLM-V2	78.59	74.40	43.39	44.94	28.57	27.01	51.02	-	28.00	24.06	25.48	-
+ DuoAttention	76.82	75.17	50.53	61.42	45.86	45.46	58.30	0.70	28.67	<u>24.44</u>	25.96	0.70
+ PruLong	77.03	73.99	<u>51.32</u>	60.98	42.70	48.76	58.38	0.70	27.60	22.33	24.35	0.70
+ Elastic Attention (FA-SSA)	83.35	79.24	50.79	67.03	47.83	47.32	61.81	0.66	34.00	<u>24.44</u>	<u>27.88</u>	0.70
+ Elastic Attention (FA-XA)	86.56	85.38	56.88	69.42	49.48	43.47	63.27	0.67	<u>32.00</u>	25.94	28.12	0.72
Qwen3-8B 骨干模型												
Qwen3-8B	89.69	85.62	63.23	82.39	65.84	66.71	75.74	-	39.33	27.82	31.97	-
+ InfLLM-V2	77.01	68.53	25.93	53.47	34.96	32.95	52.58	-	29.32	28.67	29.09	-
+ DuoAttention	81.03	78.85	56.61	70.10	54.68	56.28	65.94	0.70	40.67	25.56	31.01	0.70
+ PruLong	87.20	82.69	61.64	73.05	59.74	58.82	69.90	0.70	<u>38.67</u>	27.82	<u>31.73</u>	0.70
+ Elastic Attention (FA-SSA)	86.62	82.81	64.55	77.41	61.17	61.75	71.74	0.65	37.33	31.20	33.41	0.66
+ Elastic Attention (FA-XA)	85.07	85.12	65.08	82.34	64.57	63.41	73.87	0.76	30.68	<u>30.77</u>	30.74	0.78
Llama-3.1-8B-Instruct 骨干模型												
Llama-3.1-8B-Instruct	92.88	92.83	89.46	70.79	80.12	72.34	83.47	-	32.00	33.08	32.69	-
+ InfLLM-V2	89.30	80.93	60.98	35.90	32.29	47.27	59.10	-	<u>29.32</u>	28.67	<u>29.09</u>	-
+ DuoAttention	87.20	77.85	66.99	40.13	57.45	42.92	62.92	0.70	28.67	27.44	27.88	0.70
+ PruLong	83.54	69.35	56.83	30.88	33.74	21.64	48.82	0.70	28.00	28.92	28.61	0.70
+ Elastic Attention (FA-SSA)	<u>89.93</u>	83.42	80.20	56.30	68.16	56.47	72.85	0.65	28.00	29.70	<u>29.09</u>	0.68
+ Elastic Attention (FA-XA)	92.82	92.00	87.80	68.23	78.87	68.51	81.82	0.72	30.67	30.83	30.77	0.75

Table 3. 不同 MLP 隐层维度的比较。


隐层维度	LongBench	RULER	LongBench-V2	平均
$2 \times d'$	48.07	60.67	26.92	45.22
$4 \times d'$ (默认)	48.08	61.81	27.88	45.92
$6 \times d'$	48.07	62.08	26.20	45.45
$8 \times d'$	48.47	65.27	25.48	46.40

MLP 中间隐层维度影响 我们研究 Attention Router 中 Task-MLP 与 Router-MLP 的中间隐层维度对性能的影响。具体测试范围为 $\times 2 \sim \times 8$ ，其中 $\times 4$ 是主实验默认设置。如表 3 所示，所有设置在 3 个基准上的平均性能差异很小。尽管 $\times 8$ 取得最高总分，我们在主实验中仍采用 $\times 4$ ，因为其在性能收益与额外参数开销之间更均衡。

注意力模式路由分析 Attention Router 分配的注意力计算模式在头级别呈现稳定且一致的规律。我们观察到，在 LLM 中部分头主要采用 FA，而另一些头则常被分配到 SA。如图 6 所示，我们分析了 LongBench-E 6 个子任务上各头的模式分布。可以发现，一部分主要位于中高层的头在各任务中持续以 FA 模式激活。这与 Wu et al. (2024) 的发现一致，说明这些头具有检索头特性。图中浅色高亮的部分头会在不同任务间切换，其余头则稳定路由到 SA。更多结果见附录 H.2。

5.2. 目标稀疏度 t 分配的影响


我们研究目标稀疏度 t (式 8) 对模型性能的影响。具体做法是固定稀疏鲁棒任务目标 $t_{\text{rob}} = 1$ ，并将稀疏敏感任务目标 t_{sen} 从 0.7 逐步降低到 0.4。如图 7 所

Figure 7. 不同训练目标稀疏度 t 设置下的性能与测试时 Ω_{MSR} 对比。柱状图表示性能，折线图表示各任务的 Ω_{MSR} 。


示，随着 t_{sen} 降低，模型分配得到的 Ω_{MSR} 在不同任务间的区分度略有提升。但也可观察到， Ω_{MSR} 并不会严格等于目标 t 。原因在于我们采用的是任务相关且非紧约束，不会强迫模型精确满足指定稀疏度。完整训练曲线与解释见附录 H.4。此外，当 t_{sen} 过低（如 0.4）时，即分配更高比例 FA 计算，整体性能甚至可能超过骨干模型。但从推理效率角度考虑，主实验采用 $t_{\text{sen}} = 0.7$ 与 $t_{\text{rob}} = 1.0$ ，在总体性能与推理效率之间取得更好平衡。

5.3. 整体性能与推理效率

我们在 RULER 多个上下文长度区间上比较不同方法的任务性能与推理效率。实现细节见附录 D.2。如图 8



(a) RULER 上的性能。



(b) 推理加速。


(c) Ω_{ESR} 统计。

Figure 8. 不同方法在 RULER 上的性能与推理加速对比。以 Llama-3.1-8B-Instruct 为骨干，比较训练式方法（FA-SSA）与其他前沿稀疏注意力方法。我们报告 Ω_{ESR} ，以公平比较不同方法在“实际被关注 token 比例”上的差异。

Table 4. 将检索头替换为 XA 的结果。

方法	LongBench	RULER	LongBench-V2	平均
Qwen3-4B	48.45	66.00	25.96	46.80
+ XA-SSA	48.14	63.70	25.96	45.93
Qwen3-8B	52.16	75.74	31.97	53.26
+ XA-SSA	49.25	66.31	32.69	49.42
Llama-3.1-8B	53.28	83.47	32.69	56.48
+ XA-SSA	50.71	70.27	29.09	50.02

所示，我们的方法在所有对比方法中持续取得最佳性能。同时，随着上下文长度增加，模型会动态分配更高 Ω_{MSR} ，推理加速也随之提升。相比之下，若干基线受限于架构设计。例如 NSA 与 InfLLM-V2 对 KV 头数有严格整除约束（如 16 的倍数），与 Llama-3.1-8B 的配置并不匹配；此外 MoBA 与 InfLLM-V2 需要预留部分预算用于序列级特征预计算，在 256K 上下文下会出现 GPU 显存溢出。最后，我们分析基于实际关注 token 数计算的 Ω_{ESR} 。结果表明，随序列长度增加，训练式混合模型的 Ω_{ESR} 近似保持常数；而我们的方法能达到更低且更稳定的 Ω_{ESR} ，并略优于可比基线（如 PruLong），体现了更好的有效稀疏可扩展性。更多细节与对比见附录 H.3。

5.4. Elastic Attention 的可扩展性

我们将检索头以 XA 实现，形成 XA-SSA 配置，使整个模型运行在全 SA 范式下，以评估 Elastic Attention 的可扩展性。如表 4 所示，XA-SSA 仍能保持较强性能。例如在 Qwen3-4B 上，3 个长上下文基准的平均性能差距仍可控制在 1 分以内。尽管 8B 规模模型有一定性能下降，但这种权衡伴随显著推理加速，因为模型采用了完全稀疏注意力结构。

6. 结论

我们提出了 *Elastic Attention*，一种测试时自适应稀疏注意力机制，可根据输入动态调整模型稀疏度。我们表明，通过区分稀疏鲁棒与稀疏敏感两类任务，可以实现有效稀疏分配。因此，Elastic Attention 通过引入轻量 Attention Router，在 FA 与 SA 模式之间按头路由，以适配不同输入任务形态。值得注意的是，Elastic Attention 的额外开销极小，无需修改预训练骨干模型。在 3 个广泛认可的长上下文基准上、面向不同前沿 LLM 的实验验证了我们方法的优势。

References

Ainslie, J., Lee-Thorp, J., De Jong, M., Zemlyanskiy, Y., Lebrón, F., and Sanghai, S. Gqa: Training gen-

- eralized multi-query transformer models from multi-head checkpoints. *arXiv preprint arXiv:2305.13245*, 2023.
- Bai, Y., Lv, X., Zhang, J., Lyu, H., Tang, J., Huang, Z., Du, Z., Liu, X., Zeng, A., Hou, L., Dong, Y., Tang, J., and Li, J. LongBench: A bilingual, multi-task benchmark for long context understanding. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 3119–3137, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-long.172. URL <https://aclanthology.org/2024.acl-long.172>.
- Bai, Y., Tu, S., Zhang, J., Peng, H., Wang, X., Lv, X., Cao, S., Xu, J., Hou, L., Dong, Y., et al. Longbench v2: Towards deeper understanding and reasoning on realistic long-context multitasks. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 3639–3664, 2025.
- Beltagy, I., Peters, M. E., and Cohan, A. Longformer: The long-document transformer. *arXiv:2004.05150*, 2020.
- Bengio, Y., Léonard, N., and Courville, A. Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*, 2013.
- Bhaskar, A., Wettig, A., Gao, T., Dong, Y., and Chen, D. Cache me if you can: How many kvs do you need for effective long-context lms? *arXiv preprint arXiv:2506.17121*, 2025.
- Child, R. Generating long sequences with sparse transformers. *arXiv preprint arXiv:1904.10509*, 2019.
- Dao, T. FlashAttention-2: Faster attention with better parallelism and work partitioning. In *International Conference on Learning Representations (ICLR)*, 2024.
- Dao, T. and Gu, A. Transformers are ssms: Generalized models and efficient algorithms through structured state space duality, 2024. URL <https://arxiv.org/abs/2405.21060>.
- DeepSeek-AI. Deepseek-v3.2-exp: Boosting long-context efficiency with deepseek sparse attention, 2025.
- Gao, Y., Zeng, Z., Du, D., Cao, S., So, H. K.-H., Cao, T., Yang, F., and Yang, M. Seerattention: Learning intrinsic sparse attention in your llms. *arXiv preprint arXiv:2410.13276*, 2024.
- Glorioso, P., Anthony, Q., Tokpanov, Y., Whittington, J., Pilault, J., Ibrahim, A., and Millidge, B. Zamba: A compact 7b ssm hybrid model, 2024. URL <https://arxiv.org/abs/2405.16712>.
- Grattafiori, A., Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Vaughan, A., et al. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.
- Guo, J., Tang, H., Yang, S., Zhang, Z., Liu, Z., and Han, S. Block Sparse Attention. <https://github.com/mit-han-lab/Block-Sparse-Attention>, 2024.
- He, Z., Zhang, Y., Zhang, C., Jiang, H., Yang, Y., and Qiu, L. Trianglemix: Accelerating prefilling via decoding-time contribution sparsity, 2025. URL <https://arxiv.org/abs/2507.21526>.
- Hsieh, C.-P., Sun, S., Krizan, S., Acharya, S., Rekesh, D., Jia, F., Zhang, Y., and Ginsburg, B. Ruler: What’s the real context size of your long-context language models? *arXiv preprint arXiv:2404.06654*, 2024.
- Huang, L., Cao, S., Parulian, N., Ji, H., and Wang, L. Efficient attentions for long document summarization. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 1419–1436, Online, June 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.naacl-main.112. URL <https://aclanthology.org/2021.naacl-main.112>.
- Jang, E., Gu, S., and Poole, B. Categorical reparameterization with gumbel-softmax. *arXiv preprint arXiv:1611.01144*, 2016.
- Ji, X., Zhang, H., Fu, F., and Cui, B. Sale : Low-bit estimation for efficient sparse attention in long-context llm prefilling, 2025. URL <https://arxiv.org/abs/2505.24179>.
- Jiang, H., Li, Y., Zhang, C., Wu, Q., Luo, X., Ahn, S., Han, Z., Abdi, A. H., Li, D., Lin, C.-Y., et al. Minference 1.0: Accelerating pre-filling for long-context llms via dynamic sparse attention. *Advances in Neural Information Processing Systems*, 37:52481–52515, 2024.
- Ku, J., Nguyen, E., Romero, D. W., Brix, G., Yang, B., Vorontsov, A., Taghibakhshi, A., Lu, A. X., Burke, D. P., Brockman, G., Massaroli, S., Ré, C., Hsu, P. D., Hie, B. L., Ermon, S., and Poli,

- M. Systems and algorithms for convolutional multi-hybrid language models at scale, 2025. URL <https://arxiv.org/abs/2503.01868>.
- Lai, X., Lu, J., Luo, Y., Ma, Y., and Zhou, X. Flex-prefill: A context-aware sparse attention mechanism for efficient long-sequence inference. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=OfjIlbelrT>.
- Li, J., Zhu, H., Liu, H., Shi, X., Zong, H., Dong, Y., Zhang, K., Jiang, S., Jin, Z., and Li, G. aixcoder-7b-v2: Training llms to fully utilize the long context in repository-level code completion. *arXiv preprint arXiv:2503.15301*, 2025.
- Li, Y., Huang, Y., Yang, B., Venkitesh, B., Locatelli, A., Ye, H., Cai, T., Lewis, P., and Chen, D. Snapkv: Llm knows what you are looking for before generation. *arXiv preprint arXiv:2404.14469*, 2024.
- Lieber, O., Lenz, B., Bata, H., Cohen, G., Osin, J., Dalmedigos, I., Safahi, E., Meirom, S., Belinkov, Y., Shalev-Shwartz, S., Abend, O., Alon, R., Asida, T., Bergman, A., Glozman, R., Gokhman, M., Manevich, A., Ratner, N., Rozen, N., Shwartz, E., Zusman, M., and Shoham, Y. Jamba: A hybrid transformer-mamba language model, 2024. URL <https://arxiv.org/abs/2403.19887>.
- Liu, J., Zhu, D., Bai, Z., He, Y., Liao, H., Que, H., Wang, Z., Zhang, C., Zhang, G., Zhang, J., et al. A comprehensive survey on long context language modeling. *arXiv preprint arXiv:2503.17407*, 2025a.
- Liu, X., Li, R., Huang, M., Liu, Z., Song, Y., Guo, Q., He, S., Wang, Q., Li, L., Liu, Q., et al. Thus spake long-context large language model. *arXiv preprint arXiv:2502.17129*, 2025b.
- Liu, Z., Desai, A., Liao, F., Wang, W., Xie, V., Xu, Z., Kyrillidis, A., and Shrivastava, A. Scissorhands: Exploiting the persistence of importance hypothesis for llm kv cache compression at test time. *Advances in Neural Information Processing Systems*, 36, 2024.
- Loshchilov, I. and Hutter, F. Decoupled weight decay regularization, 2019. URL <https://arxiv.org/abs/1711.05101>.
- Lu, E., Jiang, Z., Liu, J., Du, Y., Jiang, T., Hong, C., Liu, S., He, W., Yuan, E., Wang, Y., Huang, Z., Yuan, H., Xu, S., Xu, X., Lai, G., Chen, Y., Zheng, H., Yan, J., Su, J., Wu, Y., Zhang, N. Y., Yang, Z., Zhou, X., Zhang, M., and Qiu, J. Moba: Mixture of block attention for long-context llms, 2025a. URL <https://arxiv.org/abs/2502.13189>.
- Lu, E., Jiang, Z., Liu, J., Du, Y., Jiang, T., Hong, C., Liu, S., He, W., Yuan, E., Wang, Y., et al. Moba: Mixture of block attention for long-context llms. *arXiv preprint arXiv:2502.13189*, 2025b.
- Mei, L., Yao, J., Ge, Y., Wang, Y., Bi, B., Cai, Y., Liu, J., Li, M., Li, Z.-Z., Zhang, D., et al. A survey of context engineering for large language models. *arXiv preprint arXiv:2507.13334*, 2025.
- Narayan, S., Cohen, S. B., and Lapata, M. Don’t give me the details, just the summary! Topic-aware convolutional neural networks for extreme summarization. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, Brussels, Belgium, 2018.
- Peng, D., Fu, Z., Ye, Z., Song, Z., and Wang, J. Accelerating prefilling for long-context llms via sparse pattern sharing. *arXiv preprint arXiv:2505.19578*, 2025a.
- Peng, D., Fu, Z., Ye, Z., Song, Z., and Wang, J. Accelerating prefilling for long-context llms via sparse pattern sharing, 2025b. URL <https://arxiv.org/abs/2505.19578>.
- Ren, L., Liu, Y., Lu, Y., Shen, Y., Liang, C., and Chen, W. Samba: Simple hybrid state space models for efficient unlimited context language modeling. *arXiv preprint*, 2024. URL <https://arxiv.org/abs/2406.07522>.
- Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., and Dean, J. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *arXiv preprint arXiv:1701.06538*, 2017.
- Tang, Z., Wang, H., Qiu, Q., Ji, B., Sun, R., Zhou, K., Li, J., and Zhang, M. Loom-scope: a comprehensive and efficient long-context model evaluation framework. *arXiv preprint arXiv:2507.04723*, 2025.
- Trivedi, H., Balasubramanian, N., Khot, T., and Sabharwal, A. Musique: Multihop questions via single-hop question composition. *Transactions of the Association for Computational Linguistics*, 10:539–554, 2022.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- Wu, W., Wang, Y., Xiao, G., Peng, H., and Fu, Y. Retrieval head mechanistically explains long-context factuality. *arXiv preprint arXiv:2404.15574*, 2024.

- Xiao, G., Tang, J., Zuo, J., Guo, J., Yang, S., Tang, H., Fu, Y., and Han, S. Duoattention: Efficient long-context llm inference with retrieval and streaming heads. *arXiv*, 2024a.
- Xiao, G., Tian, Y., Chen, B., Han, S., and Lewis, M. Efficient streaming language models with attention sinks. In *The Twelfth International Conference on Learning Representations*, 2024b. URL <https://openreview.net/forum?id=NG7sS51zVF>.
- Xiao, G., Tang, J., Zuo, J., Yang, S., Tang, H., Fu, Y., Han, S., et al. Duoattention: Efficient long-context llm inference with retrieval and streaming heads. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Xu, P., Ping, W., Wu, X., Liu, Z., Shoenybi, M., and Catanzaro, B. Chatqa 2: Bridging the gap to proprietary llms in long context and rag capabilities. *arXiv preprint arXiv:2407.14482*, 2024.
- Xu, R., Xiao, G., Huang, H., Guo, J., and Han, S. Xattention: Block sparse attention with antidiagonal scoring. In *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025.
- Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., Zheng, C., Liu, D., Zhou, F., Huang, F., Hu, F., Ge, H., Wei, H., Lin, H., Tang, J., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Zhou, J., Lin, J., Dang, K., Bao, K., Yang, K., Yu, L., Deng, L., Li, M., Xue, M., Li, M., Zhang, P., Wang, P., Zhu, Q., Men, R., Gao, R., Liu, S., Luo, S., Li, T., Tang, T., Yin, W., Ren, X., Wang, X., Zhang, X., Ren, X., Fan, Y., Su, Y., Zhang, Y., Zhang, Y., Wan, Y., Liu, Y., Wang, Z., Cui, Z., Zhang, Z., Zhou, Z., and Qiu, Z. Qwen3 technical report, 2025. URL <https://arxiv.org/abs/2505.09388>.
- Yu, Y., Liu, J., Wu, Q., Wang, H., and Pei, J. Sliding window attention adaptation. *arXiv preprint arXiv:2512.10411*, 2025.
- Yuan, J., Gao, H., Dai, D., Luo, J., Zhao, L., Zhang, Z., Xie, Z., Wei, Y., Wang, L., Xiao, Z., Wang, Y., Ruan, C., Zhang, M., Liang, W., and Zeng, W. Native sparse attention: Hardware-aligned and natively trainable sparse attention. In Che, W., Nabende, J., Shutova, E., and Pilehvar, M. T. (eds.), *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 23078–23097, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-251-0. doi: 10.18653/v1/2025.acl-long.1126. URL <https://aclanthology.org/2025.acl-long.1126/>.
- Zaheer, M., Guruganesh, G., Dubey, K. A., Ainslie, J., Alberti, C., Ontanon, S., Pham, P., Ravula, A., Wang, Q., Yang, L., et al. Big bird: Transformers for longer sequences. *Advances in neural information processing systems*, 33:17283–17297, 2020.
- Zhang, C., Bai, Y., Li, J., Gui, A., Wang, K., Liu, F., Wu, G., Jiang, Y., Bu, D., Wei, L., et al. Efficient context scaling with longcat zigzag attention. *arXiv preprint arXiv:2512.23966*, 2025a.
- Zhang, J., Xiang, C., Huang, H., Wei, J., Xi, H., Zhu, J., and Chen, J. Spargeattn: Accurate sparse attention accelerating any model inference. In *International Conference on Machine Learning (ICML)*, 2025b.
- Zhang, Z., Sheng, Y., Zhou, T., Chen, T., Zheng, L., Cai, R., Song, Z., Tian, Y., Ré, C., Barrett, C. W., Wang, Z., and Chen, B. H2O: heavy-hitter oracle for efficient generative inference of large language models. In Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S. (eds.), *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*, 2023.
- Zhao, W., Zhou, Z., Su, Z., Xiao, C., Li, Y., Li, Y., Zhang, Y., Zhao, W., Li, Z., Huang, Y., Sun, A., Han, X., and Liu, Z. Inllm-v2: Dense-sparse switchable attention for seamless short-to-long adaptation, 2025. URL <https://arxiv.org/abs/2509.24663>.

A. 代码与模型

我们开源了代码与模型：

🔗 代码：<https://github.com/LCM-Lab/Elastic-Attention>

📦 模型：https://modelscope.cn/collections/LCM_group/Elastic-Attention

B. 相关工作

B.1. 稀疏注意力机制

为缓解标准注意力的二次复杂度，现有研究大体沿两条路径发展：推理时启发式方法与训练感知稀疏化方法。推理时启发式方法通常采用静态模式（如固定滑窗或步长）（Xiao et al., 2024b; He et al., 2025; Beltagy et al., 2020）来限制感受野。为捕捉更动态的依赖关系，研究者提出了内容感知方法：token 驱逐策略依据累计重要性分数移除低信息 token（Zhang et al., 2023; Li et al., 2024; Liu et al., 2024）；基于 kernel 的估计器则识别关键 block 以跳过冗余计算（Jiang et al., 2024）。此外，prefill 优化器通过重要性驱动的选择来加速长上下文处理（Lai et al., 2025; Xu et al., 2025; Zhang et al., 2025b; Peng et al., 2025b; Ji et al., 2025）。尽管这些启发式方法有效，但其通常依赖敏感超参数，导致跨任务鲁棒性受限。

与之相比，训练式方法将稀疏性内化到优化目标中，以对齐训练与稀疏推理。其主要方向之一是可学习选择机制。例如 SeerAttention（Gao et al., 2024）、NSA（Yuan et al., 2025）与 MoBA（Lu et al., 2025a）采用可学习门控和层级约束来逼近真实注意力模式。为弥合稠密预训练与稀疏适配的差距，InFLLM-v2（Zhao et al., 2025）通过无参数池化引入稠密-稀疏可切换机制；DSA（DeepSeek-AI, 2025）则使用 lightning indexer 与两阶段训练策略高效筛选 top- k key-value 对。然而，这类方法大多聚焦于固定注意力机制内部的细粒度 block 级选择，而不是根据输入复杂度动态切换注意力计算模式本身。

B.2. 混合高效架构

为了兼顾效率与性能，混合架构通常将全注意力（FA）与线性复杂度算子进行策略性结合。主流范式是层间混合：在标准注意力层之间交替插入线性层（如 SSM 或 RNN），以恢复联想检索能力（Ku et al., 2025; Dao & Gu, 2024）。代表性大规模实现如 Jamba（Lieber et al., 2024）使用固定块比例，后续变体则通过共享全局块（Glorioso et al., 2024）或滑动窗口（Ren et al., 2024）优化内存。

近期，层内混合开始出现以提升粒度控制。例如 PruLong（Bhaskar et al., 2025）与 DuoAttention（Xiao et al., 2024a）在单层内部混合 FA 与 Streaming Sparse Attention（SSA），将不同头分配到不同模式。LongCat（Zhang et al., 2025a）提出 LoZA 机制，通过用线性复杂度 SSA 替换低敏感的 MLA 模块来构建静态 ZigZag 拓扑。但这类方法的关键限制在于：其拓扑或比例通常在推理前静态确定，缺乏对稀疏鲁棒任务与稀疏敏感任务进行动态区分的能力，导致在多样输入下资源分配可能次优。

C. 检索评分与稀疏化设置

本节详细介绍 § 2.2 中提到的检索头识别方法与渐进式稀疏化策略。

C.1. 检索分数计算

遵循 Retrieval Head（Wu et al., 2024）的方法，我们根据注意力头从长上下文中检索关键信息的能力，对其进行识别与排序。我们使用 Llama-3.1-8B-Instruct（Grattafiori et al., 2024）并采用 Needle-in-a-Haystack 探针：将特定关键信息（“needle”）插入长上下文（“haystack”）中。

对于第 ℓ 层第 h 个注意力头 $H_{\ell,h}$ ，通过其分配到 needle token 的注意力质量计算检索分数 $S_{\ell,h}$ 。形式化地，设输入长度为 s ，注意力矩阵为 $\mathcal{O}^{(\ell,h)} \in \mathbb{R}^{s \times s}$ ，needle token 索引集合为 $\mathcal{I}_{needle}$ ，则分数定义为：

$$S_{\ell,h} = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \sum_{j \in \mathcal{I}_{needle}} \mathcal{O}_{T,j}^{(\ell,h)} \quad (9)$$

其中 $\mathcal{D}$ 为验证集， $\mathcal{O}_{T,j}^{(\ell,h)}$ 表示最后一个 token（query 位置 T ）对 needle 位置 j 的注意力权重。 $S_{\ell,h}$ 越高，说明该头在长上下文中越频繁且越强地激活于相关信息。

Table 5. 不同模型稀疏率下的性能保留率。数值表示相对全注意力基线（Sparsity 0.0）的性能百分比，其中 100.00 表示与基线持平。行表示模型稀疏率，列表示评测任务。

稀疏率	Single-Doc QA	Multi-Hop QA	Summarization	Few-Shot	Synthetic	Code
Full ($\Omega_{\text{MSR}} = 0.0$)	100.00	100.00	100.00	100.00	100.00	100.00
$\Omega_{\text{MSR}} = 0.1$	85.37	96.23	99.38	96.54	92.27	99.07
$\Omega_{\text{MSR}} = 0.2$	71.32	73.84	98.00	93.83	81.26	98.49
$\Omega_{\text{MSR}} = 0.3$	61.94	69.07	96.19	91.83	59.28	98.10
$\Omega_{\text{MSR}} = 0.4$	59.36	66.48	94.75	87.01	47.61	95.58
$\Omega_{\text{MSR}} = 0.5$	57.95	64.33	93.02	87.33	45.31	99.54
$\Omega_{\text{MSR}} = 0.6$	56.95	59.66	94.68	87.05	44.75	98.66
$\Omega_{\text{MSR}} = 0.7$	56.08	61.91	92.52	88.51	41.25	97.73
$\Omega_{\text{MSR}} = 0.8$	56.04	59.55	93.73	89.07	47.98	99.86
$\Omega_{\text{MSR}} = 0.9$	56.02	63.40	94.00	90.19	48.37	98.48
$\Omega_{\text{MSR}} = 1.0$	56.46	61.45	93.42	90.19	47.98	99.46

C.2. 渐进式稀疏化策略

基于计算得到的 $S_{\ell,h}$ ，我们对模型中全部 $L \cdot H$ 个注意力头按降序排序。如正文定义，**模型稀疏率** (Ω_{MSR}) 表示被转换为局部注意力头的比例。

为模拟实验中的不同稀疏水平（例如 $\Omega_{\text{MSR}} = 20\%$ ），我们采用阈值化机制：

1. 通过 $k = \lfloor (1 - \Omega_{\text{MSR}}) \cdot (L \cdot H) \rfloor$ 计算需保留为全注意力（FA）的头数。
2. 保留检索分数最高的 top- k 个头作为 **检索头**（保持 FA），以保证全局信息整合能力。
3. 其余头（排名靠后的头）替换为 **Streaming Sparse Attention (SSA)** 头。

D. 实现细节

本节给出训练配置、基线实现细节以及面向高效长上下文处理的系统级优化。

D.1. 训练配置与超参数

模型结构。 我们在不同规模模型上验证方法可扩展性，从轻量模型 Qwen3-4B 到常用中等规模模型 Qwen3-8B (Yang et al., 2025) 与 Meta-Llama-3.1-Instruct (Grattafiori et al., 2024)。为保留预训练模型通用能力，我们遵循参数高效微调协议：冻结预训练骨干，仅优化 *Attention Router* 参数。在任务表示构建上，我们使用边界池化策略，仅聚合序列开头 100 个和结尾 100 个 token。这两段通常包含关键系统指令与用户请求，对准确任务识别最重要。

优化设置。 全部模型在序列长度 $L = 65,536$ 、‘bfloat16’ 精度下训练，以适应长上下文依赖。优化器采用 AdamW (Loshchilov & Hutter, 2019) ($\beta_1 = 0.9, \beta_2 = 0.95$)，并在分布式集群上使用 Fully Sharded Data Parallel (FSDP) 及 Hybrid Sharding 策略。我们采用解耦学习率策略以平衡 router 收敛与稀疏正则：

- **Router 参数：** 对 attention router 使用 5×10^{-4} 学习率，以更快适应检索模式。
- **正则系数：** 对稀疏正则项使用更高学习率 1×10^{-3} 。具体地，双正则系数 λ_1 和 λ_2 随机初始化，并与 router 参数联合优化。

学习率调度采用余弦衰减，并在前 20% 训练步进行线性 warmup。

D.2. 基线实现细节

为严格评估方法有效性，我们与一组前沿稀疏注意力机制进行对比，分为免训练方法与训练式适配方法。

Table 6. 超参数配置：通用配置（左）与基线专属配置（右）。

(a) 通用配置		(b) 基线专属配置			
超参数	取值	参数	MoBA	NSA	InfLLMv2
模型与训练		结构与 Kernel			
基础模型	Qwen, Llama	Block Size	1024	64	64
序列长度	65536	Top-k	8	128	64
精度	bfloat16	Window Size	-	512	2048
全局 Batch Size	48	Kernel Size	-	32	32
训练步数	300	Kernel Stride	-	16	16
Mask / Reg. LR	$5e^{-4}$ / $1e^{-3}$	可学习参数			
Warmup 比例	0.2	Q/K/V Proj	✓	✓	✓
AdamW 动量 (β_1, β_2)	(0.9, 0.95)	Gate	-	✓	-
权重衰减	0.1	Compress K/V	-	✓	-
学习率调度	Cosine	额外配置			
稀疏配置		Compress Type	Pooling	Linear	Pooling
Sink / Local Size	128 / 2048	Use NoPE	-	-	False
Block / Chunk Size	64 / 16384	Dense Len	-	-	8192
Stride / Threshold	16 / 0.9				
选择模式	Inverse				

免训练方法。 我们采用 XAttention⁵ (Xu et al., 2025) 作为主要免训练基线。该类方法基于启发式稀疏策略，不更新模型参数。

训练式方法。 对于需要训练适配的方法，包括 InfLLM_v2⁶ (Zhao et al., 2025)、MoBA⁷ (Lu et al., 2025a)、NSA⁸ (Yuan et al., 2025)、PruLong⁹ (Bhaskar et al., 2025) 与 DuoAttention¹⁰ (Xiao et al., 2025)，我们统一采用一致的微调协议以保证公平。不同于我们完全冻结骨干，许多对比方法需要更新投影层。对 InfLLM_v2、MoBA 与 NSA，我们将可训练范围限制为 query-key-value 投影权重 (W_{qkv}) 及其方法特定参数，其余骨干冻结。全部基线在相同环境与数据集下训练，并严格遵循原始超参数设置，例如 MoBA 的 block size 为 1024、NSA 为 64，以及 InfLLM_v2 的 dense context length 为 8K。详细超参数比较见表 6（右）。

D.3. 稀疏与 Kernel 配置

为实现高效流式推理，我们采用 Block-Sparse-Attention (Guo et al., 2024)。该配置定义了注意力机制的粒度与保留策略：

- **Block Size**：设为 64，作为最小稀疏单元。
- **Chunk Size**：设为 16,384，用于支持超长序列处理。
- **Sink Token 策略**：将“sink token”大小设为 128，以保留 attention sink 现象并保证流式生成稳定性。

具体 kernel 参数（如 stride、归一化、选择模式）见表 6（左）中的 *Sparsity Config* 部分。

⁵<https://github.com/mit-han-lab/x-attention>

⁶https://modelscope.cn/models/OpenBMB/MiniCPM4-8B/file/view/master/modeling_minicpm.py

⁷<https://github.com/MoonshotAI/MoBA>

⁸<https://github.com/XunhaoLai/native-sparse-attention-triton>

⁹<https://github.com/princeton-pli/PruLong>

¹⁰<https://github.com/mit-han-lab/duo-attention>

Algorithm 1 串行分发（基线）与并行 BSA（本文）对比

(a) PyTorch 基线实现	(b) 本文方法（基于 BSA 并行）
输入: $\mathbf{Q}, \mathbf{K}, \mathbf{V}$, Router $\mathcal{R}$ 1: $\mathbf{r} \leftarrow \mathcal{R}(\mathbf{x})$ 步骤 1: 串行拆分 $\mathcal{I}_{\text{full}} \leftarrow \{h \mid \mathbf{r}_h = 0\}$ $\mathcal{I}_{\text{sp}} \leftarrow \{h \mid \mathbf{r}_h = 1\}$ $\mathbf{Q}_{\text{full}} \leftarrow \mathbf{Q}[:, \mathcal{I}_{\text{full}}]$ 2: 步骤 2: 分开计算 $\mathbf{O}_{\text{full}} \leftarrow \text{FlashAttn}(\dots)$ $\mathbf{O}_{\text{sp}} \leftarrow \text{SlidingWin}(\dots)$ 步骤 3: 结果合并 $\mathbf{O}[:, \mathcal{I}_{\text{full}}] \leftarrow \mathbf{O}_{\text{full}}$ $\mathbf{O}[:, \mathcal{I}_{\text{sp}}] \leftarrow \mathbf{O}_{\text{sp}}$	输入: $\mathbf{Q}, \mathbf{K}, \mathbf{V}$, Router $\mathcal{R}$ 1: $\mathbf{r} \leftarrow \mathcal{R}(\mathbf{x})$ 2: $\mathbf{m} \leftarrow \text{Map}(\mathbf{r})$ 步骤 1: 统一执行 $\mathbf{O} \leftarrow \text{BSA_Krn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}, \mathbf{m})$ Kernel 内部: 3: $\text{par_for } h \text{ do}$ if $\mathbf{m}[h] == \text{SP}$ then $\mathbf{O}[h] \leftarrow \text{Sparse}(\dots)$; else $\mathbf{O}[h] \leftarrow \text{Full}(\dots)$; end if end par_for

E. Elastic Attention 的高效部署

混合注意力的关键系统瓶颈在于：如何在单个 batch 内高效调度异构注意力工作负载。算法 1(a) 展示了传统范式 (*Serial Dispatch*)，代表实现如 Flash-Attn¹¹ (Dao, 2024)。该方法需要根据路由决策 r 显式重排数据（红色部分），并重新物化输入张量。

这会引入两类主要低效，与长上下文高吞吐需求相冲突：(1) **内存开销**：需要分配和拷贝非连续张量片段（如分离检索头与稀疏头）；(2) **Kernel 启动与调度开销**：正文已说明，长上下文场景中序列维并行占主导。为不同头组分别启动 kernel 会割裂工作负载，带来多次启动延迟，并削弱 GPU 在可用 streaming multiprocessor 间全局调度 thread block 的能力。

为解决上述问题，我们采用 Block Sparse Attention (BSA) Kernel¹² (Guo et al., 2024) (算法 1(b))。该设计无需拆分张量，而是将路由决策 r 作为轻量元数据 $\mathbf{m}$ 直接传入 kernel。如绿色框所示，kernel 在 *thread-block* 级别分支：每个 thread block 动态读取其分配头在 $\mathbf{m}$ 中的类型，并执行对应注意力逻辑。这使全部头可通过**一次统一 kernel 启动**完成计算。通过保持网格维度 (Batch $\times$ Heads $\times$ Sequence Blocks) 不变，我们有效消除了冗余内存拷贝与负载碎片化，使 GPU 硬件调度器可以更优地分配序列 block。更多实现细节可参考我们提供的匿名代码仓库。

F. Attention Router 优化的理论说明

优化 attention router 的核心难点在于离散选择不可导。为使模型学习“某任务需要哪些注意力头”，我们采用基于 Gumbel-Softmax（在二值场景下为 Gumbel-Sigmoid）的连续松弛，以及 Straight-Through Estimator (STE)。

F.1. 潜表示与 Logit 生成

给定 Key 隐状态 $\mathbf{x}_K \in \mathbb{R}^{s \times H \times d'}$ ，其中 s 为序列长度、 d' 为隐藏维度，router 首先通过池化与两层 MLP 提取任务感知表示：

$$\mathbf{x}'_K = \text{Pooling}(\mathbf{x}_K), \mathbf{x}'_K \in \mathbb{R}^{H \times d'} \quad (10)$$

随后，逐头路由 logits $\mathbf{z}$ 计算为：

$$\mathbf{z} = \text{MLP}_{\text{router}}(\text{MLP}_{\text{task}}(\mathbf{x}'_K)), \quad (11)$$

其中 $\mathbf{z} \in \mathbb{R}^H$ 表示每个头对某一注意力模式（如 FA/SA）的未归一化偏好。

¹¹<https://github.com/Dao-AI-Lab/flash-attention>

¹²<https://github.com/mit-han-lab/Block-Sparse-Attention>

Table 7. LongBench-E 细粒度结果对比。每个比较组中性能第 1 与第 2 的结果分别以加粗和下划线 标出。

方法	Single-Document QA		Multi-Document QA		Summarization		Few-shot Learning			Synthetic		Code		平均
	MF-en	Qasper	HotpotQA	2WikiMQA	GovReport	MultiNews	TREC	TriviaQA	SAMSum	PCount	Pre	Lec	RB-P	
Qwen3-4B 骨干模型														
Qwen3-4B	52.16	35.21	44.81	32.15	33.47	23.45	70.67	88.22	39.74	2.33	96.84	57.93	50.84	48.45
+ InFLM-V2	49.13	37.51	40.26	29.68	33.99	25.92	67.67	86.14	38.76	4.30	72.78	62.56	<u>56.59</u>	46.68
+ DuoAttention	48.85	34.60	42.25	29.18	33.26	23.68	66.33	<u>87.70</u>	39.73	2.11	92.24	57.57	50.25	46.95
+ PruLong	48.88	34.28	45.14	30.01	33.36	23.70	66.33	88.31	39.77	4.79	89.67	55.44	50.95	47.19
+ MoBA	42.41	35.80	38.76	29.84	<u>33.82</u>	<u>25.11</u>	68.67	85.69	39.34	2.33	72.52	58.61	50.63	45.09
+ NSA	42.46	33.90	38.10	31.53	31.69	23.07	68.00	82.49	39.82	5.67	41.93	<u>62.44</u>	53.77	43.02
+ XAttention	<u>50.36</u>	32.80	44.54	<u>33.17</u>	33.79	23.73	<u>69.00</u>	87.44	39.90	3.42	74.59	59.62	49.42	46.44
+ Elastic Attention (FA-SSA)	49.13	35.27	47.87	29.85	33.35	23.65	69.33	87.23	40.62	2.00	94.86	57.80	50.87	<u>48.08</u>
+ Elastic Attention (FA-XA)	52.06	<u>36.74</u>	45.65	33.18	33.45	23.55	68.67	87.33	39.79	4.39	84.32	50.47	58.11	47.59
+ Elastic Attention (XA-SSA)	49.21	34.63	<u>47.32</u>	30.02	33.14	23.75	68.00	87.64	<u>40.12</u>	<u>5.50</u>	<u>93.00</u>	59.15	50.98	48.14
Qwen3-8B 骨干模型														
Qwen3-8B	49.92	41.22	58.98	44.21	33.27	23.42	71.33	86.77	41.83	2.00	98.33	66.31	56.08	52.16
+ InFLM-V2	46.35	38.05	49.51	35.14	<u>34.49</u>	<u>24.67</u>	67.00	87.03	39.61	<u>12.07</u>	79.67	66.86	52.30	49.03
+ DuoAttention	49.59	41.32	51.82	37.22	33.14	23.19	70.33	86.83	42.11	0.00	95.00	67.43	<u>57.32</u>	50.67
+ PruLong	<u>51.06</u>	<u>41.04</u>	53.87	39.90	33.20	23.39	70.33	87.68	41.83	0.33	<u>97.00</u>	67.30	57.18	51.34
+ MoBA	48.81	40.65	48.26	38.29	35.19	25.47	67.67	84.13	40.85	14.00	83.89	68.21	56.89	50.47
+ NSA	44.29	36.96	42.26	32.63	32.93	23.00	74.33	86.74	40.36	2.67	55.33	69.81	54.57	46.12
+ XAttention	48.93	38.03	<u>57.32</u>	40.65	33.41	23.37	69.33	87.69	41.77	2.00	83.72	65.71	55.53	50.13
+ Elastic Attention (FA-SSA)	51.45	40.84	53.34	39.74	33.14	23.24	<u>72.33</u>	88.67	41.56	0.00	96.14	68.44	57.47	<u>51.51</u>
+ Elastic Attention (FA-XA)	48.18	39.83	59.38	<u>40.60</u>	33.30	23.29	69.00	87.78	<u>41.92</u>	2.33	99.56	65.40	55.74	51.66
+ Elastic Attention (XA-SSA)	45.73	33.13	51.80	30.95	33.21	23.32	70.00	<u>87.83</u>	40.73	0.67	92.78	<u>68.56</u>	55.13	49.25
Llama-3.1-8B-Instruct 骨干模型														
Llama-3.1-8B-Instruct	53.44	44.06	59.62	44.08	34.50	26.02	71.00	90.54	42.94	12.67	99.33	63.85	47.78	53.28
+ InFLM-V2	48.60	38.93	50.74	41.85	34.40	25.76	69.00	89.92	43.04	6.33	77.73	59.78	68.81	50.73
+ NSA	42.86	41.80	40.79	39.94	<u>34.57</u>	25.29	68.00	89.69	42.27	2.33	28.00	65.18	50.12	44.03
+ DuoAttention	52.68	44.62	52.01	38.41	34.01	25.84	69.67	90.33	42.06	10.13	99.00	64.69	48.24	51.82
+ PruLong	50.74	44.63	49.70	36.41	34.25	25.78	70.00	<u>91.45</u>	42.13	<u>9.80</u>	97.33	<u>68.55</u>	53.59	52.11
+ MoBA	48.92	44.33	46.36	41.45	34.79	26.65	69.67	89.91	40.76	7.33	64.67	69.47	<u>59.48</u>	49.69
+ XAttention	53.80	43.84	<u>59.98</u>	<u>43.47</u>	34.47	<u>26.05</u>	72.33	90.39	<u>42.99</u>	8.33	73.33	62.92	50.13	51.00
+ Elastic Attention (FA-SSA)	53.48	46.35	55.50	42.33	34.50	25.77	69.67	91.70	42.60	9.33	<u>98.67</u>	67.72	53.69	53.35
+ Elastic Attention (FA-XA)	<u>53.65</u>	<u>45.14</u>	60.21	45.67	34.56	26.03	<u>71.67</u>	91.37	42.62	8.31	91.00	63.22	49.75	<u>52.71</u>
+ Elastic Attention (XA-SSA)	51.81	44.79	53.53	39.27	34.56	25.98	70.67	90.59	42.24	9.07	73.67	68.12	53.49	50.71

F.2. 基于 Gumbel-Sigmoid 的可微采样

为在保持可导的同时模拟离散路由随机性，我们采用重参数化技巧 (Bhaskar et al., 2025)。对独立同分布噪声样本 $u \sim \text{Uniform}(0, 1)$ ，将其变换为 Gumbel 噪声 g ：

$$g = -\log(-\log(u + \epsilon) + \epsilon), \quad (12)$$

其中 ϵ 为数值稳定常数。

随后通过温度相关 Sigmoid，将离散二值决策松弛为连续近似 $\hat{z}_{\text{soft}}$ ：

$$\hat{z}_{\text{soft}} = \sigma\left(\frac{\mathbf{z} + g}{\tau}\right) = \frac{1}{1 + \exp\left(-\frac{\mathbf{z} + g}{\tau}\right)} \quad (13)$$

其中 $\tau \in (0, \infty)$ 为温度参数。当 $\tau \rightarrow \infty$ 时分布趋于均匀；当 $\tau \rightarrow 0$ 时， $\hat{z}_{\text{soft}}$ 逼近离散伯努利分布。第 F.3 节介绍 τ 的设置策略。

F.3. 温度退火策略

优化过程中，我们通过 τ 退火弥合连续松弛与离散部署之间的差距。退火形式为：

$$\tau^{(t)} = \max(\tau_{\min}, \tau_{\text{init}} \cdot \exp(-r \cdot p)), \quad (14)$$

其中 p 为训练步， r 为衰减率（本文设 $r = 0.6$ ）。训练早期较高 τ 可通过更稠密梯度促进探索；后期较低 τ 则促使 router 收敛到实际部署所需的“硬”二值决策。

G. 补充评测结果

本节给出正文所述基准的更细粒度结果。

Table 8. LongBench-E 上的性能结果。我们报告各任务类别的平均性能 (Perf.) 与 Ω_{MSR} 。每个比较组中性能第 1 与第 2 的结果分别以**加粗**和下划线 标出。注意 XA-SSA 未使用检索头，因此不计算 Ω_{MSR} 。

方法	S-Doc QA		M-Doc QA		Summ		In-Context		Synthetic		Code		平均	
	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR	性能	MSR
Qwen3-4B 骨干模型														
Qwen3-4B	43.69	-	38.48	-	28.46	-	66.21	-	49.59	-	54.38	-	48.45	-
+ MoBA	38.16	-	34.30	-	29.46	-	64.57	-	37.42	-	54.62	-	45.09	-
+ NSA	39.13	-	34.81	-	27.38	-	63.44	-	23.80	-	58.10	-	43.02	-
+ XAttention	41.58	-	38.85	-	<u>28.76</u>	-	65.45	-	39.01	-	54.52	-	46.44	-
+ Elastic Attention (FA-SSA)	<u>42.20</u>	0.66	<u>38.86</u>	0.68	28.50	0.76	65.73	0.73	<u>48.43</u>	0.71	54.34	0.82	<u>48.08</u>	0.73
+ Elastic Attention (FA-XA)	44.40	0.68	39.42	0.71	28.49	0.82	<u>65.26</u>	0.76	44.35	0.74	54.29	0.87	47.59	0.76
+ Elastic Attention (XA-SSA)	41.92	-	38.67	-	28.45	-	65.25	-	49.25	-	<u>55.07</u>	-	48.14	-
Qwen3-8B 骨干模型														
Qwen3-8B	45.57	-	51.59	-	28.34	-	66.64	-	50.16	-	61.20	-	52.16	-
+ MoBA	<u>44.73</u>	-	43.28	-	30.33	-	64.22	-	<u>48.95</u>	-	<u>62.55</u>	-	50.47	-
+ NSA	40.63	-	37.45	-	27.97	-	<u>67.14</u>	-	29.00	-	62.19	-	46.12	-
+ XAttention	43.48	-	<u>48.99</u>	-	<u>28.39</u>	-	66.26	-	42.86	-	60.62	-	50.13	-
+ Elastic Attention (FA-SSA)	46.15	0.64	46.54	0.65	28.19	0.72	67.52	0.71	48.07	0.65	62.95	0.78	<u>51.51</u>	0.69
+ Elastic Attention (FA-XA)	44.01	0.75	49.99	0.76	28.30	0.83	66.23	0.80	50.95	0.77	60.57	0.86	51.66	0.80
+ Elastic Attention (XA-SSA)	39.43	-	41.38	-	28.27	-	66.19	-	46.73	-	61.85	-	49.25	-
Llama-3.1-8B-Instruct 骨干模型														
Llama-3.1-8B-Instruct	48.75	-	51.85	-	30.26	-	68.16	-	56.00	-	55.81	-	53.28	-
+ MoBA	46.63	-	43.91	-	30.72	-	66.78	-	36.00	-	64.48	-	49.69	-
+ NSA	42.33	-	40.37	-	29.93	-	66.65	-	15.17	-	57.65	-	44.03	-
+ XAttention	48.82	-	<u>51.73</u>	-	30.26	-	68.57	-	40.83	-	56.53	-	51.00	-
+ Elastic Attention (FA-SSA)	49.92	0.64	48.92	0.63	30.17	0.73	67.99	0.74	54.00	0.64	60.70	0.79	53.35	0.69
+ Elastic Attention (FA-XA)	<u>49.40</u>	0.71	52.94	0.69	<u>30.30</u>	0.80	<u>68.55</u>	0.79	<u>49.66</u>	0.72	56.49	0.87	<u>52.71</u>	0.77
+ Elastic Attention (XA-SSA)	48.30	-	46.40	-	30.27	-	67.83	-	41.37	-	<u>60.81</u>	-	50.71	-

Table 9. RULER 评测详细配置。我们在指数增长的上下文窗口上评测，最长至 256k token。

参数	配置细节
上下文窗口	8k, 16k, 32k, 64k, 128k, 256k
样本规模	每个“任务-长度”组合 50 条样本
评测任务	检索 (NIAH): single_{1-3}, multikey_{1-3}, multiquery, multivalue 问答与抽取: qa_{1,2}, fwe

G.1. LongBench 评测结果

表 7 与表 8 给出了 LongBench-E 的完整结果。我们报告全部子任务指标，并按 6 类组织：单文档 QA (S-Doc QA)、多文档 QA (M-Doc QA)、摘要 (Summ)、上下文学习 (In-Context)、合成任务 (Synthetic) 与代码任务 (Code)。

G.2. LongBench-V2 与 RULER 评测结果

本小节介绍 LongBench-V2 与 RULER 的实验设置和结果。对于 RULER，如表 9 所示，评测上下文长度覆盖 8K 到 262K token 的完整范围。对应性能对比见表 10。

H. 消融研究

H.1. Attention Router 的任务可分几何结构

为解释 Attention Router 的工作机理，我们分析其内部投影层学习到的潜空间几何结构。我们的假设是：即使优化目标仅是稀疏-性能权衡、未使用显式任务监督，router 仍会隐式学习任务可分表示，以实现更优检索头分配。

形式化地，设 $\mathbf{x}'_K \in \mathbb{R}^{H \times d'}$ 为输入序列池化后的隐状态。MLP_{task} 将其映射为潜在路由表示 $\mathcal{X}_K = \text{MLP}_{\text{task}}(\mathbf{x}'_K)$ 。为量化表示区分度并缓解预训练模型的表示各向异性，我们采用 Pairwise Conditional Rescaling 策略：在特定

Table 10. RULER 与 LongBench-v2 的补充结果。

模型	RULER								LongBench-v2				
	8K	16K	32K	64K	128K	256K	平均性能	MSR	Easy	Hard	平均性能	平均	MSR
Qwen3-4B 骨干模型													
Qwen3-4B	87.49	86.82	60.05	70.98	53.19	43.27	66.00	-	32.67	22.18	25.96	-	
+ MoBA	81.74	71.85	40.74	42.88	12.78	8.67	44.35	-	22.00	26.32	24.76		
+ NSA	86.82	76.94	44.18	57.62	25.96	9.18	45.29	-	26.00	25.56	25.72		
+ XAttention	85.93	<u>84.60</u>	60.32	67.01	48.76	38.42	61.23	-	26.00	24.81	25.24		
+ Elastic Attention (FA-SSA)	83.35	79.24	50.79	<u>67.03</u>	47.83	<u>47.32</u>	61.81	0.66	34.00	24.44	<u>27.88</u>	0.70	
+ Elastic Attention (FA-XA)	<u>86.56</u>	85.38	<u>56.88</u>	69.42	<u>49.48</u>	43.47	<u>63.27</u>	0.67	<u>32.00</u>	<u>25.94</u>	28.12	0.72	
+ Elastic Attention (XA-SSA)	81.43	80.68	51.12	65.69	49.96	53.30	63.70	-	26.00	<u>25.94</u>	25.96	-	
Qwen3-8B 骨干模型													
Qwen3-8B	89.69	85.62	63.23	82.39	65.84	66.71	75.74	-	39.33	27.82	31.97	-	
+ MoBA	<u>85.17</u>	75.26	47.88	51.64	34.68	29.64	55.68	-	28.00	24.44	25.72		
+ NSA	78.64	65.82	45.77	43.04	32.21	24.17	45.18	-	34.67	27.44	30.05		
XAttention	83.88	<u>84.88</u>	63.23	<u>80.10</u>	63.11	<u>62.49</u>	<u>72.68</u>	-	32.67	26.69	28.85		
+ Elastic Attention (FA-SSA)	86.62	82.81	<u>64.55</u>	77.41	61.17	61.75	71.74	0.65	<u>37.33</u>	31.20	33.41	0.66	
+ Elastic Attention (FA-XA)	85.07	85.12	65.08	82.34	64.57	63.41	73.87	0.76	30.68	30.77	30.74	0.78	
+ Elastic Attention (XA-SSA)	71.48	74.49	56.35	69.03	<u>64.56</u>	55.73	66.31	-	38.00	29.70	<u>32.69</u>	-	
Llama-3.1-8B-Instruct 骨干模型													
Llama-3.1-8B-Instruct	92.88	92.83	89.46	70.79	80.12	72.34	83.47	-	32.00	33.08	32.69	-	
+ MoBA	89.05	67.14	30.12	6.13	1.15	0	37.38	-	10.00	12.78	11.78	-	
+ NSA	73.27	50.68	21.39	22.52	15.30	11.42	30.58	-	21.33	25.19	23.80		
+ XAttention	93.11	<u>89.74</u>	<u>86.11</u>	<u>66.89</u>	<u>75.55</u>	41.6	<u>75.36</u>	-	26.67	28.2	27.64		
+ Elastic Attention (FA-SSA)	89.93	83.42	80.20	56.30	68.16	56.47	72.85	0.65	<u>28.00</u>	<u>29.70</u>	<u>29.09</u>	0.73	
+ Elastic Attention (FA-XA)	<u>92.82</u>	92.00	87.80	68.23	78.87	68.51	81.82	0.72	30.67	30.83	30.77	0.75	
+ Elastic Attention (XA-SSA)	89.07	82.99	77.74	58.86	64.48	47.68	70.27	-	30.67	28.20	<u>29.09</u>	-	

任务对 (u, v) 张成的局部子空间内进行归一化，从而剥离全局方差影响并衡量几何关系。

定义任务 k 的潜表示集合为 $\mathcal{X}_k$ ，任务对相似度指标 M_{uv} 的计算如下。先构建局部支撑集合 $\mathcal{S}_{uv} = \mathcal{X}_u \cup \mathcal{X}_v$ ，并计算其特征维标准差 σ_{uv} ：

$$\sigma_{uv} = \sqrt{\frac{1}{|\mathcal{S}_{uv}|} \sum_{\mathbf{x} \in \mathcal{S}_{uv}} (\mathbf{x} \odot \mathbf{x})} + \epsilon, \quad (15)$$

其中 $\odot$ 表示逐元素乘法，且计算默认激活零均值。据此定义投影 $\phi_{uv}(\mathbf{x}) = \mathbf{x} \oslash \sigma_{uv}$ ($\oslash$ 为逐元素除法)。指标 M_{uv} 为投影后任务质心的余弦相似度：


$$M_{uv} = \text{CosSim} \left(\frac{1}{|\mathcal{X}_u|} \sum_{\mathbf{x} \in \mathcal{X}_u} \phi_{uv}(\mathbf{x}), \frac{1}{|\mathcal{X}_v|} \sum_{\mathbf{x} \in \mathcal{X}_v} \phi_{uv}(\mathbf{x}) \right). \quad (16)$$

如图 9b 所示，该潜空间呈现明显模块化结构。当相似度接近零 ($M_{uv} \approx 0$) 时，说明 MLP_{task} 将不同任务映射到局部流形上近似正交的子空间。这种几何正交性表明 router 在无显式任务标签监督下，仍可隐式充当语义判别器，将任务表示解耦到相互独立的方向，从而施加差异化稀疏策略。

H.2. 注意力模式路由分析

对多任务热力图进行比较可以发现，不同模型家族在注意力机制上存在本质差异。对于 Qwen3 (图 11a)，我们观察到 **结构普适性**：一部分头在所有任务中都稳定激活（深红）或稳定稀疏（深蓝），表明其注意力拓扑具备任务无关性。而 Llama3.1 呈现 **上下文依赖稀疏**：尽管多任务聚合图（图 11b）不显示“全局恒激活头”，单任务拆分图（图 11c）表明强激活头确实存在，但会随输入上下文动态迁移。这说明 Qwen3 更依赖固定检索头，而 Llama3.1-8B-Instruct 会根据任务需求自适应重分配注意力资源。

训练过程中我们观察到，不同任务的有效稀疏水平会逐步分化。即使共享同一非紧约束 t ，任务间差异



17
Figure 10. **Router 时延分析**。Router 仅引入极小开销（平均 0.196 ms）。该设计在 512 到 1M token 范围内保持长度无关的稳定速度。




Figure 9. 路由表示 $\mathbf{z}_{\text{task}}$ 的两两余弦相似度。大量接近零的分数 ($M_{uv} \approx 0$) 说明 router 将不同任务映射到局部流形上的正交子空间，验证了模型在无监督条件下对任务语义的隐式解耦。

仍会自然出现。这一行为由拉格朗日约束驱动：它动态调整任务损失权重，使每个任务对“实际稀疏度 Ω_{MSR} 与目标 t 的偏差”具备不同容忍度。

H.3. 长度外推与稀疏动态分析

我们在 RULER (8K-256K) 上评估长度外推能力，骨干模型为 Llama-3.1-8B-Instruct。图 12 可视化了性能、推理加速与 Ω_{ESR} 的关系。当上下文扩展到 256K 时，MoBA 与 NSA 等基线出现灾难性退化（准确率接近 0）；相比之下，Elastic Attention (FA-XA) 保持了更强鲁棒性，得分仍有 68.51。即使是高效率配置 Elastic Attention (XA-SSA)，也可达到 47.68，显著优于标准 Xattention 基线 (35.82)，且在更高稀疏度下运行。

图 12(b)(c) 还显示了关键效率优势。NSA 与 InfLLM-V2 等方法虽可达到高稀疏度 (> 0.95)，但受动态选择开销或 kernel 限制，推理加速有限甚至回退 ($< 1.0\times$)。相对地，我们的 XA-SSA 在接近极限稀疏度 (~ 0.995) 下仍能实现 $3.28\times$ 加速，验证了 router 的低额外开销。而 Elastic Attention (FA-XA) 则在保持关键信息的同时达到更均衡权衡，实现 $1.51\times$ 加速。

总体而言，Elastic Attention 构建了更优 Pareto 前沿：Elastic Attention (FA-XA) 优先信息保留 ($\Omega_{\text{ESR}} \approx 0.65$) 以抑制“上下文坍塌”；Elastic Attention (XA-SSA) 则通过自适应极致稀疏最大化吞吐。两种配置都在各自精度-效率区间持续优于对比方法。

H.4. 损失曲线与监控指标

为验证 Elastic Attention 的训练稳定性与动态路由能力，我们在图 13 中可视化了详细训练动态。该图从四个维度拆解优化过程：主语言建模损失、稀疏正则损失、路由稀疏指标 (Ω_{MSR}) 演化，以及自适应系数 (λ) 演化。

优化稳定性。 如图 13a 与图 13b 所示，语言建模目标与 Attention Router 参数的联合优化过程稳定。LM loss 快速下降并稳定在约 2.1，说明轻量 router 的集成与稀疏性引入未阻碍骨干模型收敛。与此同时，稀疏正则损失在前 100 步显著下降（约从 0.16 降至 0.06），表明连续松弛 (Gumbel-Softmax) 有效引导 router 满足预设稀疏约束。

Elastic Attention 分配差异 (Ω_{MSR})。 图 13c 为 § 1 的动机提供了实证支持：下游任务天然具有不同注意力稀疏敏感性。




Figure 11. 扩展的头鲁棒性分析。与图 6 类似，热力图可视化了每个头被激活为全注意力的频率。(a)(b) 分别展示 Qwen3-8B 与 Llama3.1-8B-Instruct 的多任务全局鲁棒性；(c) 展示 Llama3.1-8B-Instruct 在单任务设定下的鲁棒性。蓝色越深表示头越稳定稀疏，红色越深表示头越稳定激活。

- **任务相关路由**：从中性初始化开始，Attention Router 会自动学习任务差异。与假设一致，**稀疏敏感任务**（如 Code 与 In-Context learning）收敛到更高 Ω_{MSR} （约 0.80–0.85），意味着分配更多全注意力（FA）以保持性能。
- **稀疏鲁棒效率**：相比之下，**稀疏鲁棒任务**（如 Q&A）在更低水平附近收敛，更接近目标阈值（虚线，表示 t_{sen} ）。这表明 Elastic Attention 能识别可承受更高稀疏度的任务，从而提升推理吞吐并避免不必要计算。


自适应系数 (λ)。图 13d 展示了拉格朗日乘子 (λ) 的演化，它们会动态调整违反稀疏目标的惩罚强度。我们观察到 λ_5 (In-Context) 增长最快，说明模型优先满足该敏感任务的稠密需求。这一自适应机制可自动平衡计算成本与模型质量，减少人工任务级调参需求。

H.5. 输入截断对任务识别的影响


为平衡路由效率与准确性，我们研究了 Attention Router 对输入序列长度的敏感性。具体地，我们分析不同截断预算如何影响 router 区分任务类型并分配合适稀疏模式的能力。图 14 展示了 6 个下游任务在截断预算从 50 token（边界池化）到全序列时的性能与稀疏趋势。

边界池化假设。默认策略使用边界池化：仅聚合前 100 与后 100 个 token。该设计基于一个经验观察：任务指令 (System Prompt) 通常位于上下文开头，用户具体查询通常位于结尾；中间内容多为长文档本体（如待摘要文本），对生成阶段必要，但对路由阶段往往是噪声。


信噪比分析。如图 14 所示，性能通常在 100–200 token 截断附近趋于饱和。值得注意的是，使用全序列并不会带来性能提升，且在部分场景（如多文档 QA）会导致次优路由。我们认为原因是任务识别信号被稀释：当 router 处理更多文档正文 token 时，指令语义特征会被高方差内容掩盖。由此 router 更难准确判别任务类型，导致稀疏模式趋同（长长度下稀疏曲线更平），但生成质量并未相应提升。这些结果验证了“100 token 边界窗口”是一种稳健配置：能保留关键任务描述信息，同时过滤由正文引入的噪声。



(a) RULER 性能。



(b) 效率分析。



(c) 稀疏率。

Figure 12. RULER 基准 (8K-256K) 上的长度外推能力与稀疏动态分析。以 Llama-3.1-8B-Instruct 为骨干，对比 Elastic Attention 两种配置 (FA-XA, XA-SSA) 及 MoBA、NSA 等方法。(a) 报告 RULER 评分；(b)(c) 展示推理加速与 Ω_{ESR} 的权衡，体现了我们方法更优的 Pareto 前沿。

I. 误差分析

在表 15、16 与 17 中，我们给出与多种基线的代表性输出对比。由于上下文过长，仅展示了部分输入片段。我们观察到，性能提升的主要来源在于：本方法能够更准确识别并利用与查询相关的关键上下文片段。




Figure 13. Elastic Attention 训练目标分解。我们展示 Attention Router 的训练动态：(a) 主语言建模目标，(b) 稀疏正则项，(c)(d) 分别为任务级稀疏分配 (Ω_{MSR}) 与自适应系数 (λ) 的演化，说明模型会自动区分稀疏鲁棒与稀疏敏感任务。




Figure 14. 路由器输入截断长度对下游性能与 Ω_{MSR} 的影响。我们比较了对“序列前缀与后缀拼接结果”施加不同截断预算 ($L \in \{50, \dots, 800, \text{All}\}$) 时的效果。结果表明，输入长度超过 100 token 后性能收益很小，且由于信噪比下降可能削弱 router 选择性。

案例 1：政策决策（长上下文）

上下文：

“地图阴影区域表示 ESCAP 成员与准成员。* 亚洲及太平洋经济社会委员会（ESCAP）是亚太地区最具包容性的政府间平台。该委员会推动 53 个成员国和 9 个准成员合作，共同应对可持续发展挑战。ESCAP 是联合国五个区域委员会之一。ESCAP 秘书处通过产出行动导向知识、提供技术援助与能力建设服务，支持各国发展目标、区域协议以及《2030 年可持续发展议程》的落实。* 地图上的名称与材料展示方式，不代表联合国秘书处对任何国家或地区法律地位的立场……”

问题：

在保持政治与社会稳定的前提下，政府应采取何种政策组合，才能更好平衡财政可持续性、私营部门参与以及能源转型？

正确预测（我们的方法 / 标准答案）：

“渐进式能源转型 + 国家绿色投资银行”方案：建立国家绿色投资银行……在未来五年维持现有化石燃料补贴，以保障能源价格稳定并逐步扩大可再生能源……同时推迟征收碳税。

错误基线：

Qwen3-8B、PruLong、DuoAttn、InfLLM-V2：

“激进财政再平衡”方案：提高石油生产碳税……在五年内逐步取消化石燃料补贴……（错误：过早征收碳税和取消补贴，与稳定目标冲突）

MoBA：

“立即取消化石燃料补贴”方案：立刻取消所有化石燃料补贴……并在两年内引入碳定价机制……（错误：“立即取消”忽视社会稳定约束）

NSA：

“混合融资 + 出口导向”方案：建立公私混合融资基金……实施适度碳税……（错误：错误强调出口市场，且碳税时机不当）

Figure 15. 复杂政策推理任务上的定性对比。我们的模型正确识别出满足稳定性约束所需的“渐进式”路径，而基线往往幻觉出“激进”或“立即”措施，违背题设稳定要求。

案例 2：法律推理与文档理解

上下文：

截至 2024 年 6 月 20 日的加拿大法律文本（含英法双语条文）片段：包括《财政管理法》（Financial Administration Act）及其法条编纂信息、修订状态、官方法律效力说明等内容；文本中穿插英法双语段落与法律术语，结构冗长且噪声较高。

问题：

“特别经济措施法（SEMA）”与“财政管理法（FAA）”在职责上不同……在一个加拿大公民企业资产被扣押的假设场景中，它们的适用差异应如何理解？哪一种解释最准确地体现两者之间的细微关系？

正确预测（我们的方法 / 标准答案）：

SEMA 允许政府在更广泛的制裁框架下先行冻结资产，而不立即涉及没收归属；相对地，FAA 需要法律程序裁定资产是否应被永久没收并重新分配用于公共用途。

错误基线：

Qwen3-8B、PruLong、DuoAttn、MoBA、NSA：

回答仅指出 SEMA 可冻结资产、FAA 需评估法律依据并确保符合加拿大法律……（错误：回答过于泛化，未识别“公共用途再分配”这一关键结论）

InfLLM-V2：

强调 FAA 需法律审查并可能用于政府用途，SEMA 可先行冻结并延后即时决定……（错误：过度聚焦流程时延，而非资产去向这一实体差异）

Figure 16. 双语法律文档上的对比。我们的模型准确抽取了 FAA 关于资产再分配用于公共用途的关键法律含义，而基线多停留在“法律评估/合规”层面的泛化表述。

案例 3: 长上下文叙事理解 (《基督山伯爵》)

上下文:

《基督山伯爵》开篇长段落节选: 1810 年 2 月 24 日, 马赛港外了望台发现“法老号”归航, 船只经由多港返回并缓慢驶入港口; 城内围观者因其异常航行状态而猜测是否发生不幸事件…… (原文篇幅较长, 此处省略部分上下文)

问题:

是谁写信并将充满谎言的举报信送交检察官, 从而陷害了埃德蒙·唐泰斯?

正确预测 (我们的方法 / 标准答案):

Danglars、Fernand 和 Caderousse。

✓

错误基线:

Llama3.1-8B-Instruct、DuoAttn、NSA:

Fernand、Villefort 和 Danglars

(错误: 实体混淆, 把检察官 *Villefort* 误当成共谋者)

InfLLM-V2:

Fernand 和 Caderousse

(错误: 信息不完整, 遗漏主谋 *Danglars*)

PruLong:

Caderousse、Villefort 和 Fernand

(错误: 实体混淆, 错误包含 *Villefort*)

Figure 17. 叙事实体追踪任务的定性比较。该任务要求识别陷害主角的具体共谋角色。我们的模型准确检索到正确三人组, 而基线常将“Villefort (检察官)”幻觉性并入共谋者集合, 未能区分策划者与后续司法角色。