



Shiva Krishna Reddy Malay<sup>\*1</sup> Shravan Nayak<sup>\*1 2 3</sup> Jishnu Nair<sup>1</sup> Sagar Davasam<sup>1</sup> Aman Tiwari<sup>1</sup>  
Sathwik Tejaswi<sup>1</sup> Sridhar Krishna Nemala<sup>1</sup> Srinivas Sunkara<sup>1</sup> Sai Rajeswar<sup>1 2 3</sup>

## 摘要

大语言模型正从被动的信息提供者转变为面向复杂工作流的主动智能体。然而，若要将其作为可靠的企业 AI 员工部署，现有基准仍构成阻碍：它们未能刻画专业环境的复杂性，尤其是持久状态变化与严格访问协议下的长程规划需求。本文提出 ENTERPRISEOPS-GYM，一个用于评估真实企业场景中智能体规划能力的基准。具体而言，ENTERPRISEOPS-GYM 提供一个容器化沙箱，包含 164 张数据库表和 512 个功能工具，以模拟现实中的检索摩擦。该环境在八个关键业务领域（包括客户服务、人力资源和 IT）上评估 1,150 个由专家策划的任务。我们对 14 个前沿模型的评估揭示了当前系统的重要局限：表现最佳的 Claude Opus 4.5 仅取得 37.4% 的成功率。进一步分析表明，提供人类专家计划可将性能提升 14–35 个百分点，说明战略性推理是主要瓶颈。此外，智能体经常无法拒绝不可行任务，最佳模型的正确拒绝率也仅为 53.9%，从而可能产生非预期且有害的副作用。结果表明，当前智能体尚未准备好实现自治企业部署。更广泛地说，ENTERPRISEOPS-GYM 为推进专业工作流中智能体规划的鲁棒性提供了具体的测试平台。

<sup>\*</sup> 同等贡献 <sup>1</sup>ServiceNow Research <sup>2</sup>Mila - Quebec AI Institute

<sup>3</sup>Universite de Montreal. 通讯作者: Shiva Krishna Reddy Malay <shivakrishnareddy.ma@servicenow.com>。




图 1. ENTERPRISEOPS-GYM 上智能体工具使用的性能-成本权衡。图中给出闭源与开源模型的任务成功率及其单任务估算成本。开源模型成本更低，但成功率始终更低；成本较高的模型虽有适度性能增益，却仍远未达到可靠的任务完成水平。

 <https://enterpriseops-gym.github.io>

## 1. 引言

如今，大语言模型最常被部署为对话助手，用来回答问题、起草邮件和概括文档 (OpenAI, 2025; Anthropic, 2025b)。但一种影响更为深远的能力正在快速出现：LLM 作为代表用户行动的自治智能体 (Xu et al., 2024)。设想一个智能体只根据一条指令，就能检索网页上的实时库存信息、找出最佳产品并完成购买，无需任何后续输入。规划和工具使用的近期进展，正使 AI 员工的愿景越来越可信：自治智能体可处理从软件工程 (Jimenez et al., 2024)、数据分析 (Drouin et al., 2024) 到销售运营和企业管理 (Huang et al., 2025a;b) 的专业工作流。然而，要在现实的专业部署中有效运作，这类智能体不能只会




图 2. ENTERPRISEOPS-GYM 概览：面向有状态智能体规划与工具使用的基准。（左上）ENTERPRISEOPS-GYM 覆盖八个企业领域，并在可复现沙箱中评估多步智能体规划、策略遵循、状态驱动工具调用与跨领域编排。（右上）领域专家构建沙箱并编写贴近实际的单领域和跨领域任务，执行真值轨迹，编写以结果为中心的验证逻辑；经多阶段质量保证后，还为完成任务撰写人工专家计划。（下方）给定任务及作为系统级策略的约束，智能体与环境交互并执行工具。最终状态验证器检查目标完成情况、策略合规性与副作用。图中示例里，智能体未遵守关联案例知识的系统策略：自动发现知识库时，必须将参数设为“suggested”；此外，它还因未解析给定案例的标识符而没有正确发送邮件通知。

遵循指令；它们还必须：（1）在交错的长工具调用序列中连贯地维护状态；（2）执行跨越数十个动作的多步计划；（3）严格遵从工作场所的访问控制策略和流程规则。

这些要求在企业领域尤为关键。在这里，智能体不只是检索信息；它们会直接修改在线数据库、触发下游工作流，并影响真实用户。动作带有状态且往往不可逆；错误会在相互连接的系统中悄然传播；严格的组织策略约束着每一步。图 2 展示了一个此类任务：用户任务与细致的系统策略约束相互作用，所需能力远不止表层的指令跟随。智能体既要完成搜索案例、检索知识库文章、通知客户这样的多步工作流，也要遵守知识库文章标记的三级策略，并通过串联多个工具独立解析一项隐含信息，即客户的电子邮件地址。同样重要的是，智能体还必须知道何时停止。盲目尝试违反策略的任务会破坏系统状态，在生产环境中带来直接的安全风险。

尽管这一挑战迫在眉睫，现有基准仍未能充分刻画它。通用工具使用评测 (Li et al., 2023; Qin et al., 2024; Chen et al., 2025) 将工具调用视为原子且无状态的操作，衡量的是没有状态依赖或跨系统协调的短序列准确率。面向企业的基准 (Drouin et al., 2024; Boisvert et al., 2024; Huang et al., 2025a;b; Jha et al., 2025; Vishwakarma et al., 2025) 已出现，以应对专业环境中的挑战。它们虽作出了重要贡献，却通常局限于单一厂商生态（例如仅 Salesforce 或仅 ServiceNow），环境较浅，数据库表少于 25 张、工具不足 50 个、任务跨度较短，且对智能体行为的策略约束有限（见表 1）。

为弥补这一缺口，我们提出 ENTERPRISEOPS-GYM，一个用于在高保真企业仿真中评估智能体规划的基准。ENTERPRISEOPS-GYM 横跨八个相互连接的生态系统，既包括 Calendar、Drive、Teams 和 Email 等通用生产力工具，也包括人力资源（HR）、IT 服务

管理 (ITSM)、客户服务管理 (CSM) 等关键业务功能, 并由需要协调跨领域执行的 Hybrid 类别统一起来。该基准在这些领域上包含 1,150 个由专家编写的任务, 其中 30 个不可行场景用于检验智能体能否正确拒绝无法满足的请求, 同时不在系统中留下副作用。任务由手写 SQL 脚本验证, 检查目标完成、状态完整性、策略合规性和非预期副作用。ENTERPRISEOPS-GYM 运行于完全交互式的容器化环境, 其中包含 164 张关系数据库表和 512 个功能工具; 专家轨迹平均为 9 步, 最长达 34 步。这样的规模旨在压力测试企业自动化的核心挑战: 长程规划、跨系统状态管理与受策略约束的执行。

我们对 14 个前沿模型的评估揭示了当前智能体能力与企业要求之间的显著鸿沟。性能高度受领域复杂度影响: 模型在协作任务上表现最好, 顶尖模型在 Email、Teams 和 Drive 上达到 51–52%, 但在受策略管控的 ITSM (28.5%) 和跨领域 Hybrid 任务 (30.7%) 上明显下降。这些恰恰是不可避免需要约束感知推理的领域。总体最佳模型 Claude Opus 4.5 仅达到 37.4%, 开源模型进一步落后。不可行性识别是关键弱点, 即使最佳模型也只能在 53.9% 的策略违规任务上干净地拒绝。测试时计算扩展有所帮助, 却不是普遍的补救方案: 某些 workflow 很早进入平台期, 或者无论思考预算如何增加都只得到有限改进。重要的是, 我们发现战略性规划而非工具使用才是主要瓶颈: 加入干扰工具几乎没有影响, 而提供人工编写的计划可使模型提升 14–35 个百分点。更复杂的多智能体编排同样无法弥合这个差距; 由于任务具有很强的顺序状态依赖, 把任务拆解为子任务甚至会使性能回退。综上, 当前智能体尚未准备好用于自治企业部署。

本文贡献如下:

- 我们提出 ENTERPRISEOPS-GYM: 一个覆盖八个企业领域、含 1,150 个专家策划任务的基准。它以结果为中心的验证机制约束目标完成、状态完整性、策略合规性和副作用检查, 并包含 30 个不可行任务, 用于评估安全拒绝行为。
- 我们构建了一个完全交互式、容器化的企业环

境, 含 164 张关系数据库表和 512 个功能工具, 复杂度比先前企业基准高一个数量级。

- 我们评估了 14 个前沿模型, 揭示并分析规划、状态管理与策略合规方面的系统性失败模式, 并给出构建更可靠企业智能体的可操作洞见。我们还将向社区发布 ENTERPRISEOPS-GYM, 以推动有状态智能体规划与企业工具使用研究。

## 2. 相关工作

LLM 智能体基准大致可分为三类主题: 通用工具使用与 API 评测、企业平台仿真, 以及智能体规划与计算机使用。表 1 从关键维度总结了 EnterpriseOps-Gym 与它们的比较。

**API 与工具使用基准** 早期基准工作着重测试智能体在通用开放领域中调用 API 和串联工具的能力。ToolLLM (Qin et al., 2024) 在超过 16,000 个真实 Web API 上建立大规模评测; API-Bank (Li et al., 2023) 提供了较小但可运行的系统, 用于评估 73 个工具上的规划与检索能力。AceBench (Chen et al., 2025) 将规模进一步扩展至 4,538 个工具并支持动态多轮评估;  $\tau$ -bench (Yao et al., 2024) 和  $\tau^2$ -bench (Barres et al., 2025) 则引入用户模拟和拒绝鲁棒性作为评测维度。这些基准对衡量工具调用准确性作出了重要贡献, 但仍以通用 Web 导向或开放领域 API 为核心; 它们没有建模企业环境所特有的多系统、策略受限且有状态的生态, 而这正是 ENTERPRISEOPS-GYM 所针对的场景。

**企业基准** 第二类基准直接面向企业平台。单平台环境将范围限制在一个厂商内: WorkArena (Drouin et al., 2024) 和 WorkArena+ (Boisvert et al., 2024) 在 ServiceNow 中评估组合式任务完成; CRM Arena (Huang et al., 2025a) 与 CRM Arena-Pro (Huang et al., 2025b) 聚焦 Salesforce 特定 workflow; ITBench (Jha et al., 2025) 面向 IT 事件解决。多领域工作拓展了范围, 但强调点不同: TheAgentCompany (Xu et al., 2024) 模拟一家初创软件公司, 要求智能体通过 Web 浏览器、bash 终端和代码执行交



| 基准                                         | 侧重点        | 领域数量     | 任务数量                    | 工具数量       | 平均步骤      | 数据库表数      | 平均外键       | 拒绝能力?    | 人工任务策划?  | 人工计划?    |
|--------------------------------------------|------------|----------|-------------------------|------------|-----------|------------|------------|----------|----------|----------|
| 通用工具使用                                     |            |          |                         |            |           |            |            |          |          |          |
| API-Bank (Li et al., 2023)                 | 工具使用       | 8        | 314                     | 73         | 3         | 0          | 0          | ✗        | ✓        | ✗        |
| ACEBench (Chen et al., 2025)               | 工具使用       | 8        | 2000                    | 4538       | 2         | 0          | 0          | ✓        | ✓        | ✗        |
| $\tau$ -bench (Yao et al., 2024)           | 用户交互       | 2        | 165                     | 28         | —         | 3          | 0.7        | ✓        | ✓        | ✗        |
| $\tau^2$ -bench (Barres et al., 2025)      | 用户交互       | 3        | 279                     | 56         | —         | 9          | —          | ✓        | ✗        | ✗        |
| 企业专用                                       |            |          |                         |            |           |            |            |          |          |          |
| WorkArena (Drouin et al., 2024)            | ServiceNow | 7        | 33                      | 30         | 10        | 7          | 0.9        | ✗        | ✗        | ✗        |
| WorkArena++ (Boisvert et al., 2024)        | ServiceNow | 7        | 682 ( <sup>†</sup> 341) | 30         | 30-50     | 7          | —          | ✓        | ✗        | ✗        |
| ITBench (Jha et al., 2025)                 | IT         | 3        | 94                      | 10         | —         | —          | —          | ✗        | ✓        | ✗        |
| WorkBench (Styles et al., 2024)            | 工作场所       | 5        | 690 ( <sup>†</sup> 69)  | 26         | 2         | 5          | 0          | ✗        | ✓        | ✗        |
| TheAgentCompany (Xu et al., 2024)          | 初创公司       | 7        | 175                     | —          | —         | 0          | 0          | ✗        | ✓        | ✗        |
| CRMArena (Huang et al., 2025a)             | Salesforce | 1        | 1170 ( <sup>†</sup> 9)  | 27         | —         | 16         | 1.3        | ✗        | ✓        | ✗        |
| CRMArena-Pro (Huang et al., 2025b)         | Salesforce | 3        | 8560 ( <sup>†</sup> 19) | —          | —         | 25         | —          | ✓        | ✓        | ✗        |
| EnterpriseBench (Vishwakarma et al., 2025) | 企业         | 5        | 500                     | 46         | 3         | 17         | 1.2        | ✓        | ✗        | ✗        |
| <b>ENTERPRISEOPS-GYM (本文)</b>              | <b>企业</b>  | <b>8</b> | <b>1150</b>             | <b>512</b> | <b>9*</b> | <b>164</b> | <b>1.7</b> | <b>✓</b> | <b>✓</b> | <b>✓</b> |

表 1. 与现有智能体基准的比较。数据库表报告环境中唯一数据库表的数量；平均外键衡量每张表的平均外键数，反映关系密度以及智能体必须处理的表间依赖复杂度。— 表示原工作未报告该值。\* 平均步骤反映理想的人工编写执行轨迹；模型轨迹可能需要显著更多步骤。人工计划是专家为完成任务撰写的逐步自然语言计划。<sup>†</sup> 括号内的值表示唯一任务模板数。

互，这一范式与 ENTERPRISEOPS-GYM 的结构化工具调用 API 场景根本不同；WorkBench (Styles et al., 2024) 覆盖办公生产力工具；EnterpriseBench (Vishwakarma et al., 2025) 则评估沙箱企业数据上的函数调用。在这些基准中，关系数据库复杂度一贯受限于不足 25 张表；任务要么局限于单一厂商生态，要么缺少专家编写的依据，或未明确评估拒绝行为。ENTERPRISEOPS-GYM 跨越八个企业领域，既包含业务系统 (CSM、ITSM、HR)，也包含协作服务 (Email、Calendar、Teams、Drive)，并提供高连接度的 164 张数据库表、512 个工具、1,150 个专家策划任务以及受策略约束的不可行场景。

**智能体规划与计算机使用** 规划是自治智能体的核心能力，已有若干基准在多样的通用场景中研究它。UserBench (Qian et al., 2025) 在多轮旅行规划任务上评估智能体，其中模拟用户逐步且隐式地表达偏好，因此需要主动澄清意图。Gaia2 (Froger et al., 2025) 在异步模拟移动环境中评估智能体，测试搜索、执行、时序推理、适应性、歧义处理和多智能体协作。VitaBench (He et al., 2025) 在送餐、到店就餐和在线旅行等真实服务的复杂多轮任务上评估智能

体，并使用具有动态偏好的模拟用户。另一条并行研究线关注计算机使用智能体：OSWorld (Xie et al., 2024)、WindowsAgentArena (Bonatti et al., 2025)、WebArena (Zhou et al., 2024) 和 UI-Vision (Nayak et al., 2025) 都在需要复杂序列决策的桌面或 Web GUI 上评测智能体。尽管这些设置也要求精密的规划，它们处理的是日常情景或计算环境，而非企业环境中受策略管控的多系统语境。ENTERPRISEOPS-GYM 同样强调较长的规划跨度，但其独特位置在于规划深度与企业领域保真度的交汇处。

### 3. ENTERPRISEOPS-GYM

本节介绍 ENTERPRISEOPS-GYM 的设计和构建，包括领域选择、沙箱环境、Section 3.1 中的任务形式，以及 Section 3.2 中的数据集统计。

#### 3.1. EnterpriseOps-Gym 构建

**领域选择** 我们与具有企业软件实操经验的领域专家 (SME) 协商后，依据三项原则选择领域：(i) 与真实行业垂直领域相关；(ii) 策略复杂度和数据敏感性具有多样性；(iii) 有领域专家可编写并验证真




图 3. 八个 ENTERPRISEOPS-GYM 领域的任务分布。

实任务。据此得到两组互补的领域。

第一组由客户服务管理 (CSM)、人力资源 (HR) 和信息技术服务管理 (ITSM) 构成，是企业组织的运营骨干。这些领域几乎存在于每一种行业垂直领域，具有严格的流程合规、访问控制策略和高风险 workflow，错误会带来切实后果。CSM 管理支持工单和服务协议的完整生命周期；HR 在严格隐私与流程规则下处理敏感员工数据；ITSM 覆盖包括事件管理和系统配置在内的后端 IT 运维。其重策略性质和现实复杂度使其适于压力测试约束感知规划。

第二组由 Email、Calendar、Teams 和 Drive 组成，涵盖所有企业每天使用的通用协作工具。智能体必须熟练掌握它们，才能充当有效的 AI 员工。尽管单独看来更简单，这些领域仍需要精密编排：Email 处理复杂邮箱 workflow，Calendar 管理时间和资源访问策略，Teams 管理协作工作空间，Drive 则维护文件系统完整性与安全性。

最后，Hybrid 要求在这些碎片化工具之间进行跨领域编排，智能体切换系统时必须保持上下文与数据完整性。八个领域共同覆盖完整的企业 workflow 谱系，从内部运营、面向客户的流程到协作基础设施，因而可同时评估专用和通用的智能体能力。

**沙箱环境与数据生成** 我们与专业数据标注公司 Turing<sup>1</sup> 合作，组建了由 160 多名贡献者构成的团

<sup>1</sup><https://www.turing.com>

队，其中包括构建环境的软件工程师，以及 CSM、ITSM、HR 等技术领域的主题专家。为提供可复现且真实的评测场地，我们开发了容器化 Docker 沙箱，其中承载领域特定的数据库、API 和工具执行层。该环境复现企业约束而不暴露专有基础设施。对每个领域，我们创建真实的数据库模式，并填充种子数据和用于访问、操作数据的工具。底层数据由 SME 从强现实视角设计；在官方产品文档和 SME 洞见的指引下，我们依据行业标准数据库模式建模真实的表结构、约束与工具。从固定的数据和工具种子出发，标注员会按每个任务的需要向环境扩展新表、模式和记录。

**任务构建流水线** 任务创建遵循严格流水线，以确保高复杂度与对真实工作流的忠实性。在**场景设计**阶段，标注员依据明确的复杂度阈值构建具有挑战性的多步场景，考量工具调用数量、验证条件和状态依赖等维度（动作顺序对成功至关重要）、访问约束（例如“只有团队所有者可以创建私有频道”）及其他策略冲突（用户请求与系统策略相冲突）。我们约束任务具有唯一最终状态，尽管到达它可能有多条有效路径。此外，我们设计了 30 个不可行任务：由于工具不足、显式策略违规或资源不可用，任务完成在设计上就是不可能的。对于每个任务，标注员也会更新沙箱，增加必要的表和工具。随后进入**真值执行与计划编写**阶段：标注员为每个任务提供细粒度的逐步计划，并在沙箱中手动执行以捕获黄金标准轨迹，记录每次调用的参数、响应和执行理由。标注员还会编写自然语言推理计划，将每个动作明确地锚定在系统约束、用户请求和可用工具上。计划会引用系统提示词中的策略，并解释顺序依赖，从而使任务在给定上下文中得到完整依据。

我们实施**以结果为中心的验证**：标注员编写可执行 SQL 验证脚本，在任务完成后检查环境最终状态。这样我们评估的是结果而不是僵化的动作序列，因而允许多条有效的解题路径。评测会检查必需条件（是否达成目标？）、完整性约束（是否遵守外键约束？）、权限合规（智能体是否避免未授权动作？）及其他副作用。最后，我们进行多轮**质量保证**：复审

标注员（包括作者）评估给定初始状态和可用工具时任务是否可行，指令是否清晰完整且不依赖外部依赖或领域知识，验证脚本的正确性和覆盖率，以及真值计划、指令和验证脚本的流畅性与连贯性。

### 3.2. 数据集统计

**任务统计** EnterpriseOps-Gym 在 1,150 个任务上评估智能体，这些任务旨在复现真实企业操作的深度，其中包括 30 个不可行任务，用来测试智能体能否正确拒绝无法满足的请求。动作空间广泛而多样，跨领域含 512 个唯一工具；各领域工具集从 Calendar 的 37 个到 ITSM 的 93 个不等。专家人工轨迹平均为 9.15 步，规划跨度在领域间显著不同：Email 平均 6.2 步，CSM 平均 12.1 步，HR 最长可达 34 步。除长度外，任务的约束也很密集：平均每个任务要求满足 5.3 个不同的验证条件，最复杂的场景需要解决 44 个条件。

**环境统计** 我们的沙箱环境建模了一个高度互连的数据生态，八个领域共含 164 张唯一数据库表。平均每个任务与由 24.9 张表构成的子图交互，Hybrid 场景中最多达到 73 张。这意味着智能体必须在一个大型、部分可观测的数据图上推理，才能正确执行任务。每个任务平均涉及 3,443 行数据库记录；在 CSM 等数据密集领域中超过 10,000 行。为量化关系复杂度，我们测量每张表的平均外键（FK）数量。依赖程度很高，Calendar 平均为 1.1 个外键，HR 为 2.4 个，整体均值约为 1.7，超过先前基准的关系密度（见表 1）。更高的外键密度意味着智能体在构造有效工具参数时必须解析更多表间依赖，因此参照完整性成为关键挑战。

## 4. 实验

### 4.1. 基线

我们评估了一组多样化基线，覆盖闭源前沿模型、开源推理模型与非推理模型。所有智能体均在统一接口下评测，使用相同的任务指令、工具定义、沙箱环境和评估协议。除非另有说明，智能体都在预言式工具设置下运行，即假设一个完美检索器为

智能体提供正确工具集。这样可将评测聚焦于规划和执行本身，无需显式发现工具。我们还通过增加可用工具数量进行消融，以分析工具集大小如何影响性能。我们采用标准的 ReAct 式推理和工具执行循环，它已被证明在智能体设置中有效 (Yao et al., 2022)。闭源模型包括 Claude 4.5 (Anthropic, 2025b;a) 的 Opus 和 Sonnet 变体、GPT (OpenAI, 2025) 的 5.2 High、5.2 Low、5 和 5-Mini 变体，以及 Gemini (Gemini Team, 2025) 的 3-Pro、3-Flash 和 2.5-Pro 变体；开源模型包括 Kimi-K2-Thinking (K-Team, 2025)、DeepSeek-V3.2 (DeepSeek-AI, 2024)、GPT-OSS-120B (Medium) (OpenAI et al., 2025)，以及 Qwen3 (Yang et al., 2025) 的 235B Inst.、30B Think 和 4B Think 变体。

### 4.2. 评估指标

我们以 pass@1 任务完成率评估模型：仅当模型在满足所有给定约束的同时完成全部任务要求时，得分才为 1。任务完成由基准策划过程中主题专家 (SME) 手写的 SQL 验证器执行验证。我们将三次运行的 pass@1 平均值作为主要指标，以降低方差，因为它刻画端到端任务成功。我们也测量验证器级成功率；该指标可细致反映成功验证检查的平均数量，但它可能具有误导性：智能体可能通过平凡轨迹片段的验证器（例如初始设置），却在核心任务逻辑、系统合规要求或副作用检查上失败。因此，pass@1 对现实中智能体效用的评估更准确。

### 4.3. 结果

**模型在不同领域中的表现如何？** 总体而言，Claude Opus 4.5 达到最佳平均任务完成率 (37.4%)，并在多种 workflows 中表现突出：它在 Email (51.9%)、Calendar (43.2%)、HR (32.1%) 和 Hybrid (30.7%) 上领先。Gemini-3-Flash 是总体第二名 (31.9%)，并在服务与运维管理工作流 ITSM 上居首 (28.5%)。Claude Sonnet 4.5 (30.9%) 在协作和以文档为中心的工作流上仍然强劲，分别在 Teams (51.0%) 和 Drive (52.1%) 上领先。GPT-5 则呈现更具领域特异性的峰值，在 CSM 上最高 (36.4%)。整体上，开源模型仍落后于闭源系统；最强开源模型 DeepSeek-V3.2 (High)



| 模型                                         | Teams       | CSM         | Email | ITSM        | Calendar    | HR          | Drive       | Hybrid      | 不可行         | 平均          |
|--------------------------------------------|-------------|-------------|-------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| 闭源模型                                       |             |             |       |             |             |             |             |             |             |             |
| Claude Opus 4.5 (Anthropic, 2025b)         | 50.0        | 34.2        | 51.9  | 23.8        | <b>43.2</b> | <b>32.1</b> | 49.5        | <b>30.7</b> | 50.0        | <b>37.4</b> |
| Gemini-3-Flash (Gemini Team, 2025)         | 47.3        | 35.0        | 44.3  | <b>28.5</b> | 30.5        | 12.6        | 49.7        | 24.2        | 38.5        | 31.9        |
| GPT-5.2 (High) (OpenAI, 2025)              | 31.0        | 34.8        | 51.0  | 21.7        | 38.5        | 25.0        | 40.0        | 22.2        | 50.0        | 31.8        |
| Claude Sonnet 4.5 (Anthropic, 2025b)       | <b>51.0</b> | 16.7        | 51.3  | 17.6        | 34.6        | 21.6        | <b>52.1</b> | 28.1        | 46.2        | 30.9        |
| GPT-5 (OpenAI, 2025)                       | 26.3        | <b>36.4</b> | 49.0  | 18.9        | 41.3        | 17.9        | 34.0        | 23.5        | 50.5        | 29.8        |
| Gemini-3-Pro (Gemini Team, 2025)           | 43.0        | 27.7        | 33.6  | 22.2        | 28.8        | 12.5        | 46.7        | 22.9        | 50.0        | 28.0        |
| GPT-5.2 (Low) (OpenAI, 2025)               | 25.0        | 21.2        | 43.3  | 6.7         | 28.9        | 13.0        | 26.7        | 20.9        | <b>53.9</b> | 21.9        |
| GPT-5-Mini (OpenAI, 2025)                  | 25.7        | 15.8        | 47.4  | 8.9         | 28.8        | 10.7        | 23.8        | 22.5        | 47.4        | 21.3        |
| Gemini-2.5-Pro (Gemini Team, 2025)         | 39.3        | 11.6        | 31.1  | 13.9        | 12.5        | 4.9         | 27.0        | 19.6        | 34.7        | 18.2        |
| 开源模型                                       |             |             |       |             |             |             |             |             |             |             |
| DeepSeek-V3.2 (High) (DeepSeek-AI, 2024)   | 37.0        | 14.1        | 47.1  | 16.1        | 21.2        | 16.3        | 35.2        | 22.9        | 53.8        | 24.5        |
| GPT-OSS-120B (High) (OpenAI et al., 2025)  | 32.0        | 16.3        | 42.3  | 6.1         | 35.6        | 16.3        | 41.0        | 19.6        | 50.0        | 23.7        |
| DeepSeek-V3.2 (Medium) (DeepSeek-AI, 2024) | 35.7        | 15.4        | 45.8  | 9.6         | 21.5        | 15.0        | 27.6        | 22.9        | 40.0        | 22.3        |
| Kimi-K2-Thinking (K-Team, 2025)            | 30.0        | 7.1         | 51.0  | 12.2        | 15.4        | 8.2         | 39.6        | 15.7        | 30.5        | 19.5        |
| Qwen3-30B (Think) (Yang et al., 2025)      | 22.0        | 5.4         | 51.9  | 6.7         | 18.3        | 7.6         | 25.7        | 15.7        | 36.8        | 16.8        |
| Qwen3-235B (Inst.) (Yang et al., 2025)     | 28.0        | 4.7         | 38.1  | 9.3         | 15.7        | 7.8         | 23.8        | 17.7        | 30.5        | 16.1        |
| Qwen3-4B (Think) (Yang et al., 2025)       | 24.0        | 3.8         | 38.4  | 5.6         | 5.8         | 7.1         | 21.9        | 15.8        | 31.6        | 13.7        |

表 2. ENTERPRISEOPS-GYM 上的总体任务完成性能。我们报告各模型在预言式工具模式下、按领域划分的成功完成任务百分比。仅当所有以结果为中心的验证检查均通过时，任务才被视为成功。

平均达到 24.5%，略高于 GPT-OSS-120B (High) 的 23.7%。它们在 CSM、ITSM 和 HR 这类服务、策略和面向人的领域尤为困难。Qwen3-30B (Think) 相对于其规模表现出人意料地好，超过了更大的 instruct 变体，并在 Email 上取得很有竞争力的 51.9%，并列第一。最后，ITSM 和 Hybrid 跨领域工作流是最困难的设置，最佳分数分别仅为 28.5% 和 30.7%，突显服务运营和跨领域协调仍是所有模型家族的关键瓶颈。

**增加额外工具如何影响性能？** 我们选择总体性能强、成本效益高的 Claude Sonnet 4.5，采用消融实验评估其对工具过载的鲁棒性。我们向预言式工具集加入额外的干扰工具 (+5、+10 和 +15)。为使该设置尤其困难且能代表现实中的检索错误，我们要求 Claude 检索那些看上去与任务最相关的干扰工具。令人意外的是，性能保持得非常稳定：平均完成率反而平均略增约 ~1.0% (+5 时为 +0.07%，+10 时为 +2.35%，+15 时为 +0.64%)。唯一另一个显著变化是输出 token 平均增加 4–9%。这表明模型会利用额外 token 预算仔细筛选并选择合适的工具。这种鲁棒性

可能来自 LLM 在工具使用上的广泛训练。因此，我们的结果表明，这些智能体的首要瓶颈并非工具发现，而是任务规划与系统策略遵守。

**哪个模型提供最佳性能–成本权衡？** 最佳性能–成本权衡取决于优先考虑绝对质量，还是每美元质量。由 Figure 1 的 Pareto 前沿可见，Gemini-3-Flash 在闭源模型中提供最强的实用权衡：其单任务成本为 0.03 USD、性能为 31.9%，以仅为 GPT-5 (29.8%，0.16 USD) 和 Claude Sonnet 4.5 (30.9%，0.26 USD) 一小部分的成本，取得了更高成功率，成本低 80–90%。在开源生态中，DeepSeek-V3.2 (High) 是 Pareto 占优选项，以仅 0.014 USD 达到 24.5%；紧随其后的是 GPT-OSS-120B (High)，以 0.015 USD 达到 23.7%，二者是总体最具价值的开源选择。Qwen3-235B (Inst.) 总体最便宜 (0.007 USD)，但性能下限显著，仅有 16.1%。鉴于各系统成功率均低于 40%，在没有人工监督时它们仍不足以可靠地自治部署。若追求最高绝对可靠性，Claude Opus 4.5 仍是首选 (37.4%)，但每任务需付出 0.36 USD 的高昂溢价。




图 4. 性能随规划跨度稳定下降。闭源（实线）和开放权重（虚线）模型在 4–16 个步骤的不同跨度长度上的 Pass@1 准确率。粗线为组均值  $\pm 1$  个标准误差。两组性能均单调下降，开放模型随跨度增长下降更快。

**模型拒绝不可行任务的能力如何？** 我们在八个领域中策划了 30 个不可行任务，评估模型是否会对无法满足的请求作出恰当弃权。每个任务平均包含 10 项验证检查，以确保系统中没有副作用。任务通过三种主要机制变得不可行：工具可用性不足、显式策略违规（如日程冲突、数据访问规则等）和资源不可用（如用户未激活、系统处于迁移模式等）。此外，任务采用复合约束，平均每项请求包含 3–4 个约束，模型须评估多个相交条件来判断任务可行性。如表 2 所示，GPT-5.2 (Low) 与 DeepSeek-V3.2 (High) 在弃权且不在系统留下副作用方面最好，分别为 53.9% 和 53.8%；GPT-5 为 50.5%，Claude Opus 4.5、Gemini-3-Pro 和 GPT-OSS-120B (High) 等一组模型均为 50.0%。但所有模型的绝对分数仍远低于生产系统可安全使用的水平。

**性能如何随任务跨度扩展？** 为理解模型能力如何随任务复杂度退化，我们按预期跨度长度对任务分层；该长度与人工编写执行轨迹中的工具执行步数

成正比。正如 Figure 4 所示，随着任务跨度增大，所有模型的性能一致衰减，反映出在多步序列中维持推理完整性的累积困难。由 Claude Opus 4.5 领衔的闭源组更有韧性：即使组均值从 4 步时约 35% 降至 16 步时不足 20%，它仍保持性能领先。相反，开源组下降更陡，Kimi K2 和 GPT OSS 120B 等模型在最大跨度时趋近 10% 的成功率。这一近乎普遍的趋势表明，当前模型可处理短至中等长度序列，但长跨度任务中错误快速累积仍是生产环境中自治可靠性的关键障碍。

**思考预算如何影响性能？** 我们针对 GPT-OSS-120B 模型 (OpenAI et al., 2025)，通过改变低、中、高思考预算评估测试时计算的影响。提高思考预算会在几乎所有领域显著改善任务完成（见图 5）。在低预算下，模型在 CSM (1.1%)、ITSM (1.1%) 和 HR (0.0%) 等复杂服务与面向人领域中严重受挫，准确率接近零。扩展到高预算可释放显著能力：Drive 从 8.6  $\rightarrow$  41.0%，Calendar 从 8.7  $\rightarrow$  35.6%，Teams 从 4.0  $\rightarrow$  32.0%。这种对测试时计算的强依赖说明 ENTERPRISEOPS-GYM 的任务执行确实需要复杂推理与规划。但性能扩展并非普遍单调：例如 Email 在中预算达到峰值 (45.2%) 后略有回落，ITSM 很早就进入平台 (1.1  $\rightarrow$  6.1%  $\rightarrow$  6.1%)。这说明仅分配更多思考 token 并不能普遍克服某些 workflows 中的根本能力瓶颈。

#### 4.4. 进一步分析

| 模型        | 计划 | CSM                     | ITSM                   | HR                     |
|-----------|----|-------------------------|------------------------|------------------------|
| Kimi-K2   | CP | 19.6 $\uparrow 12.5\%$  | 18.1 $\uparrow 5.9\%$  | 17.2 $\uparrow 9.0\%$  |
|           | HP | 42.2 $\uparrow 35.1\%$  | 29.1 $\uparrow 16.9\%$ | 34.5 $\uparrow 26.3\%$ |
| Qwen3-30B | CP | 15.2 $\uparrow 9.8\%$   | 11.7 $\uparrow 5.0\%$  | 17.9 $\uparrow 10.3\%$ |
|           | HP | 33.9 $\uparrow 28.5\%$  | 20.9 $\uparrow 14.2\%$ | 33.2 $\uparrow 25.6\%$ |
| Qwen3-4B  | CP | 16.8 $\uparrow 13.0\%$  | 12.2 $\uparrow 6.6\%$  | 19.6 $\uparrow 12.5\%$ |
|           | HP | 37.16 $\uparrow 33.4\%$ | 23.3 $\uparrow 17.7\%$ | 36.4 $\uparrow 29.3\%$ |

表 3. 计划条件执行基线。比较使用 Claude 计划 (CP) 和人工计划 (HP) 时的性能。绿色数值表示相对表 2 中 ReAct 基线的百分比提升。

上述结果表明，性能随跨度长度急剧退化，且模型






图 5. 思考预算对性能的影响。直方图给出 GPT-OSS-120B 模型 (OpenAI et al., 2025) 在各领域不同思考预算下的性能。低思考预算下模型表现较差，性能会随思考预算增加而稳步提高。

在规划而非执行上最为困难。为进一步理解这一点，我们进行一系列受控消融：既将规划和执行解耦，也逐步构建更复杂的多智能体系统，测试把认知负荷分配给专门智能体能否恢复单一整体智能体无法取得的性能。

**自动规划能稳定提升较弱模型。**我们引入规划器-执行器基线：由我们表现最好的模型之一 Claude Sonnet 4.5 实例化的专用规划器，围绕用户意图、策略约束和潜在副作用生成高层计划；单独的执行器随后使用与单智能体基线相同的 ReAct 循环完成工具执行。我们在最具挑战的三个领域 (CSM、ITSM、HR) 上评估三种较弱模型 (Kimi-K2、Qwen-30B、Qwen-4B)。如表 3 所示，所有模型和领域的性能均稳定提升 6–13%，这确认即使执行器模型固定，规划质量仍是有意义的瓶颈。

**人工编写计划揭示了显著更高的上限。**为界定更好规划可能达到的效果，我们向相同执行器模型提供人工编写的参考计划，并要求其执行相应工具调用，从而完全解耦规划与执行。收益显著大于自动规划：跨模型和领域提升 14–35 个百分点，约为 Claude 生成计划所带来改进的两倍。值得注意的是，采用人工计划（以及 Claude 计划）的 Qwen3-4B 与相同条件下更大的模型相当，甚至超过它们。这表明，当战略性推理被外化后，剩余的主要挑战是忠实遵循指令和精确调用工具；无论规模如何，现代 LLM 在这两项能力上都展现了广泛的胜任力。这也可能说明，内部先验更强的大模型更倾向偏离给定计划，而较小模型会更字面地跟随逐步指令；当这些指令最优




图 6. 智能体编排对性能的影响。直方图给出采用 Claude-Sonnet-4.5 的不同多智能体架构性能。基线是第 4.1 节描述的简单 ReAct 循环。规划器 + 执行器架构先提示模型产生详细计划，再执行以该计划为条件的 ReAct 循环；规划器 + 分解 + 子任务执行器进一步进行任务分解，并为每个子任务调用一个在 ReAct 循环中运行的子智能体；最后，预言式人工计划 + 执行器以人工编写计划为条件执行 ReAct 循环。

时，这反而是优势。然而，人工计划与 LLM 计划之间的差距表明，当前 LLM 在这些任务上的战略推理仍远未达到人类水平。

**更复杂的编排不能弥合这一差距。**我们针对 Claude Sonnet 4.5 评估两种 MAS 配置：一种规划器 + 执行器系统，用自动生成的计划作为 ReAct 条件；另一种规划器 + 分解 + 子任务执行器系统，额外分解任务，并为每个子任务调用单独的子智能体。我们将这些系统与无人工编写计划的 ReAct 执行器基线比较。由图 6 可见，规划器 + 执行器设置持续优于 ReAct 基线，在 CSM 和 HR 上分别绝对提

升 10.7% 和 8.8%。但分解架构鲁棒性较弱：它虽在 ITSM 上有小幅提升，却在 CSM 和 HR 上退化，在 CSM 上甚至低于基础 ReAct (16.2% 对 16.7%)。这与 ENTERPRISEOPS-GYM 任务具有强顺序状态依赖、而分解会破坏这种依赖相一致。最终，自动系统与采用人工计划的 ReAct 之间仍然存在显著差距，说明进展需要约束感知计划生成，而非仅靠架构复杂度。

**失败模式** 我们对模型取得部分进展却最终未完成任务的样本进行了人工定性分析，观察到若干反复出现的失败模式。模型经常在没有先查询必要先决条件的情况下调用创建数据库对象的工具，从而产生带有失效外键链接的悬空记录，称为**缺失先决条件查询**。例如，一个任务要求在特定类别下创建 HR 主题时，模型跳过检索可用类别，插入了孤立记录。当某些状态转移发生时，模型也无法触发系统策略规定的后续动作，称为**级联状态传播**失败。其他失败包括：不通过先前工具交互解析正确 ID 而把未经验证的标识符传给工具调用，称为**错误 ID 解析**；以及在尚未执行所有必要步骤前过早宣称任务完成，称为**过早完成幻觉**。为更系统地归类这些错误，我们使用 LLM (Claude Sonnet 4.5 (Anthropic, 2025c)) 根据专家撰写的描述，将最终状态 SQL 验证器标记为三类：(i) 任务完成验证器检查是否实现主要用户目标；(ii) 完整性约束验证器检查系统是否保持一致状态与有效外键关系；(iii) 权限与流程合规验证器检查是否遵守管理权限和流程规则的系统策略。这些类别的验证器通过率见表 4。模型在权限与流程合规上最为困难，这对现实部署尤其关键，因为策略违规会引发级联系统故障和严重的安全漏洞。

## 5. 讨论与结论

我们提出了 ENTERPRISEOPS-GYM，一个沙箱化评估平台与基准，覆盖八个企业生产力领域中的 1,150 个专家策划任务，包含 512 个工具和由主题专家编写的 SQL 验证器。实验揭示了若干我们认为对企业级 LLM 智能体发展具有广泛意义的发现。

**当前智能体远未达到企业就绪。**即使在预言式工具访问这一最有利的检索设置下，最佳模型的任务成

| 领域       | 任务完成 |      | 完整性约束 |      | 策略合规 |      |
|----------|------|------|-------|------|------|------|
|          | 样本数  | 分数   | 样本数   | 分数   | 样本数  | 分数   |
| Teams    | 100  | 82.3 | 20    | 90.0 | 8    | 81.3 |
| CSM      | 183  | 58.3 | 30    | 70.0 | 120  | 45.5 |
| Email    | 103  | 70.9 | 17    | 76.5 | 12   | 79.2 |
| ITSM     | 176  | 53.7 | 30    | 50.6 | 70   | 30.0 |
| Calendar | 104  | 71.5 | 8     | 62.5 | 19   | 76.1 |
| HR       | 182  | 63.2 | 47    | 56.0 | 94   | 50.4 |
| Drive    | 105  | 75.1 | 26    | 87.8 | 6    | 66.7 |
| Hybrid   | 152  | 60.0 | 23    | 72.5 | 18   | 61.1 |

表 4. 按类别统计的跨领域验证器通过率。模型在完整性约束（系统状态有效性）上得分最高，其次为任务完成；策略合规表现最低。各类别样本数不同；CSM、ITSM 和 HR 等负担更重的领域更强调完整性约束和策略合规。

功率也仅为 37.4%；性能还会随跨度长度和跨领域耦合单调下降。关键在于，失败模式并非随机：我们的定性和定量分析表明，智能体在权限与流程合规方面最为困难，例如遵守策略和处理级联状态转移，而不是基本任务完成。此外，即便前沿模型也仅约一半时间能可靠拒绝不可行任务，最佳值为 53.9%，远低于无人监督部署所需的鲁棒性。这些结果说明，仅靠扩展模型容量无法弥合企业可靠性差距。

**规划是主要瓶颈，而非工具执行。**我们的计划条件消融表明，人工编写计划能在跨模型、跨领域时带来 14–35 个百分点的提升，远大于自动规划或更复杂多智能体编排的收益。值得注意的是，以人工计划为条件的 Qwen3-4B 可与同条件下大得多的模型竞争，说明一旦战略性推理被外化，即使小模型也能忠实执行。这种规划与执行能力的分离意味着，核心挑战是约束感知的计划生成，而非工具调用熟练度。与此一致，干扰工具不会显著进一步伤害性能，这再次确认工具检索不是约束性能的主要因素。因此，推进长程、策略感知的规划，是提升 ENTERPRISEOPS-GYM 上智能体性能的最高杠杆方向。

**思考预算很重要，但存在领域特异的上限。**增加测试时计算会在多数领域显著提升性能，但扩展并非普遍单调：一些领域较早进入平台期，说明额外推理 token 不能弥补领域知识或策略理解的根本缺口。未来工作应研究如何更自适应地分配测试时计算，以及针对高约束领域的定向训练能否提高这些上限。

**未来方向。**我们的结果提出三项具体研究优先级。第一，约束感知的计划生成：在提交动作序列之前，显式推理策略约束、副作用依赖和先决条件结构的方法。第二，长程状态管理：在多次工具调用中维护连贯世界状态的机制，例如情景记忆或结构化状态表示，以避免我们观察到的、随跨度增长而累积的错误。第三，安全拒绝与升级：智能体必须能可靠识别不可行或违反策略的请求并干净地弃权，而这一能力在当前所有受评系统中仍然较弱。

我们将发布 ENTERPRISEOPS-GYM、其沙箱环境和评估工具，以支持开放、社区驱动的研究。沙箱采用模块化、可扩展设计，可随企业实践演变加入新的领域、工具和工作流。通过将智能体评测扎根于真实、约束密集的企业工作流，ENTERPRISEOPS-GYM 旨在促使领域关注那些真正决定 LLM 智能体能否作为可靠 AI 员工部署的规划、安全和策略合规能力。

## 6. 致谢

我们衷心感谢 Turing 担任本项目的数据策划合作伙伴。特别感谢来自 Turing 的 Ankit Jasuja、Aakash Chavan、Harshil Parekh、Anuj Jain、Igor Vidal、Rahul Bora 和 Sudarshan Sivaraman；他们在沙箱工程和样本生成方面作出的关键贡献，使项目全过程维持了最高质量标准。我们也感谢 160 多位数据贡献者和工程师，他们在作者的明确指导和迭代反馈下细致编写基准样本；没有他们的投入，本基准无法达到如今的规模和保真度。本工作还受益于 ServiceNow 语言学团队细致的质量保证监督，尤其感谢 Racheal Hansen、Tiffany Do 和 Nidhi Kumari。我们也感谢 Rabiul Awal 对论文早期草稿提出的有益反馈。最后，衷心感谢 ServiceNow 的 Patrice Bechard 和 Vikas Yadav 在本工作开发过程中提供的宝贵意见。

## 参考文献

- Anthropic. Introducing claude opus 4.5, November 2025a. URL <https://www.anthropic.com/news/claude-opus-4-5>.
- Anthropic. Introducing claude sonnet 4.5, September 2025b. URL <https://www.anthropic.com/news/claude-sonnet-4-5>.

- Anthropic. Introducing claude opus 4.5, 2025c.
- Barres, V., Dong, H., Ray, S., Si, X., and Narasimhan, K.  $\tau^2$ -bench: Evaluating conversational agents in a dual-control environment, 2025. URL <https://arxiv.org/abs/2506.07982>.
- Boisvert, L., Thakkar, M., Gasse, M., Caccia, M., Chezelles, T. L. S. D., Cappart, Q., Chapados, N., Lacoste, A., and Drouin, A. Workarena+: Towards compositional planning and reasoning-based common knowledge work tasks, 2024. URL <https://arxiv.org/abs/2407.05291>.
- Bonatti, R., Zhao, D., Bonacci, F., Dupont, D., Abdali, S., Li, Y., Lu, Y., Wagle, J., Koishida, K., Buckner, A., Jang, L. K., and Hui, Z. Windows agent arena: Evaluating multi-modal OS agents at scale. In *Forty-second International Conference on Machine Learning*, 2025. URL <https://openreview.net/forum?id=W9s817KqYf>.
- Chen, C., Hao, X., Liu, W., Huang, X., Zeng, X., Yu, S., Li, D., Wang, S., Gan, W., Huang, Y., Liu, W., Wang, X., Lian, D., Yin, B., Wang, Y., and Liu, W. Acebench: Who wins the match point in tool usage?, 2025. URL <https://arxiv.org/abs/2501.12851>.
- DeepSeek-AI. Deepseek-v3 technical report, 2024. URL <https://arxiv.org/abs/2412.19437>.
- Drouin, A., Gasse, M., Caccia, M., Laradji, I. H., Verme, M. D., Marty, T., Boisvert, L., Thakkar, M., Cappart, Q., Vazquez, D., Chapados, N., and Lacoste, A. Workarena: How capable are web agents at solving common knowledge work tasks?, 2024.
- Froger, R., Andrews, P., Bettini, M., Budhiraja, A., Cabral, R. S., Do, V., Garreau, E., Gaya, J.-B., Laurençon, H., Lecanu, M., Malkan, K., Mekala, D., Ménard, P., Bertran, G. M.-T., Piterbarg, U., Plekhanov,



- M., Rita, M., Rusakov, A., Vorotilov, V., Wang, M., Yu, I., Benhalloum, A., Mialon, G., and Scialom, T. Are: Scaling up agent environments and evaluations, 2025. URL <https://arxiv.org/abs/2509.17158>.
- Gemini Team. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities, 2025. URL <https://arxiv.org/abs/2507.06261>.
- He, W., Sun, Y., Hao, H., Hao, X., Xia, Z., Gu, Q., Han, C., Zhao, D., Su, H., Zhang, K., Gao, M., Su, X., Cai, X., Cai, X., Yang, Y., and Zhao, Y. Vitabench: Benchmarking llm agents with versatile interactive tasks in real-world applications, 2025. URL <https://arxiv.org/abs/2509.26490>.
- Huang, K.-H., Prabhakar, A., Dhawan, S., Mao, Y., Wang, H., Savarese, S., Xiong, C., Laban, P., and Wu, C.-S. Crmarena: Understanding the capacity of llm agents to perform professional crm tasks in realistic environments. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2025a.
- Huang, K.-H., Prabhakar, A., Thorat, O., Agarwal, D., Choubey, P. K., Mao, Y., Savarese, S., Xiong, C., and Wu, C.-S. Crmarena-pro: Holistic assessment of llm agents across diverse business scenarios and interactions. *arXiv preprint arXiv:2505.18878*, 2025b.
- Jha, S., Arora, R., Watanabe, Y., Yanagawa, T., Chen, Y., Clark, J., Bhavya, B., Verma, M., Kumar, H., Kitahara, H., Zheutlin, N., Takano, S., Pathak, D., George, F., Wu, X., Turkkan, B. O., Vanloo, G., Nidd, M., Dai, T., Chatterjee, O., Gupta, P., Samanta, S., Aggarwal, P., Lee, R., Murali, P., wook Ahn, J., Kar, D., Rahane, A., Fonseca, C., Paradkar, A., Deng, Y., Moogi, P., Mohapatra, P., Abe, N., Narayanaswami, C., Xu, T., Varshney, L. R., Mahindru, R., Sailer, A., Shwartz, L., Sow, D., Fuller, N. C. M., and Puri, R. Itbench: Evaluating ai agents across diverse real-world it automation tasks, 2025. URL <https://arxiv.org/abs/2502.05352>.
- Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., and Narasimhan, K. R. SWE-bench: Can language models resolve real-world github issues? In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=VTF8yNQm66>.
- K-Team. Kimi k2: Open agentic intelligence, 2025. URL <https://arxiv.org/abs/2507.20534>.
- Li, M., Zhao, Y., Yu, B., Song, F., Li, H., Yu, H., Li, Z., Huang, F., and Li, Y. API-bank: A comprehensive benchmark for tool-augmented LLMs. In Bouamor, H., Pino, J., and Bali, K. (eds.), *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 3102–3116, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.187. URL <https://aclanthology.org/2023.emnlp-main.187/>.
- Nayak, S., Jian, X., Lin, K. Q., Rodriguez, J. A., Kalsi, M., Awal, R., Chapados, N., Özsu, M. T., Agrawal, A., Vazquez, D., Pal, C., Taslakian, P., Gella, S., and Rajeswar, S. Ui-vision: A desktop-centric gui benchmark for visual perception and interaction, 2025. URL <https://arxiv.org/abs/2503.15661>.
- OpenAI. Introducing gpt-5, August 2025. URL <https://openai.com/index/introducing-gpt-5/>.
- OpenAI, :, Agarwal, S., Ahmad, L., Ai, J., Altman, S., Applebaum, A., Arbus, E., Arora, R. K., Bai, Y., Baker, B., Bao, H., Barak, B., Bennett, A., Bertao, T., Brett, N., Brevdo, E., Brockman, G., Bubeck, S.,

- Chang, C., Chen, K., Chen, M., Cheung, E., Clark, A., Cook, D., Dukhan, M., Dvorak, C., Fives, K., Fomenko, V., Garipov, T., Georgiev, K., Glaese, M., Gogineni, T., Goucher, A., Gross, L., Guzman, K. G., Hallman, J., Hehir, J., Heidecke, J., Helyar, A., Hu, H., Huet, R., Huh, J., Jain, S., Johnson, Z., Koch, C., Kofman, I., Kundel, D., Kwon, J., Kyrylov, V., Le, E. Y., Leclerc, G., Lennon, J. P., Lessans, S., Lezcano-Casado, M., Li, Y., Li, Z., Lin, J., Liss, J., Lily, Liu, J., Lu, K., Lu, C., Martinovic, Z., McCallum, L., McGrath, J., McKinney, S., McLaughlin, A., Mei, S., Mostovoy, S., Mu, T., Myles, G., Neitz, A., Nichol, A., Pachocki, J., Paino, A., Palmie, D., Pantuliano, A., Parascandolo, G., Park, J., Pathak, L., Paz, C., Peran, L., Pimenov, D., Pokrass, M., Proehl, E., Qiu, H., Raila, G., Raso, F., Ren, H., Richardson, K., Robinson, D., Rotsted, B., Salman, H., Sanjeev, S., Schwarzer, M., Sculley, D., Sikchi, H., Simon, K., Singhal, K., Song, Y., Stuckey, D., Sun, Z., Tillet, P., Toizer, S., Tsimpourlas, F., Vyas, N., Wallace, E., Wang, X., Wang, M., Watkins, O., Weil, K., Wendling, A., Whinnery, K., Whitney, C., Wong, H., Yang, L., Yang, Y., Yasunaga, M., Ying, K., Zaremba, W., Zhan, W., Zhang, C., Zhang, B., Zhang, E., and Zhao, S. gpt-oss-120b & gpt-oss-20b model card, 2025. URL <https://arxiv.org/abs/2508.10925>.
- Qian, C., Liu, Z., Prabhakar, A., Liu, Z., Zhang, J., Chen, H., Ji, H., Yao, W., Heinecke, S., Savarese, S., Xiong, C., and Wang, H. Userbench: An interactive gym environment for user-centric agents, 2025. URL <https://arxiv.org/abs/2507.22034>.
- Qin, Y., Liang, S., Ye, Y., Zhu, K., Yan, L., Lu, Y., Lin, Y., Cong, X., Tang, X., Qian, B., Zhao, S., Hong, L., Tian, R., Xie, R., Zhou, J., Gerstein, M., dahai li, Liu, Z., and Sun, M. ToolLLM: Facilitating large language models to master 16000+ real-world APIs. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=dHng200Jjr>.
- Styles, O., Miller, S., Cerda-Mardini, P., Guha, T., Sanchez, V., and Vidgen, B. Workbench: a benchmark dataset for agents in a realistic workplace setting, 2024. URL <https://arxiv.org/abs/2405.00823>.
- Vishwakarma, H., Agarwal, A., Patil, O., Devaguptapu, C., and Chandran, M. Can llms help you at work? a sandbox for evaluating llm agents in enterprise environments, 2025. URL <https://arxiv.org/abs/2510.27287>.
- Xie, T. et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments. *arXiv preprint arXiv:2404.07972*, 2024.
- Xu, F. F., Song, Y., Li, B., Tang, Y., Jain, K., Bao, M., Wang, Z. Z., Zhou, X., Guo, Z., Cao, M., Yang, M., Lu, H. Y., Martin, A., Su, Z., Maben, L., Mehta, R., Chi, W., Jang, L., Xie, Y., Zhou, S., and Neubig, G. Theagentcompany: Benchmarking llm agents on consequential real world tasks, 2024. URL <https://arxiv.org/abs/2412.14161>.
- Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., Zheng, C., Liu, D., Zhou, F., Huang, F., Hu, F., Ge, H., Wei, H., Lin, H., Tang, J., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Zhou, J., Lin, J., Dang, K., Bao, K., Yang, K., Yu, L., Deng, L., Li, M., Xue, M., Li, M., Zhang, P., Wang, P., Zhu, Q., Men, R., Gao, R., Liu, S., Luo, S., Li, T., Tang, T., Yin, W., Ren, X., Wang, X., Zhang, X., Ren, X., Fan, Y., Su, Y., Zhang, Y., Zhang, Y., Wan, Y., Liu, Y., Wang, Z., Cui, Z., Zhang, Z., Zhou, Z., and Qiu, Z. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. React: Synergizing rea-

soning and acting in language models. *arXiv preprint arXiv:2210.03629*, 2022.

Yao, S., Shinn, N., Razavi, P., and Narasimhan, K.  $\tau$ -bench: A benchmark for tool-agent-user interaction in real-world domains, 2024. URL <https://arxiv.org/abs/2406.12045>.

Zhou, S., Xu, F. F., Zhu, H., Zhou, X., Lo, R., Sridhar, A., Cheng, X., Ou, T., Bisk, Y., Fried, D., Alon, U., and Neubig, G. Webarena: A realistic web environment for building autonomous agents, 2024. URL <https://arxiv.org/abs/2307.13854>.