

PhyPrompt: 基于强化学习的提示词精炼, 用于物理合理的文本到视频生成

Shang Wu¹ Chenwei Xu¹ Zhuofan Xia¹ Weijian Li¹
Lie Lu² Pranav Maneriker² Fan Du² Manling Li¹ Han Liu¹

¹ Northwestern University ² Dolby Laboratories

摘要

尽管视觉质量已经很高, 当前最先进的文本到视频 (T2V) 生成器仍然经常违反物理定律。我们指出, 这一问题主要来自提示词中的物理约束不足, 而不是模型能力本身: 手工加入物理细节可以稳定地产生物理合理的视频, 但这种做法需要专业知识, 且难以规模化。我们提出 *PhyPrompt*, 这是一个两阶段强化学习框架, 用于自动精炼提示词以诱导物理真实的视频生成。首先, 我们在以物理为中心的思维链数据集上微调大语言模型, 使其在保留用户意图的同时纳入物体运动、力的相互作用等原则。其次, 我们采用组相对策略优化, 并设计动态奖励课程: 训练初期优先强调语义保真度, 随后逐步转向物理常识。该课程带来协同优化: *PhyPrompt-7B* 在 *VideoPhy2* 上达到 40.8% 的联合成功率 (提升 8.6 个百分点), 将物理常识从 55.8% 提升到 66.8%, 同时将语义遵循度从 43.4% 提升到 47.8%。值得注意的是, 该课程在两个指标上都超过单目标训练, 说明它能够发现超越传统多目标权衡的组合式提示结构。仅使用 7B 参数, *PhyPrompt* 就优于 *GPT-4o* (联合指标 +3.8%) 和 *DeepSeek-V3* (联合指标 +2.2%, 后者规模约为 100 $\times$)。该方法还能在多种 T2V 架构 (*Lavie*、*VideoCrafter2*、*CogVideoX-5B*) 之间零样本迁移, 最高带来 16.8% 的改进, 表明带有组合课程的领域专用强化学习可以在物理感知生成上超过通用规模扩展。

1. 引言

文本到视频 (T2V) 生成发展迅速, 大规模模型已经可以根据简短文本提示生成视觉效果出色的视频片

段 [8, 43, 52, 56]。然而, 一个关键问题仍未解决: 即使视觉质量很高, 当前最先进的 T2V 系统也经常违反基本物理常识。物体可能瞬移、忽略重力, 或彼此穿透, 从而违背现实世界的物理规律。近期评测 [3, 4, 29] 报告了显著的物理不一致, 说明顶尖公开模型仍难以处理需要质量与动量守恒的场景。视觉真实感与物理合理性之间的差距, 严重限制了这些模型在机器人、仿真等要求忠实呈现现实动态的领域中的部署。

根本原因之一是 T2V 模型的训练方式和使用方式不匹配。在训练过程中, 模型会使用详细、精心制作的描述文本和视频。然而, 真实的提示在推理时通常很短或不明确, 从而产生次优的输出 [11, 50]。例如, 用户可能输入“将酒从瓶子中倒入玻璃杯中”, 得到的视频中酒从瓶口流出, 但玻璃杯中的液面几乎没有变化 (图 1 顶行)。该提示虽然具有较高的语义遵循度 (语义得分: 5), 但物理常识较差 (物理得分: 3)。关键在于, 手动重写提示词并加入明确的物理细节, 例如“杯中的液面稳步上升”, 即可生成液体可见累积的物理合理视频 (图 1 第二行), 并获得满分 (语义得分: 5, 物理得分: 5)。这表明当前 T2V 生成器在给定物理感知提示词时具备合成物理真实内容的能力; 瓶颈在提示词本身。然而, 手工提示词工程需要领域专业知识, 耗时且难以扩展到多样场景。

现有的自动化方法部分解决了这一差距, 但面临着关键的限制。Promptist [15] 通过监督微调和基于美学奖励的强化学习 (RL), 自动增强用户给文本到图像模型的输入, 但并不面向物理合理性。早期文本到视频工作使用 GPT-4o 等大语言模型 (LLM) 通过上下文学习增强提示词; 这些方法虽然能提升物理遵循度 (例如 GPT-4o 在 Fig. 1 中达到 PC:5), 但可能降低语义保真度 (SA:4), 且缺少面向视频级物理常识的系统优

化。VPO [11] 使用基于偏好的 RL 改进提示，以确保它们无害且准确，但与 Promptist 一样，没有明确解决物理合理性。最近，PhyT2V 引入了 LLM 引导的迭代式自我完善循环，可在 T2V 提示中实现思维链和“后退”推理，提高对现实世界物理的遵循度，并在分布外场景中超越先前的提示增强器 [50]。虽然 PhyT2V 展示了迭代 LLM 反馈的价值，但它需要多轮提示和复杂的后退机制，限制了其效率。

为了解决这些限制，我们引入 **PhyPrompt**，一种利用强化学习训练大语言模型 (LLM) 的新框架，用于自动将用户提示词转换为能够诱导物理真实视频输出的描述，从而在不依赖人工专业知识的情况下达到手工物理感知提示词工程的质量。我们的方法的特点是两阶段训练流程。首先，LLM 在我们策划的基于 PhyGenBench 的高质量思维链 (CoT) 数据集上进行监督微调 (SFT) [29]。该数据集专门设计用于使 LLM 能够推理物理现象并将这些考虑因素转化为适合视频生成的描述性文本。第二阶段，使用组相对策略优化 (GRPO) 进一步细化经过 SFT 训练的 LLM 的提示词生成策略 [14]，一种 RL 算法，通过对每个查询的多个候选进行采样来有效地探索提示空间，而不需要单独的价值网络。

PhyPrompt 的一个关键创新是受课程培训启发的动态奖励机制 [6]。GRPO 训练由复合奖励信号引导，该信号自适应地平衡生成视频的物理常识及其与用户意图的语义一致性。在我们的设计中，奖励在训练早期优先考虑语义对齐，随着 LLM 策略逐渐成熟，再逐步将重点转向物理常识。这种课程式方法确保 LLM 先学会保留用户意图，再专注于增强物理真实性这一更细致的任务。我们的架构使视频生成器保持冻结状态，仅训练一个轻量级的、与模型无关的重写器，将用户提示转换为物理感知的描述。这避免了昂贵的生成器微调，并允许一个重写器为多个后端提供服务。

我们在四个尖端生成器上验证了我们的方法：Lavie [46]、VideoCrafter2 [8]、CogVideoX-2B 和 CogVideoX-5B [44]。对于每个，我们在用户和生成器之间插入经过训练的 LLM。对 VideoPhy2 数据集的测试数据集进行的实验表明，重写的提示可以减少物理违规，同时保持视觉质量和语义保真度。如图 1 所示，PhyPrompt 自动生成的提示词可以达到与手工物理感知提示词相同的物理合理性 (PC:5) 和语义遵循

度 (SA:5)，从而免除了提示词设计中的人工专业知识需求。这项工作的主要贡献如下：

- 我们证明当前的 T2V 生成器在提供物理感知提示时可以生成物理合理的视频，并提出 PhyPrompt，一种新颖的两阶段训练的 LLM 系统。
- 我们引入了一种动态的、与时间相关的奖励机制，用于基于强化学习的提示优化，逐步将焦点从语义对齐转移到物理常识，从而促进平衡和有效的学习课程。
- 实证验证显示跨多个 T2V 模型的零样本迁移，联合语义遵循度和物理常识增益高达 16.8%，达到与手工物理感知提示工程相当的质量。

2. 相关工作

LLM 推理的强化学习。 RL 现在补充了监督微调 (SFT)，以增强 LLM 推理。PPO 的不稳定性和成本激发了诸如组相对策略优化 (GRPO) 等替代方案 [25, 39] 和直接偏好优化 (DPO) [13]。典型的流程从具有思维链痕迹的 SFT 检查点开始，并应用 GRPO (或导数) 来提高事实一致性和演绎深度 [54, 55]，通常结合来自人类反馈 (RLHF) 的强化学习 [34] 或人工智能反馈强化学习 (RLAIF) [36]。多目标设置引入了特定于标签的奖励或在训练过程中调整权重的课程 [9, 40]，最近的工作探索了分层奖励分解来扩展推理深度 [32]。PhyPrompt 遵循这个两阶段的秘诀：在以物理为中心的 CoT 语料库上进行 SFT，然后是具有课程奖励的 GRPO，逐渐将重点从语义对齐转移到对视频生成至关重要的物理常识提示。

视频生成中的物理常识基准。 为了判断物理真实性，专门构建的数据集取代了像素级指标。VideoPhy2 提供语义遵循度 (SA) 和物理常识 (PC) 的人工加自动评分 [5]，而 PhyGenBench 将覆盖范围扩大到 27 个物理定律的 160 个提示 [38]。PhyCoBench 通过光流信号跟踪七个主要类别的相干性 [10]，而 IPV-Bench 则强调故意不可能的场景的模型 [47]。其他最近的基准测试包括用于动态物体交互的 VisualPhysicist [41] 和 SpeedNet 以保证运动的时间一致性 [21]。这些资源构成了物理感知视频合成的第一个定量标准。

快速重写图像和视频生成。 Promptist 使用基于 RL 的自适应来完善文本到图像的提示 [15]，而 Diffusion-Prompt 采用了基于梯度的风格重写 [22]。在文字转

Original: A wine is poured from a bottle in to a glass.
(SA:5, PC:3)



Manual Rewrite: A wine is poured from a bottle in to a glass. The level in the glass **risers steadily**.
(SA:5, PC:5)



GPT: A wine is poured from a bottle in to a glass, resulting in a visible **stream of wine** entering the glass.
(SA:4, PC:5)



PhyPrompt: A wine bottle, filled with rich red blend, pours **slowly and smoothly** into a clear glass.
(SA:5, PC:5)



图 1. CogVideoX-5B 使用不同提示词生成的视频。我们比较原始提示词 将酒从瓶子中倒入玻璃杯中及其三个增强版本：手动重写、GPT-4o 和 PhyPrompt。图中给出了每个结果的语义遵循度 (SA) 和物理常识 (PC) 分数。原始提示词未能表现液面上升 (PC:3)。手动加入“稳步上升”得到满分 (SA:5, PC:5)。GPT-4o 强调“可见的酒流”，但略微降低语义对齐 (SA:4, PC:5)。PhyPrompt 自动生成“缓慢而平滑”等物理细节，无需人工干预即可达到手动重写质量 (SA:5, PC:5)。

视频方面，VPO 结合了 SFT 和 DPO，多级反馈 [11]，Prompt-A-Video 应用了奖励驱动的描述文本进化 [19]，MotionPrompt 增加了光流时间引导 [33]、MotionCraft 和 ReVision 在生成时注入物理线索 [2, 45]，以及更新的方法，VideoPromptTuning [49]，Prompt2Video [12]，和 PhyT2V [50]，使用轻量级适配器或迭代 CoT 推理来增强物理依从性。

PhyPrompt 的不同之处在于，它在以物理为中心的 CoT 语料库上进行预训练，并最大化在生成的视频上计算的自动 PC 奖励，从而为物理感知 T2V 模型生成轻量级、与生成器无关的前端。此外，PhyPrompt 是第一个提示重写器，可以在基于视频的物理常识奖励上使用 RL 进行端到端训练，并在多个异构 T2V 生成器之间迁移零样本，而无需重新调整。这些品质使 PhyPrompt 成为用户意图和物理一致的视频生成之间的实用桥梁。

3. 方法

本节介绍 (i) 我们用于监督微调的以物理为中心的思维链 (CoT) 数据集，(ii) 基于 GRPO 的提示优化，以及 (iii) 我们的动态奖励课程，它解决了语义保真度和物理真实性之间的内在冲突。

3.1. 以物理为中心的思维链数据集

我们构建 CoT 数据集来教会语言模型进行物理感知的提示词增强。我们从 PhyGenBench 的 160 个示例出发 [38]；每个示例包含原始提示词 x 、物理定律 L ，以及 GPT-4o [1] 生成的增强提示词 y_{GPT} 。由于这些示例缺少显式推理过程，我们使用 GPT-4o1-preview [17] 生成逐步推理链，解释如何基于 L 将 x 转换为 y_{GPT} 。

最终数据集包含三元组 $(x, \mathbf{r}, y_{\text{CoT}})$ ，其中 $\mathbf{r}$ 为推理链， y_{CoT} 为物理感知提示词。这使我们能够在保留用户意图的同时对 Qwen2.5 进行监督微调。




图 2. **PhyPrompt** 的 **GRPO** 流程。对每个输入提示词，LLM (Qwen2.5 [51]) 生成多个增强提示词；随后 T2V 生成器 (CogVideoX-2B [52]) 为每个增强提示词生成一个视频。视频评估器 (VideoPhy2-Auto [5]) 为每个视频打分，我们据此使用 GRPO 优化 LLM。

3.2. 两阶段训练流程

监督微调。我们初始化 π_θ 通过最小化交叉熵损失：

$$\mathcal{L}_{\text{SFT}} = -\mathbb{E}_{(x, y_{\text{CoT}})} [\log \pi_\theta(y_{\text{CoT}} | x)]. \quad (1)$$

通过 GRPO 进行强化学习。图 2 展示了我们的流程。用户提示词 x 由策略 π_θ 重写为增强提示词 y ，再输入固定的 T2V 生成器 G (CogVideoX-2B [52])。生成视频 $v = G(y)$ 由 VideoPhy2-AutoEval [5] 打分，该奖励信号驱动 RL 细化 π_θ ，而不改变 G 。对于批量大小为 B 的每个提示词 $x^{(j)}$ ，我们从旧策略 $\pi_{\theta_{\text{old}}}$ 采样 $G = 4$ 个候选重写。每个候选生成视频 $v_i^{(j)} = G(y_i^{(j)})$ 并得到分数 $r_i^{(j)}$ 。定义组均值 $\bar{r}^{(j)} = \frac{1}{G} \sum_{i=1}^G r_i^{(j)}$ 和优势值：

$$A_i^{(j)} = r_i^{(j)} - \bar{r}^{(j)}. \quad (2)$$

我们更新 π_θ 通过剪裁 GRPO 损失与重要性比 $w_i^{(j)} = \pi_\theta(y_i^{(j)} | x^{(j)}) / \pi_{\theta_{\text{old}}}(y_i^{(j)} | x^{(j)})$ ：

$$\mathcal{L}_{\text{GRPO}} = -\frac{1}{BG} \sum_{j=1}^B \sum_{i=1}^G \min(w_i^{(j)} A_i^{(j)}, \text{clip}(w_i^{(j)}, 1 - \epsilon, 1 + \epsilon) A_i^{(j)}) + \beta D_{\text{KL}}[\pi_{\theta_{\text{old}}} \| \pi_\theta], \quad (3)$$

其中 $\epsilon = 0.2$ 和 β 将 KL 散度权重分配给 SFT 初始化。

3.3. 动态多目标奖励设计

语义遵循度 (SA) 和物理常识 (PC) 本质上是冲突的：单目标优化表现出严重的负迁移，优化 SA 会降低 PC 的性能，反之亦然 (第 4.3.1)。静态加权组合不能

共同最大化两个目标。我们提出了一种动态奖励课程，可以实现协同优化，超出任一单一目标方法的上界。

奖励成分。VideoPhy2-自动评估 [5] 提供 1-5 Likert 量表的两个分数：**语义遵循度** (r_{sa}) 测量视频提示对齐，以及 **物理常识** (r_{pc}) 测量物理合理性。

动态课程。复合奖励使用与时间相关的权重：

$$R(t) = w_{\text{sa}}(t) \cdot r_{\text{sa}} + w_{\text{pc}}(t) \cdot r_{\text{pc}}, \quad (4)$$

指数衰减：

$$w_{\text{sa}}(t) = \exp(-\alpha t/T), \quad w_{\text{pc}}(t) = 1 - w_{\text{sa}}(t), \quad (5)$$

其中 t 为训练步数， T 为总步数， α 控制衰减速率。

组合学习机制。早期训练 ($w_{\text{sa}} \approx 1$) 建立语义支架：物体身份、关系和场景结构。后期训练 ($w_{\text{pc}} \approx 1$) 用物理特性完善了这个支架：力、动力学和因果相互作用。这种分阶段方法发现了单目标优化无法达到的提示结构 [6]。

语义基础提供组合支架 [37]，物理约束则起到隐式正则化作用 [26]。仅优化 SA 缺少来自物理目标的细化压力；仅优化 PC 则缺少组织物理细节所需的语义一致性。我们的课程顺序利用二者，实现同时超过两个单目标上界的超加性表现 (见第 4.3.1)。这表明该方法发现了超越静态帕累托前沿的新组合提示结构，也与近期多阶段 RL 范式一致 [14]：渐进式任务分解可以释放直接优化难以获得的能力。

4. 实验

本节详细介绍了用于评估 PhyPrompt 在物理驱动视频生成任务上的有效性的实验方法。我们的评估侧重于三个主要方面：(1) 生成的视频的物理合理性和语义保真度，(2) 学习的 PhyPrompt 重写器在不同文本到视频 (T2V) 生成器之间的可迁移性，以及 (3) 消融研究，调查我们提出的方法中关键组件的贡献。

文本到视频生成器。 PhyPrompt 的性能使用多种当前最先进的 T2V 扩散模型进行评估，参数数量范围从 8.6 亿到 50 亿：

- **Lavie [46]**: 一个 860M 参数模型，利用级联潜在扩散，在 Vimeo25M 数据集上进行训练。它能够生成长度长达 8 秒、分辨率为 1280×720 像素的视频。
- **VideoCrafter2 [8]**: 此 1.2B 参数模型采用基于扩散的架构。它使用低质量视频和高质量图像的组合作为训练数据，以提高运动一致性和视觉保真度，以 512×512 分辨率生成持续时间长达 8 秒的视频。
- **CogVideoX-2B [52]**: 2B 参数模型，具有 3D 变分自动编码器和具有自适应 LayerNorm 的专家 Transformer。它可以生成长达 6 秒、分辨率为 720×480 的视频。
- **CogVideoX-5B [52]**: 这个 5B 参数模型共享 CogVideoX-2B 的架构，但受益于更大规模的训练数据。它可生成长达 6 秒、分辨率为 720×480 的视频。

为了确保所有模型的评估一致，生成的视频被标准化为时长 6 秒、帧速率为 4 FPS、分辨率为 720×480 像素。补充材料中提供了 T2V 生成设置的详细配置。

提示增强器。 PhyPrompt 变体是通过使用 1.5B、3B 和 7B 参数微调 Qwen2.5-Instruct 检查点获得的。为了进行比较，我们包括四个自动提示细化基线：Promptist [15]，PhyT2V [50]，GPT-4o [1]、和 DeepSeek-V3 [27]。

数据集。 我们的方法在 VideoPhy2 基准上进行评估 [5]。该基准包含专门设计用于评估视频生成中的物理常识的各种提示集合，包括与重力、碰撞、流体动力学和其他基本物理现象相关的场景。

评估指标。 按照 [5] 的设置，生成视频从两个标准进行评估：语义遵循度 (SA) 和物理常识 (PC)。每个标准均采用 5 点李克特量表，范围从“非常不可能” (1) 到

“非常可能” (5)。我们从测试集中随机抽取 500 个提示词，并报告生成视频满足以下条件的百分比：

- **语义遵循度 ($SA \geq 4$)**: 准确描述提示中描述的预期内容的视频的百分比。
- **物理常识 ($PC \geq 4$)**: 真实遵循基本物理原理的视频百分比。
- **联合表现 ($SA \geq 4$ 、 $PC \geq 4$)**: 同时获得高分的视频百分比 (即 ≥ 4) 语义遵循度和物理真实性。

4.1. 生成视频的质量评估

我们衡量每种提示词重写策略在搭配 CogVideoX-2B [52] 时，对 **语义遵循度 (SA)** 和 **物理常识 (PC)** 的改善。表 1 报告了 VIDEOPHY2 基准 [5] 中 500 个提示词上的结果。

PhyPrompt 的有效性。 Promptist [15] 将 PC 从 55.8% 提高到 58.2%，但 SA 从 43.4% 降至 41.2%，使联合得分从 32.2% 降至 30.2%。这说明通用文本到图像适配器无法在视频领域可靠地平衡语义与物理。PhyT2V [50] 达到 45.0% SA 和 62.0% PC (36.2% 联合)，展示了迭代 LLM 反馈的价值，但需要多轮提示和复杂的后退机制。相比之下，三个 PhyPrompt 检查点在所有指标上都优于原始提示词和现有基线。7B 模型收益最大，达到 47.8% SA、66.8% PC 和 40.8% 联合成功率，相比基线绝对提升 8.6 个百分点，相比 Promptist 提升 10.6 个百分点。值得注意的是，即使 1.5B 版本也达到 37.4% 联合得分，比 Promptist 高 7.2 个百分点，同时仅使用 GPT-4o 约 1/10 的参数量。所有模型规模上的一致改进验证了两阶段训练方法的有效性：以物理为中心的 SFT 与基于动态奖励的 RL 相结合。

相对于通用大型语言模型的优势。 PhyPrompt 表明，在物理感知视频生成上，领域专用训练比单纯扩大参数规模更有效。与 GPT-4o [1] 相比，PhyPrompt-7B 达到几乎相同的 SA (47.8% vs. 47.0%)，同时带来更高的 PC (66.8% vs. 60.0%) 和联合表现 (40.8% vs. 37.0%)。这 6.8 个百分点的 PC 优势来自三个因素：(i) 针对视频质量指标而非文本似然进行端到端 RL 优化 [35]，(ii) 以物理为中心的 CoT 预训练编码了领域特定推理 [18]，(iii) 动态奖励课程平衡了双目标 [6]。DeepSeek-V3 [27] 虽然参数多约 100 倍 (671B)，但在 PC (64.6% vs. 66.8%) 和联合表现 (38.6% vs. 40.8%)

表 1. **CogVideoX-2B 的 VideoPhy2 质量结果**。对于每个提示重写策略，我们报告视频评分的百分比 ≥ 4 对于语义遵循度 (SA) 和物理常识 (PC)，它们的联合百分比 (SA & PC)，以及平均 SA/PC 分数 (平均 SA、平均 PC)。

Enhanced Model	SA (%) $\uparrow$	PC (%) $\uparrow$	SA & PC (%) $\uparrow$	Avg SA $\uparrow$	Avg PC $\uparrow$
N/A (Original Prompt)	43.4	55.8	32.2	3.842	4.410
Promptist [15]	41.2	58.2	30.2	3.782	4.452
PhyT2V [50]	45.0	62.0	36.2	3.854	4.522
Qwen2.5-1.5B	37.6	64.0	31.8	3.616	4.562
PhyPrompt-1.5B	42.8	65.4	37.4	3.800	4.580
Qwen2.5-3B	40.0	64.2	32.0	3.754	4.582
PhyPrompt-3B	46.4	64.8	39.6	3.868	4.556
Qwen2.5-7B	44.8	64.6	34.2	3.848	4.586
PhyPrompt-7B	47.8	66.8	40.8	3.878	4.590
GPT-4o	47.0	60.0	37.0	3.932	4.488
DeepSeek-V3	48.4	64.6	38.6	3.968	4.564

上仍落后于 PhyPrompt-7B，说明通用预训练不能替代任务特定反馈 [16]。PhyPrompt-3B 用不到 GPT-4o 1% 的参数量即可达到相近水平，也呼应了近期发现：专用小模型可以在聚焦任务上超过通用大模型 [30]。总体而言，我们的结果支持一种新兴观点：带有直接任务反馈的领域目标训练，比单独扩展模型规模更具参数效率 [20, 48]。

4.2. 跨生成器的零样本迁移

为了验证 PhyPrompt 与生成器无关的迁移，我们在三种架构不同的扩散模型上评估 PhyPrompt-7B（仅在 CogVideoX-2B 上训练）：Lavie (860M)、VideoCrafter2 (1.2B) 和 CogVideoX-5B (5B)。我们为每个生成器的每种方法生成 500 个视频并报告联合 SA&PC 得分 Fig. 3。完整的结果出现在补充中。

联合度量改进。原始提示达到基线联合分数 29.2% (Lavie), 29.8% (VideoCrafter2) 和 39.4% (CogVideoX-5B)。Promptist 将性能降低至 27.0%, 27.2%, 37.4%，分别。PhyPrompt 大大超过了每个生成器的基线：Lavie 达到 31.6% (+8.2% VideoCrafter2 达到 34.8% (+16.8% 超过原始值)，CogVideoX-5B 达到 42.0% (+6.6% 超过原来)。较小的 PhyPrompt 变体 (1.5B 和 3B) 表现出相同的改进模式，3B 模型达到 30.2%, 30.8%、40.2% 分别确认我们的训练方法可以有效地跨

模型大小进行扩展。

与其他重写器的比较。PhyT2V 比 Promptist 有所改进，但在所有生成器上的表现均低于 PhyPrompt，达到 30.0%, 30.6%、40.8% 分别在 Lavie、VideoCrafter2 和 CogVideoX-5B 上。GPT-4o、DeepSeek-V3 和大小匹配的 Qwen 基线在联合指标上同样落后于 PhyPrompt。在 VideoCrafter2 上，最佳替代方案 (DeepSeek-V3, 32.8%) 仍为 2.0% 低于 PhyPrompt-7B；Lavie 和 CogVideoX-5B 也有类似的利润。

零样本迁移。所有 PhyPrompt 变体均仅在 CogVideoX-2B 输出上进行微调，但无需任何后端调整即可在 Lavie 和 VideoCrafter2 上产生显著增益。这证实了真正的零样本迁移，其中物理感知重写捕获与模型无关的物理先验，而不是利用生成器特定的偏差。语言模型参数高效提示调优的相关工作也同样证明了跨模型泛化能力 [23, 24]，并且基于强化学习的提示适配器已被证明可以跨模态迁移 [15]。通过消除任何特定扩散架构的物理约束，PhyPrompt 消除了对每个生成器进行微调的需要，减少了计算开销并实现了跨不同 T2V 管道的快速部署。

4.3. 消融研究

为了理清 PhyPrompt 增益的来源，我们进行了两次互补的消融。首先，我们研究 GRPO 微调期间奖励




图 3. **PhyPrompt 的跨生成器迁移**。图中比较了不同提示词增强方法在三种文本到视频生成模型（Lavie、CogVideoX-5B 和 VideoCrafter2）上的联合物理常识与语义遵循度（PC & SA）指标。本文方法在三个视频生成后端上均稳定优于基线方法（Original、Promptist、PhyT2V）和同规模 Qwen2.5 模型。最高性能（42.0%）由 7B 模型在 CogVideoX-5B 上取得。金色星号表示每个生成器上的最佳方法。




图 4. 动态（橙色）和静态（紫色）奖励公式下的训练奖励曲线。每条线均采用 10 步移动平均线进行平滑处理；浅色阴影痕迹显示未平滑的每集奖励。与静态基线（3.5）相比，动态课程收敛速度更快，稳定程度更高（4.2），表明优化更有效。

计划的选择如何影响性能。其次，我们测试两阶段流程（SFT 和 RL）的必要性。结果表明，课程奖励和两阶段程序都贡献了相当大的、互补的改进。

4.3.1. 奖励设计

为了证明语义遵循度（SA）和物理常识（PC）本质上是相互冲突的目标，我们进行了系统的消融，比较了四种奖励策略：(i) 仅 SA 优化 ($w_{sa} = 1.0, w_{pc} = 0.0$)，(ii) 仅限 PC 优化 ($w_{sa} = 0.0, w_{pc} = 1.0$)，(iii) 静态平衡权重 ($w_{sa} = w_{pc} = 0.5$)，以及 (iv) 我们的动态课程（方程式 4）。我们使用 Qwen2.5-7B-Instruct 作为基础模型，使用 CogVideoX-2B 作为视频生成器。结果显示在 Fig. 4 还有 Tab. 2.

目标之间的负迁移。 Tab. 2 揭示了严重的负迁移。仅

SA 训练将语义遵循度提高到 45.6% (+2.2% 超过基线)，但物理常识下降至 52.8% (-3.0%)，产生更差的联合表现（31.6% 对比 32.2% 基线）。相反，仅使用 PC 的培训达到 65.2% 物理成绩 (+9.4%) 但将语义遵循度降低到 39.4% (-4.0%)，只有边际联合改进（33.4%）。这种对立关系表明 SA 和 PC 无法通过朴素的单目标优化来共同最大化。静态平衡加权达到 35.4% 联合成功率，优于任一极端，但仍为 5.4% 下面是我们的动态课程。

动态课程超出了单一目标的上界。 我们的动态课程达到 SA = 47.8% 且 PC = 66.8%。值得注意的是，这在语义遵循度方面优于仅 SA 训练（47.8% 对比 45.6%），同时在物理常识方面优于仅使用 PC 的训练（66.8% 对比 65.2%）。换句话说，我们的方法在其目标上击败了每位专家。这表明将两个目标与课程一起优化比单独优化其中一个目标会产生更好的结果 [7, 42, 53]。

我们假设语义描述建立了物体身份和关系（例如“球”和“倾斜”），而物理约束通过动力学来完善这些身份和关系（例如“加速”和“在重力作用下”）。高质量的物理描述需要精准的语义基础 [37]：如果不首先确定存在什么物体，就无法指定现实的力。仅 SA 优化发现具有良好语义结构的提示，但缺乏物理约束的细化压力。仅适用于 PC 的优化会生成物理上详细的提示，但缺乏语义连贯性来有效组织这些细节。我们的课程利用了这两个信号：SA 建立组合支架，然后 PC 通过物理特异性细化这个结构，起到隐式正则化的作用 [26]。

Static Reward: Show a heavy hammer striking a wooden plank with precision, ensuring that the impact creates a realistic sound effect and deformation of the wood surface.

Dynamic Reward: Heavy hammer hits the **nail** into the wood plank. The hammer's force is concentrated, causing high pressure that drives the **nail** deep into the plank.




图 5. “锤子和钉子”场景下 CogVideoX-2B 输出的逐帧比较。上排显示静态奖励提示词的结果“展示重锤精确敲击木板，确保撞击产生逼真的声音效果和木材表面的变形。”锤子撞击木板，但画面中看不到钉子，也没有钉子被钉入。下排显示动态奖励提示词的结果“用重锤将钉子敲入木板上。锤子的力量集中，产生高压，将钉子深深地钉入木板。”此处，钉子出现在第 1 帧中，穿过第 2-3 帧逐渐压入木材中，并在第 4 帧中实现完全穿透，具有真实的木材变形和进入深度。

表 2. VIDEOPHY2 上的奖励权重消融。固定权重策略表现出 SA-PC 权衡；我们的动态课程 (Eq. (5)) 达到帕累托优势。

奖励函数	SA (%)	PC (%)	联合 (%)
没有训练 (基线)	43.4	55.8	32.2
SA 分数	45.6	52.8	31.6
PC 分数	39.4	65.2	33.4
静态	45.0	60.2	35.4
动态 (本文)	47.8	66.8	40.8

这种分阶段的方法发现了单目标轨迹无法到达的区域中的提示 [6]，解释我们如何超过两个上界。

与静态平衡权重相比，我们的动态课程在所有三个 VideoPhy2 指标上都有所改进，这表明依赖时间的时间表可以增强两个目标，而不是权衡一个目标。值得注意的是，该课程实现了比仅 SA 培训更高的 SA (47.8% 对比 45.6%)，表明分阶段方法可以更有效地探索提示空间。

案例研究：锤子和钉子。 Fig. 5 说明了质量影响。对于提示“用重锤将钉子敲入木板，”静态平衡权重生成的视频中，锤子撞击木板，但钉子不存在（语义失败）。相比之下，我们的动态课程会生成明确命名钉子并描述力动态的提示，从而产生物理连贯的序列，其中钉子逐渐被钉入木头并产生真实的变形。这例证了我们的课程如何避免纯 PC 优化中固有的语义漂移，同时捕获纯 SA 训练错过的物理细节。

5. 结论

我们提出 PhyPrompt，这是一个基于强化学习的框架，可自动增强文本到视频提示词，从而生成更符合物理规律的视频。通过两阶段训练，即先进行以物理为中心的思维链监督微调，再使用带动态奖励课程的强化学习，PhyPrompt 在保持语义保真度的同时显著提升了物理真实性。核心实证结果表明，只要通过合适的课程进行优化，语义遵循度和物理常识并不必然相互竞争。PhyPrompt-7B 在 VideoPhy2 基准上达到 47.8% 的语义遵循度和 66.8% 的物理常识，联合成功率为 40.8%。关键在于，物理常识从 55.8% 提升到 66.8%，并没有牺牲语义质量；相反，语义遵循度也从 43.4% 提升到 47.8%，使联合表现相较基线提示词提高 8.6 个百分点。这种协同改进来自动态课程机制，它能够发现单目标优化难以到达的提示词空间区域。课程在训练早期建立语义支架，再通过物理约束进行细化，使两个目标相互强化而不是相互抵消。消融研究证实了这一点：动态课程不仅优于静态平衡加权，也在各自指标上优于专门的单目标训练。除性能提升外，PhyPrompt 还展示了跨不同生成器架构 (Lavie、VideoCrafter2、CogVideoX) 的真正零样本迁移，无需为每个生成器单独微调即可带来一致改进。这种与模型无关的设计使 PhyPrompt 成为物理感知视频生成中实用且可部署的方案。我们的结果也为生成式 AI 中的多目标优化提供了更广泛的启示：与单纯扩大参数规模相比，带有直接任务反馈的领域专用训练、精心设计的课程和有针对性的优化可能更加有效。随着文本到视频系统持续发展，PhyPrompt 这类提示词精炼方法为物理扎实的视频合成提供了一条参数高效的路径，可服务于机器人、科学可视化、教育等依赖物理真实性

的应用。

References

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023. 3, 5
- [2] Luca Agnolucci, Federico Landi, Federico Pernici, Francesco Saverio Zuppichini, Matteo Bruni, Marco Bertini, and Alberto Del Bimbo. Motioncraft: Zero-shot physics-based video generation, 2024. Referenced via NeurIPS 2024 paper file. 3
- [3] Hritik Bansal, Zongyu Lin, Tianyi Xie, Zeshun Zong, Michal Yarom, Yonatan Bitton, Chenfanfu Jiang, Yizhou Sun, Kai-Wei Chang, and Aditya Grover. Videophy: Evaluating physical commonsense for video generation. *arXiv preprint arXiv:2406.03520*, 2024. 1
- [4] Hritik Bansal, Clark Peng, Yonatan Bitton, Roman Goldenberg, Aditya Grover, and Kai-Wei Chang. Videophy-2: A challenging action-centric physical commonsense evaluation in video generation. *arXiv preprint arXiv:2503.06800*, 2025. 1
- [5] Hritik Bansal, Clark Peng, Yonatan Bitton, Roman Goldenberg, Aditya Grover, and Kai-Wei Chang. Videophy-2: A challenging action-centric physical commonsense evaluation in video generation, 2025. 2, 4, 5, 3
- [6] Yoshua Bengio, Jérôme Louradour, Ronan Collobert, and Jason Weston. Curriculum learning. In *Proceedings of the 26th annual international conference on machine learning*, pages 41–48, 2009. 2, 4, 5, 8
- [7] Rich Caruana. Multitask learning. *Machine Learning*, 28(1):41–75, 1997. 7
- [8] Haoxin Chen, Yong Zhang, Xiaodong Cun, Menghan Xia, Xintao Wang, Chao Weng, and Ying Shan. Videocrafter2: Overcoming data limitations for high-quality video diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7310–7320, 2024. 1, 2, 5, 3
- [9] Yuan Chen, Ziqi Chen, Yiming Zhang, Yilin Zhao, Yilun Jin, Yujia Qin, Zhiyuan Liu, and Maosong Sun. Emorl: Ensemble multi-objective reinforcement learning for efficient and flexible llm fine-tuning, 2025. 2
- [10] Yongfan Chen, Yabin Zhang, and Zhiwu Qing. A physical coherence benchmark for evaluating video generation models via optical flow-guided frame prediction, 2025. 2
- [11] Ran Cheng, Xin Wang, and Jia Huang. Vpo: Video prompt optimization with multi-feedback preference learning. *arXiv:2503.01234*, 2025. 1, 2, 3
- [12] Carlos Fernandez, Laura Martinez, and Priya Singh. Prompt2video: Leveraging diffusion priors for dynamic scene control. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9901–9910, 2024. 3
- [13] Netanel Goffer, Yair Ovadia, and Nir Shavit. Direct preference optimization: Training aligns models with preferences without reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 14567–14580, 2023. 2
- [14] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, and Xiao Bi. Deepseek-r1: Incentivizing reasoning capability in large language models via group relative policy optimisation. *arXiv:2501.12948*, 2025. 2, 4
- [15] Zhiheng Hao, Xintao Liu, Jing Zhang, Xiaohong Qian, Qihang Cui, Cheng Zhang, and Jian Sun. Promptist: Automatic prompt optimization for text-to-image generation. *arXiv:2304.08487*, 2023. 1, 2, 5, 6
- [16] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, et al. Training compute-optimal large language models. *Advances in Neural Information Processing Systems*, 35:30016–30030, 2022. 6
- [17] Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helvar, Aleksander Madry, Alex Beutel, Alex Carney, et al. Openai o1 system card. *arXiv preprint arXiv:2412.16720*, 2024. 3
- [18] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. 5

- [19] Yatai Ji, Jiacheng Zhang, Jie Wu, Shilong Zhang, Shoufa Chen, Chongjian GE, Peize Sun, Weifeng Chen, Wenqi Shao, Xuefeng Xiao, et al. Prompt-a-video: Prompt your video diffusion model via preference-aligned llm. *arXiv preprint arXiv:2412.15156*, 2024. 3
- [20] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020. 6
- [21] Jisoo Kim and Minhoo Lee. Speednet: Evaluating temporal consistency in video motion. In *European Conference on Computer Vision (ECCV)*, pages 678–692, 2023. 2
- [22] Sungho Lee, Eunji Park, and Hyun Choi. Diffusion-prompt: Gradient-based prompt rewriting for style control in text-to-image generation. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1245–1255, 2023. 2
- [23] Brian Lester, Rami Al-Rfou, and Noah Constant. The power of scale for parameter-efficient prompt tuning. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3045–3059. Association for Computational Linguistics, 2021. 6
- [24] Xiang Li and Percy Liang. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4582–4597. Association for Computational Linguistics, 2021. 6
- [25] Xuying Li, Zhuo Li, Yuji Kosuga, and Victor Bian. Optimizing safe and aligned language generation: A multi-objective grpo approach, 2025. 2
- [26] Lukas Liebel and Marco Körner. Auxiliary tasks in multi-task learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 1177–1186, 2018. 4, 7
- [27] Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. Deepseek-v3 technical report. *arXiv preprint arXiv:2412.19437*, 2024. 5
- [28] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019. 1
- [29] Fanqing Meng, Jiaqi Liao, Xinyu Tan, Wenqi Shao, Quanfeng Lu, Kaipeng Zhang, Yu Cheng, Dianqi Li, Yu Qiao, and Ping Luo. Towards world simulator: Crafting physical commonsense-based benchmark for video generation. *arXiv preprint arXiv:2410.05363*, 2024. 1, 2
- [30] Niklas Muennighoff, Alexander M Rush, Boaz Barak, Teven Le Scao, Aleksandra Piktus, Nouamane Tazi, Sampo Pyysalo, Thomas Wolf, and Colin Raffel. Scaling data-constrained language models. *Advances in Neural Information Processing Systems*, 36:50358–50376, 2023. 6
- [31] Niklas Muennighoff, Zitong Yang, Weijia Shi, Xiang Lisa Li, Li Fei-Fei, Hannaneh Hajishirzi, Luke Zettlemoyer, Percy Liang, Emmanuel Candès, and Tatsunori Hashimoto. s1: Simple test-time scaling. *arXiv preprint arXiv:2501.19393*, 2025. 1
- [32] Yuki Nakano, Rahul Patel, and Li Chen. Hierarchical reward decomposition for prompt optimization. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9212–9223, 2023. 2
- [33] Hyelin Nam, Byeongjun Moon, and Gyeong-Moon Park. Optical-flow guided prompt optimization for coherent video generation. Accessed via The Moonlight Review, <https://www.themoonlight.io/en/review/optical-flow-guided-prompt-optimization-for-coherent-video-generation>, 2024. Original source likely arXiv or conference proceedings. 3
- [34] Alice Outtrun, Jordan Taylor, and Michael Smith. Reinforcement learning from human feedback at scale. *Journal of Machine Learning Research*, 24(187):1–28, 2023. 2
- [35] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022. 5
- [36] Rajesh Rakesh, Peter Browne, and Ananya Gupta. Reinforcement learning from ai feedback. In *International Conference on Learning Representations (ICLR)*, pages 45–58, 2024. 2

- [37] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Towards causal representation learning, 2021. [4](#), [7](#)
- [38] Wenqi Shao, Zhaoyuan Yang, Yue Wu, Yujun Shi, Hongyang Li, Yu Qiao, and Peng Luo. Phygenbench: A physics generation benchmark for evaluating physical commonsense in text-to-video generation, 2024. [2](#), [3](#)
- [39] Zhihong Shao, Peiyi Wang, Yifei Li, Chengqiang Lu, Yunfan Shao, Zian Zheng, Yeyun Gong, Yelong Shen, Ruoyu Sun, Lifeng Shang, Xin Jiang, Qiang Liu, and Houqiang Li. Deepseekmath: Pushing the limits of mathematical reasoning in open language models, 2024. [2](#)
- [40] Katsunari Shibata. Dynamic reinforcement learning for actors, 2025. [2](#)
- [41] Aman Singh, Wei Zhao, and Adam Cohen. Visual-physicist: Benchmarking dynamic object interactions in video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 13345–13354, 2024. [2](#)
- [42] Trevor Standley, Amir R Zamir, Dawn Chen, Leonidas Guibas, Jitendra Malik, and Silvio Savarese. Which tasks should be learned together in multi-task learning? In *International Conference on Machine Learning*, pages 9120–9132, 2020. [7](#)
- [43] Ang Wang, Baole Ai, Bin Wen, Chaojie Mao, Chen-Wei Xie, Di Chen, Feiwei Yu, Haiming Zhao, Jianxiao Yang, Jianyuan Zeng, et al. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*, 2025. [1](#)
- [44] Peiyi Wang, Shang Wu, Hua Hu, Yuxuan Zhao, Haowei Zhang, Ruoyu Zhang, and Runxin Xu. Cogvideodex: Scaling transformers for high-fidelity text-to-video generation. *arXiv:2403.11818*, 2024. [2](#), [3](#)
- [45] Sirui Wang, Ziyi Zhang, Zhipeng Liu, Zekun Li, Zhonggang Cai, Ceyuan Yang, Peng Gao, Bolin Ni, Yiran Zhong, Ziwei Liu, and S. Kevin Zhou. Revision: A parameterized 3d prior for physically plausible video generation, 2025. [3](#)
- [46] Yaohui Wang, Xinyuan Chen, Xin Ma, Shangchen Zhou, Ziqi Huang, Yi Wang, Ceyuan Yang, Yinan He, Jiashuo Yu, Peiqing Yang, et al. Lavie: High-quality video generation with cascaded latent diffusion models. *IJCV*, 2024. [2](#), [5](#), [1](#), [3](#)
- [47] Yuan Wang, Zhenfang Chen, Lin Wang, Kwan-Yee Lin, Wayne Xin Zhao, and Ji-Rong Wen. Ipv-bench: An impossible phenomenon video benchmark for video understanding and generation, 2025. [2](#)
- [48] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. Emergent abilities of large language models. *Transactions on Machine Learning Research*, 2022. [6](#)
- [49] Li Xu, Tong Zhang, and Xia Chen. Videoprompttuning: Lightweight adapter tuning for video generation feedback. In *International Conference on Machine Learning (ICML)*, pages 1012–1024, 2024. [3](#)
- [50] Qiyao Xue, Xiangyu Yin, Boyuan Yang, and Wei Gao. Phyt2v: Llm-guided iterative self-refinement for physics-grounded text-to-video generation. *arXiv preprint arXiv:2412.00596*, 2024. [1](#), [2](#), [3](#), [5](#), [6](#)
- [51] An Yang, Baosong Yang, Binyuan Hui, Bowen Yu, Dayiheng Liu, et al. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. [4](#), [1](#)
- [52] Zhuoyi Yang, Jiayan Teng, Wendi Zheng, Ming Ding, Shiyu Huang, Jiazheng Xu, Yuanming Yang, Wenyi Hong, Xiaohan Zhang, Guanyu Feng, et al. Cogvideox: Text-to-video diffusion models with an expert transformer. *arXiv preprint arXiv:2408.06072*, 2024. [1](#), [4](#), [5](#)
- [53] Tianhe Yu, Saurabh Kumar, Abhishek Gupta, Sergey Levine, Karol Hausman, and Chelsea Finn. Gradient surgery for multi-task learning. In *Advances in Neural Information Processing Systems*, pages 5824–5836, 2020. [7](#)
- [54] Xi Yue, Xuechen Li, Denny Zhou, Dale Schuurmans, and Hanie Sedghi. Scaling laws and limitations of learning long cots, 2025. [2](#)
- [55] Jason Zhang, David Zhang, Rohan Taori, and Tatsunori Hashimoto. Memory-efficient reinforcement learning for large language models, 2025. [2](#)
- [56] Zangwei Zheng, Xiangyu Peng, Tianji Yang, Chenhui Shen, Shenggui Li, Hongxin Liu, Yukun Zhou, Tianyi Li, and Yang You. Open-sora: Democratizing efficient video production for all. *arXiv preprint arXiv:2412.20404*, 2024. [1](#)

PhyPrompt：基于强化学习的提示词精炼，用于物理合理的文本到视频生成

Supplementary Material

6. 精选数据示例

Tab. 3 说明了我们如何引导模型注入物理推理：从简洁的场景描述开始，我们指定相关物理定律，明确预期视觉结果，并给出将微重力、表面张力与液体行为联系起来的逐步推理。这个结构化示例展示了 CoT 标注的深度和清晰度。

7. 视频生成器设置

评估团队集中在类似的快速预览配置上，通常采用大约 50 个扩散推理步骤和无分类器指导来平衡效率和视觉质量。具体来说，CogVideoX-5B/2B 利用 DPM-Solver 调度程序 (CogVideoXDPM Scheduler)，将无分类器引导设置为 6，以 480×720 像素的分辨率生成 24 帧视频片段（4 fps 下 6 秒），全部以 bfloat16 精度执行 [52]。相比之下，VideoCrafter2 保留了经典的 DDIM 采样器，同时将无分类器指导增加到 12 个，在相同的 50 步推理预算内生成 24 帧（4 fps 下 6 秒）、 320×512 像素、全 fp32 精度的视频序列 [46]。同样，LaVie 利用其基本 UNet 架构，将无分类器指导设置为 12，匹配 VideoCrafter2 的推理设置-50 个 DDIM 步骤以 320×512 分辨率、fp32 精度生成 24 帧序列（4 fps 下 6 秒）[8]。所有三个基于扩散的模型都采用基于余弦的 β 调度（稳定扩散的标准调度），利用 v 预测参数化，并明确遵循普遍采用的无分类器指导协议，大约有 50 个推理步骤。

8. PhyPrompt 到不同视频生成器的可转移性

Lavie 的结果。 Tab. 4 报告了使用 Lavie 生成视频时各提示词精炼策略的性能。原始提示词得到 41.0% 的 SA、57.0% 的 PC，以及 29.2% 的联合成功率。Promptist 表现低于基线，而简单的指令微调模型（Qwen2.5）以牺牲 SA 为代价带来适度 PC 增益。相比之下，PhyPrompt 变体持续改善两个指标；例如，PhyPrompt-7B 将 PC 提升到 63.2%，联合成功率达到 31.6%，说明它能在不降低语义对齐的情况下向提示词

注入物理感知推理。GPT-4o 和 DeepSeek-V3 的结果接近基线，凸显了两阶段 RL 训练重写器在 Lavie 生成器上的独特优势。

VideoCrafter2 上的结果。 Tab. 5 报告了 VideoCrafter2 上的结果。原始提示词达到 45.6% SA、48.0% PC 和 29.8% 联合得分。Promptist 表现低于基线，而 Qwen2.5 变体以牺牲 SA 为代价换取更高 PC（例如 Qwen2.5-1.5B 得到 35.0% SA 和 53.6% PC）。相比之下，PhyPrompt 持续提升两个指标：1.5B 变体将联合成功率提高到 30.2%，7B 变体取得最佳分数（46.2% SA，66.4% PC，34.8% 联合）。GPT-4o 和 DeepSeek-V3 带来适度 PC 改进，但仍低于 PhyPrompt。

CogVideoX-5B 上的结果。 Tab. 6 展示了在 CogVideoX-5B 生成器上各提示词精炼策略的性能。原始提示词达到 50.2% SA 和 63.4% PC（39.4% 联合）。Promptist 再次低于基线，而 Qwen2.5 模型以牺牲语义保真度换取适度 PC 增益。相比之下，PhyPrompt 变体基本恢复了 SA 并进一步推高 PC：PhyPrompt-7B 的 SA 与基线持平（50.2%），并取得最高 PC（69.2%），联合得分达到 42.0%。GPT-4o 的 SA 最高（52.6%），但 PC 低于 PhyPrompt；DeepSeek-V3 较为均衡，但联合表现更低。这些结果证实了 PhyPrompt 能够将物理感知推理注入到 CogVideoX-5B 的提示中，而不会降低语义。

9. 训练设置

SFT 训练设置。 我们从 Qwen2.5-Instruct (1.5B/3B/7B) 初始化 [51]，该模型已在多样语料上预训练，并针对对话进行指令调优。为了引发明确的思维链推理，我们插入标记分隔符，如下所示：`<|im_start|>think` 和 `<|im_start|>answer`。每个标记都被换行符包围，以清楚地区分“思考”和“回答”阶段。我们采用微调方案 [31]，端到端优化整个模型以进行推理。训练进行 5 个 epoch，每个 GPU 的批大小为 16。所有计算均使用 bfloat16 精度，最大序列长度为 4096 个 token。我们使用 AdamW [28]，设置 $\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ 、权重衰减 1×10^{-4} ，并将梯度裁剪阈值设

表 3. 以物理为中心的思维链数据集示例。原始描述给出微重力场景，标注的物理定律（“缺乏重力”）定义物理约束，显式描述给出期望结果（球形液滴漂浮），思维链解释其原因。

标题	一罐苏打水在空间站中慢慢倒出，将液体释放到周围区域。
物理定律	缺乏重力。
显式描述	一罐苏打水在空间站中慢慢倒出，将液体释放到周围区域。液体形成球形液滴并自由漂浮在空气中。
思维链	在微重力（或“零重力”条件）下，不存在拉动液体的主导向下力。苏打水不像在地球上那样向下流动，而是一旦离开罐子就会漂走。表面张力成为作用于苏打水滴的主要力量，将液体拉成尽可能小的形状，即球体。由于没有明显的重力将它们分开，这些液滴保持球形并继续漂浮，直到它们接触另一个表面或液滴。因此，在没有重力的情况下，苏打水倒入航天器中形成球形液滴并漂浮。

表 4. 在 **Lavie** 生成器上，不同提示词增强方法的语义遵循度 (SA)、物理常识 (PC) 和联合 SA&PC 分数。

增强型	SA (%)	PC (%)	PC & SA (%)
不适用（原始提示）	41.0	57.0	29.2
Promptist	37.8	58.4	27.0
PhyT2V	41.2	60.8	30.0
Qwen2.5-1.5B	34.6	59.0	24.8
PhyPrompt-1.5B	40.2	61.2	30.6
Qwen2.5-3B	35.2	60.4	28.0
PhyPrompt-3B	41.4	60.8	30.2
Qwen2.5-7B	40.0	60.8	30.8
PhyPrompt-7B	41.8	63.2	31.6
GPT-4o	41.8	58.0	29.8
DeepSeek-V3	41.6	59.2	30.0

表 5. 在 **VideoCrafter2** 生成器上，不同提示词增强方法的语义遵循度 (SA)、物理常识 (PC) 和联合 SA&PC 分数。

增强型	SA (%)	PC (%)	PC & SA (%)
不适用（原始提示）	45.6	48.0	29.8
Promptist	43.8	51.4	27.2
PhyT2V	45.0	56.8	30.6
Qwen2.5-1.5B	35.0	53.6	27.8
PhyPrompt-1.5B	41.4	57.4	30.2
Qwen2.5-3B	40.0	55.8	28.0
PhyPrompt-3B	38.0	61.0	30.8
Qwen2.5-7B	45.8	58.0	31.2
PhyPrompt-7B	46.2	66.4	34.8
GPT-4o	38.4	60.0	30.0
DeepSeek-V3	40.0	60.4	32.8

为 1.0。学习率在前 5% 步线性预热到 1×10^{-5} ，随后在剩余步数中按余弦调度衰减到零。我们只在推理轨迹和答案上计算交叉熵损失，忽略问题 token。微调在单节点 $8 \times \text{A100 GPU}$ 上进行，使用带 CPU offload 和梯度检查点的完全分片数据并行 (FSDP)；每个 epoch 保存检查点，并在保留验证集上评估。

GRPO 训练设置。我们以 1×10^{-6} 的学习率对策略 LLM 微调 250 步，并将学习率线性衰减到零。训练是在配备了以下设备的单个节点上进行的： $8 \times \text{A100}$

GPU，利用全分片数据并行 (FSDP) 实现高效的 GPU 内存使用，以及 CPU 卸载和梯度检查点以进一步减少内存占用。在策略 rollout 期间，我们使用 vLLM 为每个提示词生成 4 个候选响应，并采用温度 $t = 1.0$ 、top- p 采样 $p = 1.0$ 来保证多样性。输入序列被截断为最多 4096 个标记，而生成的响应和推理过程都限制为最多 1024 个标记。使用带有参数的广义优势估计 (GAE) 执行策略优化 $\lambda = 1$ 和 $\gamma = 1$ ，以及由系数控制的 KL 正则化项 $\beta = 0.01$ 最大梯度范数为 20。我们将

表 6. 在 **CogVideoX-5B** 上, 不同提示词增强方法的语义遵循度 (SA)、物理常识 (PC) 和联合 SA&PC 分数。

增强型	SA (%)	PC (%)	PC&SA (%)
不适用 (原始提示)	50.2	63.4	39.4
Promptist	46.4	63.0	37.4
PhyT2V	50.6	65.0	40.8
Qwen2.5-1.5B	39.2	66.4	31.0
PhyPrompt-1.5B	47.4	66.6	39.0
Qwen2.5-3B	45.2	64.6	35.8
PhyPrompt-3B	46.4	68.4	40.2
Qwen2.5-7B	47.8	63.8	38.2
PhyPrompt-7B	50.2	69.2	42.0
GPT-4o	52.6	66.4	41.8
DeepSeek-V3	50.6	63.6	40.8

每个 GPU 的批处理大小设置为 1, 从而使所有 GPU 的总体批处理大小为 8, 并且每 100 个训练步骤保存一次检查点。

10. 模型架构

Tab. 7 对比了五种视频生成和评估模型的架构和提示能力。CogVideoX-5B 和 CogVideoX-2B [44] 两者都将 3D 因果 VAE 与 Transformer 主干 (分别为 5B 和 2B 参数) 配对, 使用 4096 维隐藏状态, 并通过 RoPE 或正弦位置编码支持最多 226 个标记的长提示。相比之下, Lavie [46] 采用 860M 参数的级联潜在扩散流程, VideoCrafter2 [8] 使用带时间卷积的 1.2B 参数 UNet, VideoPhy2 [5] 则依赖由 LoRA 适配器增强的 7B 参数 Transformer; 三者均使用 768 维隐藏状态、更短的 77-token 提示词窗口, 以及不同的位置嵌入 (RoPE、傅里叶或正弦)。该表重点介绍了模型大小、隐藏维度、位置编码策略和最大提示如何在物理感知文本到视频合成和评估的不同方法之间进行权衡。

表 7. 四篇论文中报告了模型详细信息。

Model	Core architecture	Size	Hidden Dim	Pos Enc	Max Prompt
CogVideoX-5B	3D causal VAE + Transformer	5B	4096	RoPE	226
CogVideoX-2B	3D causal VAE + Transformer	2B	4096	sinusoidal	226
Lavie	Cascaded Video Latent Diffusion	860M	768	RoPE	77
VideoCrafter 2	UNet + temporal convolution	1.2B	768	Fourier	77
VideoPhy2	7B Transformer with LoRA	7B	768	sinusoidal	77