

PivotRL: 以较低计算成本实现高精度智能体后训练

Junkeun Yi^{*,1} Damon Mosk-Aoyama^{*,1} Baihe Huang^{*,2} Ritu Gala¹ Charles Wang¹ Sugam Dipak Devare¹
Khushi Bhardwaj¹ Abhibha Gupta¹ Oleksii Kuchaiev¹ Jiantao Jiao^{**,1,2} Jian Zhang^{**,1} Venkat
Srinivasan^{**,†,1}

¹NVIDIA ²UC Berkeley

* 共同一作 ** 共同指导 † 通讯作者: venkats@nvidia.com

摘要. 长时程智能体任务的后训练在计算效率与泛化能力之间存在张力。监督微调 (SFT) 虽然计算高效, 却往往带来域外 (OOD) 性能退化; 端到端强化学习 (E2E RL) 能够保留 OOD 能力, 但由于需要进行多轮 on-policy rollout, 计算成本很高。我们提出 **PivotRL**, 一种直接作用于已有 SFT 轨迹的新框架, 试图同时获得 SFT 的计算效率与 E2E RL 的 OOD 准确性。PivotRL 依赖两个核心机制: 其一, 在局部执行 on-policy rollout, 并筛选出 *pivot*, 即那些采样动作结果方差较高、信息量更大的中间轮次; 其二, 对功能等价的动作给予奖励, 而不是要求与 SFT 演示字符串严格一致。我们从理论上证明, 这两点会带来更强的学习信号和更高的自然梯度范数, 同时尽可能保持与训练任务无关动作上的策略概率排序不变。与在相同数据上训练的标准 SFT 相比, PivotRL 在四个智能体领域上的域内平均准确率高出 +4.17%, 在非智能体任务上的 OOD 准确率高出 +10.04%。特别是在智能体编程任务上, PivotRL 仅用 E2E RL 四分之一的 rollout 轮次数, 就达到了有竞争力的准确率。PivotRL 已被用于 NVIDIA 的 Nemotron-3-Super-120B-A12B, 并成为其生产级智能体后训练的核心方案。

1. 引言

长时程智能体任务要求大语言模型 (LLM) 与环境进行多轮交互。这类任务包括对话式工具使用 (Schick et al., 2023; Qin et al., 2023)、智能体编程 (Jimenez et al., 2024)、终端交互 (Xie et al., 2024) 以及网页搜索 (Yao et al., 2022; Wei et al., 2025)。它们已经成为能够执行复杂现实工作流的 AI 系统前沿。然而, 对这些长时程智能体能力进行后训练, 会在训练效率与泛化能力之间引入一个根本性矛盾。监督微调 (SFT) 为获得新能力提供了计算高效的机制, 但它往往难以泛化到训练分布之外, 并会灾难性地损害域外 (OOD) 性能 (Chu et al., 2025; Luo et al., 2025b)。相比之下, 端到端强化学习 (E2E RL) 通常能取得更高的域内准确率, 同时较稳健地保留 OOD 能力 (Ouyang et al., 2022; Chen et al., 2025)。但 E2E RL 的代价也很高, 因为每次参数更新都需要与环境反复进行多轮 on-policy rollout。于是, 自然会出现下面这个问题:

能否在不承担完整轨迹 rollout 成本的前提下, 把 SFT 的数据效率与 E2E RL 的泛化能力结合起来, 同时获得域内准确率与 OOD 保留能力?

为了解决这个问题, 一个自然想法是把 SFT 轨迹演示重新用于 RL。具体而言, 可以从一条 SFT 轨迹中随机选取某个中间轮次, 以它为条件进行 on-policy rollout; 只有当生成动作与 SFT 数据中的演示动作完全一致时, 才给予正奖励。这样做缓解了 SFT 数据只训练单一演示续写的低利用率问题, 但我们的初步实验发现, 它相较于同数据的标准 SFT 并不能提升 OOD 准确率。进一步分析表明, 这一失败主要来自两个瓶颈。第一, 随机选择的中间轮次往往几乎不提供学习信号; 在 Group Relative Policy Optimization (GRPO) (Shao et al., 2024) 下, 这些轮次上采样得到的动作常常要么全部成功、要么全部失败, 归一化优势接近零, 因此无法产生有意义的梯度更新。第二, 在生成式动作空间中, 要求与 SFT 演示严格字符串匹配过于苛刻, 因为大量功能等价的动作完全可能与唯一的演示续写不同。例如, 一个工具调用或搜索查询即使不与演示完全一致, 也可能是合理的。

基于这些观察，我们提出 **PivotRL**，一种面向长时程智能体 RL 的新框架，同时解决上述两个瓶颈。PivotRL 进行局部 on-policy rollout，并筛选出 *pivot*：即那些采样动作同时出现成功和失败结果的、信息量更高的助手轮次。因此，训练只需要从这些 pivot 状态出发执行简短的局部 rollout，而不必生成完整轨迹。为了有效为这些 rollout 打分，我们使用适合具体领域的 verifier，对功能等价的动作赋予奖励，而不是像以往那样严格惩罚任何偏离 SFT 演示的行为 (Shao et al., 2024; Rohatgi et al., 2025)。

我们还对这些核心设计做了简洁的理论分析。第一，我们证明状态级奖励目标的自然梯度 Fisher 范数会随奖励标准差增长。因此，沿着 KL 路径的 GRPO 更新量也会随该方差直接增大，这验证了我们通过筛选“结果有混合成败”的 pivot 来最大化局部域内学习信号的策略。第二，我们证明，基于功能奖励的 RL 会把概率质量转移到与专家演示功能等价的动作上，同时保持其它动作的条件分布不变。这样就保留了参考策略在与任务无关动作上的相对排序，从而缓解了 OOD 退化。

在实验上，我们首先表明：在完全相同的训练数据下，也就是使用相同提示与专家轨迹时，PivotRL 比 SFT 带来更大的域内提升，同时显著减少 OOD 回退。当分别在对话式工具使用、智能体编程、终端工具使用和搜索四个领域训练时，PivotRL 相对基座模型的域内平均提升达到 +14.11¹，显著高于 SFT 的 +9.94。更关键的是，PivotRL 几乎不会造成 OOD 回退（平均变化为 +0.21），而 SFT 在数学、科学问答与竞赛编程等非智能体领域上则出现了严重退化（平均为 -9.48）。其次，我们在 SWE-Bench 上将 PivotRL 与 E2E RL 直接比较。SWE-Bench 是评估长时程智能体能力的严格基准，并拥有较成熟的 E2E RL 基线 (Jimenez et al., 2024; Wang et al., 2025b)。我们在该基准上展示，PivotRL 仅用约 4× 更少的 rollout 轮次数就能达到与 E2E RL 有竞争力的准确率。PivotRL 已在领先的开源大模型中完成大规模部署；在 NVIDIA 的 Nemotron-3-Super LLM (Team, 2026) 后训练中，它与 SFT 和 E2E RL 一起构成了智能体后训练的核心 workflow。

2. 预备知识与动机性观察

轮次级智能体训练。 设 τ 为在智能体任务中收集得到的一条交互轨迹。将 τ 按照助手决策边界分解，可得 $\tau = (s_0, a_0^*, \dots, s_T, a_T^*)$ ，其中 s_t 表示从轨迹 τ_i 起点到第 t 个助手动作之前的完整交互历史， a_t^* 则是在该状态上的演示助手续写。在轮次级智能体训练中，一个动作指的是一次模型调用边界上的完整助手续写，而不是单个 token。SFT 的标准负对数似然损失为

$$\mathcal{L}_{\text{sft}}(\theta) = -\mathbb{E}_{\tau \sim \mathcal{D}_{\text{sft}}, (s_t, a_t^*) \sim \tau} [\log \pi_\theta(a_t^* | s_t)].$$

记 π_0 为参考策略，E2E RL 从 π_{old} 采样 rollout，并优化 GRPO (Shao et al., 2024) 目标：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{\substack{s \sim \mathcal{D}_{\pi_{\text{old}}} \\ a_i \sim \pi_{\text{old}}(\cdot | s)}} \left[\frac{1}{G} \sum_{i=1}^G \min \left(w_i(\theta) \hat{A}_i, \text{clip}(w_i(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) - \beta \text{KL}(\pi_\theta(\cdot | s) \parallel \pi_0(\cdot | s)) \right]$$

其中 $w_i(\theta) = \frac{\pi_\theta(a_i | s)}{\pi_{\text{old}}(a_i | s)}$ 是重要性采样权重， $\mathcal{D}_{\pi_{\text{old}}}$ 表示 on-policy rollout 轨迹中状态 s_t 的分布，而

$$\hat{A}_i = \frac{r_i - \frac{1}{G} \sum_{j=1}^G r_j}{\text{std}(\{r_j\}_{j=1}^G) + \epsilon_{\text{std}}}. \quad (1)$$

表示在 G 个采样到的端到端 rollout 组内进行归一化后的优势。

来自专家轨迹的局部 RL。 为了规避完整端到端轨迹生成带来的高计算成本，我们考虑一种局部 RL 范式。在这个设定中，我们不再从初始环境状态展开完整交互直到终止，而是直接使用 SFT 数据集集中的中间专家状态 s_t 作为条件，并从这些状态出发进行有针对性的轮次级 rollout。给定专家轨

¹ 本文所有性能分数与差值均以百分点报告。

迹数据集 $\mathcal{D}_{\text{sft}} = \{\tau_i\}_{i=1}^N$ ，一种最直接的适配方式是：先采样一个状态 s_t ，再从 $\pi_\theta(\cdot | s_t)$ 采样动作；只有当该动作与演示续写完全一致时才给奖励：

$$r_{\text{strict}}(s, a) = \mathbf{1}[a = a^*(s)]. \quad (2)$$

这种做法是把 SFT 演示转换为局部 RL 框架的最直接方式：交互历史被严格固定在专家轨迹上，随后动作按当前策略采样，信用分配只在完美复现演示续写时才给出。然而， τ^2 -Bench 上的经验结果表明，这种朴素局部 RL 相比于同数据的行为克隆只带来极其有限的收益，其准确率仅为 57.34，甚至低于同数据 SFT 的 58.44。因此，仅仅把专家演示转写为基于精确匹配奖励的局部 RL episode，并不足以带来实质性性能改进。

动机性观察。 通过初步实验，我们发现 rollout 预算分配与局部信用分配存在两个瓶颈。第一，若某个轮次上的动作要么全部成功、要么全部失败，那么在组归一化 RL 下它是没有信息量的。事实上，如果一批奖励 $\{r_i\}_{i=1}^G$ 全部为 0 或全部为 1，那么式 (1) 中的归一化优势就为零。我们在 τ^2 -Bench 和 SWE-Bench 上观察到，随机采样的轮次中有 71% 会产生 0 学习信号，也就是说它们要么已经全部被解决，要么全部失败，对梯度没有贡献。第二，精确匹配的局部信用过于严格。在生成式动作空间里，许多工具调用、shell 命令或搜索步骤在局部上是可接受的，即使它们与唯一的演示字符串并不完全相同。将精确匹配与更宽松的 verifier 奖励 r_{func} （见第 3.1 节）比较，我们定义 miss rate 为 $\Pr[r_{\text{strict}}(s, a) = 0 | r_{\text{func}}(s, a) = 1]$ 。较高的 miss rate 意味着，精确匹配会错误地丢弃在当前决策点上实际上功能正确的 rollout。这两个瓶颈正好对应 PivotRL 的两个核心组成部分：首先筛选出 *pivot*，也就是仍然会产生混合结果的高信息轮次；其次，用奖励局部可接受动作的 verifier 取代精确匹配信用。

3. PivotRL

PivotRL 相比第 2 节中的朴素局部 RL 基线只做了两处改动：其一，对抽取出的轮次进行筛选，把在线 rollout 预算集中到信息量更高的状态上；其二，用基于 verifier 的奖励替代严格精确匹配的局部信用。下面我们先介绍完整训练流程，再给出两个理论结果来解释这些设计。第 3.1 节介绍方法本身，第 3.2 节则分别分析这两个组成部分：命题 3.1 与定理 3.2 说明为什么“响应结果差异较大”的轮次能在组归一化 RL 下提供更强的局部学习信号，而定理 3.3 表明，基于 verifier 的奖励会把概率质量转移到可接受动作上，同时相对参考策略保持保守。

3.1. 方法

在轮次级训练中，我们从每条轨迹 $\tau = (s_0, a_0^*, \dots, s_T, a_T^*)$ 中抽取助手轮次，构成 *pivot candidate* 数据集：

$$\mathcal{D}_{\text{cand}} = \{(s_t, a_t^*)\}_{\tau \in \mathcal{D}_{\text{SFT}}, t=0, \dots, T}. \quad (3)$$

PivotRL 由三个步骤组成：(i) 离线分析各个轮次，只保留未来仍可能有信息量的状态；(ii) 在保留下来的轮次上执行局部 on-policy rollout；(iii) 优化基于 verifier 的 GRPO 风格目标。完整流程见算法 1。第一步对应第 2 节中的“无信息轮次”瓶颈，第二步则对应“局部信用过于严格”的瓶颈。

离线轮次筛选。 我们在一个冻结的参考策略 π_0 下估计每个抽取轮次的信息量，通常 π_0 就是 PivotRL 的初始化策略。对某个轮次状态 s ，我们从 $\pi_0(\cdot | s)$ 采样 K 个局部 rollout，用 verifier 打分，并计算

$$\hat{\mu}(s) = \frac{1}{K} \sum_{k=1}^K r_{\text{func}}(s, a^{(k)}), \quad \hat{\sigma}^2(s) = \frac{1}{K} \sum_{k=1}^K (r_{\text{func}}(s, a^{(k)}) - \hat{\mu}(s))^2. \quad (4)$$

Algorithm 1 PivotRL

```

1: 输入: 专家轨迹  $\mathcal{D}_{\text{sft}}$ 、参考策略  $\pi_0$ 、初始策略  $\pi_\theta$ 、verifier  $V$ 、rollout 组大小  $G$ 、难度阈值  $\lambda_{\text{diff}}$ 
2: 从  $\mathcal{D}_{\text{sft}}$  中抽取轮次  $\mathcal{D}_{\text{cand}} = \{(s_t, a_t^*)\}$ 
3: 用式 (4) 对每个  $s \in \mathcal{D}_{\text{cand}}$  进行离线分析
4: 令  $\mathcal{D}_{\text{pivot}} \leftarrow \mathcal{D}_{\text{adv}}$ 
5: for  $k = 1, \dots, K_{\text{train}}$  do
6:   从  $\mathcal{D}_{\text{pivot}}$  中采样一个 minibatch  $\{s_b\}_{b=1}^B$ 
7:   for 每个  $s_b$  do
8:     从  $\pi_{\theta_{\text{old}}}(\cdot | s_b)$  采样  $\{a_{b,i}\}_{i=1}^G$ 
9:     执行给每个  $a_{b,i}$  打分所需的短 rollout
10:    对  $i = 1, \dots, G$ , 令  $r_{b,i} \leftarrow r_{\text{func}}(s_b, a_{b,i})$ 
11:    计算  $\hat{A}_{b,i} \leftarrow \frac{r_{b,i} - \frac{1}{G} \sum_{j=1}^G r_{b,j}}{\text{std}(\{r_{b,j}\}_{j=1}^G) + \epsilon_{\text{std}}}$ 
12:   end for
13:   使用式 (7) 更新  $\theta$ 
14: end for

```

随后, 我们只保留经验奖励方差非零且奖励均值较低的轮次:

$$\mathcal{D}_{\text{adv}} = \{(s, a^*) \in \mathcal{D}_{\text{cand}} : \hat{\sigma}^2(s) > 0, \hat{\mu}(s) < \lambda_{\text{diff}}\}. \quad (5)$$

第一个过滤条件会移除在参考策略下已经“全对”或“全错”的轮次; 第二个过滤条件则把训练进一步集中到那些结果混合、且仍然具有难度的轮次上。因此, 这个筛选后的子集被称为 *pivot*, 并用于 PivotRL 训练。我们记保留下来的训练集为 $\mathcal{D}_{\text{pivot}}$; 若无特别说明, 默认使用 $\mathcal{D}_{\text{pivot}} = \mathcal{D}_{\text{adv}}$ 。

基于 verifier 的局部奖励。 对于一个保留状态 s (即位于 $\mathcal{D}_{\text{adv}}$ 中), 设 $\mathcal{M}(s) \subseteq \mathcal{A}(s)$ 表示在领域特定 verifier 下局部可接受的动作集合。PivotRL 定义奖励为

$$r_{\text{func}}(s, a) = \mathbf{1}[a \in \mathcal{M}(s)]. \quad (6)$$

与式 (2) 中的严格局部奖励相比, 这个 verifier 会对当前轮次上任何可接受的动作记分, 而不仅仅是唯一的演示续写。根据不同领域, verifier 可以是归一化字符串或模式校验、任务特定的等价性规则, 或者轻量级的 LLM 判别器。

给定保留轮次集合 $\mathcal{D}_{\text{pivot}}$ 和 rollout 组大小 G , PivotRL 在每个选中状态处采样 $\{a_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot | s)$, 并优化

$$\mathcal{J}_{\text{PivotRL}}(\theta) = \mathbb{E}_{\substack{s \sim \mathcal{D}_{\text{pivot}} \\ \{a_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot | s)}} \left[\frac{1}{G} \sum_{i=1}^G \min(w_i(\theta) \hat{A}_i, \text{clip}(w_i(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i) - D_{\text{KL}} \right], \quad (7)$$

其中 $D_{\text{KL}} = \beta \text{KL}(\pi_\theta(\cdot | s) \parallel \pi_0(\cdot | s))$, 并且

$$w_i(\theta) = \frac{\pi_\theta(a_i | s)}{\pi_{\theta_{\text{old}}}(a_i | s)}, \quad (8)$$

$\hat{A}_i$ 则是由局部 verifier 奖励 $\{r_{\text{func}}(s, a_i)\}_{i=1}^G$ 计算得到的式 (1) 中的组归一化优势。相较于端到端 RL, 训练期间唯一需要的在线交互只是给每个轮次级动作打分所需的那段短 rollout。

3.2. PivotRL 的理论分析

接下来我们分析第 3.1 节中的两个设计选择。首先，我们形式化说明：在组归一化的局部 RL 中，为什么“结果混合”的轮次才是值得投入预算的状态。随后，我们证明基于 verifier 的奖励会导向一种保守的、带 KL 正则的更新：它会增加局部可接受动作上的总概率质量，同时保持参考策略在可接受集合内外的相对排序。除特别说明外，本小节中都假设动作空间有限、 $\mathcal{M}(s) \neq \emptyset$ ，且对任意 s, a 都有 $\pi_0(a | s) > 0$ 。

命题 3.1 (只有结果混合的轮次才会产生非零的组归一化更新). 设 s 为固定状态， $\{r_i\}_{i=1}^G$ 是该状态下一个 rollout 组对应的二值奖励。如果所有奖励都相同，那么式 (1) 中的归一化优势对每个 i 都等于零。等价地说，只有奖励方差为正的 rollout 组，才会对组归一化更新产生非零贡献。

命题 3.1 直接解释了为什么在 RL 之前要先筛轮次：如果某个轮次在局部采样下要么总是容易、要么根本不可能成功，那么把 rollout 预算花在它身上就不会在组归一化训练下改变策略。

对任意定义在 $\mathcal{A}(s)$ 上的分布 π ，记

$$T_\pi = \{v : \mathcal{A}(s) \rightarrow \mathbb{R} : \mathbb{E}_{a \sim \pi}[v(a)] = 0\}, \quad \langle u, v \rangle_{F, \pi} = \mathbb{E}_{a \sim \pi}[u(a)v(a)],$$

并令 $\nabla^{\text{nat}} J_s(\pi) \in T_\pi$ 表示在该 Fisher 几何下 J_s 的自然梯度。

定理 3.2 (奖励方差决定局部 GRPO 信号强度). 考虑状态级期望奖励目标

$$J_s(\pi) = \mathbb{E}_{a \sim \pi}[r(s, a)],$$

以及 KL 路径

$$\pi_{s, \beta}(a) = \frac{\pi_0(a | s) e^{r(s, a)/\beta}}{\sum_{b \in \mathcal{A}(s)} \pi_0(b | s) e^{r(s, b)/\beta}}.$$

定义总体 GRPO 分数

$$\gamma_{s, \beta} := -\mathbb{E}_{a \sim \pi_{s, \beta}} \left[\frac{r(s, a) - \mathbb{E}_{a' \sim \pi_{s, \beta}}[r(s, a')]}{\sqrt{\text{Var}_{a' \sim \pi_{s, \beta}}(r(s, a'))}} \partial_\beta \log \pi_{s, \beta}(a) \right]. \quad (9)$$

则有

$$\gamma_{s, \beta} = \frac{1}{\beta^2} \left\| \nabla^{\text{nat}} J_s(\pi_{s, \beta}) \right\|_{F, \pi_{s, \beta}} = \frac{\sqrt{\text{Var}_{a \sim \pi_{s, \beta}}(r(s, a))}}{\beta^2}. \quad (10)$$

特别地，在固定 β 的情况下，奖励方差越大的状态，其自然梯度范数与总体 GRPO 分数也越大。

解释。定理 3.2 针对理想化的、带 KL 正则的状态级更新路径 $\pi_{s, \beta} \propto \pi_0 e^{r(s, \cdot)/\beta}$ ，给出了一个总体、路径级的结论。它表明，对于组归一化局部 RL 来说，奖励方差并不只是启发式诊断量，而是 KL 路径上局部自然梯度信号的精确尺度。对二值 verifier 奖励而言，更大的方差意味着这个轮次上成功与失败更加混合，这正是 PivotRL 要优先筛选此类轮次的原因。

定理 3.3 (功能奖励以最小 KL 变化把概率质量推向可接受动作). 固定 $\beta > 0$ ，考虑带正则项的目标

$$\mathcal{L}_{\text{func}, \beta}(\pi) = \mathbb{E}_{s \sim d} \left[-\mathbb{E}_{a \sim \pi(\cdot | s)}[r_{\text{func}}(s, a)] + \beta \text{KL}(\pi(\cdot | s) \| \pi_0(\cdot | s)) \right], \quad (11)$$

其中 $r_{\text{func}}(s, a) = \mathbf{1}[a \in \mathcal{M}(s)]$ ， d 为一个固定的状态分布。对每个状态 s ，定义

$$\rho(s) = \pi_0(\mathcal{M}(s) | s), \quad q_\beta(s) = \frac{\rho(s) e^{1/\beta}}{(1 - \rho(s)) + \rho(s) e^{1/\beta}}. \quad (12)$$

基准	Base	SFT	PivotRL	相对 SFT 的 Δ
τ^2 -Bench	44.35	58.44	63.81	+5.37
SWE-Bench Verified	19.07	37.40	32.67	-4.73
Terminal-Bench	5.42	13.75	20.00	+6.25
BrowseComp	2.50	1.50	11.30	+9.80

Table 1 | 域内结果。Base 指 Qwen3-30B-A3B-Thinking-2507; SFT 与 PivotRL 使用完全相同的训练数据。PivotRL 在四个基准中的三个上优于 SFT，相对 Base 的平均提升为 +14.11，而 SFT 为 +9.94。

那么， $\mathcal{L}_{\text{func},\beta}$ 存在唯一极小化解 π_β^* ，使得对每个状态 s （在 d -几乎处处意义下）都有

$$\pi_\beta^*(\mathcal{M}(s) | s) = q_\beta(s) \geq \rho(s), \quad (13)$$

且当 $0 < \rho(s) < 1$ 时不等号严格成立。进一步地，在所有满足式 (13) 的分布中， $\pi_\beta^*(\cdot | s)$ 是

$$\text{KL}(\pi(\cdot | s) \| \pi_0(\cdot | s))$$

的唯一极小化解，并且它保持了参考策略在 $\mathcal{M}(s)$ 及其补集 $\mathcal{M}(s)^c$ 内部的相对排序：

$$\frac{\pi_\beta^*(a | s)}{\pi_\beta^*(b | s)} = \frac{\pi_0(a | s)}{\pi_0(b | s)} \quad \text{当 } a, b \in \mathcal{M}(s), \quad \frac{\pi_\beta^*(a | s)}{\pi_\beta^*(b | s)} = \frac{\pi_0(a | s)}{\pi_0(b | s)} \quad \text{当 } a, b \in \mathcal{M}(s)^c. \quad (14)$$

解释。定理 3.3 分离出了功能奖励本身的作用：它表明，基于功能奖励的 RL 所得到的极小策略，等价于把参考策略做 KL 投影，投影到“在可接受动作上拥有更高概率质量 $q_\beta(s)$ ”的策略集合上。由式 (14) 可知，功能奖励 RL 会同时保持 (i) 可接受动作集合内部，以及 (ii) 其补集内部的条件分布不变。由于助手轮次的动作空间呈指数级大，任意给定动作通常只与单个任务相关。在这一假设下，不可接受动作的补集可视为与当前任务无关的动作集合，因此这些与任务无关动作之间的相对排序会被保留，这也解释了 PivotRL 为什么能够较好地保留 OOD 性能。

4. 实验

如第 4.1 节所示，PivotRL 相比同数据 SFT 带来了更大的域内收益，同时几乎消除了 OOD 退化。在 SWE-Bench 上，端到端 RL (E2E RL) 通常被视为标准训练范式，而如第 4.2 节所示，PivotRL 在无需多轮环境 rollout 的前提下就能达到可比的准确率。第 4.3 节的消融实验进一步表明，pivot 筛选和功能奖励两者都是获得完整收益所必需的。

设置。我们分别在四个智能体领域上训练模型，即对话式工具使用、软件工程、终端控制和网页浏览，并分别在对应基准上评估： τ^2 -Bench (Barres et al., 2025)、SWE-Bench Verified (Jimenez et al., 2024)、Terminal-Bench (Team, 2025c) 和 BrowseComp (Wei et al., 2025)。所有实验都从 Qwen3-30B-A3B-Thinking-2507 (下文简称“Base”) 出发，使用 Nemo-RL (NVIDIA, 2025b) 进行优化，并用 Nemo-Gym (NVIDIA, 2025a) 执行环境 rollout。对每一组 SFT 与 PivotRL 的比较，基座模型、提示词与专家轨迹都完全相同。各领域特定的数据构建、verifier 设计与超参数见附录 A.2。

4.1. 域内与 OOD 准确率

表 1 给出了各训练领域上的域内准确率。PivotRL 在 τ^2 -Bench (+5.37)、Terminal-Bench (+6.25) 和 BrowseComp (+9.80) 上都优于 SFT，相对 Base 的平均域内提升为 +14.11，而 SFT 为 +9.94。更关

OOD 基准	Base	Δ SFT	Δ PivotRL
IFBench	52.04	-11.46	+0.82
AIME25	86.04	-19.72	-1.20
MATH500	98.05	-8.51	+0.35
LiveCodeBench	66.52	-7.76	-0.17
Scicode	36.83	-11.39	+1.90
MMLU-Pro	80.84	-2.99	+0.31
MMLU-ProX	78.58	-7.16	+0.12
WMT24++	36.97	-9.61	-0.49
平均	66.62	-9.83	+0.21

Table 2 | 相对于 Base 的 OOD 性能变化 (Δ)，这里对表 1 中四次训练的结果做平均。SFT 平均退化 -9.83 ；PivotRL 基本保持不变 ($+0.21$)。




Figure 1 | SWE-Bench 上训练准确率与 (a) 累计 rollout 轮次数、(b) 累计 rollout 时间的关系，所有方法使用相同数量的计算节点。PivotRL 以约 $\sim 4\times$ 更少的 rollout 轮次数和约 $\sim 5.5\times$ 更短的训练时间，达到了与 E2E RL 可比的准确率。

键的是 OOD 保留能力。表 2 报告了四次训练在八个 OOD 基准上的平均变化。SFT 的平均 OOD 变化为 -9.83 ，最差情况出现在终端领域训练后 (AIME25 下降 -64.48 ，MATH500 下降 -34.50)。相比之下，PivotRL 在所有基准上都基本维持 Base 水平，平均变化为 $+0.21$ ，且单个基准上的最大下降也不超过 -3.12 。表 3 给出了按训练领域拆分的完整结果。对每个训练领域而言，PivotRL (rl) 都能保持 OOD 性能，而 SFT (sft) 会造成广泛退化，终端领域训练后的退化尤其明显，此时 AIME25 从 86.04 跌到 21.56。

4.2. 在 SWE-Bench 上与端到端 RL 的比较

SWE-Bench 是一个天然的对比点，因为对软件工程智能体来说，E2E RL 是标准训练方式：每个 GitHub issue 都需要一条多轮工具使用轨迹，而评测 harness 提供二值成功信号。为了比较 rollout 成本，我们统计总 rollout 轮次数：对 PivotRL 而言，每个训练样本只对应一次单轮 rollout，因此总数等于训练样本数；对 E2E RL 而言，我们对所有训练轨迹的轮次数求和。

所有方法都从 Base 出发，并使用 OpenHands harness (Wang et al., 2025b) 评测。图 1 展示了准确率相对于累计 rollout 轮次数和累计 rollout 时间的变化。为了达到相同准确率，PivotRL 需要的 rollout 轮次数约少 $\sim 4\times$ ，在相同计算节点数下所需墙钟时间约少 $\sim 5.5\times$ 。

Benchmark	Base	τ^2		SWE	
		sft	rl	sft	rl
Peak In-Domain	–	58.44 (+14.09)	63.81 (+19.46)	37.40 (+18.33)	32.67 (+13.60)
IFBench	52.04	44.42 (-7.62)	53.29 (+1.25)	38.80 (-13.24)	54.79 (+2.75)
AIME25	86.04	76.25 (-9.79)	85.63 (-0.41)	82.29 (-3.75)	85.00 (-1.04)
MATH500	98.05	98.00 (-0.05)	98.35 (+0.30)	98.30 (+0.25)	98.65 (+0.60)
LiveCodeBench	66.52	64.98 (-1.54)	66.96 (+0.44)	57.27 (-9.25)	66.96 (+0.44)
Scicode	36.83	31.95 (-4.88)	38.68 (+1.85)	24.85 (-11.98)	39.87 (+3.04)
MMLU-Pro	80.84	79.81 (-1.03)	81.31 (+0.47)	78.90 (-1.94)	81.13 (+0.29)
MMLU-ProX	78.58	74.31 (-4.27)	78.92 (+0.34)	75.58 (-3.00)	78.81 (+0.23)
WMT24++	36.97	34.25 (-2.72)	36.54 (-0.43)	35.69 (-1.28)	36.66 (-0.31)

Benchmark	Base	Terminal		BrowseComp	
		sft	rl	sft	rl
Peak In-Domain	–	13.75 (+8.33)	20.00 (+14.58)	1.50 (-1.00)	11.30 (+8.80)
IFBench	52.04	24.77 (-27.27)	49.47 (-2.57)	54.35 (+2.31)	53.89 (+1.85)
AIME25	86.04	21.56 (-64.48)	82.92 (-3.12)	85.21 (-0.83)	85.83 (-0.21)
MATH500	98.05	63.55 (-34.50)	98.00 (-0.05)	98.30 (+0.25)	98.40 (+0.35)
LiveCodeBench	66.52	45.15 (-21.37)	64.54 (-1.98)	67.62 (+1.10)	66.96 (+0.44)
Scicode	36.83	9.39 (-27.44)	39.13 (+2.30)	35.58 (-1.25)	37.28 (+0.45)
MMLU-Pro	80.84	71.57 (-9.27)	80.85 (+0.01)	81.13 (+0.29)	81.31 (+0.47)
MMLU-ProX	78.58	59.13 (-19.45)	78.49 (-0.09)	76.68 (-1.90)	78.60 (+0.02)
WMT24++	36.97	6.31 (-30.66)	36.48 (-0.49)	33.18 (-3.79)	36.26 (-0.71)

Table 3 | 四次单领域训练的逐领域 OOD 结果。每个单元格中先给出分数，再给出相对 Base 的 Δ 。PivotRL (rl) 持续保持了 OOD 性能，而 SFT (sft) 则出现普遍退化，尤其是在终端领域训练后最为明显。

4.3. 消融实验

我们在表 4 中给出了消融结果。为了分别考察 PivotRL 各个组成部分的贡献，我们在 τ^2 -Bench 上每次去掉一个组件。去掉筛选后，准确率从 63.81 降到 59.68；去掉功能奖励后，结果进一步降到 57.34。Pivot 的作用在于把 rollout 集中到那些仍然具有非零优势信号的状态上（命题 3.1），而功能奖励则保证了那些虽然文本不同、但语义正确的动作仍然能够获得信用。

图 2 与图 3 展示了这些收益背后的训练动态。在随机采样下，每个 batch 的奖励方差很快塌缩，说明多数被采样到的 pivot 已不再提供有效的优势信号。相比之下，经过筛选的 pivot 集合能够在训练更深阶段维持更高的奖励方差，并优化到更高的验证准确率。

4.4. 集成到大规模后训练中

PivotRL 被用于 Nemotron-3-Super 的大规模后训练过程中 (Team, 2026)。表 5 给出了 Nemotron-3-Super 后训练流水线中的智能体基准准确率，其中 PivotRL 负责智能体环境，而其他 RL 环境负责推理与对话。

配置	τ^2 -Bench
完整 PivotRL ($\mathcal{D}_{adv}$ + functional reward)	63.81
– Pivot 筛选 ($\mathcal{D}_{cand}$ + functional reward)	59.68
– Functional reward ($\mathcal{D}_{cand}$ + strict reward)	57.34
同数据 SFT	58.44
Base	44.35

Table 4 | τ^2 -Bench 上的消融结果。Pivot 筛选和功能奖励两者都不可或缺；去掉任意一个都会降低准确率。




Figure 2 | τ^2 -Bench 上 RL 训练过程中的准确率。 $\mathcal{D}_{adv}$ 的优化效果最强，并优于同数据 SFT。




Figure 3 | τ^2 -Bench 上 RL 训练过程中的奖励标准差。 $\mathcal{D}_{adv}$ 维持了更高的奖励方差，因此局部更新信息量也更高。

5. 相关工作

5.1. 智能体 LLM 与训练方案

智能体语言模型会在自然语言与接地动作之间交替，从而完成跨工具、代码与网页导航的复杂环境交互 (Yao et al., 2023; Schick et al., 2023; Xu et al., 2023; Qin et al., 2023; Shridhar et al., 2021; Wang et al., 2022; Jimenez et al., 2024; Wang et al., 2025b; Pan et al., 2025; Yao et al., 2022; Wei et al., 2025; Ma et al., 2024; Wang et al., 2024)。强化学习 (RL) 进一步优化了多轮探索与信用分配 (Ouyang et al., 2022; Schulman et al., 2017, 2015; Wang et al., 2025a; Song et al., 2024; Zhang et al., 2025)，并受益于近来在可扩展策略优化、分层建模与多智能体协同方面的进展 (Ji et al., 2025; Rohatgi et al., 2025; Xue et al., 2025; Dong et al., 2025a; Yang et al., 2025; Yu et al., 2025; Luo et al., 2025a; Dong et al., 2025b; Su et al., 2025; Zhou et al., 2024; Prabhakar et al., 2025; Zhou et al., 2025; Xi et al., 2025)。与此同时，带可验证奖励的 RL (RLVR) 在推理类任务中取得了成功 (Shao et al., 2024; Xin et al., 2024; DeepSeek-AI, 2025a; Team, 2025a)，而 on-policy distillation 则被用于缓解 off-policy 分布偏移 (Lu & Lab, 2025; Zhao et al., 2026; Liu et al., 2025a; Hübotter et al., 2026)。我们的工作正位于这一交叉点上：我们面向智能体任务，把监督轨迹转写成轮次级 verifier 奖励，从而在不引入独立奖励模型的情况下进行 on-policy 优化。

5.2. 把行为克隆改造成 RL

离线监督微调 (SFT) 经常遭遇灾难性遗忘和泛化退化 (Luo et al., 2025b; Li et al., 2024; Imanov, 2026; Kirkpatrick et al., 2017; Li & Hoiem, 2016)，这一现象也与“表层对齐假说”一致 (Zhou et al., 2023; Vergara-Browne et al., 2026; Raghavendra et al., 2024)。从理论上讲，离线模仿学习的次优性会随着任务时域长度呈平方增长 (Rajaraman et al., 2020)，因此往往需要通过在线数据聚合引入环境交互才能弥补 (Ross et al., 2011; Swamy et al., 2023)。关键在于，on-policy RL 能通过保留更广泛的能力来缓解

基准	Nemotron-3-Super SFT	经过 PivotRL 阶段后
τ^2 -Bench	48.00	64.00
SWE-Bench Verified	12.87	61.33
Terminal-Bench 1.1 Core	23.33	34.17
BrowseComp	13.03	25.04

Table 5 | Nemotron-3-Super 在 RL 阶段前后的智能体基准准确率。该 RL 阶段在智能体垂直领域中包含 PivotRL 环境，在推理与对话领域中包含其他 RL 环境。

这类遗忘 (Shenfeld et al., 2025; Chen et al., 2025)。为了把离线知识迁移到在线阶段，已有方法会将专家演示与 RL 更新结合 (Uchendu et al., 2023; Hester et al., 2018)、利用部分轨迹前缀 (Setlur et al., 2026)，或者把 SFT token 重新用作 rollout 奖励 (Ming et al., 2026)。在这条 SFT 到 RL 的桥梁上，我们的方法进一步针对多轮工具使用场景，提出了基于轮次的 pivot 筛选与功能奖励。

6. 结论

本文提出了 PivotRL，这是一种轮次级强化学习算法，旨在以可承受的方式为大语言模型执行长时程智能体任务的后训练。我们在四个不同的智能体领域上的实验表明，该方法同时具备有效性与可扩展性。与使用相同数据的标准 SFT 相比，PivotRL 的域内平均准确率高出 +4.17，同时在 OOD 保留上多出 +10.04 的优势，显著缓解了灾难性遗忘。进一步地，与端到端 RL 相比，PivotRL 能以更低得多的计算成本取得相近准确率。PivotRL 的性能收益主要来自两点：一是 on-policy rollout 带来了更充分的动作空间覆盖，二是 verifier 产生的奖励能为功能正确的动作分配信用。未来，我们计划把该框架扩展到非程序化 verifier，例如 LLM-as-a-judge 框架 (Zheng et al., 2023) 和过程奖励模型 (Lightman et al., 2023)，同时探索动态采样等在线奖励剖析方法 (Yu et al., 2025)。

References

- Anomaly. Opencode: The open source coding agent, 2026. URL <https://github.com/anomalyco/opencode>.
- Victor Barres, Honghua Dong, Soham Ray, Xujie Si, and Karthik Narasimhan. τ^2 -bench: Evaluating conversational agents in a dual-control environment, 2025. URL <https://arxiv.org/abs/2506.07982>.
- Howard Chen, Noam Razin, Karthik Narasimhan, and Danqi Chen. Retaining by doing: The role of on-policy data in mitigating forgetting, 2025. URL <https://arxiv.org/abs/2510.18874>.
- Tianzhe Chu, Yuexiang Zhai, Jihan Yang, Shengbang Tong, Saining Xie, Dale Schuurmans, Quoc V. Le, Sergey Levine, and Yi Ma. Sft memorizes, rl generalizes: A comparative study of foundation model post-training, 2025. URL <https://arxiv.org/abs/2501.17161>.
- DeepSeek-AI. Deepseek-r1 incentivizes reasoning in llms through reinforcement learning. *Nature*, 645 (8081):633–638, September 2025a. ISSN 1476-4687. doi: 10.1038/s41586-025-09422-z. URL <http://dx.doi.org/10.1038/s41586-025-09422-z>.
- DeepSeek-AI. Deepseek-v3.2: Pushing the frontier of open large language models, 2025b. URL <https://arxiv.org/abs/2512.02556>.
- Guanting Dong, Yifei Chen, Xiaoxi Li, Jiajie Jin, Hongjin Qian, Yutao Zhu, Hangyu Mao, Guorui Zhou, Zhicheng Dou, and Ji-Rong Wen. Tool-star: Empowering LLM-brained multi-tool reasoner via reinforcement learning, 2025a. URL <https://arxiv.org/abs/2505.16410>.

- Guanting Dong, Hangyu Mao, Kai Ma, Licheng Bao, Yifei Chen, Zhongyuan Wang, Zhongxia Chen, Jiazhen Du, Huiyang Wang, Fuzheng Zhang, Guorui Zhou, Yutao Zhu, Ji-Rong Wen, and Zhicheng Dou. Agentic reinforced policy optimization, 2025b. URL <https://arxiv.org/abs/2507.19849>.
- Todd Hester, Matej Vecerik, Olivier Pietquin, Marc Lanctot, Tom Schaul, Bilal Piot, Dan Horgan, John Quan, Andrew Sendonaris, Ian Osband, Gabriel Dulac-Arnold, John Agapiou, Joel Z. Leibo, and Audrunas Gruslys. Deep q-learning from demonstrations. In *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence*, AAAI’18/IAAI’18/EAAI’18. AAAI Press, 2018. ISBN 978-1-57735-800-8.
- Jonas Hübner, Frederike Lübeck, Lejs Behric, Anton Baumann, Marco Bagatella, Daniel Marta, Ido Hakimi, Idan Shenfeld, Thomas Kleine Buening, Carlos Guestrin, and Andreas Krause. Reinforcement learning via self-distillation, 2026. URL <https://arxiv.org/abs/2601.20802>.
- Olaf Yunus Laitinen Imanov. Mechanistic analysis of catastrophic forgetting in large language models during continual fine-tuning, 2026. URL <https://arxiv.org/abs/2601.18699>.
- Naman Jain, Jaskirat Singh, Manish Shetty, Liang Zheng, Koushik Sen, and Ion Stoica. R2e-gym: Procedural environments and hybrid verifiers for scaling open-weights swe agents, 2025. URL <https://arxiv.org/abs/2504.07164>.
- Yuxiang Ji, Ziyu Ma, Yong Wang, Guanhua Chen, Xiangxiang Chu, and Liaoni Wu. Tree search for LLM agent reinforcement learning, 2025. URL <https://arxiv.org/abs/2509.21240>.
- Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik R Narasimhan. SWE-bench: Can language models resolve real-world github issues? In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=VTF8yNQm66>.
- James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, Demis Hassabis, Claudia Clopath, Dharshan Kumaran, and Raia Hadsell. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017. doi: 10.1073/pnas.1611835114. URL <https://www.pnas.org/doi/abs/10.1073/pnas.1611835114>.
- Hongyu Li, Liang Ding, Meng Fang, and Dacheng Tao. Revisiting catastrophic forgetting in large language model tuning. *arXiv preprint arXiv:2406.04836*, 2024. doi: 10.48550/arXiv.2406.04836. URL <https://arxiv.org/abs/2406.04836>.
- Zhizhong Li and Derek Hoiem. Learning without forgetting. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2016. URL <https://arxiv.org/abs/1606.09282>.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step, 2023. URL <https://arxiv.org/abs/2305.20050>.
- Junnan Liu, Linhao Luo, Qianren Mao, Zhijun Chen, Zhuoran Li, Thuy-Trang Vu, and Gholamreza Hafari. Learning with interaction: Agentic distillation for large language model reasoning. In *International Conference on Learning Representations*, 2025a. URL <https://openreview.net/forum?id=zyp9QT5Gf1>.

- Weiwen Liu, Xu Huang, Xingshan Zeng, Xinlong Hao, Shuai Yu, Dexun Li, Shuai Wang, Weinan Gan, Zhengying Liu, Yuanqing Yu, Zezhong Wang, Yuxian Wang, Wu Ning, Yutai Hou, Bin Wang, Chuhan Wu, Xinzhi Wang, Yong Liu, Yasheng Wang, Duyu Tang, Dandan Tu, Lifeng Shang, Xin Jiang, Ruiming Tang, Defu Lian, Qun Liu, and Enhong Chen. Toolace: Winning the points of llm function calling, 2025b. URL <https://arxiv.org/abs/2409.00920>.
- Kevin Lu and Thinking Machines Lab. On-policy distillation. *Thinking Machines Lab: Connectionism*, 2025. URL <https://thinkingmachines.ai/blog/on-policy-distillation>.
- Xufang Luo, Yuge Zhang, Zhiyuan He, Zilong Wang, Siyun Zhao, Dongsheng Li, Luna K. Qiu, and Yuqing Yang. Agent lightning: Train any ai agents with reinforcement learning, 2025a. URL <https://arxiv.org/abs/2508.03680>.
- Yun Luo, Zhen Yang, Fandong Meng, Yafu Li, Jie Zhou, and Yue Zhang. An empirical study of catastrophic forgetting in large language models during continual fine-tuning, 2025b. URL <https://arxiv.org/abs/2308.08747>.
- Chang Ma, Junlei Zhang, Zhihao Zhu, Cheng Yang, Yujiu Yang, Yaohui Jin, Zhenzhong Lan, Lingpeng Kong, and Junxian He. Agentboard: An analytical evaluation board of multi-turn LLM agents, 2024. URL <https://arxiv.org/abs/2401.13178>.
- Rui Ming, Haoyuan Wu, Shoubo Hu, Zhuolun He, and Bei Yu. One-token rollout: Guiding supervised fine-tuning of llms with policy gradient, 2026. URL <https://arxiv.org/abs/2509.26313>.
- MiniMax. Minimax-m2.5, 2026. URL <https://huggingface.co/MiniMaxAI/MiniMax-M2.5>.
- NVIDIA. Nemo gym: An open source library for scaling reinforcement learning environments for llm. <https://github.com/NVIDIA-NeMo/Gym>, 2025a. GitHub repository.
- NVIDIA. Nemo rl: A scalable and efficient post-training library. <https://github.com/NVIDIA-NeMo/RL>, 2025b. GitHub repository.
- OpenAI. Openai codex: The coding agent for software development, 2026. URL <https://developers.openai.com/codex>.
- Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback, 2022. URL <https://arxiv.org/abs/2203.02155>.
- Jiayi Pan, Xingyao Wang, Graham Neubig, Navdeep Jaitly, Heng Ji, Alane Suhr, and Yizhe Zhang. Training software engineering agents and verifiers with swe-gym, 2025. URL <https://arxiv.org/abs/2412.21139>.
- Akshara Prabhakar, Zuxin Liu, Ming Zhu, Jianguo Zhang, Tulika Awalgaonkar, Shiyu Wang, Zhiwei Liu, Haolin Chen, Thai Hoang, Juan Carlos Niebles, Shelby Heinecke, Weiran Yao, Huan Wang, Silvio Savarese, and Caiming Xiong. Apigen-mt: Agentic pipeline for multi-turn data generation via simulated agent-human interplay, 2025. URL <https://arxiv.org/abs/2504.03601>.
- Yujia Qin, Shihao Liang, Yining Ye, Kunlun Zhu, Lan Yan, Yaxi Lu, Yankai Lin, Xin Cong, Xiangru Tang, Bill Qian, Sihan Zhao, Lauren Hong, Runchu Tian, Ruobing Xie, Jie Zhou, Mark Gerstein, Dahai Li, Zhiyuan Liu, and Maosong Sun. Toolllm: Facilitating large language models to master 16000+ real-world apis, 2023. URL <https://arxiv.org/abs/2307.16789>.

- Mohit Raghavendra, Vaskar Nath, and Sean Hendryx. Revisiting the superficial alignment hypothesis, 2024. URL <https://arxiv.org/abs/2410.03717>.
- Nived Rajaraman, Lin F. Yang, Jiantao Jiao, and Kannan Ramchandran. Toward the fundamental limits of imitation learning. *Advances in Neural Information Processing Systems*, 33:2914–2924, 2020.
- Dhruv Rohatgi, Abhishek Shetty, Donya Saleh, Yuchen Li, Ankur Moitra, Andrej Risteski, and Dylan J. Foster. Taming imperfect process verifiers: A sampling perspective on backtracking, 2025. URL <https://arxiv.org/abs/2510.03149>.
- Stéphane Ross, Geoffrey J. Gordon, and J. Andrew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011. URL <http://proceedings.mlr.press/v15/ross11a.html>.
- Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools, 2023. URL <https://arxiv.org/abs/2302.04761>.
- John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In Francis Bach and David Blei (eds.), *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pp. 1889–1897, Lille, France, 07–09 Jul 2015. PMLR. URL <https://proceedings.mlr.press/v37/schulman15.html>.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms, 2017. URL <https://arxiv.org/abs/1707.06347>.
- Amrith Setlur, Zijian Wang, Andrew Cohen, Paria Rashidinejad, and Sang Michael Xie. Reuse your flops: Scaling rl on hard problems by conditioning on very off-policy prefixes, 2026. URL <https://arxiv.org/abs/2601.18795>.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y.K. Li, Y. Wu, and Daya Guo. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Idan Shenfeld, Jyothish Pari, and Pulkit Agrawal. RL’s razor: Why online reinforcement learning forgets less, 2025. URL <https://arxiv.org/abs/2509.04259>.
- Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. Alfworld: Aligning text and embodied environments for interactive learning, 2021. URL <https://arxiv.org/abs/2010.03768>.
- Yifan Song, Da Yin, Xiang Yue, Jie Huang, Sujian Li, and Bill Yuchen Lin. Trial and error: Exploration-based trajectory optimization for LLM agents, 2024. URL <https://arxiv.org/abs/2403.02502>.
- Hongjin Su, Shizhe Diao, Ximing Lu, Mingjie Liu, Jiacheng Xu, Xin Dong, Yonggan Fu, Peter Belcak, Hanrong Ye, Hongxu Yin, Yi Dong, Evelina Bakhturina, Tao Yu, Yejin Choi, Jan Kautz, and Pavlo Molchanov. Toolorchestra: Elevating intelligence via efficient model and tool orchestration, 2025. URL <https://arxiv.org/abs/2511.21689>.
- Gokul Swamy, Nived Rajaraman, Matthew Peng, Sanjiban Choudhury, J. Andrew Bagnell, Zhiwei Steven Wu, Jiantao Jiao, and Kannan Ramchandran. Minimax optimal online imitation learning via replay estimation, 2023. URL <https://arxiv.org/abs/2205.15397>.

- GLM-4.5 Team. Glm-4.5: Agentic, reasoning, and coding (arc) foundation models, 2025a. URL <https://arxiv.org/abs/2508.06471>.
- Kimi Team. Kimi k2: Open agentic intelligence, 2025b. URL <https://arxiv.org/abs/2507.20534>.
- NVIDIA Nemotron Team. Nvidia nemotron-3 super technical report. <https://research.nvidia.com/labs/nemotron/files/NVIDIA-Nemotron-3-Super-Technical-Report.pdf>, 2026. NVIDIA Research Technical Report.
- The Terminal-Bench Team. Terminal-bench: A benchmark for ai agents in terminal environments, Apr 2025c. URL <https://github.com/laude-institute/terminal-bench>.
- Ikechukwu Uchendu, Ted Xiao, Yao Lu, Banghua Zhu, Mengyuan Yan, Joséphine Simon, Matthew Ben-
nice, Chuyuan Fu, Cong Ma, Jiantao Jiao, Sergey Levine, and Karol Hausman. Jump-start reinforcement
learning. In *International Conference on Machine Learning*, 2023.
- Tomás Vergara-Browne, Darshan Patil, Ivan Titov, Siva Reddy, Tiago Pimentel, and Marius Mosbach. Op-
erationalising the superficial alignment hypothesis via task complexity, 2026. URL <https://arxiv.org/abs/2602.15829>.
- Hanlin Wang, Chak Tou Leong, Jiashuo Wang, Jian Wang, and Wenjie Li. Spa-rl: Reinforcing LLM agents
via stepwise progress attribution, 2025a. URL <https://arxiv.org/abs/2505.20732>.
- Ruiyi Wang, Haoifei Yu, Wenxin Zhang, Zhengyang Qi, Maarten Sap, Graham Neubig, Yonatan Bisk, and
Hao Zhu. Sotopia- π : Interactive learning of socially intelligent language agents, 2024. URL <https://arxiv.org/abs/2403.08715>.
- Ruoyao Wang, Peter Jansen, Marc-Alexandre Côté, and Prithviraj Ammanabrolu. Scienceworld: Is your
agent smarter than a 5th grader?, 2022. URL <https://arxiv.org/abs/2203.07540>.
- Xingyao Wang, Boxuan Li, Yufan Song, Frank F. Xu, Xiangru Tang, Mingchen Zhuge, Jiayi Pan, Yueqi Song,
Bowen Li, Jaskirat Singh, Hoang H. Tran, Fuqiang Li, Ren Ma, Mingzhang Zheng, Bill Qian, Yanjun Shao,
Niklas Muennighoff, Yizhe Zhang, Binyuan Hui, Junyang Lin, Robert Brennan, Hao Peng, Heng Ji, and
Graham Neubig. Openhands: An open platform for ai software developers as generalist agents, 2025b.
URL <https://arxiv.org/abs/2407.16741>.
- Jason Wei, Zhiqing Sun, Spencer Papay, Scott McKinney, Jeffrey Han, Isa Fulford, Hyung Won Chung,
Alex Tachard Passos, William Fedus, and Amelia Glaese. Browsecomp: A simple yet challenging bench-
mark for browsing agents, 2025. URL <https://arxiv.org/abs/2504.12516>.
- Zhiheng Xi, Jixuan Huang, Chenyang Liao, Baodai Huang, Honglin Guo, Jiaqi Liu, Rui Zheng, Junjie Ye, Ji-
azheng Zhang, Wenxiang Chen, Wei He, Yiwen Ding, Guanyu Li, Zehui Chen, Zhengyin Du, Xuesong Yao,
Yufei Xu, Jiecao Chen, Tao Gui, Zuxuan Wu, Qi Zhang, Xuanjing Huang, and Yu-Gang Jiang. Agentgym-
rl: Training LLM agents for long-horizon decision making through multi-turn reinforcement learning,
2025. URL <https://arxiv.org/abs/2509.08755>.
- Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh Jing Hua, Zhou-
jun Cheng, Dongchan Shin, Fangyu Lei, Yitao Liu, Yiheng Xu, Shuyan Zhou, Silvio Savarese, Caiming
Xiong, Victor Zhong, and Tao Yu. Osworld: Benchmarking multimodal agents for open-ended tasks in
real computer environments, 2024. URL <https://arxiv.org/abs/2404.07972>.
- Huajian Xin, Z. Z. Ren, Junxiao Song, Zhihong Shao, Wanjia Zhao, Haocheng Wang, Bo Liu, Liyue Zhang,
Xuan Lu, Qiushi Du, Wenjun Gao, Qihao Zhu, Dejian Yang, Zhibin Gou, Z. F. Wu, Fuli Luo, and Chong

- Ruan. Deepseek-prover-v1.5: Harnessing proof assistant feedback for reinforcement learning and monte-carlo tree search, 2024. URL <https://arxiv.org/abs/2408.08152>.
- Qiantong Xu, Fenglu Hong, Bo Li, Changran Hu, Zhengyu Chen, and Jian Zhang. On the tool manipulation capability of open-source large language models, 2023. URL <https://arxiv.org/abs/2305.16504>.
- Zhenghai Xue, Longtao Zheng, Qian Liu, Yingru Li, Xiaosen Zheng, Zejun Ma, and Bo An. Simpletir: End-to-end reinforcement learning for multi-turn tool-integrated reasoning, 2025. URL <https://arxiv.org/abs/2509.02479>.
- Shihui Yang, Chengfeng Dou, Peidong Guo, Kai Lu, Qiang Ju, Fei Deng, and Rihui Xin. Dcpo: Dynamic clipping policy optimization, 2025. URL <https://arxiv.org/abs/2509.02333>.
- Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. Webshop: Towards scalable real-world web interaction with grounded language agents, 2022. URL <https://arxiv.org/abs/2207.01206>.
- Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models, 2023. URL <https://arxiv.org/abs/2210.03629>.
- Qiyang Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, Xin Liu, Haibin Lin, Zhiqi Lin, Bole Ma, Guangming Sheng, Yuxuan Tong, Chi Zhang, Mofan Zhang, Wang Zhang, Hang Zhu, Jinhua Zhu, Jiaze Chen, Jiangjie Chen, Chengyi Wang, Hongli Yu, Yuxuan Song, Xiangpeng Wei, Hao Zhou, Jingjing Liu, Wei-Ying Ma, Ya-Qin Zhang, Lin Yan, Mu Qiao, Yonghui Wu, and Mingxuan Wang. Dapo: An open-source llm reinforcement learning system at scale, 2025. URL <https://arxiv.org/abs/2503.14476>.
- Zijing Zhang, Ziyang Chen, Mingxiao Li, Zhaopeng Tu, and Xiaolong Li. Rlvmr: Reinforcement learning with verifiable meta-reasoning rewards for robust long-horizon agents, 2025. URL <https://arxiv.org/abs/2507.22844>.
- Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. Self-distilled reasoner: On-policy self-distillation for large language models, 2026.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging llm-as-a-judge with mt-bench and chatbot arena, 2023. URL <https://arxiv.org/abs/2306.05685>.
- Chunting Zhou, Pengfei Liu, Puxin Xu, Srinu Iyer, Jiao Sun, Yuning Mao, Xuezhe Ma, Avia Efrat, Ping Yu, Lili Yu, Susan Zhang, Gargi Ghosh, Mike Lewis, Luke Zettlemoyer, and Omer Levy. Lima: Less is more for alignment, 2023. URL <https://arxiv.org/abs/2305.11206>.
- Yifei Zhou, Andrea Zanette, Jiayi Pan, Sergey Levine, and Aviral Kumar. Archer: Training language model agents via hierarchical multi-turn rl, 2024. URL <https://arxiv.org/abs/2402.19446>.
- Yifei Zhou, Song Jiang, Yuandong Tian, Jason Weston, Sergey Levine, Sainbayar Sukhbaatar, and Xian Li. Sweet-rl: Training multi-turn LLM agents on collaborative reasoning tasks, 2025. URL <https://arxiv.org/abs/2503.15478>.

A. 实验细节

本附录给出第 4 节实验所用的领域特定训练流程、术语约定以及更详细的消融分析。

A.1. 术语约定

在所有实验中，我们把从轨迹中抽取出的每个助手轮次都称为 *pivot candidate*，而把经过离线筛选、真正用于 PivotRL 训练的子集称为 *pivot*。一个 *action* 指的是一次模型调用边界上的完整助手续写，而不是单个 token。具体到不同基准，这个完整续写可能是对话式工具使用轮次、编程智能体工具调用、bash 命令，或一次搜索/浏览步骤；若某个基准包含纯自然语言的助手轮次，它们同样也被视为动作。

在单领域实验中，OOD change 表示模型在训练领域之外各个基准上的得分变化，相对于 base model 计算。

对于 pivot 选择，我们使用两个子集：*random* ($\mathcal{D}_{\text{cand}}$)，即直接使用全部 pivot candidate；以及 *low-reward-mean* ($\mathcal{D}_{\text{adv}}$)，即同时要求奖励方差非零，并且演示动作与参考策略平均奖励之间存在明显差距。

A.2. 领域特定训练细节

在四个领域中，我们都会先从演示轨迹中一次性抽取 pivot candidate，离线分析后再筛选，RL 训练时只从保留下来的集合中采样。下面分别介绍各个领域中的动作定义、数据构建和局部 verifier。

τ^2 -Bench。 我们使用一个合成数据生成流水线，构建了一个包含 281,774 条轨迹、覆盖 838 个 domain 的 SFT 轨迹数据集，做法与 ToolAce (Liu et al., 2025b)、Kimi-K2 (Team, 2025b) 和 DeepSeek-V3.2 (DeepSeek-AI, 2025b) 类似。训练基座为 Qwen3-30B-A3B-Thinking-2507。轨迹中的每个助手轮次都先被视作 pivot candidate。在该领域中，一个动作是模型调用边界上的完整助手轮次，其中可能包含自然语言、工具调用，或二者兼有。随后，我们按第 3.1 节中的方式比较 random 与 low-reward-mean pivot 集合。我们将对话式工具使用环境与数据发布在 Nemo-Gym 和 Nemotron-Post-Training-v3 中。

Terminal-Bench。 我们使用 Terminus-1 和 Terminus-2 智能体，从 Qwen/Qwen3-Coder-480B-A35B-Instruct 与 moonshotai/Kimi-K2-Instruct 收集已解决轨迹。每个助手 bash 动作都被视为 pivot candidate，而该领域中的动作就是模型调用边界上生成的下一个 bash 命令。我们从 low-reward-mean 集合 $\mathcal{D}_{\text{adv}}$ 出发，并额外进行命令去重，以提高多样性。最终数据集约含 20,000 个样本。局部 verifier 用于判断采样命令是否与演示命令在局部上可互换：它结合了输出模式校验、归一化字符串相似度以及基于等价性的 LLM-as-judge 打分，针对命令本身及其直接效果进行判定。

SWE-Bench Verified。 我们使用基于 OpenHands (Wang et al., 2025b)、OpenCode (Anomaly, 2026) 与 Codex (OpenAI, 2026) 生成的内部轨迹数据集；任务来自 SWE-Gym (Pan et al., 2025) 和 R2E-Gym (Jain et al., 2025)，基座模型为 MiniMaxAI/MiniMax-M2.5 (MiniMax, 2026)。我们使用 OpenHands harness 评测 mean@3。每个非错误的工具调用动作都视为 pivot candidate，而动作就是编程轨迹中的下一个助手工具调用。筛选到 $\mathcal{D}_{\text{adv}}$ 后，最终训练集包含 87,718 个样本。局部 verifier 只匹配工具调用名称。这是一个刻意设计得较粗粒度的局部信号：它只检查模型是否在 pivot 点选择了正确类别的下一步操作（例如 search、open、edit 或 run），而不试图在每个轮次上评估工具参数或 patch 质量。最终任务成功与否仍完全由 SWE-Bench 的完整评测 harness 决定。

对于第 4.2 节中的 E2E RL 对比，PivotRL 使用 batch size 为 1024（64 个 prompt $\times$ 16 个 generation），

	τ^2 - Airline	τ^2 - Retail	τ^2 - Telecom	τ^2 - Average
gpt-oss-120b-high	55.33	58.19	67.20	60.24
gpt-oss-20b-high	43.33	50.20	52.63	48.72
Qwen3-235B-A22B-Thinking-2507	50.00	66.08	46.78	54.29
Qwen3-30B-A3B-Thinking-2507	50.00	54.39	28.65	44.35
Qwen + SFT	51.33	58.19	65.79	58.44
Qwen + Random Pivots ($\mathcal{D}_{\text{cand}}$)	58.00	63.74	57.31	59.68
Qwen + Low-Reward-Mean Pivots ($\mathcal{D}_{\text{adv}}$)	58.67	69.01	63.74	63.81

Table 6 | τ^2 -Bench 上不同 pivot 选择策略的效果（训练过程中的最佳 checkpoint）。随机轮次相较基座模型已有提升，而 low-reward-mean pivots 表现更强。

每个样本只 rollout 1 个 turn；在第 130 步达到 32.67% 准确率时，累计 rollout turn 数约为 $\sim 133\text{K}$ 。E2E RL 基线使用 batch size 为 512（16 个 prompt $\times$ 32 个 generation），每条轨迹包含 12–25 个 turn；在大约第 72 步达到相同的 32.67% 准确率时，累计 rollout turn 数约为 $\sim 542\text{K}$ 。在这一对齐准确率下，PivotRL 所需 rollout turn 约少 $\sim 4\times$ ，墙钟时间约少 $\sim 5.5\times$ （见图 1）。两种方法使用相同数量的计算节点。

BrowseComp. 我们从一个多跳问答数据集出发，结合在线搜索引擎与 DeepSeek-V3.2 生成浏览轨迹。每个与搜索相关的助手步骤在模型调用边界上都被视为 pivot candidate；在该领域中，一个动作就是下一步浏览操作，例如发起搜索查询、打开搜索结果，或执行下一步证据收集动作。最终数据集包含 13,215 个样本。

A.3. 详细消融分析

A.3.1. τ^2 -Bench 上轮次选择策略的影响

我们在 τ^2 -Bench 上比较了两种 pivot 选择策略：

- random pivots ($\mathcal{D}_{\text{cand}}$): 不做筛选；
- low-reward-mean ($\mathcal{D}_{\text{adv}}$): 先保留结果混合的 pivot，再进一步保留那些演示动作奖励与参考策略平均值差距较大的轮次，具体见式 (5)。

表 6 表明，筛选越有针对性，收益越单调：random pivots 相比 SFT 已经有所提升（59.68 对 58.44），而 low-reward-mean pivots 则取得最佳结果（63.81）。

B. 省略证明

B.1. 定理 3.2 的证明

Proof. 固定状态 s 和 $\beta > 0$ 。为简便起见，记

$$\pi = \pi_{s,\beta}, \quad q = \mathbb{E}_{a \sim \pi}[r(s, a)], \quad \sigma^2 = \text{Var}_{a \sim \pi}(r(s, a)).$$

首先计算 J_s 在 π 处的自然梯度。令 $v \in T_\pi$ ，考虑指数扰动

$$\pi_t(a) = \frac{\pi(a)e^{tv(a)}}{\sum_{b \in \mathcal{A}(s)} \pi(b)e^{tv(b)}}.$$

对任意 $v \in T_\pi$, 有

$$\left. \frac{d}{dt} \right|_{t=0} \log \pi_t(a) = v(a) - \sum_{b \in \mathcal{A}(s)} \pi(b) v(b) = v(a).$$

因此

$$\begin{aligned} DJ_s(\pi)[v] &= \left. \frac{d}{dt} \right|_{t=0} \mathbb{E}_{a \sim \pi_t} [r(s, a)] \\ &= \left. \frac{d}{dt} \right|_{t=0} \sum_{a \in \mathcal{A}(s)} \pi_t(a) r(s, a) \\ &= \sum_{a \in \mathcal{A}(s)} \pi(a) r(s, a) v(a) \\ &= \sum_{a \in \mathcal{A}(s)} \pi(a) (r(s, a) - q) v(a) \\ &= \langle r(s, \cdot) - q, v \rangle_{F, \pi}. \end{aligned}$$

由于这一结论对所有 $v \in T_\pi$ 成立, 其 Riesz 表示元为

$$\nabla^{\text{nat}} J_s(\pi) = r(s, \cdot) - q.$$

于是有

$$\begin{aligned} \|\nabla^{\text{nat}} J_s(\pi)\|_{F, \pi}^2 &= \mathbb{E}_{a \sim \pi} [(r(s, a) - q)^2] \\ &= \text{Var}_{a \sim \pi}(r(s, a)) \\ &= \sigma^2. \end{aligned} \tag{15}$$

接着计算指数倾斜路径对 β 的导数。定义

$$Z_s(\beta) = \sum_{b \in \mathcal{A}(s)} \pi_0(b | s) e^{r(s, b)/\beta}.$$

则

$$\log \pi_{s, \beta}(a) = \log \pi_0(a | s) + \frac{r(s, a)}{\beta} - \log Z_s(\beta).$$

对 β 求导得

$$\partial_\beta \log \pi_{s, \beta}(a) = -\frac{r(s, a)}{\beta^2} - \frac{Z'_s(\beta)}{Z_s(\beta)}.$$

而

$$\begin{aligned} Z'_s(\beta) &= \sum_{b \in \mathcal{A}(s)} \pi_0(b | s) e^{r(s, b)/\beta} \left(-\frac{r(s, b)}{\beta^2} \right) \\ &= -\frac{1}{\beta^2} \sum_{b \in \mathcal{A}(s)} \pi_0(b | s) e^{r(s, b)/\beta} r(s, b) \\ &= -\frac{Z_s(\beta)}{\beta^2} \mathbb{E}_{b \sim \pi_{s, \beta}} [r(s, b)] \\ &= -\frac{q}{\beta^2} Z_s(\beta). \end{aligned}$$

因此

$$\begin{aligned}\partial_\beta \log \pi_{s,\beta}(a) &= -\frac{1}{\beta^2}(r(s,a) - q) \\ &= -\frac{1}{\beta^2} \nabla^{\text{nat}} J_s(\pi_{s,\beta})(a).\end{aligned}$$

若 $\sigma = 0$ ，则对 π -几乎处处的 a 都有 $r(s,a) = q$ ，于是

$$\nabla^{\text{nat}} J_s(\pi) = 0, \text{ 并且 } \frac{1}{\beta^2} \|\nabla^{\text{nat}} J_s(\pi)\|_{F,\pi} = 0.$$

现在假设 $\sigma > 0$ 。则

$$\begin{aligned}\gamma_{s,\beta} &= -\mathbb{E}_{a \sim \pi} \left[\frac{r(s,a) - q}{\sigma} \partial_\beta \log \pi(a) \right] \\ &= -\mathbb{E}_{a \sim \pi} \left[\frac{r(s,a) - q}{\sigma} \left(-\frac{1}{\beta^2} (r(s,a) - q) \right) \right] \\ &= \frac{1}{\beta^2 \sigma} \mathbb{E}_{a \sim \pi} [(r(s,a) - q)^2] \\ &= \frac{\sigma}{\beta^2}.\end{aligned}$$

结合式 (15)，得到

$$\gamma_{s,\beta} = \frac{1}{\beta^2} \|\nabla^{\text{nat}} J_s(\pi_{s,\beta})\|_{F,\pi_{s,\beta}} = \frac{\sigma}{\beta^2}.$$

定理得证。 □

B.2. 定理 3.3 的证明

Proof. 由于

$$\mathcal{L}_{\text{func},\beta}(\pi) = \mathbb{E}_{s \sim d} [\ell_s(\pi)]$$

在不同状态之间没有耦合，因此只需对每个固定状态 s 求解逐点极小化问题。总体目标的结论随即在 d -几乎处处意义下成立。

固定状态 s ，记 $M = \mathcal{M}(s)$, $\rho = \pi_0(M | s)$, $\pi_0(a) = \pi_0(a | s)$ 。

我们先处理边界情形。若 $\rho = 0$ ，则由于对每个 $a \in \mathcal{A}(s)$ 都有 $\pi_0(a) > 0$ ，可知 $M = \emptyset$ 。于是 $r_{\text{func}}(s,a) \equiv 0$ ，从而 $\ell_s(\pi) = \beta \text{KL}(\pi \| \pi_0)$ ，其唯一极小值在 $\pi = \pi_0$ 处取得。若 $\rho = 1$ ，则 $M = \mathcal{A}(s)$ ，因此 $r_{\text{func}}(s,a) \equiv 1$ ，并有 $\ell_s(\pi) = -1 + \beta \text{KL}(\pi \| \pi_0)$ ，其唯一极小值同样在 $\pi = \pi_0$ 处取得。

接下来考虑非退化情形 $0 < \rho < 1$ 。令 p 为 $\mathcal{A}(s)$ 上任意一个分布，并定义

$$q = p(M) = \sum_{a \in M} p(a).$$

对 $q \in (0, 1)$ ，定义条件分布

$$p_+(a) = \frac{p(a)}{q}, \quad a \in M, \quad p_-(a) = \frac{p(a)}{1-q}, \quad a \notin M,$$

类似地,

$$\pi_{0,+}(a) = \frac{\pi_0(a)}{\rho}, \quad a \in M, \quad \pi_{0,-}(a) = \frac{\pi_0(a)}{1-\rho}, \quad a \notin M.$$

利用 KL 散度的链式法则, 可得

$$\begin{aligned} \text{KL}(p \parallel \pi_0) &= \sum_{a \in M} p(a) \log \frac{p(a)}{\pi_0(a)} + \sum_{a \notin M} p(a) \log \frac{p(a)}{\pi_0(a)} \\ &= q \text{KL}(p_+ \parallel \pi_{0,+}) + (1-q) \text{KL}(p_- \parallel \pi_{0,-}) + q \log \frac{q}{\rho} + (1-q) \log \frac{1-q}{1-\rho}. \end{aligned}$$

又因为 $\mathbb{E}_{a \sim p}[r_{\text{func}}(s, a)] = q$, 逐点目标可写为

$$\ell_s(p) = -q + \beta \left[q \text{KL}(p_+ \parallel \pi_{0,+}) + (1-q) \text{KL}(p_- \parallel \pi_{0,-}) + q \log \frac{q}{\rho} + (1-q) \log \frac{1-q}{1-\rho} \right].$$

在固定 q 时, 最后两项是常数, 而前两项 KL 项非负, 并且当且仅当

$$p_+ = \pi_{0,+}, \quad p_- = \pi_{0,-}$$

时取零。因此, 在固定 q 时, 唯一极小化解为

$$\bar{p}_q(a) = \begin{cases} \frac{q}{\rho} \pi_0(a), & a \in M, \\ \frac{1-q}{1-\rho} \pi_0(a), & a \notin M. \end{cases}$$

把 $p = \bar{p}_q$ 代回去, 条件 KL 项被消去, 得到如下标量问题

$$\phi_s(q) = -q + \beta \left[q \log \frac{q}{\rho} + (1-q) \log \frac{1-q}{1-\rho} \right], \quad q \in [0, 1],$$

其中采用惯例 $0 \log 0 = 0$ 。

当 $q \in (0, 1)$ 时,

$$\begin{aligned} \phi'_s(q) &= -1 + \beta \log \frac{q(1-\rho)}{(1-q)\rho}, \\ \phi''_s(q) &= \beta \left(\frac{1}{q} + \frac{1}{1-q} \right) > 0. \end{aligned}$$

因此 ϕ_s 在 $(0, 1)$ 上严格凸, 且其中至多只有一个驻点。解 $\phi'_s(q) = 0$ 得 $q = \frac{\rho e^{1/\beta}}{(1-\rho) + \rho e^{1/\beta}}$ 。于是, ℓ_s 的唯一极小值为 $\pi_\beta^*(\cdot \mid s) = \bar{p}_{q_\beta(s)}$, 即

$$\pi_\beta^*(a \mid s) = \begin{cases} \frac{q_\beta(s)}{\rho(s)} \pi_0(a \mid s), & a \in \mathcal{M}(s), \\ \frac{1-q_\beta(s)}{1-\rho(s)} \pi_0(a \mid s), & a \notin \mathcal{M}(s). \end{cases} \quad (16)$$

在所有满足可接受动作总质量为 $q_\beta(s)$ 的分布中, 上述分块缩放后的分布正是唯一的 KL 极小化解。

由式 (16), 排序保持性质立刻成立。若 $a, b \in \mathcal{M}(s)$, 则

$$\frac{\pi_{\beta}^*(a \mid s)}{\pi_{\beta}^*(b \mid s)} = \frac{\pi_0(a \mid s)}{\pi_0(b \mid s)}.$$

同理, 若 $a, b \notin \mathcal{M}(s)$, 则

$$\frac{\pi_{\beta}^*(a \mid s)}{\pi_{\beta}^*(b \mid s)} = \frac{\pi_0(a \mid s)}{\pi_0(b \mid s)}.$$

证明完毕。 □