

远程直接内存访问协议规范

RFC 5040 中文译本

R. Recio、B. Metzler、P. Culley、J. Hilland、D. Garcia

原文发布于 2007 年 10 月；本文为技术中文翻译

译本说明

本文翻译 IETF RFC 5040 《A Remote Direct Memory Access Protocol Specification》。协议字段名、消息名、位值、术语缩写和规范性关键词保留英文，以免影响实现对照；**MUST**、**SHOULD**、**MAY** 分别表示**必须**、**应当**和**可以**，其规范性含义遵循 RFC 2119。本文不是新的协议规范；发生歧义时，以[RFC Editor](#) 发布的英文原文为准。

摘要

本规范定义远程直接内存访问协议 (Remote Direct Memory Access Protocol, RDMAP)。RDMAP 建立在直接数据放置协议 (Direct Data Placement Protocol, DDP) 之上，为上层协议 (ULP) 提供远程读和远程写服务。它使数据可直接落入 ULP 缓冲区，避免中间拷贝，并支持内核旁路实现。RDMAP 定义 RDMA Write、RDMA Read、Send 和 Terminate 消息、其头部、流管理、排序/完成规则及安全要求。

目录

1	引言	3
1.1	体系结构目标	3
1.2	协议概述	3
1.3	RDMAP 分层	3
2	术语表	3
2.1	通用术语	3
2.2	LLP 与 DDP 术语	4
2.3	RDMA 术语	4
3	ULP 与传输属性	4
3.1	传输要求与假设	4
3.2	RDMAP 与 ULP 的交互	4
4	头部格式	5
4.1	RDMAP Control 与 Invalidate STag 字段	5
4.2	RDMA 消息定义	5

4.3 Write、Read 与 Send 头部 6

5 数据传输 6

5.1 RDMA Write 消息 6

5.2 RDMA Read 操作 6

5.2.1 RDMA Read Request 6

5.2.2 RDMA Read Response 6

5.3 Send 消息类型 6

5.4 Terminate 消息 7

5.5 排序与完成 7

6 RDMAP 流管理 7

6.1 流初始化 7

6.2 流拆除 7

6.2.1 RDMAP 异常终止 7

7 RDMAP 错误管理 7

7.1 错误上报 7

7.2 远端检测到入站 RDMA 消息的错误 8

8 安全考虑 8

8.1 RDMAP 专有安全要求 8

8.2 RDMAP 的安全服务 8

9 IANA 考虑事项 8

10 参考文献 9

A 附录 A：用于 RDMA 消息的 DDP 段格式 9

B 附录 B：排序与完成规则摘要 9

C 附录 C：贡献者与作者 10

1 引言

RDMA 的目标是在端系统之间高效地移动数据，同时保留 DDP 提供的直接放置能力。传统网络栈通常把数据在用户缓冲区、内核缓冲区和网卡缓冲区之间多次复制；RDMA 允许 RNIC (RDMA Network Interface Card, RDMA 网络接口卡) 借助 DDP 指定的标签缓冲区直接完成放置，从而降低 CPU、内存带宽和延迟开销。

1.1 体系结构目标

RDMA 的设计目标如下：

- 支持一端把数据直接写入另一端已授权的 ULP 缓冲区；
- 支持一端从另一端已授权的 ULP 缓冲区读取数据；
- 支持以 DDP 未标记消息传递语义发送数据；
- 允许 ULP 同时使用这些传输方式，并可使大数据传输不经过中间复制；
- 将远端内存访问限制在对端明确通告、且由 STag 授权的范围内；
- 可运行在可靠、有序的下层传输 (LLP) 之上，且不自行提供拥塞控制或可靠传输。

RDMA 不定义会话建立、资源协商、ULP 消息格式或对端身份验证策略；这些职责由 ULP、DDP 和 LLP 的组合承担。

1.2 协议概述

RDMA 使用四类消息：**RDMA Write** 把本地数据写入远端已通告缓冲区；**RDMA Read Request** 请求远端读取其已通告缓冲区；**RDMA Read Response** 携带对读请求的响应数据；**Send** 则使用 DDP 未标记缓冲区按队列顺序放置数据。**Terminate** 用于报告致命协议错误。

对于直接访问，接收方先注册内存区域并生成 **STag** (Steering Tag, 导向标签)。发起方在消息中给出 STag、目标偏移和长度；RNIC 仅在 STag 有效、访问权限匹配且范围合法时执行传输。写操作为单向操作；读操作由请求和响应组成。Send 不能访问任意远端内存，仅能消费接收方预先提供的未标记缓冲区。

1.3 RDMA 分层

RDMA 位于 ULP 与 DDP 之间。ULP 向 RDMA 提交操作、注册缓冲区并接收完成与错误；RDMA 为 DDP 构造适合的有标记或未标记消息；DDP 再借助 LLP 将段可靠、有序地传送。RDMA 假设 LLP 已提供连接关联、可靠传送、按流顺序交付和消息边界所需的语义。

2 术语表

2.1 通用术语

术语	含义
ULP	上层协议；直接使用 RDMA 服务的协议或应用。
RNIC	实现 DDP 与 RDMA 的网络接口硬件/软件实体。
Endpoint	通信端点；一个 RDMA Stream 的一端。
RDMA Stream	两端点间、建立在一个 DDP Stream 上的双向逻辑数据流。
Local / Remote Peer	执行操作的一方 / 该操作所涉及的对端。
Consumer	使用 RDMA 服务的实体，通常是 ULP。
S Tag	由 RNIC 产生的导向标签，标识一个已注册缓冲区及其访问权限。
S Tagged Buffer	用 S Tag 通告、可被 RDMA 有标记消息访问的缓冲区。
Untagged Buffer	供 DDP 未标记消息按接收队列顺序放置的缓冲区。
TO	Target Offset；从 S Tag 所标识缓冲区起始位置开始的字节偏移。

2.2 LLP 与 DDP 术语

LLP (Lower Layer Protocol, 下层协议) 是承载 DDP 的传输协议。DDP Stream 是一个双向的、可靠有序的数据流；DDP 以有标记 (Tagged) 或未标记 (Untagged) 消息直接放置数据。**M/R/S** (Message Sequence Number, 消息序号) 用于未标记消息排序；**ULP Payload** 为 DDP 段中由 ULP 提供或接收的数据。

2.3 RDMA 术语

RDMA Write 是从本地向远端目标缓冲区的推送；**RDMA Read** 是由本地发起、由远端响应数据的拉取。**Solicited Event** 是请求接收端在消费消息时产生异步提示的标志。**Invalidate** 使随消息携带的 S Tag 在接收端失效，用于撤销访问授权。

3 ULP 与传输属性

3.1 传输要求与假设

RDMA 必须运行在满足 DDP 要求的 LLP 上：同一方向内可靠、有序地交付字节；为每个 DDP Stream 提供独立的双向通信；保留连接/流边界；并使端点能检测不可恢复的连接错误。RDMA 不重排、重传或确认 RDMA 消息，也不定义拥塞控制。若 LLP 不能提供这些属性，不得直接用于 RDMA。

每一端必须能在流建立前配置资源限制，包括可注册内存、未标记接收缓冲区数、待处理读请求数以及完成队列容量。RNIC 或特权资源管理器必须避免一个消费者耗尽其他消费者的资源。

3.2 RDMA 与 ULP 的交互

ULP 在使用远端访问前注册本地缓冲区，并通过其自身控制协议把 S Tag、TO、长度和权限安全地交给对端。ULP 提交 Write、Read 或 Send 后，RDMA 以完成事件报告本地操作已经完成、失败或被终止；本地完成不必表示远端 ULP 已处理数据。

对 RDMA Write, ULP 必须确认对端所给目标范围允许本次写入。对 RDMA Read, 发起方必须提供足够的本地接收缓冲区; 响应方必须确认请求所指远端源范围允许读取。Send 的接收端必须预先张贴足够的未标记缓冲区, 且 ULP 负责建立流量控制, 避免发送端超过接收方可用缓冲区。

ULP 应在不再允许远端访问前使 STag 失效, 并等待所有可能使用该 STag 的操作完成。仅凭应用层“已发送”并不能安全地释放内存。

4 头部格式

所有 RDMA 头部都放在 DDP ULP Payload 的开头。RDMA Control 字段为 8 位: 高位保留, 低位中的 Version 标识协议版本; Opcode 指定消息类型; Invalidate 位表示是否携带要失效的 STag。保留位在发送时必须为零, 接收时必须忽略, 除非相应消息规则另有规定。

4.1 RDMA Control 与 Invalidate STag 字段

字段	规则
Version	RFC 5040 定义的版本为 1。接收不支持的版本是致命协议错误。
Opcode	取值定义为 RDMA Write、RDMA Read Request、RDMA Read Response、Send、Send with Solicited Event 与 Terminate。
Invalidate	仅在 Send with Invalidate 变体中为 1; 随后紧跟 32 位 Invalidate STag。

4.2 RDMA 消息定义

消息	用途
RDMA Write	把 ULP Payload 写入远端指定 STag/TO; 使用 DDP 有标记消息。
RDMA Read Request	请求远端读取指定 STag/TO/长度; 请求本身通过有标记消息发送。
RDMA Read Response	返回读出的数据; 使用与请求配对的有标记消息。
Send	向对端下一可用未标记缓冲区提交数据。
Send with Solicited Event	与 Send 相同, 但请求对端产生提示事件。
Send with Invalidate	与 Send 相同, 并使指定远端 STag 失效; 也可和 Solicited Event 组合。
Terminate	指示检测到不可恢复错误并终止流。

4.3 Write、Read 与 Send 头部

RDMA Write 头部包含 Control、目标 STag 和 Target Offset。RDMA Read Request 还包含请求长度以及响应端用于放置响应数据的 STag/TO；因而响应端既验证被读的源区域，也验证返回数据的目标区域。RDMA Read Response 包含 Control，后接读取的数据。Send 头部只包含 Control；带 Invalidate 的 Send 在其后携带要撤销的 STag。Terminate 头部携带层、错误类型、错误代码和导致错误的已截断消息头，便于诊断。

5 数据传输

5.1 RDMA Write 消息

发送端将 Control、目标 STag、TO 与数据作为一个 RDMA Write 交给 DDP。接收 RNIC 必须验证 STag 存在、允许远程写、TO 与数据长度不越界，并将 ULP Payload 放置到目标位置。验证成功后，接收方可以完成该写入；发生验证失败、长度错误、非法头部或资源错误时，必须按错误管理规则报告并终止流。

RDMA Write 可用于数据推送和控制信息传递。一个逻辑写操作可能由多个 DDP 段组成，但 ULP 与实现必须遵守 DDP 的分段和排序约束。接收端不得把不完整或失败写操作视为已交付的 ULP 消息。

5.2 RDMA Read 操作

读操作包含 Read Request 和 Read Response。请求端给出远端源缓冲区的 STag、TO 和读取长度，并同时给出本地用于接收响应的 STag、TO。响应端验证远端源区域的读权限和范围；请求端在响应到达时验证本地目标区域的写权限和范围。

5.2.1 RDMA Read Request

Read Request 的目标是响应端可读的源内存；请求消息还描述响应应被放进请求端的哪个本地已注册缓冲区。响应端接到请求后，不应把该请求交由 ULP 才能完成；RNIC 可直接从已注册缓冲区取数并生成响应。请求端必须在读完成前保持其接收缓冲区有效。

5.2.2 RDMA Read Response

Read Response 携带源区域的内容。读响应的长度必须等于请求长度；不匹配为协议错误。响应只代表其被构造时读到的数据，不构成远端内存的一致性或原子性保证；ULP 必须自行定义并实现同步。

5.3 Send 消息类型

Send 通过 DDP 未标记消息承载 ULP Payload。它按 M/R/S 消息序号映射到接收方张贴的未标记缓冲区；接收方未张贴相应缓冲区、序号失配或缓冲区不足均是致命错误。带 Solicited Event 的变体仅增加通知语义，不改变数据放置规则。带 Invalidate 的变体必须在数据成功放置后再使指定 STag 失效；若 STag 无效，按错误规则处理。

5.4 Terminate 消息

一端检测到不可恢复的 RDMA 错误时，应发送 Terminate，以便对端取得错误层、类型和代码。发送 Terminate 后，该端必须进行流的异常终止；接收 Terminate 的一端也必须终止该流。Terminate 不保证一定能送达，因此 LLP 的断连错误也必须被上报。

5.5 排序与完成

同一方向上，RDMA 操作遵循其 DDP/LLP 交付顺序；但读请求与读响应处在相反方向，且远程内存访问本身不提供跨操作的原子性。完成事件表示 RNIC 已达到该操作所规定的本地完成点。实现必须维持：此前提提交的操作不会因稍后操作而违反流内可见顺序；一个缓冲区在相关完成前不得被重用；遇到终止后，尚未完成的操作必须以失败或未完成状态报告给 ULP。

6 RDMA 流管理

6.1 流初始化

RDMA Stream 在其底层 DDP Stream 已建立、且双方已为该流配置资源后开始。初始化时，双方必须协商或由 ULP 确定使用的 RDMA 版本、所需的未标记缓冲区与流量控制规则；RDMA 不定义握手消息。端点不得在完成初始化前发送 RDMA 消息。

ULP 必须在任何对端访问发生前安全地传递 STag 和访问范围。STag 是能力令牌，但不是对端身份认证的替代品；发布 STag 就是在其权限范围内授予访问能力。

6.2 流拆除

正常拆除由 ULP 协调：停止提交新操作，等待已提交操作完成，撤销不再需要的 STag，随后关闭 DDP/LLP 流。异常拆除由 Terminate 或 LLP 错误触发。

6.2.1 RDMA 异常终止

在本端或远端发现致命错误后，RNIC 必须阻止该流继续执行新操作，通知本地 ULP，并释放或隔离相关流资源。已注册的内存不应仅因流终止自动变为安全可复用；ULP 仍必须遵守本地注册与完成规则。

7 RDMA 错误管理

7.1 错误上报

错误可被本地 RNIC、远端 RNIC、DDP 或 LLP 发现。RDMA 必须尽可能将错误上报给本地 ULP；若可发送，必须向远端发送 Terminate。错误报告至少应说明发生层、错误类别和原因。协议错误、保护错误、资源错误和未支持版本/操作码均可能导致终止。

7.2 远端检测到入站 RDMA 消息的错误

远端处理入站消息时必须检查版本、opcode、保留位、头部长度的有效性、访问权限、TO/长度边界以及 DDP 段格式。对于 RDMA Read Request，还必须检查请求长度和响应目标描述。检测到下列情况不得执行数据访问：

- STag 不存在、已经失效，或未授予所请求的远程读/写权限；
- Target Offset 与长度超出注册内存区域；
- 消息截断、格式错误，或 Opcode 与 DDP 消息类型不匹配；
- 资源不足、版本不受支持或未标记序号不合法。

这类错误通常不可恢复，因为流两端的状态已不再可信；实现必须终止流，而不是尝试继续处理后续 RDMA 消息。

8 安全考虑

RDMA 暴露的是受 STag 限定的远端内存能力，因此安全设计的核心是保护 STag、限制其权限与生命周期，并防止资源耗尽。RDMA 本身不认证对端、不加密数据，也不保证消息完整性；部署必须选择合适的 LLP/网络安全服务。

8.1 RDMA 专有安全要求

RNIC 必须确保 STag 难以猜测，不能让一个 STag 访问注册范围以外的内存，必须在失效后拒绝访问，并在本地消费者之间隔离内存和资源。特权资源管理器必须限制单一消费者注册内存、张贴接收缓冲区、发起读操作和占用队列的能力，防止拒绝服务。ULP 不应向未认证实体泄露 STag、TO 或可访问长度。

8.2 RDMA 的安全服务

需要机密性、对端认证、完整性或抗重放时，应由下层安全服务提供。RFC 5040 讨论 IPsec 在 RDMA 上的使用：保护应覆盖承载 DDP/RDMA 的数据流；安全关联必须在允许 RDMA 流量前建立；密钥管理与策略必须同时绑定端点、流和所需服务。仅依赖 STag 不能防御窃听、伪造、重放或中间人攻击。

9 IANA 考虑事项

本规范没有要求 IANA 新建注册表或分配新的名称空间。

10 参考文献

参考文献

- [1] R. Recio 等, *A Remote Direct Memory Access Protocol Specification*, RFC 5040, 2007 年 10 月, <https://doi.org/10.17487/RFC5040>。
- [2] S. Bradner, *Key words for use in RFCs to Indicate Requirement Levels*, RFC 2119, 1997 年 3 月。
- [3] H. Shah 等, *Direct Data Placement over Reliable Transports*, RFC 5041, 2007 年 10 月。
- [4] J. Pinkerton 等, *Direct Data Placement Protocol (DDP) / Remote Direct Memory Access Protocol (RDMA) Security*, RFC 5042, 2007 年 10 月。

A 附录 A: 用于 RDMA 消息的 DDP 段格式

下表汇总 RDMA 消息选择的 DDP 段类别。字段的精确位布局、保留位和长度限制以 RFC 5041 与 RFC 5040 原文附录 A 为准。

RDMA 消息	DDP 段	放置语义
RDMA Write	Tagged DDP Segment	写入目标 STag/TO。
RDMA Read Request	Tagged DDP Segment	请求访问响应端源 STag/TO。
RDMA Read Response	Tagged DDP Segment	写入请求端给出的响应目标 STag/TO。
Send / Send with SE	Untagged DDP Segment	消费下一个匹配 M/R/S 的未标记缓冲区。
Send with Invalidate	Untagged DDP Segment	与 Send 相同；成功后执行 STag 失效。
Terminate	Untagged DDP Segment	报告错误并关闭流。

B 附录 B: 排序与完成规则摘要

操作	本地完成的含义	关键约束
RDMA Write	本端 RNIC 已完成提交规定的发送处理。	远端数据可见性由写入交付决定；释放源缓冲区前等待本地完成。
RDMA Read	请求端已收到并放置完整响应。	保持请求端目标与响应端源在相关完成前有效。

操作	本地完成的含义	关键约束
Send	本端已完成发送处理；接收端在匹配未标记缓冲区后完成接收。	发送前必须有 ULP 流量控制保证可用接收缓冲区。
Terminate	终止正在进行；不保证送达。	后续未完成操作必须向 ULP 报错或取消。

C 附录 C：贡献者与作者

原规范的主要作者为 Renato J. Recio、Bernard Metzler、Paul R. Culley、Jeff Hilland 与 Dave Garcia。RFC 5040 还列出 Uri Elzur、Hari Ghadia、Howard C. Herbert、Mike Ko、Mike Krause、Dave Minturn、Mike Penna、Jim Pinkerton、Hemal Shah、Allyn Romanow、Tom Talpey、Patricia Thaler、Jim Wendt、Madeline Vega 与 Claudia Salzberg 等贡献者。联系方式、版权声明和知识产权声明请参阅原文。