

ScaleCUA: 以跨平台数据扩展开源计算机使用智能体

Zhaoyang Liu*, Jingjing Xie*, Zichen Ding*, Zehao Li*, Bowen Yang*, Zhenyu Wu*,
Xuehui Wang, Qiushi Sun, Shi Liu, Weiyun Wang, Shenglong Ye, Qingyun Li, Xuan Dong, Yue Yu,
Chenyu Lu, YunXiang Mo, Yao Yan, Zeyue Tian, Xiao Zhang, Yuan Huang, Yiqian Liu, Weijie Su,
Gen Luo, Xiangyu Yue, Biqing Qi, Bowen Zhou, Kai Chen, Yu Qiao, Qifeng Chen, Wenhai Wang
上海人工智能实验室; * 共同贡献




图 1: 性能比较。上排展示以 GUI 为中心的基准上的总体性能，下排展示使用作者所收集数据后相对于基线的一致提升。

摘要

视觉语言模型 (Vision-Language Model, VLM) 使能够自主操作 GUI 的计算机使用智能体 (Computer Use Agent, CUA) 成为可能, 展现出巨大潜力。然而, 要开发鲁棒的 CUA, 需要大量关于软件界面和操作过程的领域内知识。不同于互联网上广泛存在的图文对, 计算机使用数据, 尤其是操作轨迹, 不仅稀缺, 而且采集成本高昂。因此, 该领域的进展仍同时受制于数据规模以及现有 VLM 有限的迁移能力。

本文提出 ScaleCUA, 向扩展开源 CUA 迈进一步。作者通过一个将自动化智能体与人类专家结合起来的闭环流水线, 构建了覆盖 6 种操作系统和 3 类任务领域的大规模数据集。在这些扩展后的数据上训练得到的 ScaleCUA 能够跨平台无缝运行。具体而言, 它相较基线取得显著增益 (WebArena-Lite-v2 上 +26.6, ScreenSpot-Pro 上 +10.7), 并刷新多项最佳结果 (MMBench-GUI L1-Hard 为 94.4%, OSWorld-G 为 60.6%, WebArena-Lite-v2 为 47.4%)。这些发现凸显了数据驱动扩展对于通用跨平台 CUA 的作用。作者发布数据、模型和代码以推动后续研究: <https://github.com/OpenGVLab/ScaleCUA>。

1 引言

人类能够通过图形用户界面 (GUI) 与数字环境交互, 从而高效获取信息并完成任务。近期视觉语言模型的发展赋予了模型强大的视觉感知和任务规划能力, 使这类交互的自动化日益可行。因此, 近来的研究越来越关注计算机使用智能体, 也称 GUI 智能体; 其目标是仅依赖视觉观测, 自主操作桌面、移动端和 Web 平台。

一些 CUA (Qin et al., 2025; Anthropic, 2025; Hong

et al., 2025; OpenAI, 2025) 已表现出很强的性能, 但它们通常建立在闭源模型或无法获得的专有数据集之上。更根本地说, 有效使用计算机需要丰富的软件与操作流程领域知识, 而当前基础模型在这方面仍有很大缺口。与互联网上大量存在的图文对不同, 计算机使用数据, 尤其是细粒度动作轨迹, 数量稀少、采集昂贵、标注成本高, 并且不会自然地在线归档。此外, 软件、网页和操作系统快速演化, 已有轨迹还面临过时风险, 进一步限制了其效用。这些挑战从数据规模和模型泛化性两方面形成了扩展 CUA 的显著瓶颈。为解决这些限制, 作者主要推进两项工作: (a) 构建大规模、跨平台、以 GUI 为中心的训练语料; (b) 开发一族可扩展、通用的基础模型, 用于通用计算机使用智能体。

作者首先提出由两个协同闭环组成的跨平台交互式数据流水线。智能体-环境交互闭环使自动化智能体能够与多种 GUI 环境交互; 智能体-人类混合数据采集闭环则引入专家标注轨迹, 以保证覆盖面与质量。该流水线覆盖 Windows、macOS、Linux、Android、iOS 和 Web 六类主要平台, 能够采集丰富的屏幕状态观测、元数据 (例如无障碍树、XML、DOM 结构等) 以及原始轨迹。作者还设计了统一动作空间, 使智能体能够更一致、更高效地与多种真实环境交互。

依托这一基础设施, 作者整理并标注了一个全面的开源计算机使用训练数据集, 包含三类主要任务: (a) GUI 理解, 共 47.1 万个样本, 覆盖区域描述、OCR、布局理解等; (b) GUI 定位, 共 1710 万个训练样本, 用于支持更精确的 UI 元素定位; (c) 任务完成, 包含超过 1.5 万条弱语义轨迹和 4000 条高层目标驱动轨迹。作者使用 GPT-4o、Claude-3.7-Sonnet 等先进 VLM 标注采集到的数据, 并探索数据增强以进一步提高多样性, 由此建立了一个完全开放且多样的训练数据集。

在该语料之上, 作者以 Qwen2.5-VL (Bai et al., 2025) 为基础训练了一系列名为 **ScaleCUA** 的基础智能体模型。ScaleCUA 支持三种不同的推理范式, 以提高灵活性并兼容不同智能体框架: (a) 定位模式, 根据文本描述精确定位 UI 元素, 便于在模块化智能体中与能力更强的推理规划器高效集成; (b) 直接动作模式, 不消耗额外的中间推理 token, 而是直接生成底层可执行动作, 从而高效完成任务; (c) 推理动作模式, 先根据当前观测和历史上下文生成思考过程, 再生成下一动作, 以提高任务规划准确性。数据构建阶段设计的统一动作空间使这些智能体能够通过标准化控制模式接入异构环境。

作者进行了大量实证研究, 考察不同数据来源、训练任务和智能体设计等因素对性能的影响。结果表明, 数据增强、弱语义轨迹和通用推理数据有助于提高规划能力。作者还在多个 GUI 智能体基准上评测不同智能体范式,

并系统比较智能体式工作流与原生模型。先前研究 (Xu et al., 2024; Qin et al., 2025; OpenAI, 2025; Anthropic, 2025) 也曾探索这些重要问题, 但公开训练数据有限, 或是在使用专有数据的封闭条件下进行; 本文的研究旨在为推进基于视觉语言模型的计算机自动化提供基础性、统一的认识。

本文贡献概括如下:

1. 作者通过结合自动化智能体与人类专家的交互式数据流水线, 整理了一个跨平台计算机使用数据集。它覆盖 Windows、macOS、Linux、Android、iOS 和 Web 六类主要平台, 以及理解、定位和任务完成三类以 GUI 为中心的任务领域, 为研究和训练通用 CUA 提供了坚实基础。
2. 作者开发了 ScaleCUA: 一族将感知、推理和动作统一在单一模型中的鲁棒基础智能体模型。它支持定位、直接动作和推理动作等灵活推理范式, 并使用统一动作空间实现无缝跨平台交互。
3. 作者在若干跨平台在线基准上, 对理解、定位和端到端任务完成进行了全面评测。实验不仅表明这些智能体能够取得最佳或具有竞争力的性能, 也为开发更强大的计算机使用智能体提供了有启发性的方向。

2 相关工作

视觉语言模型。近年来, 视觉语言模型取得了长足发展, 既包括专有 API 服务 (Team et al., 2023, 2024; Anthropic, 2024a; xAI, 2025; OpenAI, 2023; Hurst et al., 2024), 也包括开源模型 (Wang et al., 2024b; Bai et al., 2025; Chen et al., 2024c,b; Zhu et al., 2025; Xiaomi, 2025; Team et al., 2025a; MetaAI, 2025), 能力范围已扩展至多种任务。一些通用 VLM (Team et al., 2025c; Guo et al., 2025; Bai et al., 2025; Zhu et al., 2025; Xiaomi, 2025; Wang et al., 2025a) 在预训练或监督微调阶段整合了大量 GUI 知识, 因而获得了明确的计算机使用能力。然而, 尽管部分工作 (Hurst et al., 2024; Anthropic, 2024a; Guo et al., 2025; Zhu et al., 2025; Bai et al., 2025) 在视觉语言任务上表现出较强的泛化与规划能力, 它们仍难以解决简单的计算机使用任务。此外, 用于训练这些模型的 GUI 语料在很大程度上仍是专有的。

GUI 智能体。GPT-4o 等通用 VLM 的近期进展促成了模块化 GUI 智能体: 它们把决策和感知拆分为规划与定位两个角色。这类智能体通常采用规划器-定位器范式 (Cheng et al., 2024; Hong et al., 2024; Lu et al., 2024b; Yu et al., 2025; Wu et al., 2025; Gou et al., 2024; Zhang et al., 2025c; Wu et al., 2024b; Zhou et al., 2025), 由基于 VLM 的规划器预测下一项高层操作及相关对象描述, 再由专门的 GUI 定位模型在界面中定位该对象。Yang et al. (2024) 进一步把动作历史纳入定位, 使定位器能够适应有上下文的 GUI 动态变化。

受通用智能体式工作流 (Wu et al., 2023b; Li et al., 2023; Hong et al., 2023) 启发, 一些工作 (Wu et al., 2024a; Liu et al., 2025a; Zhao et al., 2025; Agashe et al., 2025; Chen et al., 2025b) 通过协调负责规划、反思和记忆增强决策的多个智能体, 将这种设计扩展到 GUI 环境。尽管性能强劲, 智能体式工作流通常具有较高的计算延迟和显著的 token 消耗, 而且其性能从根本上受底层 VLM 能力约束。与模块化智能体不同, 原生计算机使用智能

体 (Xu et al., 2024; Wu et al., 2024b; Sun et al., 2024; Qin et al., 2025; Luo et al., 2025; Liu et al., 2025b; Sun et al., 2025) 在一个端到端训练的统一模型中整合规划与定位, 并从原始视觉输入直接预测底层可执行动作。例如, AGUVIS (Xu et al., 2024) 和 UI-TARS (Qin et al., 2025) 使用大量任务轨迹训练, 表现出出色的推理与适应能力。总体而言, 原生智能体使感知与动作之间的对齐更紧密; 模块化智能体和智能体式工作流也能受益于原生智能体的改进。本文不仅关注跨平台 GUI 智能体基础模型的训练, 还承诺开源全部数据, 以加速整个领域的发展。

GUI 数据集。开源数据集通过捕获跨平台的多种交互、视觉感知与指令遵循行为, 显著推动了 GUI 智能体的发展。在移动端环境中, RICO (Deka et al., 2017) 提供超过 7 万张带手势轨迹的 Android UI 屏幕; AITW (Rawles et al., 2023) 提供约 71.5 万条与 3 万条自然语言命令对齐的人类示范; AitZ (Zhang et al., 2024) 则构建了 18,643 个屏幕-动作对, 并附带动作思维链标注。

在 Web 领域, MiniWoB (Shi et al., 2017) 模拟了多种带交互序列和奖励的 Web 任务; WebShop (Yao et al., 2022) 在真实商品目录上提供语言驱动的电子商务任务及人类轨迹; Mind2Web (Deng et al., 2023) 将该思路扩展至 137 个真实网站, 提供 2350 个长程开放式任务。在桌面平台方面, Xie et al. (2024) 构建了通过界面分解合成的 400 万样本数据集, 提高了定位准确率; He et al. (2025) 采集了 312 条人类标注轨迹, 并通过轨迹增强扩充数据。

此外, 一些工作探索可扩展的数据生成方式。例如, OS-Genesis (Sun et al., 2024) 通过探索合成移动端和 Web 轨迹, AGUVIS (Xu et al., 2024) 则从异构开源语料中整理出带多模态定位与推理标注的大规模数据集。由于 GUI 交互轨迹的获取成本很高, 另一些研究收集 GUI 教程数据以缓解数据稀缺: META-GUI (Sun et al., 2022) 在教程中提出基于对话的标注; TongUI (Zhang et al., 2025a) 从 YouTube、WikiHow 等教学来源收集约 14.3 万条任务轨迹, 并将指令与屏幕截图、动作关联起来; GUI-World (Chen et al., 2025a) 提供超过 1.2 万段 GUI 屏幕录制视频, 以促进对 GUI 动态的时间理解。尽管已有这些进展, 现有 GUI 语料在覆盖面与多样性上仍然有限, 桌面环境尤其如此。数据稀缺对 UI 元素定位和多步任务规划提出了显著挑战。

3 跨平台交互式数据流水线

开发鲁棒计算机使用智能体的一项关键挑战, 是计算机使用领域缺少兼具高质量和多样性的训练数据。采集计算机使用轨迹尤其昂贵且低效, 主要原因是环境具有动态性, 并经常依赖特定任务的资源文件, 这严重限制了全自动数据采集流水线的可行性。本节详细介绍用于训练计算机使用智能体的数据获取与标注流水线。

3.1 概述

计算机使用领域的现有数据集主要分为两类: 人工轨迹采集和基于自动搜索的探索。人工采集 (Zhang et al., 2024; Rawles et al., 2023; Deng et al., 2023; Lu et al., 2024a) 虽然能产生高质量轨迹, 却成本极高、劳动密集, 而且天然难以扩展。相反, 自动探索方法 (Sun et al., 2024) 虽可扩展, 却会产生噪声很大的轨迹。因此, 任何




图 2: 跨平台交互式数据流水线。流水线包含两个协同闭环: (1) **智能体-环境交互闭环**, 智能体通过观测与动作同桌面、移动端和 Web 等多平台 GUI 环境交互; (2) **智能体-人类混合数据采集体**, 自主智能体与人类专家共同采集由屏幕截图和结构化元数据组成的原始轨迹。所得轨迹随后被标注并转化为 GUI 理解、GUI 定位和序列动作建模等任务的训练语料。

一种策略都无法单独提供训练通用 GUI 智能体所需的质量与多样性。

基于这些限制, 作者提出跨平台交互式数据流水线, 有策略地把智能体与人类整合到数据采集中。如图 2 所示, 流水线运行两个协同闭环: 智能体-环境交互闭环和智能体-人类混合数据采集体。前者让智能体与多平台 GUI 环境交互, 后者则整合由自主智能体和人类专家共同采集的轨迹。这些由屏幕截图和结构化元数据组成的轨迹随后被标注, 并转化为 GUI 理解、定位和序列动作建模等任务的训练语料。双闭环框架在保持数据质量的同时保证对 GUI 状态的广泛覆盖, 为训练可泛化的计算机使用智能体奠定坚实基础。

智能体-环境交互闭环。作者首先在 Windows、Ubuntu、macOS、Web 浏览器、Android 和 iOS 等异构平台之间建立统一接口, 以标准化观测获取和动作执行。这一统一抽象支持闭环数据采集, 并提供可兼容不同智能体架构的灵活接口, 从而显著提高在线评测的可扩展性和效率。为构建双模式数据采集框架, 作者研究了针对各平台提取 GUI 元数据的方法。对于桌面环境 (Windows、Ubuntu、macOS), 一般可以通过无障碍树获得界面布局和 UI 元素坐标; Web 平台通过浏览器渲染的文档对象模型 (DOM) 结构提供元素信息; Android 应用则可从解析后的 XML 布局文件中取得 UI 元素位置。

然而, 作者观察到桌面平台的无障碍树经常缺失属性, 而 iOS/iPadOS 系统限制对布局信息的访问。在这些情况下, 作者使用 OmniParser (Yu et al., 2025) 估计 UI 元素边界框, 在噪声容忍度与效率收益之间取得平衡。

智能体-人类混合数据采集体。在统一多种环境的交互接口之后, 下一个自然问题是如何部署自动智能体来收集交互轨迹, 同时最大限度覆盖 GUI 状态。作者实验了两种不同的探索策略。第一种使用 GPT-4o、Claude、Gemini 等 VLM 驱动的智能体浏览界面; 但由于这些模型的内在偏置, 所得轨迹缺少足够多样性。第二种策略使用规则驱动的随机游走智能体。规则智能体采用深度优先搜索 (DFS) 进行探索, 每一步都从可用动作空间中随机选择一个动作, 并用启发式剪枝减少搜索中的冗余或无信息分支。该策略的详细设计见附录中的数据整理细节。去重后, 这一简单方法实现了明显更广的 GUI 覆盖。虽然所得轨迹在宏观层面往往缺少明确高层目标, 但

表 1: 计算机使用数据集比较: 平台覆盖、任务类型 (理解、定位与轨迹) 和采集方法。

数据来源	平台			理解		定位		轨迹		采集方法
	桌面	移动端	Web	样本数	元素数	样本数	平均步数	样本数	平均步数	
SeeClick (2024)	✓	✓	✓	—	763K	—	—	—	—	自动
GUIEnv (2024a)	✓	✓	✓	—	10.7M	—	—	—	—	自动
WebUI (2023a)	✓	✓	✓	—	400K	—	—	—	—	自动
Widget Captioning (2020b)	✓	✓	✓	—	163K	—	—	—	—	人工
RicoSCA (2020a)	✓	✓	✓	—	178K	—	—	—	—	自动
RICO (2017)	✓	✓	✓	—	72K	—	—	—	—	混合
OmniACT (2024)	✓	✓	✓	—	9.8K	—	—	—	—	自动
MM-Mind2Web (2024)	✓	✓	✓	—	—	1K	7.7	—	—	人工
GUIAct (2024a)	✓	✓	✓	—	67K	5.7K	6.7	—	—	自动
AitZ (2024)	✓	✓	✓	—	—	2.5K	6.0	—	—	人工
AndroidControl (2024)	✓	✓	✓	—	—	13.6K	5.5	—	—	人工
GUI Odyssey (2024a)	✓	✓	✓	—	—	7.7K	15.3	—	—	人工
AMEX (2024)	✓	✓	✓	—	—	3.0K	11.9	—	—	人工
AitW (2023)	✓	✓	✓	—	—	2.3K	8.1	—	—	人工
OS-Atlas (2024b)	✓	✓	✓	—	13.6M	—	—	—	—	自动
OS-Genesis (2024)	✓	✓	✓	—	—	2.5K	6.4	—	—	自动
JEDI (2025)	✓	✓	✓	877K	3.1M	—	—	—	—	自动
AgentNet (2025b)	✓	✓	✓	—	—	22K	—	—	—	自动
本文	✓	✓	✓	471K	17.1M	19.0K	9.0	—	—	混合

其中许多子序列仍能为智能体模型学习提供有价值的监督信号。

尽管自动化提高了效率, 大量质量评估仍揭示出系统元数据和基于视觉预测的边界框中存在相当多噪声。因此, 为降低噪声并保证高质量标注, 作者用专家整理的轨迹补充自动采集。为简化专家操作, 作者构建了一个统一的跨平台数据采集系统, 将前端交互界面与后端环境解耦, 使标注人员能够高效切换平台。专家需要完成生产力、娱乐和系统操作等领域的特定目标。

结合智能体驱动与专家驱动两种方式, 作者得到规模可观的原始 GUI 轨迹语料, 其中包含大量屏幕截图及相应元数据。随后, 作者使用 GPT-4o (Hurst et al., 2024)、Claude-3.5 (Anthropic, 2024a) 等先进 VLM 进行数据标注, 并将语料划分为 GUI 理解、GUI 定位和任务完成三类主要任务。这个全面的数据集最终为训练可泛化的计算机使用智能体提供了坚实基础。

统一动作空间。如附录动作空间表所示, 作者建立了覆盖桌面、浏览器和移动端三类主要环境的跨平台动作空间。这一统一接口支持一致的行为建模, 并便于在异构平台上共同训练。动作空间既包含通用操作的核心子集 (如 click、write 等), 也包含移动环境所需的特定平台动作 (如 long_press、open_app 等)。统一动作空间使智能体能够泛化核心行为, 同时保留利用环境特定动作的灵活性。由于每项动作都以感知平台但语义一致的方式表达, 该设计还简化了数据标注和下游策略学习; 更多细节见原文附录的动作空间小节。

3.2 面向任务的数据整理

智能体驱动和专家驱动的数据共同形成大量原始 GUI 轨迹, 其中包含广泛的屏幕截图及相应元数据。随后, 作者使用 GPT-4o (Hurst et al., 2024)、Claude-3.7 (Anthropic, 2025) 等先进 VLM 标注数据, 并将语料分为 GUI 理解、GUI 定位和已标注轨迹三类主要任务。在标注后的 GUI 语料基础上, 作者旨在构建开源计算机使用数据集 ScaleCUA-Data。该全面数据集最终为训练可泛化的计算机使用智能体提供坚实基础。

GUI 理解。作者设计了一组任务, 以促进对 GUI 的细粒度感知和推理。在元素层面, 模型学习描述视觉外观、提取文本内容 (指代表达 OCR)、理解空间布局、推断功能语义并预测用户意图; 在屏幕截图层面, 数据包含用于概括全局布局 and 内容的界面描述, 以及用于描述状态随时间变化的屏幕转移描述。这些任务为训练具备强界面理解能力的智能体奠定基础。

GUI 定位。定位任务使智能体能够把自然语言指令映射到相应界面区域。作者构造三类定位监督：(1) 点定位，识别精确点击位置；(2) 边界框定位，为基于区域的操作定位区域；(3) 动作定位，把空间目标与底层命令关联起来。所有定位任务都源自先前标注的理解数据，并通过 LLM 驱动的数据增强进一步扩展，以提高覆盖面和泛化能力。

弱语义轨迹。基于规则的智能体执行深度优先探索，以覆盖不同 GUI 状态。虽然这些轨迹没有明确任务意图，作者仍可根据屏幕相似度将其切分为子轨迹，得到弱语义交互流。这些序列捕获常见 GUI 模式，以低成本监督帮助模型学习通用界面导航。

人工整理轨迹。为了补充自动化数据，作者聘请专家操作者采集真实、目标驱动的示范，任务取自日常、娱乐和生产领域。为此，作者开发了一个将各平台环境隔离开来的统一跨平台系统。这些整理后的轨迹为推理与规划提供高质量监督，并充当使模型行为与人类意图对齐的参考信号。

标注与增强。每张屏幕截图都与包含 UI 布局结构的元数据配对。作者去除频繁重复的状态并采样多样化交互元素，再用 VLM 标注其外观、位置和功能描述。这些标注支持问答与定位任务。为了增加数据多样性，作者使用元素裁剪、合成式分辨率缩放和背景替换等增强技术。轨迹级标注则通过基于推理的提示丰富，以生成指令、思维链和替代动作。全部提示模板见原文附录。

3.3 数据统计

作者采集的语料覆盖理解、定位和任务规划三类主要任务领域。如表 1 所示，该数据集包含 47.1 万个理解样本，涉及 VQA、OCR、布局理解和屏幕转移推理等多种任务。对于定位，作者整理了超过 1710 万条多种格式（边界框、点和动作）的标注，使文本指令与 GUI 元素能够细粒度对齐。此外，数据集还提供 1.9 万条任务规划轨迹，覆盖人工整理与增强轨迹，平均每条轨迹 9 步。



图 3: 作者数据集的数据分布。

图 3 展示了各平台的数据分布。由于桌面应用覆盖更广、界面更多样，桌面任务占据主导，同时移动端和 Web 环境也有相当规模。与现有资源相比，作者的数据集（表 1）最为全面，覆盖桌面（Windows、Linux、macOS）、移动端和 Web 上的三类任务。以往数据集 (Deka et al., 2017; Chen et al., 2024a; Wu et al., 2024b) 通常只关注单一任务领域，而本文数据集将异构监督信号整合为统一格式。

讨论。这样的规模与多样性使计算机使用智能体能够在感知和动作两类范式下得到均衡评测。借助双闭环采集流水线，作者覆盖了底层元素识别、中层定位和高层任务规划。与现有工作 (Sun et al., 2024; Wu et al., 2024b; Zhang et al., 2024; Rawles et al., 2023) 相比，本文探索了更多样的数据采集策略（人类专家、VLM 驱动智能体和规则驱动智能体），并覆盖更广的平台范围（桌面、移动端和 Web）。特别地，对于随机游走智能体，作者通过大量实验和迭代改进设计了更高效的算法，显著




图 4: 计算机使用智能体的三种推理范式。(1) 定位模式，识别目标 UI 元素的空间坐标与边界框；(2) 直接动作模式，智能体仅根据当前观测和指令生成可执行动作；(3) 推理动作模式，智能体先生成思维链推理，再产生结构化动作。这些模式为计算机使用智能体完成任务提供不同层次的功能。

提高数据采集效率与 GUI 覆盖。借助该流水线，作者已从多个平台采集超过 200 万张原始屏幕截图。此外，作者还通过构建跨理解、定位和规划的多种代理任务，为训练鲁棒计算机使用智能体投入了大量工作。

4 扩展计算机使用智能体

4.1 任务定义

CUA 已被用于程序化自动操作。早期方法如利用 DOM 解析完成 Web 自动化的 Selenium¹，以及编写确定性桌面交互脚本的 AutoHotkey²，实现了精确但受限的界面控制。大规模 VLM 极大拓宽了这一范式，使智能体 (Cheng et al., 2024; Wang et al., 2024a; Zhang et al., 2025b) 能够在图形用户界面上进行像素级感知与交互。

时刻 t 的智能体-环境交互可以简单定义为：

$$a_t = \pi_\theta(\text{task}, o_t, h_{<t}), \quad o_{t+1} = \mathcal{E}(a_t), \quad (1)$$

其中， π 表示参数为 θ 的智能体模型， $\mathcal{E}$ 表示虚拟机或 Docker 容器等环境， task 表示任务指令。观测 o 包括原始屏幕像素、无障碍树或 DOM 数据等元素。历史 $h_{<t} = \{(a_0, o_0), \dots, (a_{t-1}, o_{t-1})\}$ 为智能体决策过程提供上下文。一些工作 (Sun et al., 2024; Xu et al., 2024) 选择为历史中的 (a_i, o_i) 生成自然语言描述，因为这样能够显著节省推理成本预算。每个动作指定一种操作及相应参数，并在环境中执行；动作细节见原文附录的动作空间表。

本文坚持基于屏幕截图对计算机使用任务建模。这一范式与人类行为一致，并能有效避免带噪无障碍树和 DOM 数据的干扰。

4.2 基础智能体模型

为训练鲁棒的计算机使用智能体，作者采用先进视觉语言模型 Qwen2.5-VL (Bai et al., 2025) 作为基础模型，因为它具有强大的多模态理解能力，并能扩展到不同 GUI 平台。如图 4 所示，模型以三种模式运行：(1) 定位模式，模型根据当前观测和指令执行 UI 定位；(2) 直

¹<https://github.com/SeleniumHQ/selenium>

²<https://github.com/AutoHotkey/AutoHotkey>

接动作模式，模型依据当前观测和历史上下文，直接生成可执行动作的底层指令；(3) 推理动作模式，模型先产生推理过程，再生成动作。模型生成的输出使用 XML 标签格式化。

定位模式表示模型只关注 UI 元素定位。它利用视觉观测引导模型生成空间点、边界框或引用坐标的动作（如 *click*、*doubleClick*、*moveTo* 等），以实现精确定位。在此模式下，模型仅以屏幕截图和指令作为输入。部署时，该范式可让 GPT-4o 等强大通用 VLM 充当规划器，让本文模型充当定位器，以模块化范式完成计算机使用任务。

直接动作模式要求模型不生成中间推理步骤或无关输出，而是高效地直接预测可执行动作。给定任务指令、当前屏幕观测和交互历史，模型同时输出一条底层指令和一个可执行动作。底层指令以简洁自然语言描述预期操作（例如“打开设置菜单”），`<action>` 标签中的动作则对应具体底层控制命令（例如 `click(x=213, y=234)`）。生成的底层指令会被追加到对话历史，作为可供人理解的描述和后续步骤的历史上下文，使模型能够在多步交互中保持上下文。底层指令与动作分别被包裹在 `<operation>...</operation>` 和 `<action>...</action>` 中。

该模式省去动作前显式的中间思考或推理步骤，从而快速执行任务。它支持精简的感知-动作闭环：模型持续观测环境并输出已定位动作。通过向交互历史加入极少但有信息量的语言反馈，智能体既能保持连贯行为，又能降低推理延迟。实证结果表明，这一设计能够高效完成复杂 GUI 任务，特别适合在线游戏等强调快速响应的实时任务。

推理动作模式指在生成动作前执行思维链过程，其模型输入与直接动作模式一致。推理轨迹会明确描述智能体对任务目标的解释，以及选择某个动作的理由；它通常引用屏幕中的视觉线索，并将其与用户指令联系起来。例如，模型可能先推理“任务是调节亮度。我看到右上角有一个设置图标，它很可能通向显示设置”，然后提出 `click(x=1040, y=75)` 这样的动作。中间思考过程被包裹在 `<think>...</think>` 标签中，可提高动作可靠性，尤其适用于上下文理解和逻辑定位至关重要的歧义任务或多步任务。

由于生成过程更长，该模式会引入更高的计算成本与延迟，但能显著提高智能体行为的质量和可解释性。显式推理为每一步提供人类可理解的理由，支持对决策模式和失败案例进行细粒度分析，并可用于迭代改进模型的推理启发式方法。在动作前加入结构化思考后，智能体能够以透明方式执行复杂任务，因此特别适合重视精确性和可解释性的长程交互场景。

4.3 训练方案

作者根据模型大小和可用硬件资源，为不同 ScaleCUA 模型采用不同配置。ScaleCUA-3B 使用 mini-batch 大小 4、梯度累积 1，在 128 张 A100 GPU 上训练。ScaleCUA-7B 使用同样的有效 batch 配置（mini-batch 大小 2、梯度累积 2）和同样的 GPU 设置。ScaleCUA-32B 的参数量显著更大，因此作者把 mini-batch 大小降为 2，并使用梯度累积 2，以维持有效 batch 大小 4；训练在 128 张 H200 GPU 上进行，以适应更高的显存占用。所有模型的学习率均为 1.0×10^{-5} ，最大 token 长度均为 40960。

对于所有模型，作者实验了训练语料中不同比例的通用多模态数据。3B、7B 和 32B 模型分别以 25%、50% 和 75% 的通用数据比例训练。实验中，当通用数据占 GUI

专用训练语料的 25% 时，3B 模型训练后已能在 GUI 智能体基准上取得较强性能。考虑到更大模型能够记忆更多数据样本，作者将 7B 模型的比例提高到 50%，并将 32B 模型进一步提高到 75%。

5 实验

5.1 评测设置

为全面评估计算机使用智能体的能力，评测覆盖理解、定位和智能体任务完成能力。需要特别指出：所有基准上的模型评测都只使用纯视觉观测。

为验证 **GUI 理解性能**，作者采用 MMBench-GUI L1 (Wang et al., 2025c)。该基准通过多项选择题评估智能体在不同平台上对界面内容的细粒度感知与推理，可作为无需显式执行动作的基础 GUI 理解标准化测试。

为量化 **GUI 定位性能**，作者在 ScreenSpot-v2 (Wu et al., 2024b)、ScreenSpot-Pro (Li et al., 2025) 和 OSWorld-G (Xie et al., 2025) 上进行结构化评测。这些数据集用于衡量 UI 元素的空间定位能力。ScreenSpot-v2 强调文本目标和视觉目标上的跨平台定位准确率；ScreenSpot-Pro 按使用领域划分应用，支持对开发、创意、科学和生产场景中的定位性能进行细粒度分析。OSWorld-G 的屏幕截图由先前模型在 OSWorld 上运行时采样，因此可更精确地区分当前模型在 OSWorld 上的瓶颈究竟来自定位能力还是规划能力。默认情况下，作者仅在 ScreenSpot-Pro 上使用 2K 分辨率，在其他定位基准上使用 1080p。

对于**端到端智能体评测**，作者在一组离线和在线 GUI 交互基准上测试模型。离线评测使用 AndroidControl 数据集，它提供低复杂度和高复杂度任务的细粒度控制基准。在线设置则把智能体部署到动态实时环境，包括 OSWorld (Xie et al., 2024)、WindowsAgentArena (Bonatti et al., 2024)、MacOSArena (Wang et al., 2025c)、AndroidWorld (Rawles et al., 2024) 和 WebArena-Lite-v2。若无特殊说明，消融实验中的在线基准使用 50 步预算。这些平台覆盖桌面、移动端和 Web 环境，能够全面评估智能体在真实、平台特定任务中的完成能力。

值得注意的是，WebArena-Lite (Liu et al., 2024a) 原本并非为纯视觉评测设计。此外，其中一些任务无法完成，甚至需要桌面环境以外的动作。为解决这些限制，作者将其升级为 WebArena-Lite-v2，为评测视觉 Web 智能体提供更合适的框架；细节见原文附录。

作者还在四个广泛使用的视觉语言基准上验证模型的**通用能力**：MMMU (Yue et al., 2024)、MathVista (Lu et al., 2023)、OCRBench (Liu et al., 2024b) 和 RealWorldQA (xAI, 2024)。这些基准共同覆盖全面多模态理解、数学推理、基于 OCR 的视觉问答以及真实世界视觉问答等多类任务。它们与计算机使用智能体性能密切相关，因为 OCR 熟练度是有效定位的基础，而多模态推理是复杂规划能力的必要前提。

另外，为确保在线评测的可扩展性和平台适应性，作者使用 vLLM³ (Kwon et al., 2023) 部署 QwenVL 模型。这种多维评测设置使作者能够跨不同数据集和平台，系统分析智能体框架从感知、定位到规划与执行的每个组成部分。

³<https://github.com/vllm-project/vllm>

表 2: MMBench-GUI L1 (GUI 内容理解) 上的结果 (Wang et al., 2025c)。

模型	Windows	macOS	Linux	iOS	Android	Web	总体
简单难度							
GPT-4o (2024)	62.5	67.9	62.4	58.5	56.4	58.5	60.2
Claude-3.5 (2024a)	41.3	50.0	41.6	42.0	39.0	41.8	41.5
Claude-3.7 (2025)	34.7	49.1	39.4	42.8	37.5	40.8	39.1
Qwen-Max-VL (2023)	69.1	72.5	69.9	70.8	63.1	69.5	68.2
Qwen2.5-VL-72B (2025)	65.9	75.2	73.0	67.2	58.1	72.1	67.0
UI-TARS-72B-DPO (2025)	41.6	28.5	35.2	31.1	52.3	35.3	40.2
InternVL3-72B (2025)	74.7	78.7	79.2	83.6	80.1	81.2	79.2
GUI-Owl-7B (2025)	83.0	84.5	85.6	82.6	83.3	88.1	84.5
GUI-Owl-32B (2025)	93.7	89.3	93.3	95.7	90.5	94.1	92.8
ScaleCUA-3B	86.4	83.5	79.9	85.4	80.3	87.4	83.6
ScaleCUA-7B	89.5	86.9	89.1	86.2	87.0	90.1	88.4
ScaleCUA-32B	<u>93.4</u>	91.7	94.3	<u>93.1</u>	90.5	<u>92.3</u>	<u>92.5</u>
中等难度							
GPT-4o (2024)	56.3	63.1	59.7	54.1	57.7	55.0	57.2
Claude-3.5 (2024a)	39.3	47.6	46.0	44.6	42.0	34.33	41.26
Claude-3.7 (2025)	39.3	39.2	42.3	39.5	36.1	36.2	38.4
Qwen-Max-VL (2023)	63.4	73.9	66.9	68.0	63.7	64.6	65.4
Qwen2.5-VL-72B (2025)	66.3	72.7	72.6	59.3	66.2	68.2	67.5
UI-TARS-72B-DPO (2025)	38.8	41.6	37.1	41.7	54.7	31.6	41.8
InternVL3-72B (2025)	71.5	78.6	79.9	78.4	81.4	78.7	77.9
GUI-Owl-7B (2025)	88.9	88.1	91.2	84.4	85.3	83.6	86.9
GUI-Owl-32B (2025)	<u>94.1</u>	84.5	<u>95.9</u>	<u>87.8</u>	92.8	88.6	<u>91.7</u>
ScaleCUA-3B	91.8	78.5	88.7	74.8	88.6	79.5	85.6
ScaleCUA-7B	93.6	91.7	93.4	84.3	89.6	85.8	90.1
ScaleCUA-32B	95.1	<u>89.4</u>	96.3	92.2	<u>92.6</u>	<u>87.2</u>	92.5
困难难度							
GPT-4o (2024)	60.7	60.4	52.4	45.3	50.9	50.8	53.5
Claude-3.5 (2024a)	37.40	42.70	34.07	40.86	36.96	38.1	37.6
Claude-3.7 (2025)	33.0	34.5	32.0	39.2	37.0	38.9	35.7
Qwen-Max-VL (2023)	66.6	67.6	65.8	60.2	58.8	65.3	63.7
Qwen2.5-VL-72B (2025)	70.7	68.9	71.0	57.6	53.9	68.1	64.6
UI-TARS-72B-DPO (2025)	31.5	35.9	24.2	36.3	58.1	19.9	35.8
InternVL3-72B (2025)	75.1	77.4	76.2	70.4	75.7	78.1	75.7
GUI-Owl-7B (2025)	87.8	<u>96.4</u>	94.3	87.8	88.9	94.1	90.9
GUI-Owl-32B (2025)	93.3	95.2	<u>95.9</u>	<u>92.2</u>	95.4	92.69	<u>94.2</u>
ScaleCUA-3B	92.3	89.4	93.8	85.3	88.3	88.6	89.9
ScaleCUA-7B	91.9	91.9	94.9	89.6	92.9	91.4	92.3
ScaleCUA-32B	<u>93.0</u>	96.5	96.4	93.1	<u>94.5</u>	<u>94.0</u>	94.4

5.2 综合评测

5.2.1 GUI 理解

作者在 MMBench-GUI L1 (GUI 内容理解) 上评测模型。该基准遵循 MMBench-GUI 协议，衡量模型在六个平台上的细粒度感知和推理能力。如表 2 所示，ScaleCUA 始终取得具有竞争力或更优的结果。即使是轻量级 ScaleCUA-3B，也在简单难度上达到 83.6%，比 Qwen2.5-VL-72B 高 16.6 个百分点。ScaleCUA-7B 进一步提升到 88.4%；ScaleCUA-32B 达到 92.5%，尽管训练语料不同，仍与 GUI-Owl-32B 相当。在中等难度任务上，ScaleCUA-32B 得到 92.5%；在困难任务上则达到 94.4%，优于所有专有和开源模型。这些结果表明，使用跨平台 GUI 专用数据扩展训练十分有效，并证实多样化训练语料能够显著增强模型对异构环境的视觉理解。

5.2.2 GUI 定位

随后，作者评测 GUI 定位，即跨桌面、移动端和 Web 环境，将视觉元素与文本或功能指代进行定位和关联的能力。如表 3 和表 4 所示，ScaleCUA 在不同基准上始终取得最佳性能。在 ScreenSpot-v2 上，ScaleCUA-32B 的平均分达到 94.7%，超过所有开源 VLM。即使轻量级 ScaleCUA-3B 也达到 89.2%；尽管参数少得多，它仍比 Qwen2.5-VL-7B 高 0.4 个百分点。在难度更高的

ScreenSpot-Pro 上，ScaleCUA-32B 再次领先，总体达到 59.2%，并在创意软件、CAD 和办公应用等多种领域取得较强准确率。

OSWorld-G 与 MMBench-GUI L2 的更多结果见原文附录。总体上，这些结果表明，使用 GUI 专用数据进行规模扩展能为定位带来显著收益。多个 GUI 定位基准上的一致提升也验证了双闭环数据流水线学习鲁棒 UI 元素定位的有效性。

5.2.3 任务完成

作者在移动端 (AndroidWorld (Rawles et al., 2024))、Ubuntu (OSWorld (Xie et al., 2024))、Windows (WindowsAgentArena (Bonatti et al., 2024))、macOS (MacOSArena (Wang et al., 2025c)) 和 Web (WebArena-Lite-v2) 上评测端到端任务完成，同时考察原生智能体与规划器-定位器 workflow。表 5 的结果给出三项结论。第一，原生 ScaleCUA-32B 取得最强的 Web 性能：15 步预算下为 44.2%，50 步预算下为 47.4%，分别比最佳原生基线 UI-TARS-72B-DPO 高 20.8 和 26.0 个百分点，也显著超过 Qwen2.5-VL-72B。第二，在 WindowsAgentArena 的 15 步设置中，ScaleCUA-32B 达到 24.2%，比 UI-TARS-72B-DPO 的 17.9% 高 6.3 个百分点；不过，50 步设置对所有原生模型仍很困难。第三，在 GPT-4o 充当规划器、ScaleCUA-7B 充当定位器的工作流设置中，Android-

表 3: ScreenSpot-v2 上的结果 (Wu et al., 2024b)。

方法	移动端		桌面		Web		平均
	文本	图标/控件	文本	图标/控件	文本	图标/控件	
Operator (2025)	47.3	41.5	90.2	80.3	92.8	84.3	70.5
Claude-3.7-Sonnet (2025)	—	—	—	—	—	—	87.6
UI-TARS-1.5 (2025)	—	—	—	—	—	—	94.2
Seed-1.5-VL (2025)	—	—	—	—	—	—	95.2
Kimi-VL-A3B-Thinking-2506 (2025b)	—	—	—	—	—	—	91.4
MiMo-VL-7B-RL (2025)	—	—	—	—	—	—	90.5
InternVL3.5-241B-A28B (2025a)	97.9	91.5	97.4	82.9	94.0	89.2	92.9
SeeClick (2024)	78.4	50.7	70.1	29.3	55.2	32.5	55.1
OmniParser-v2 (2024b)	95.5	74.6	92.3	60.9	88.0	59.6	80.7
OS-Atlas-Base-7B (2024b)	95.2	75.8	90.7	63.6	90.6	77.3	84.1
UI-TARS-2B (2025)	95.2	79.1	90.7	68.6	87.2	78.3	84.7
UI-TARS-7B (2025)	96.9	89.1	95.4	85.0	93.6	85.2	91.6
UI-TARS-72B (2025)	94.8	86.3	91.2	87.9	91.5	87.7	90.3
Qwen2.5-VL-3B (2025)	93.4	73.5	88.1	58.6	88.0	71.4	80.9
Qwen2.5-VL-7B (2025)	97.6	87.2	90.2	74.2	93.2	81.3	88.8
Qwen2.5-VL-32B (2025)	97.9	88.2	98.5	79.3	91.2	86.2	91.3
JEDI-3B (2025)	96.6	81.5	96.9	78.6	88.5	83.7	88.6
JEDI-7B (2025)	96.9	87.2	95.9	87.9	<u>94.4</u>	84.2	91.7
GUI-Actor-7B (2025)	97.6	88.2	96.9	85.7	93.2	86.7	92.1
GTA1-7B (2025)	99.0	88.6	94.9	<u>89.3</u>	92.3	86.7	92.4
GTA1-32B (2025)	<u>98.6</u>	89.1	96.4	86.4	95.7	88.7	93.2
GUI-Owl-7B (2025)	99.0	92.4	96.9	85.0	93.6	85.2	92.8
GUI-Owl-32B (2025)	98.6	90.0	97.9	87.8	<u>94.4</u>	86.7	93.2
ScaleCUA-3B	94.1	86.3	94.9	79.3	89.7	85.7	89.2
ScaleCUA-7B	97.3	90.5	95.4	87.9	94.0	88.7	92.7
ScaleCUA-32B	<u>98.6</u>	<u>91.9</u>	99.0	90.0	<u>94.4</u>	91.6	<u>94.7</u>

World 达到 48.3%，WebArena-Lite-v2 的 50 步设置达到 35.1%，优于 UI-TARS-1.5-7B (28.6%) 和 UGround-V1-7B (26.5%) 等强定位器。

除这些重点结果外，还可观察到几个趋势。(i) 模型从 3B 扩展至 7B、再扩展至 32B 时，Windows 与 Web 性能单调提升，说明随着模型容量增大，跨平台数据与统一动作空间可转化为更强的计算机使用能力。(ii) 步数预算的影响是一致的：包括 ScaleCUA 在内的大多数智能体在 50 步限制下都有显著性能提升。(iii) 跨平台差异仍然存在：AndroidWorld 更有利于规划器-定位器 workflow，它们缩小了与移动端专用原生模型的差距，但尚未消除；macOS 基准的结果整体偏低，说明存在操作系统特定的可操作性缺口，而不只是定位能力有限。综合来看，ScaleCUA 作为计算机使用智能体的基础模型具备鲁棒的任务完成能力，也能在规划器-定位器流水线中充当具有竞争力且可迁移的定位器。

5.3 数据集消融实验

本节对作者的数据集进行消融。如图 1 所示，使用作者整理的训练语料进行训练，相比使用公共数据训练的基线可获得一致提升。表 6 进一步展示数据增强、弱语义轨迹、坐标格式和分辨率的影响。

首先，作者评估数据增强的作用。不使用增强时，模型在 ScreenSpot-Pro 上达到 37.8%；元素裁剪、屏幕截图拼接等简单增强则将性能提高到 41.3%。这证实数据增强通过让模型接触更广泛的视觉条件，提高了泛化性与鲁棒性。第二，作者考察由基于规则的随机探索产生的弱语义轨迹。尽管这些轨迹缺少明确高层目标，它们仍能以较低成本为界面导航提供监督。第三，作者研究定位任务中坐标表示的影响。使用原始坐标训练的模型优于




图 5: 不同条件下的评测。(a) 不同屏幕截图分辨率下的 GUI 定位准确率；(b) 直接动作模式与推理动作模式的成功率，推理始终提高性能；(c) 训练数据扩展；(d) 使用通用数据的影响，GUI 基准与多模态基准呈现不同趋势。

使用归一化坐标的模型 (ScreenSpot-Pro 上为 42.3% 对 37.9%)。这说明精确绝对位置能够更好地捕捉跨平台布局规律，减少归一化引入的歧义。最后，作者对训练分辨率进行消融。更高分辨率在不同基准间存在权衡：2K 提高 ScreenSpot-Pro 上的定位性能 (45.5% 对 42.3%)，并基本保持 OSWorld-G 准确率 (52.5% 对 54.3%)，但会略微降低 OSWorld 和 AndroidWorld 上的智能体成功率。这说明细粒度定位受益于高分辨率监督，而智能体基准可能因过度拟合像素级细节受到影响。UI 元素定位与在线智能体基准上的提升表明，训练数据设计是构建可扩展、可泛化计算机使用智能体的核心。

5.4 智能体诊断分析

为更好地理解影响计算机使用智能体性能的因素，作者围绕分辨率、推理模式、数据扩展和是否加入通用多模态数据开展了额外分析，如图 5 所示。这些研究更深入地揭示了效率、准确率和泛化性之间的权衡。

分辨率的影响。图 5(a) 评测不同屏幕截图分辨率下的定位准确率。作者观察到，从 720p 提升到 2K 时，准确

表 4: ScreenSpot-Pro 上的结果 (Li et al., 2025)。

智能体模型	开发			创意			CAD			科学			办公			系统			平均
	文本	图标	平均	文本	图标	平均	文本	图标	平均	文本	图标	平均	文本	图标	平均	文本	图标	平均	
SeeClick (2024)	0.6	0.0	0.3	1.0	0.0	0.6	2.5	0.0	1.9	3.5	0.0	2.0	1.1	0.0	0.9	2.8	0.0	1.5	1.1
Qwen2-VL-7B (2024b)	2.6	0.0	1.3	1.5	0.0	0.9	0.5	0.0	0.4	6.3	0.0	3.5	3.4	1.9	3.0	0.9	0.0	0.5	1.6
ShowUI-2B (2024)	16.9	1.4	9.4	9.1	0.0	5.3	2.5	0.0	1.9	13.2	7.3	10.6	15.3	7.5	13.5	10.3	2.2	6.6	7.7
CogAgent-18B (2024)	14.9	0.7	8.0	9.6	0.0	5.6	7.1	3.1	6.1	22.2	1.8	13.4	13.0	0.0	10.0	5.6	0.0	3.1	7.7
Aria-UI (2024)	16.2	0.0	8.4	23.7	2.1	14.7	7.6	1.6	6.1	27.1	6.4	18.1	20.3	1.9	16.1	4.7	0.0	2.6	11.3
Claude (2024b)	22.0	3.9	12.6	25.9	3.4	16.8	14.5	3.7	11.9	33.9	15.8	25.8	30.1	16.3	26.9	11.0	4.5	8.1	17.1
Operator (2025)	50.0	19.3	35.1	51.5	23.1	39.6	16.8	14.1	16.1	58.3	24.5	43.7	60.5	28.3	53.0	34.6	30.3	32.7	36.6
OS-Atlas-7B (2024b)	33.1	1.4	17.7	28.8	2.8	17.9	12.2	4.7	10.3	37.5	7.3	24.4	33.9	5.7	27.4	27.1	4.5	16.8	18.9
UGround-V1-7B (2024)	—	—	35.5	—	—	27.8	—	—	13.5	—	—	38.8	—	—	48.8	—	—	26.1	31.1
UGround-V1-72B (2024)	—	—	31.1	—	—	35.8	—	—	13.8	—	—	50.0	—	—	51.3	—	—	25.5	34.5
UI-TARS-2B (2025)	47.4	4.1	26.4	42.9	6.3	27.6	17.8	4.7	14.6	56.9	17.3	39.8	50.3	17.0	42.6	21.5	5.6	14.3	27.7
UI-TARS-7B (2025)	58.4	12.4	36.1	50.0	9.1	32.8	20.8	9.4	18.0	63.9	31.8	50.0	63.3	20.8	53.5	30.8	16.9	24.5	35.7
UI-TARS-1.5-7B (2025)	58.4	12.4	31.8	58.1	15.4	40.2	38.6	11.0	31.8	66.7	21.9	47.2	74.6	35.9	65.6	49.5	13.5	33.2	42.0
UI-TARS-72B (2025)	63.0	17.3	40.8	57.1	15.4	39.6	18.8	12.5	17.2	64.6	20.9	45.7	63.3	26.4	54.8	42.1	15.7	30.1	38.1
Qwen2.5-VL-3B (2025)	38.3	3.4	21.4	40.9	4.9	25.8	22.3	6.3	18.4	44.4	10.0	29.5	48.0	17.0	40.9	33.6	4.5	20.4	25.9
Qwen2.5-VL-7B (2025)	51.9	4.8	29.1	36.9	8.4	24.9	17.8	1.6	13.8	48.6	8.2	31.1	53.7	18.9	45.7	34.6	7.9	22.4	27.6
Qwen2.5-VL-32B (2025)	74.0	21.4	48.5	61.1	13.3	41.1	38.1	15.6	32.6	78.5	29.1	57.1	76.3	37.7	67.4	55.1	27.0	42.3	47.6
JEDI-3B (2025)	61.0	13.8	38.1	53.5	8.4	34.6	27.4	9.4	23.0	54.2	18.2	38.6	64.4	32.1	57.0	38.3	9.0	25.0	36.1
JEDI-7B (2025)	42.9	11.0	27.4	50.0	11.9	34.0	38.0	14.1	32.2	72.9	25.5	52.4	75.1	47.2	68.7	33.6	16.9	26.0	39.5
UI-R1-3B (2025)	22.7	4.1	—	27.3	3.5	—	11.2	6.3	—	42.4	11.8	—	32.2	11.3	—	13.1	4.5	—	17.8
InfGUI-R1-3B (2025b)	51.3	12.4	32.4	44.9	7.0	29.0	33.0	14.1	28.4	58.3	20.0	41.7	65.5	28.3	57.0	43.9	12.4	29.6	35.7
GUI-G1-3B (2025)	50.7	10.3	31.1	36.6	11.9	26.6	39.6	9.4	32.2	61.8	30.0	48.0	67.2	32.1	59.1	23.5	10.6	16.1	37.1
GUI-Owl-7B (2025)	76.6	31.0	54.5	59.6	27.3	46.1	64.5	21.9	54.1	79.1	37.3	61.0	77.4	39.6	68.7	59.8	33.7	47.9	54.9
GUI-Owl-32B (2025)	84.4	39.3	62.5	65.2	18.2	45.5	62.4	28.1	54.0	82.6	39.1	63.8	81.4	39.6	<u>71.8</u>	70.1	36.0	54.6	<u>58.0</u>
ScaleCUA-3B	57.8	18.6	38.8	42.9	16.8	32.0	54.3	28.1	47.9	64.6	35.5	52.0	66.7	37.7	53.9	31.8	16.9	25.0	42.3
ScaleCUA-7B	66.2	20.7	44.1	56.6	20.3	41.3	54.8	21.9	46.7	77.1	24.5	54.3	74.0	45.3	67.4	49.5	18.0	35.2	47.9
ScaleCUA-32B	75.3	35.2	<u>55.8</u>	73.2	30.8	55.4	60.4	39.1	55.2	76.4	46.4	<u>63.4</u>	81.4	49.1	73.9	63.6	41.6	<u>53.6</u>	59.2

率持续提高；到 4K 时边际收益减弱。ScreenSpot-Pro 的受益最为明显，表明细粒度元素定位需要高分辨率细节。ScreenSpot-v2 和 OSWorld-G 中，分辨率不超过 1080p 的图像占主导，因此评测时把输入分辨率提高到 1080p 以上不会带来性能增益，有时甚至会造成轻微下降。

直接动作模式与推理动作模式。图 5(b) 比较计算机使用智能体的两种推理模式。在所有基准上，推理动作模式 (RAM) 的成功率都高于直接动作模式 (DAM)，绝对增益为 1.4% 至 8.2%。该优势在 WebArena-Lite-v2 等复杂多步环境中尤其明显。结果表明，显式推理有助于模型保持任务连贯性，并减少长程交互中的错误传播。不过，性能提升以更高推理延迟为代价，说明不同部署场景需要在效率与鲁棒性之间进行权衡。

随训练数据扩展的行为。图 5(c) 展示成功率随训练数据比例变化的关系。所有基准都受益于数据增加，但增益呈对数趋势，大部分提升在数据比例超过 75% 后趋于饱和。值得注意的是，WebArena-Lite-v2 在整个范围内近似线性提升，说明它对数据规模的需求更高，也更敏感。相比之下，ScreenSpot-Pro 只使用一半可用数据就能达到有竞争力的准确率，说明某些定位基准对数据的需求较低。这一观察表明，应根据基准的内在复杂度分配数据。

通用多模态数据的影响。图 5(d) 分析训练中加入通用多模态数据的影响。结果呈现清晰分化：随着通用数据比例增加，GUI 基准性能逐渐下降，而通用基准性能稳定提高，并在约 75% 时达到峰值。该权衡表明，混合异构数据源会引入相互冲突的优化信号。多模态语料扩大时，模型的通用能力提高，但 GUI 专业知识会被稀释。结果说明，可能需要数据平衡训练策略，才能在不牺牲通用推理能力的同时保留 GUI 专业能力。由于更大模型能够记忆更多知识，将 7B 模型的通用数据比例提高至 50%、32B 模型提高至 75% 是合理的。

讨论。这些结果揭示了几个关键观察。高分辨率输入与基于推理的推理方式能够改善定位和任务完成，但会产生计算成本。扩大数据规模仍然至关重要，不过不同基准对规模的敏感程度不同。最后，加入通用多模态数

据会提高推理能力，却可能损害 GUI 定位准确率，因此需要谨慎设计数据混合策略。这些发现强调，要构建鲁棒的通用智能体，可扩展的跨平台训练数据非常重要。

6 结论

本文提出 **ScaleCUA**：一个为 CUA 定制的新模型与数据集系列。通过整理大规模跨平台数据，并在桌面、移动端和 Web 环境间标准化动作空间，作者建立了用于评测和训练智能体的统一基础。结合自动化智能体-环境交互与人在环标注的双闭环数据流水线，使作者能够构建覆盖 GUI 理解、元素定位和任务完成的多样化基准。

大量实验表明，ScaleCUA 显著优于开源和专有基线。在 GUI 理解任务上，ScaleCUA-32B 在所有平台和难度等级都取得最佳准确率，凸显 GUI 专用监督的益处。在 ScreenSpot-v2、ScreenSpot-Pro 和 OSWorld-G 等定位基准上，本文模型持续刷新性能纪录，验证了细粒度元素级对齐的有效性。此外，L2-GUI 定位和在线基准上的强劲结果进一步说明模型在真实交互环境中具有鲁棒性。

这些贡献将视觉语言建模与实际 GUI 交互连接起来，推动了计算机使用智能体的前沿。尽管长程推理和跨应用泛化仍有局限，结果表明，扩展专用训练流水线有望构建鲁棒、通用的计算机使用系统。作者希望 ScaleCUA 及其发布资源能成为未来研究的坚实基础，支持构建有能力、可信且可部署的 CUA。

局限性

本文开发了一族基础智能体模型，并建立了用于收集跨平台 GUI 交互轨迹的全面数据流水线。尽管如此，仍存在若干局限。

第一，由智能体采集的数据在质量上仍落后于专家众包。基于规则的探索通常产生语义较弱的轨迹，而专家整理数据又难以低成本扩展。如何把自动化采集与

表 5: 智能体在不同平台和基准上的在线评测。AndroidWorld 中的每个任务都有预定义的最大步数。♣ 表示模型使用的步数未知, ★ 表示步数超过 50。

方法	移动端	Ubuntu		Windows		macOS		Web	
	(AndroidWorld)	(OSWorld)		(WindowsAgentArena)		(MacOSArena)		(WebArena-Lite-v2)	
	预定义步数	15 步	50 步	15 步	50 步	15 步	50 步	15 步	50 步
原生智能体									
Kimi-VL-A3B (2025b)	–	8.2♣		10.4♣		–	–	–	–
Seed1.5-VL (2025)	62.1	36.7★		39.6★		–	–	–	–
GLM-4.1V-Thinking (2025)	41.7	14.9★		–	–	–	–	–	–
GLM-4.5V-Thinking (2025)	57.0	35.8★		–	–	–	–	–	–
PC Agent-E (2025)	–	14.9♣		–	–	–	–	–	–
COMPUTERRL (2025)	–	47.3♣		–	–	–	–	–	–
GPT-4o (2024)	21.6	6.8	10.1	5.6	3.5	0.0	1.4	2.0	3.3
Claude-3.7 (2025)	11.2	7.4	10.3	7.1	6.4	5.7	<u>7.1</u>	2.0	2.6
Qwen2.5-VL-72B (2025)	27.6	9.8	10.6	11.8	9.7	1.4	5.7	15.6	14.4
InternVL3.5-241B-A28B (2025a)	29.7	11.1	11.6	15.2	18.0	2.9	5.7	11.7	11.7
Aguvis-72B (2024)	26.1	3.8	4.2	4.1	3.5	0.0	0.0	5.8	9.0
UI-TARS-7B-SFT (2025)	33.0	17.7	–	–	–	–	–	11.0	13.6
UI-TARS-1.5-7B (2025)	31.6	22.1	23.9	11.1	15.9	<u>7.1</u>	<u>7.1</u>	20.8	26.0
UI-TARS-72B-DPO (2025)	<u>46.6</u>	24.2	25.2	11.1	17.9	8.6	8.6	23.4	21.4
OpenCUA-7B (2025b)	–	<u>24.3</u>	<u>28.1</u>	–	–	–	–	–	–
OpenCUA-32B (2025b)	–	29.7	34.1	–	–	–	–	–	–
ScaleCUA-3B	23.7	9.6	12.4	13.1	15.2	0.0	1.4	31.8	33.1
ScaleCUA-7B	27.2	14.3	15.0	<u>18.0</u>	<u>20.7</u>	4.3	4.3	<u>37.7</u>	<u>37.7</u>
ScaleCUA-32B	30.6	16.5	17.7	21.4	24.2	<u>7.1</u>	<u>7.1</u>	44.2	47.4
智能体式 workflow									
规划器	定位器								
GPT-4o	Aria-UI (2024)	<u>44.8</u>	15.2♣	–	–	–	–	–	–
	OS-Atlas-7B (2024b)	–	14.6♣	–	–	–	–	–	–
	UGround-V1-7B (2024)	32.8	13.1	16.1	13.1	20.7	<u>1.4</u>	0.0	<u>23.2</u>
	UI-TARS-1.5-7B (2025)	37.9	16.5	19.1	14.5	26.2	<u>1.4</u>	0.0	<u>22.6</u>
	JEDI-3B (2025)	–	22.4	–	29.1	–	–	–	–
	JEDI-7B (2025)	–	<u>22.7</u>	<u>25.0</u>	<u>30.2</u>	<u>32.9</u>	–	–	–
	ScaleCUA-7B	48.3	22.9	28.1	31.7	36.6	5.7	8.6	28.6
									35.1

表 6: 数据消融实验。在线基准的最大步数设为 50。

(a) 数据增强消融。训练中仅使用 GUI 相关数据。

模型	训练数据	增强	SS-Pro
Qwen2.5VL-3B	ours-only	✓	37.8
		✓	41.3

(b) 弱语义轨迹消融。使用的公共数据集见原文附录。

模型	训练数据	+ 弱语义	OSWorld	WAL-v2
Qwen2.5VL-3B	public-only	✓	7.9	8.4
		✓	8.5	14.3

(c) 坐标类型消融。

模型	类型	ScreenSpot-Pro
Qwen2.5VL-3B	归一化	37.9
	原始	42.3

(d) 训练期间最大分辨率的消融。

模型	分辨率	SS-Pro	OSWorld-G	OSWorld	AW
Qwen2.5VL-3B	1080P	42.3	54.3	12.4	23.3
	2K	45.5	52.5	11.2	13.4

迭代式模型改进有效耦合，形成自我改进闭环，仍是一个开放挑战。

第二，尽管本文重点是跨平台计算机使用智能体构建鲁棒基础模型，但尚未加入反思、基于记忆的决策或层次化规划等高级智能体机制。此外，作者也没有探索策略奖励模型（Policy Reward Model, PRM）或强化学习等优化策略。这些技术有望提高推理、适应和长程决策能力，但需要以强大的基础模型为前提。

第三，当前记忆机制较为初级，只把先前操作视为扁平历史。这种浅层设计限制了长程推理，并可能造成次优执行。本文的主要目标是利用大规模 GUI 语料训练具备强泛化和指令遵循能力的基础智能体模型。开发能够捕获时间依赖、轻量而有效的记忆系统，是未来工作的重

要方向。

综上，尽管本文框架为训练 GUI 智能体提供了统一基础，要实现闭环学习和高层推理能力仍需进一步研究。解决这些局限对于实现完全自主、智能的计算机使用智能体至关重要。

参考文献

Saaket Agashe, Kyle Wong, Vincent Tu, Jiachen Yang, Ang Li, and Xin Eric Wang. Agent s2: A compositional generalist-specialist framework for computer use agents, 2025. URL <https://arxiv.org/abs/2504.00906>.

Anthropic. Claude 3.5. Anthropic AI Assistant, September 2024a. URL <https://www.anthropic.com/claude>. Accessed: 2025-06-23.

Sonnet Anthropic. Model card addendum: Claude 3.5 haiku and upgraded claude 3.5 sonnet, 2024b. URL <https://api.semanticscholar.org/CorpusID:273639283>.

Sonnet Anthropic. Claude 3.7 sonnet system card, 2025. URL <https://www.anthropic.com/news/claude-3-7-sonnet>.

- Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A frontier large vision-language model with versatile abilities. *arXiv preprint arXiv:2308.12966*, 2023.
- Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. Qwen2. 5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025.
- Rogério Bonatti, Dan Zhao, Francesco Bonacci, Dillon Dupont, Sara Abdali, Yinheng Li, Yadong Lu, Justin Wagle, Kazuhito Koishida, Arthur Buckner, et al. Windows agent arena: Evaluating multi-modal os agents at scale. *arXiv preprint arXiv:2409.08264*, 2024.
- Yuxiang Chai, Siyuan Huang, Yazhe Niu, Han Xiao, Liang Liu, Dingyu Zhang, Peng Gao, Shuai Ren, and Hongsheng Li. Amex: Android multi-annotation expo dataset for mobile gui agents. *ArXiv preprint*, 2024. URL <https://arxiv.org/abs/2407.17490>.
- Dongping Chen, Yue Huang, Siyuan Wu, Jingyu Tang, Huichi Zhou, Qihui Zhang, Zhigang He, Yilin Bai, Chu-jie Gao, Liuyi Chen, et al. Gui-world: A video benchmark and dataset for multimodal gui-oriented understanding. In *ICLR*, 2025a.
- Wentong Chen, Junbo Cui, Jinyi Hu, Yujia Qin, Junjie Fang, Yue Zhao, Chongyi Wang, Jun Liu, Guirong Chen, Yupeng Huo, et al. Guicourse: From general vision language models to versatile gui agents. *arXiv preprint arXiv:2406.11317*, 2024a.
- Xuetian Chen, Yinghao Chen, Xinfeng Yuan, Zhuo Peng, Lu Chen, Yuekeng Li, Zhoujia Zhang, Yingqian Huang, Leyan Huang, Jiaqing Liang, et al. Os-map: How far can computer-using agents go in breadth and depth? *arXiv preprint arXiv:2507.19132*, 2025b.
- Zhe Chen, Weiyun Wang, Yue Cao, Yangzhou Liu, Zhangwei Gao, Erfei Cui, Jinguo Zhu, Shenglong Ye, Hao Tian, Zhaoyang Liu, et al. Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling. *arXiv preprint arXiv:2412.05271*, 2024b.
- Zhe Chen, Jiannan Wu, Wenhao Wang, Weijie Su, Guo Chen, Sen Xing, Muyan Zhong, Qinglong Zhang, Xizhou Zhu, Lewei Lu, et al. Internvl: Scaling up vision foundation models and aligning for generic visual-linguistic tasks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 24185–24198, 2024c.
- Kanzhi Cheng, Qiushi Sun, Yougang Chu, Fangzhi Xu, Yantao Li, Jianbing Zhang, and Zhiyong Wu. SeeClick: Harnessing gui grounding for advanced visual gui agents. *arXiv preprint arXiv:2401.10935*, 2024.
- Biplab Deka, Zifeng Huang, Chad Franzen, Joshua Hibschman, Daniel Afargan, Yang Li, Jeffrey Nichols, and Ranjitha Kumar. Rico: A mobile app dataset for building data-driven design applications. In *Proceedings of the 30th annual ACM symposium on user interface software and technology*, pp. 845–854, 2017.
- Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Sam Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2web: Towards a generalist agent for the web. *Advances in Neural Information Processing Systems*, 36:28091–28114, 2023.
- Boyu Gou, Ruohan Wang, Boyuan Zheng, Yanan Xie, Cheng Chang, Yiheng Shu, Huan Sun, and Yu Su. Navigating the digital world as humans do: Universal visual grounding for gui agents. *arXiv preprint arXiv:2410.05243*, 2024.
- Dong Guo, Faming Wu, Feida Zhu, Fuxing Leng, Guang Shi, Haobin Chen, Haoqi Fan, Jian Wang, Jianyu Jiang, Jiawei Wang, et al. Seed1. 5-vl technical report. *arXiv preprint arXiv:2505.07062*, 2025.
- Yanheng He, Jiahe Jin, and Pengfei Liu. Efficient agent training for computer use, 2025. URL <https://arxiv.org/abs/2505.13909>.
- Sirui Hong, Xiawu Zheng, Jonathan Chen, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, et al. Metagpt: Meta programming for multi-agent collaborative framework. *arXiv preprint arXiv:2308.00352*, 3(4):6, 2023.
- Wenyi Hong, Weihao Wang, Qingsong Lv, Jiazhang Xu, Wenmeng Yu, Junhui Ji, Yan Wang, Zihan Wang, Yuxiao Dong, Ming Ding, et al. Cogagent: A visual language model for gui agents. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 14281–14290, 2024.
- Wenyi Hong, Wenmeng Yu, Xiaotao Gu, Guo Wang, Guobing Gan, Haomiao Tang, Jiale Cheng, Ji Qi, Junhui Ji, Lihang Pan, et al. Glm-4.1 v-thinking: Towards versatile multimodal reasoning with scalable reinforcement learning. *arXiv preprint arXiv:2507.01006*, 2025.
- Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. Gpt-4o system card. *arXiv preprint arXiv:2410.21276*, 2024.
- Raghav Kapoor, Yash Parag Butala, Melisa Russak, Jing Yu Koh, Kiran Kamble, Waseem AlShikh, and Ruslan Salakhutdinov. Omniact: A dataset and benchmark for enabling multimodal generalist autonomous agents for desktop and web. In *European Conference on Computer Vision*, pp. 161–178. Springer, 2024.
- Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E. Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with page-dattention. In *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles*, 2023.

- Hanyu Lai, Xiao Liu, Yanxiao Zhao, Han Xu, Hanchen Zhang, Bohao Jing, Yanyu Ren, Shuntian Yao, Yuxiao Dong, and Jie Tang. Computerrl: Scaling end-to-end online reinforcement learning for computer use agents. *arXiv preprint arXiv:2508.14040*, 2025.
- Guohao Li, Hasan Hammoud, Hani Itani, Dmitrii Khizbullin, and Bernard Ghanem. Camel: Communicative agents for” mind” exploration of large language model society. *Advances in Neural Information Processing Systems*, 36:51991–52008, 2023.
- Kaixin Li, Ziyang Meng, Hongzhan Lin, Ziyang Luo, Yuchen Tian, Jing Ma, Zhiyong Huang, and Tat-Seng Chua. Screenspot-pro: Gui grounding for professional high-resolution computer use. *arXiv preprint arXiv:2504.07981*, 2025.
- Wei Li, William Bishop, Alice Li, Chris Rawles, Folawiyi Campbell-Ajala, Divya Tyamagundlu, and Oriana Riva. On the effects of data scale on computer control agents, 2024. URL <https://arxiv.org/abs/2406.03679>.
- Yang Li, Jiacong He, Xin Zhou, Yuan Zhang, and Jason Baldridge. Mapping natural language instructions to mobile UI action sequences. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020a. URL <https://aclanthology.org/2020.acl-main.729>.
- Yang Li, Gang Li, Luheng He, Jingjie Zheng, Hong Li, and Zhiwei Guan. Widget captioning: Generating natural language description for mobile user interface elements. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2020b. URL <https://aclanthology.org/2020.emnlp-main.443>.
- Kevin Qinghong Lin, Linjie Li, Difei Gao, Zhengyuan Yang, Shiwei Wu, Zechen Bai, Weixian Lei, Lijuan Wang, and Mike Zheng Shou. Showui: One vision-language-action model for gui visual agent, 2024. URL <https://arxiv.org/abs/2411.17465>.
- Haowei Liu, Xi Zhang, Haiyang Xu, Yuyang Wanyan, Junyang Wang, Ming Yan, Ji Zhang, Chunfeng Yuan, Changsheng Xu, Weiming Hu, and Fei Huang. Pc-agent: A hierarchical multi-agent collaboration framework for complex task automation on pc. *arXiv preprint arXiv:2502.14282*, 2025a.
- Xiao Liu, Tianjie Zhang, Yu Gu, Iat Long Iong, Yifan Xu, Xixuan Song, Shudan Zhang, Hanyu Lai, Xinyi Liu, Hanlin Zhao, et al. Visualagentbench: Towards large multimodal models as visual foundation agents. *arXiv preprint arXiv:2408.06327*, 2024a.
- Yuhang Liu, Pengxiang Li, Congkai Xie, Xavier Hu, Xiaotian Han, Shengyu Zhang, Hongxia Yang, and Fei Wu. Infigui-r1: Advancing multimodal gui agents from reactive actors to deliberative reasoners. *arXiv preprint arXiv:2504.14239*, 2025b.
- Yuliang Liu, Zhang Li, Mingxin Huang, Biao Yang, Wenwen Yu, Chunyuan Li, Xu-Cheng Yin, Cheng-Lin Liu, Lianwen Jin, and Xiang Bai. Ocrbench: on the hidden mystery of ocr in large multimodal models. *Science China Information Sciences*, 67(12):220102, 2024b.
- Pan Lu, Hritik Bansal, Tony Xia, Jiacheng Liu, Chunyuan Li, Hannaneh Hajishirzi, Hao Cheng, Kai-Wei Chang, Michel Galley, and Jianfeng Gao. Mathvista: Evaluating mathematical reasoning of foundation models in visual contexts. *arXiv preprint arXiv:2310.02255*, 2023.
- Quanfang Lu, Wenqi Shao, Zitao Liu, Fanqing Meng, Boxuan Li, Botong Chen, Siyuan Huang, Kaipeng Zhang, Yu Qiao, and Ping Luo. Gui odyssey: A comprehensive dataset for cross-app gui navigation on mobile devices. *arXiv preprint arXiv:2406.08451*, 2024a.
- Yadong Lu, Jianwei Yang, Yelong Shen, and Ahmed Awadallah. Omniparser for pure vision based gui agent, 2024b. URL <https://arxiv.org/abs/2408.00203>.
- Zhengxi Lu, Yuxiang Chai, Yaxuan Guo, Xi Yin, Liang Liu, Hao Wang, Han Xiao, Shuai Ren, Guanqing Xiong, and Hongsheng Li. Ui-r1: Enhancing efficient action prediction of gui agents by reinforcement learning. *arXiv preprint arXiv:2503.21620*, 2025.
- Run Luo, Lu Wang, Wanwei He, and Xiaobo Xia. Gui-r1: A generalist r1-style vision-language action model for gui agents. *arXiv preprint arXiv:2504.10458*, 2025.
- MetaAI. llama4, 2025. URL <https://ai.meta.com/blog/llama-4-multimodal-intelligence/>. Accessed: 2025-06-23.
- OpenAI. Gpt-4 technical report. *ArXiv*, abs/2303.08774, 2023. URL <https://api.semanticscholar.org/CorpusID:257532815>.
- OpenAI. Computer-using agent: Introducing a universal interface for ai to interact with the digital world, 2025. URL <https://openai.com/index/computer-using-agent>.
- Yujia Qin, Yining Ye, Junjie Fang, Haoming Wang, Shihao Liang, Shizuo Tian, Junda Zhang, Jiahao Li, Yunxin Li, Shijue Huang, et al. Ui-tars: Pioneering automated gui interaction with native agents. *arXiv preprint arXiv:2501.12326*, 2025.
- Christopher Rawles, Alice Li, Daniel Rodriguez, Oriana Riva, and Timothy Lillicrap. Androidinthewild: A large-scale dataset for android device control. *Advances in Neural Information Processing Systems*, 36: 59708–59728, 2023.
- Christopher Rawles, Sarah Clinckemaillie, Yifan Chang, Jonathan Waltz, Gabrielle Lau, Marybeth Fair, Alice Li, William Bishop, Wei Li, Folawiyi Campbell-Ajala, et al. Androidworld: A dynamic benchmarking

- environment for autonomous agents. *arXiv preprint arXiv:2405.14573*, 2024.
- Tianlin Shi, Andrej Karpathy, Linxi Fan, Jonathan Hernandez, and Percy Liang. World of bits: An open-domain platform for web-based agents. In Doina Precup and Yee Whye Teh (eds.), *Proceedings of the 34th International Conference on Machine Learning, ICML 2017, Sydney, NSW, Australia, 6-11 August 2017*, volume 70 of *Proceedings of Machine Learning Research*, pp. 3135–3144. PMLR, 2017. URL <http://proceedings.mlr.press/v70/shi17a.html>.
- Liangtai Sun, Xingyu Chen, Lu Chen, Tianle Dai, Zichen Zhu, and Kai Yu. Meta-gui: Towards multi-modal conversational agents on mobile gui. *arXiv preprint arXiv:2205.11029*, 2022.
- Qiushi Sun, Kanzhi Cheng, Zichen Ding, Chuanyang Jin, Yian Wang, Fangzhi Xu, Zhenyu Wu, Chengyou Jia, Liheng Chen, Zhoumianze Liu, et al. Os-genesis: Automating gui agent trajectory construction via reverse task synthesis. *arXiv preprint arXiv:2412.19723*, 2024.
- Qiushi Sun, Zhoumianze Liu, Chang Ma, Zichen Ding, Fangzhi Xu, Zhangyue Yin, Haiteng Zhao, Zhenyu Wu, Kanzhi Cheng, Zhaoyang Liu, et al. Scienceboard: Evaluating multimodal autonomous agents in realistic scientific workflows. *arXiv preprint arXiv:2505.19897*, 2025.
- Gemini Team, Rohan Anil, Sebastian Borgeaud, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, Katie Millican, et al. Gemini: a family of highly capable multi-modal models. *arXiv preprint arXiv:2312.11805*, 2023.
- Gemini Team, Petko Georgiev, Ving Ian Lei, Ryan Burnell, Libin Bai, Anmol Gulati, Garrett Tanzer, Damien Vincent, Zhufeng Pan, Shibo Wang, et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *arXiv preprint arXiv:2403.05530*, 2024.
- Gemma Team, Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Rivière, et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 2025a.
- Kimi Team, Angang Du, Bohong Yin, Bowei Xing, Bowen Qu, Bowen Wang, Cheng Chen, Chenlin Zhang, Chenzhuang Du, Chu Wei, Congcong Wang, Dehao Zhang, Dikang Du, Dongliang Wang, Enming Yuan, Enzhe Lu, Fang Li, Flood Sung, Guangda Wei, Guokun Lai, Han Zhu, Hao Ding, Hao Hu, Hao Yang, Hao Zhang, Haoning Wu, Haotian Yao, Haoyu Lu, Heng Wang, Hongcheng Gao, Huabin Zheng, Jiaming Li, Jianlin Su, Jianzhou Wang, Jiaqi Deng, Jiezhong Qiu, Jin Xie, Jinhong Wang, Jingyuan Liu, Junjie Yan, Kun Ouyang, Liang Chen, Lin Sui, Longhui Yu, Mengfan Dong, Mengnan Dong, Nuo Xu, Pengyu Cheng, Qizheng Gu, Runjie Zhou, Shaowei Liu, Sihan Cao, Tao Yu, Tianhui Song, Tongtong Bai, Wei Song, Weiran He, Weixiao Huang, Weixin Xu, Xiaokun Yuan, Xingcheng Yao, Xingzhe Wu, Xinxing Zu, Xinyu Zhou, Xinyuan Wang, Y. Charles, Yan Zhong, Yang Li, Yangyang Hu, Yanru Chen, Yejie Wang, Yibo Liu, Yibo Miao, Yidao Qin, Yimin Chen, Yiping Bao, Yiqin Wang, Yongsheng Kang, Yuanxin Liu, Yulun Du, Yuxin Wu, Yuzhi Wang, Yuzi Yan, Zaida Zhou, Zhaowei Li, Zhejun Jiang, Zheng Zhang, Zhilin Yang, Zhiqi Huang, Zihao Huang, Zijia Zhao, and Ziwei Chen. Kimi-VL technical report, 2025b. URL <https://arxiv.org/abs/2504.07491>.
- Kimi Team, Angang Du, Bohong Yin, Bowei Xing, Bowen Qu, Bowen Wang, Cheng Chen, Chenlin Zhang, Chenzhuang Du, Chu Wei, et al. Kimi-vl technical report. *arXiv preprint arXiv:2504.07491*, 2025c.
- Junyang Wang, Haiyang Xu, Jiabo Ye, Ming Yan, Weizhou Shen, Ji Zhang, Fei Huang, and Jitao Sang. Mobile-agent: Autonomous multi-modal mobile device agent with visual perception. *arXiv preprint arXiv:2401.16158*, 2024a.
- Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, et al. Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024b.
- Weyun Wang, Zhangwei Gao, Lixin Gu, Hengjun Pu, Long Cui, Xingguang Wei, Zhaoyang Liu, Linglin Jing, Shenglong Ye, Jie Shao, et al. Internvl3. 5: Advancing open-source multimodal models in versatility, reasoning, and efficiency. *arXiv preprint arXiv:2508.18265*, 2025a.
- Xinyuan Wang, Bowen Wang, Dunjie Lu, Junlin Yang, Tianbao Xie, Junli Wang, Jiaqi Deng, Xiaole Guo, Yiheng Xu, Chen Henry Wu, Zhennan Shen, Zhuokai Li, Ryan Li, Xiaochuan Li, Junda Chen, Boyuan Zheng, Peihang Li, Fangyu Lei, Ruisheng Cao, Yeqiao Fu, Dongchan Shin, Martin Shin, Jiarui Hu, Yuyan Wang, Jixuan Chen, Yuxiao Ye, Danyang Zhang, Dikang Du, Hao Hu, Huarong Chen, Zaida Zhou, Haotian Yao, Ziwei Chen, Qizheng Gu, Yipu Wang, Heng Wang, Diyi Yang, Victor Zhong, Flood Sung, Y. Charles, Zhilin Yang, and Tao Yu. Opencua: Open foundations for computer-use agents, 2025b. URL <https://arxiv.org/abs/2508.09123>.
- Xuehui Wang, Zhenyu Wu, JingJing Xie, Zichen Ding, Bowen Yang, Zehao Li, Zhaoyang Liu, Qingyun Li, Xuan Dong, Zhe Chen, et al. Mmbench-gui: Hierarchical multi-platform evaluation framework for gui agents. *arXiv preprint arXiv:2507.19478*, 2025c.
- Jason Wu, Siyan Wang, Siman Shen, Yi-Hao Peng, Jeffrey Nichols, and Jeffrey Bigham. Webui: A dataset for enhancing visual ui understanding with web semantics. *ACM Conference on Human Factors in Computing Systems (CHI)*, 2023a.

- Qianhui Wu, Kanzhi Cheng, Rui Yang, Chaoyun Zhang, Jianwei Yang, Huiqiang Jiang, Jian Mu, Baolin Peng, Bo Qiao, Reuben Tan, et al. Gui-actor: Coordinate-free visual grounding for gui agents. *arXiv preprint arXiv:2506.03143*, 2025.
- Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Jiale Liu, et al. Autogen: Enabling next-gen llm applications via multi-agent conversation. *arXiv preprint arXiv:2308.08155*, 2023b.
- Zhiyong Wu, Chengcheng Han, Zichen Ding, Zhenmin Weng, Zhoumianze Liu, Shunyu Yao, Tao Yu, and Lingpeng Kong. Os-copilot: Towards generalist computer agents with self-improvement. *arXiv preprint arXiv:2402.07456*, 2024a.
- Zhiyong Wu, Zhenyu Wu, Fangzhi Xu, Yian Wang, Qiushi Sun, Chengyou Jia, Kanzhi Cheng, Zichen Ding, Liheng Chen, Paul Pu Liang, et al. Os-atlas: A foundation action model for generalist gui agents. *arXiv preprint arXiv:2410.23218*, 2024b.
- xAI. Grok-1.5 vision preview, 2024. URL <https://x.ai/blog/grok-1.5v>.
- xAI. Grok-3, 2025. URL <https://x.ai/blog/grok-3>.
- LLM-Core-Team Xiaomi. MIMO-VL technical report, 2025. URL <https://arxiv.org/abs/2506.03569>.
- Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh J Hua, Zhoujun Cheng, Dongchan Shin, Fangyu Lei, et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments. *Advances in Neural Information Processing Systems*, 37:52040–52094, 2024.
- Tianbao Xie, Jiaqi Deng, Xiaochuan Li, Junlin Yang, Haoyuan Wu, Jixuan Chen, Wenjing Hu, Xinyuan Wang, Yuhui Xu, Zekun Wang, Yiheng Xu, Junli Wang, Doyen Sahoo, Tao Yu, and Caiming Xiong. Scaling computer-use grounding via user interface decomposition and synthesis, 2025. URL <https://arxiv.org/abs/2505.13227>.
- Yiheng Xu, Zekun Wang, Junli Wang, Dunjie Lu, Tianbao Xie, Amrita Saha, Doyen Sahoo, Tao Yu, and Caiming Xiong. Aguis: Unified pure vision agents for autonomous gui interaction. *arXiv preprint arXiv:2412.04454*, 2024.
- Yan Yang, Dongxu Li, Yutong Dai, Yuhao Yang, Ziyang Luo, Zirui Zhao, Zhiyuan Hu, Junzhe Huang, Amrita Saha, Zeyuan Chen, et al. Gta1: Gui test-time scaling agent. *arXiv preprint arXiv:2507.05791*, 2025.
- Yuhao Yang, Yue Wang, Dongxu Li, Ziyang Luo, Bei Chen, Chao Huang, and Junnan Li. Aria-ui: Visual grounding for gui instructions. *arXiv preprint arXiv:2412.16256*, 2024.
- Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. Webshop: Towards scalable real-world web interaction with grounded language agents. In Sanmi Koyejo, S. Mohamed, A. Agarwal, Danielle Belgrave, K. Cho, and A. Oh (eds.), *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022. URL http://papers.nips.cc/paper_files/paper/2022/hash/82ad13ec01f9fe44c01cb91814fd7b8c-Abstract-Conference.html.
- Jiabo Ye, Xi Zhang, Haiyang Xu, Haowei Liu, Junyang Wang, Zhaoqing Zhu, Ziwei Zheng, Feiyu Gao, Junjie Cao, Zhengxi Lu, et al. Mobile-agent-v3: Foundational agents for gui automation. *arXiv preprint arXiv:2508.15144*, 2025.
- Wenwen Yu, Zhibo Yang, Jianqiang Wan, Sibao Song, Jun Tang, Wenqing Cheng, Yuliang Liu, and Xiang Bai. Omniparser v2: Structured-points-of-thought for unified visual text parsing and its generality to multimodal large language models. *arXiv preprint arXiv:2502.16161*, 2025.
- Xinbin Yuan, Jian Zhang, Kaixin Li, Zhuoxuan Cai, Lujian Yao, Jie Chen, Enguang Wang, Qibin Hou, Jinwei Chen, Peng-Tao Jiang, et al. Enhancing visual grounding for gui agents via self-evolutionary reinforcement learning. *arXiv preprint arXiv:2505.12370*, 2025.
- Xiang Yue, Yuansheng Ni, Kai Zhang, Tianyu Zheng, Ruoqi Liu, Ge Zhang, Samuel Stevens, Dongfu Jiang, Weiming Ren, Yuxuan Sun, et al. Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9556–9567, 2024.
- Bofei Zhang, Zirui Shang, Zhi Gao, Wang Zhang, Rui Xie, Xiaojian Ma, Tao Yuan, Xinxiao Wu, Song-Chun Zhu, and Qing Li. Tongui: Building generalized gui agents by learning from multimodal web tutorials. *arXiv preprint arXiv:2504.12679*, 2025a.
- Chi Zhang, Zhao Yang, Jiaxuan Liu, Yanda Li, Yucheng Han, Xin Chen, Zebiao Huang, Bin Fu, and Gang Yu. Appagent: Multimodal agents as smartphone users. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, pp. 1–20, 2025b.
- Jiwen Zhang, Jihao Wu, Yihua Teng, Minghui Liao, Nuo Xu, Xiao Xiao, Zhongyu Wei, and Duyu Tang. Android in the zoo: Chain-of-action-thought for GUI agents. In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen (eds.), *Findings of the Association for Computational Linguistics: EMNLP 2024, Miami, Florida, USA, November 12-16, 2024*, pp. 12016–12031. Association for Computational Linguistics, 2024. doi: 10.18653/V1/2024.FINDINGS-EMNLP.702. URL <https://doi.org/10.18653/v1/2024.findings-emnlp.702>.

- Junlei Zhang, Zichen Ding, Chang Ma, Zijie Chen, Qiushi Sun, Zhenzhong Lan, and Junxian He. Breaking the data barrier—building gui agents through task generalization. *arXiv preprint arXiv:2504.10127*, 2025c.
- Di Zhao, Longhui Ma, Siwei Wang, Miao Wang, and Zhao Lv. Cola: A scalable multi-agent framework for windows ui task automation. *arXiv preprint arXiv:2503.09263*, 2025.
- Boyuan Zheng, Boyu Gou, Jihyung Kil, Huan Sun, and Yu Su. Gpt-4v(ision) is a generalist web agent, if grounded. In *Forty-first International Conference on Machine Learning*, 2024. URL <https://openreview.net/forum?id=piecKJ2DlB>.
- Yuqi Zhou, Sunhao Dai, Shuai Wang, Kaiwen Zhou, Qinglin Jia, and Jun Xu. Gui-g1: Understanding r1-zero-like training for visual grounding in gui agents. *arXiv preprint arXiv:2505.15810*, 2025.
- Jinguo Zhu, Weiyun Wang, Zhe Chen, Zhaoyang Liu, Shenglong Ye, Lixin Gu, Yuchen Duan, Hao Tian, Weijie Su, Jie Shao, et al. Internvl3: Exploring advanced training and test-time recipes for open-source multi-modal models. *arXiv preprint arXiv:2504.10479*, 2025.