

StartupBench：基于市场验证端到端工作流的通用智能体基准评测

Liya Zhu、Xin Ma、Tao Liu、Haodong Wang、Ge Zhang 等

ByteDance Seed；南京大学；M-A-P；TokenWave.AI

完整作者名单见“贡献”部分

2026 年 8 月 18 日 · arXiv:2608.17800

<https://startupbench.github.io/>

摘要

大语言模型（LLM）和智能体的近期进展，显著提升了人工智能系统执行复杂任务的能力。然而，现有基准大多依赖研究者选定的任务，因此尚不清楚这些进展能否延伸至现实用户真正希望人工智能系统完成的工作。我们提出 **StartupBench**：一个以经过市场验证的人工智能初创企业产品为基础的端到端（E2E）智能体基准。我们并非根据对“有用智能体能力”的预设来定义任务，而是系统研究已经获得实际采用的人工智能产品及其产品工作流和用户，从而识别人工智能在多种专业领域中已经形成真实需求的现实任务。我们将这些工作流转化为面向完整交付物的任务，并用能够刻画复杂要求的细粒度评分细则进行评估。在统一智能体框架下评测的代表性模型中，即使最强模型也只能成功完成约 30% 的 StartupBench 任务，尽管许多任务已取得可观的部分进展。进一步分析表明，复杂指令遵循和领域专门知识等方面是主要失败来源。我们的结果揭示，许多经市场验证的工作流仍超出当前通用智能体的可靠能力范围，并使 StartupBench 成为衡量智能体能否端到端完成现实用户任务的一项实证尺度。

译者说明：本稿逐句翻译摘要、全部正文和附录；公式、图表、引用、数值及作者的限定性表述均按原文保留。图内文字与参考文献题名保留英文。

1 引言

大语言模型（LLM）正日益从主要用于检索信息或回答问题的系统 [Du et al. \[2026\]](#), [Mialon et al. \[2024\]](#), [Wang et al. \[2024\]](#)，演变为能够完成复杂现实任务的智能体。当前的人工智能系统被期望执行端到端（E2E）工作流、协调多种能力，并在现实约束下生成满足实际要求的交付物。随着人工智能不断融入专业工作，自主完成用户委派的任务已经成为衡量模型能力的重要标准。因此，评估人工智能系统能否可靠地把自身能力转化为可供专业使用的交付物，是下一代基准面临的一项核心挑战。

近期基准在现实环境下评估端到端任务执行方面取得了重要进展，但仍存在若干重要局限。第一，许多基准

任务仍主要从研究者视角定义，而不是植根于已通过现实人工智能应用证明具有实际需求的工作流 [Phan et al. \[2025\]](#), [Patwardhan et al. \[2025\]](#), [Mialon et al. \[2024\]](#)，因而难以反映真实的用户需求和交付物要求。第二，尽管一些基准会评估完整交付物 [Tang et al. \[2026\]](#), [Sun et al. \[2026\]](#)，其评估协议往往远比交付物本身粗糙。现实工作成果通常涉及众多功能、结构、格式和领域特定要求，整体式评估无法如实检查这些要求。因此，现有基准对以下问题仍只能提供有限证据：当前模型和智能体在多大程度上能够满足复杂的现实用户要求，并可靠地产出可供专业使用的交付物？

为解决这些局限，我们注意到，人工智能原生初创企业提供了一类天然的现实人工智能工作流程来源：其产品已经过现实采用和商业需求验证，能够直接证明用户重视这些任务并希望将其委派给人工智能。因此，我们提出 **StartupBench**。这是一个由调研和访谈驱动的基准，它从这些工作流中提炼跨领域的现实端到端用户需求。StartupBench 涵盖 6 个主要领域的 97 项任务，并围绕以下设计原则构建：

- **以实际采用为基础的任务来源。**我们系统调研人工智能原生初创企业及其产品，并结合产品演示和用户访谈，识别已证明存在现实需求的工作流。随后，我们将这些工作流构造成基准任务，同时保留其核心用户目标和实际要求。
- **端到端交付物。**每项任务都要求生成现实工作流程中用户最终期望的完整交付物，而不是中间输出或简化演示。
- **基于细粒度评分细则的评估。**每项 StartupBench 任务均使用多条相互独立的评分细则，覆盖预期交付物的不同维度，包括功能、结构、格式和领域特定质量，从而全面而如实地评估现实任务完成情况。

我们在统一智能体框架下使用 StartupBench 评估代表性模型。结果表明，即使最强模型也只能成功完成约 30% 的基准任务，说明当前通用系统距离可靠生成可供




图 1: StartupBench 概览: 真实人工智能产品 workflow、长时程智能体执行、六大领域覆盖以及多格式交付物生成。

专业使用的交付物仍相去甚远。不同领域之间的性能差异很大，其中金融、STEM 与计算机科学以及教育与人文学科尤其困难。进一步分析表明，这些失败主要源于复杂指令遵循和领域专门知识方面的局限，并据此指出未来基础模型和智能体系统值得推进的方向。

概括而言，我们的贡献如下：

- 我们提出一种由调研和访谈驱动的方法，用于从真实人工智能采用场景构建智能体基准。
- 我们构建了 StartupBench。该基准经由人工智能原生初创企业调研、企业用户访谈、面向用户的任务抽象、专家数据构建和多阶段质量控制而形成。
- 我们针对当前基础模型和通用智能体在源自初创企业的工作流上的表现开展全面实证研究，为判断人工智能智能体是否正从“回答问题”迈向“可靠完成真实工作”提供实用评估信号。

2 相关工作

2.1 商业人工智能智能体与垂直工作流

基础模型的近期进展，使人工智能智能体逐渐获得规划、工具使用、文件处理和多步执行能力 [Yao et al., 2023, Schick et al., 2023]，推动人工智能系统从通用对话助手走向面向工作流的产品。在实践中，商业人工智能产品日益把这些能力封装进文档处理、数据分析、金融研究、企业运营和知识工作等垂直工作流。这一趋势表明，人工智能的现实价值不仅取决于孤立的模型能力，还取决于这些能力能否被产品化为有用的工作成果。然而，现有学术基准很少把商业采用本身作为发现任务的来源。StartupBench 通过从经市场验证的人工智能原生

初创企业及其深度用户中提取任务来弥补这一缺口，使任务构建从研究者定义的环境转向需求驱动的工作流构建。

2.2 人工智能智能体的端到端评估

智能体基准已从能力评估逐步发展为端到端任务完成评估。早期基准主要关注工具使用、多步推理和通用助手能力，AgentBench 与 GAIA 即属此类 [Liu et al., 2024, Mialon et al., 2024]。后续工作把评估扩展到更现实的交互环境，包括网页交互和计算机使用任务 [Zhou et al., 2024, Xie et al., 2024]。更新近的基准则进一步迈向专业工作和具有经济意义的任务，覆盖企业软件、模拟工作场所、职业任务和长时程工作流 [Drouin et al., Xu et al., 2026, Patwardhan et al., 2025, Hu et al., 2026, Zhu et al., 2026, Meng et al., 2026]。这些工作体现出从孤立能力测试到现实任务完成评估的清晰转变。StartupBench 延续这一方向，但在任务来源上有所不同：它并非主要依赖公共环境、职业分类或模拟工作场所，而是从人工智能原生初创企业产品、企业端 (ToB) 用户需求和预期业务交付物中提取任务。

2.3 面向复杂交付物评估的智能体裁判

随着智能体任务从简短回答转向报告、电子表格、幻灯片、代码补丁和结构化文件等异构交付物，评估也必须从以能力为中心的打分转向以交付物为中心的考查 You et al. [2026]。大语言模型裁判 (LLM-as-a-Judge) 已广泛用于开放式回答评估，MT-Bench 和 Prometheus 研究了基于偏好或以评分细则为条件的裁判方法 [Zheng et al., 2023, Kim et al., 2024]。然而，对于智能体工作流，裁判往往需要在最终产物中检索证据、检查文件、验证状态并核对约束。智能体裁判 (Agent-as-a-Judge) 通过为评

估者配备工具和环境交互能力扩展了大语言模型裁判；AJ-Bench 还进一步研究裁判智能体的信息获取、状态验证和过程验证能力 [Zhuge et al., 2025, Shi et al., 2026]。StartupBench 采用这种以交付物为中心的评估范式，把专家评分细则与会检查原始产物及证据视图的自动裁判智能体相结合，以评估智能体能否将模型能力转化为可用的工作成果。

3 StartupBench

StartupBench 旨在评估模型和智能体能否完成用户已经委派给人工智能产品的现实工作流。实现这一目标所需的数据既要反映真实用户需求，又要支持受控评估。因此，我们要求每项任务都具备真实性、可解答性、可评估性和区分度：任务应源自人工智能产品的实际使用，为有效解法提供充分信息，明确输出要求和评估标准，并保持足够难度，以区分当前不同模型和智能体。

单纯依赖人工任务设计，或直接从产品演示中提取内容，都不足以得到此类数据。前者可控，却可能脱离真实需求；后者真实，却常常缺少上下文、成功标准或可复现的任务说明。因此，我们采用图 2 所示的、由调研和访谈驱动的多阶段流程。首先，我们调研经市场验证的人工智能原生初创企业；随后访谈深度用户，识别使用情境、任务目标和预期交付物；再招募领域专家，把经过验证的场景转化为基准实例；最后从真实性、可解答性、可评估性和具有区分度的难度四方面实施质量控制。

3.1 数据集构建

3.1.1 面向市场验证智能体场景的初创企业调研

我们首先调研在不同领域构建智能体产品的人工智能原生初创企业。为识别获得市场验证的工作流，我们仅保留融资额超过 100 万美元的初创企业，并要求存在真实采用证据，即付费使用或显著的用户吸引力。融资是市场预期的一项粗略信号，而付费或用户规模证据则表明产品的使用已超出探索性演示。该阶段的输出是供用户访谈使用的候选产品和工作流池。在这一阶段，我们收集了 20 余个初创企业智能体，作为后续阶段的基础。

3.1.2 用于发现场景与需求的用户访谈

对于每个候选初创企业产品，我们访谈来自不同领域、使用相应智能体的深度用户，以恢复公开产品描述之外的实际使用情况。访谈旨在获取使用情境、用户目标、输入信息、预期交付物、成功标准和常见约束。我们把这些发现汇总为场景说明和代表性演示案例，作为后续标注阶段的锚点。在这一阶段，我们访谈了 30 多位深度用户，并为每个候选智能体至少收集一个演示案例。

3.1.3 由专家构建领域任务

我们以访谈得到的工作流说明和代表性用户场景作为参考或种子任务，招募 50 多位领域专家重构基准任务。在把任务调整为可复现评估实例的同时，专家需保留原始工作流目标、实际约束和预期交付物。专家并非设计合成问题，而是把真实用户请求标准化为能够忠实代表现实专业工作流的基准任务。

每项任务都必须满足三项原则：它必须源自用户会自然委派给人工智能智能体的现实工作请求；必须包含端到端工作流，而非孤立子任务；必须生成具有明确成功标准和细粒度评分细则的具体专业交付物，以便进行客观评估。

为实现标准化评估，每项任务被表示为三元组

$$\mathcal{T} = (q, \mathcal{E}, \mathcal{R}),$$

其中， q 是描述任务的自然语言用户请求， $\mathcal{E}$ 表示包含完成任务所需全部输入文件和资源的工作空间， $\mathcal{R} = \{(p_i, w_i)\}_{i=1}^n$ 是一组带权评估细则，用于评估交付物质量的互补方面。详细任务说明和标注指南见附录 A.1。在这一阶段，我们收集了 150 多项候选任务，以供后续质量控制。

3.1.4 质量控制

为保证基准的质量与一致性，每项任务都要经历以下多阶段质量控制流程。

专家交叉验证。每项任务至少由另一位领域专家独立审查。审查者验证任务质量的四个方面：（1）任务描述和工作空间的真实性与正确性；（2）重构工作流的忠实度；（3）评估细则的有效性；（4）参考交付物与最终评估协议之间的一致性。详细审查标准见附录 A.2。

难度控制。我们在基准所采用的同一评估框架下，使用若干前沿模型开展试运行，以校准任务难度¹。始终能以高质量完成的任务会因区分度有限而被排除。试运行结果还充当额外的质量保障环节：如果失败源于指令含混、工作空间信息不全或评估标准说明不足，而不是任务本身的难度，则相应任务会在纳入前得到修订并再次验证。

3.2 StartupBench 统计信息

StartupBench 包含 97 项现实工作流任务，覆盖 6 个一级领域：医疗与健康、金融、法律、商业与管理、STEM 与计算机科学，以及教育与人文学科。这些任务旨在反映现实办公环境中面向交付物的工作流，要求智能体理解任务情境、遵循复杂约束、处理异构文件并生成可用的工作成果。评估时，每项任务平均使用 25.3 条细粒度评分细则，覆盖 6 个维度和 3 个重要性层级，从而能

¹我们从 GPT-5.5、Seed-2.1-Pro 和 GLM-5.1 中随机选择模型执行试运行，目的是构建具有挑战性和区分度的基准，而不是估计模型在自然任务分布上的表现。

表 1: StartupBench 与现有基准的比较。E2E 表示端到端 workflow 完成;“逐项评估”表示按准则逐项裁判。✓、✗和 △ 分别表示完全支持、不支持和部分支持。

基准	任务来源	最终输出	E2E	逐项评估	过程逻辑	开放式	评估方法
GAIA [Mialon et al., 2024]	人工	文本	△	✗	✗	✗	规则
OSWorld [Xie et al., 2024]	真实 + 人工	环境状态	△	✗	✗	✗	执行
DAComp [Lei et al., 2025]	真实 + 人工	工作空间	✓	✗	✗	✓	混合
GDPval [Patwardhan et al., 2025]	人工	工作成果	✓	✗	✗	△	人工
Workspace-Bench [Tang et al., 2026]	模拟 + 人工	工作空间	✓	✗	✗	✓	智能体裁判
OneMillionBench [Yang et al., 2026]	专家编写	文本	△	✗	△	✓	模型裁判
Agents’ Last Exam [Sun et al., 2026]	职业引导	工作空间	✓	✗	△	△	混合
OfficeQA Pro [Opsahl-Ong et al., 2026]	语料库支撑	文本	✗	✗	✗	✗	答案匹配
StartupBench (本文)	市场验证 + 专家构建	工作空间	✓	✓	✓	✓	智能体裁判



图 2: StartupBench 数据构建流程。我们筛选经市场验证的初创企业智能体，收集真实用户 workflow，构建任务产物与实例，并通过多阶段审查校准质量和难度。

够细致评估复杂的长时程 workflow 和多样的工作交付物。StartupBench 的领域覆盖和主要输出格式汇总见表 2。

3.3 StartupBench 任务的自动评估

如前所述，StartupBench 中的每项任务都定义为三元组 $\mathcal{T} = (q, \mathcal{E}, \mathcal{R})$ 。给定 $(q, \mathcal{E})$ ，待评模型会生成一组交付物 $\mathcal{D}$ 。在评估前，我们构建一个轻量证据视图 $\mathcal{V}(\mathcal{D})$ ，由提取出的文本内容和渲染页面图像组成，以便在异构产物之间导航；必要时，裁判仍可访问原始文件。

StartupBench 并不依赖单个整体判断，而是通过独立的 AgentJudge 会话逐项评估每条评分细则。大多数任务包含 20 余条细粒度评分细则，覆盖预期交付物的不同方面，包括功能、完整性、格式和领域特定要求。分别评估这些准则，使每一条细则都能得到专门的推理和工

具使用，避免不相关评估维度之间相互干扰，同时确保所有要求都被显式检查。最终任务分数由全部细则级评估结果聚合得到。

遵循智能体裁判范式，每条评分细则都由一个轻量智能体而非单次前向传播完成评估。设 J 表示 Agent-Judge 使用的裁判提示和评估协议；给定任务说明、交付物、证据视图和目标评分点 p_i ，裁判同时生成二元判断 $y_i \in \{0, 1\}$ （表示是否满足该细则）以及文本理由 e_i ：

$$(y_i, e_i) = \text{AgentJudge}(J, q, \mathcal{D}, \mathcal{V}(\mathcal{D}), p_i), \quad (1)$$

最终任务分数通过聚合所有评分细则的加权判断计算：

表 2: StartupBench 统计信息。基准包含 97 项现实 workflow 任务，覆盖六个一级领域，并要求多种交付物格式。

类别	数量	占比 (%)
总体统计		
任务总数	97	100.0
一级领域	6	—
领域分布		
医疗与健康	21	21.6
金融	18	18.6
法律	16	16.5
商业与管理	19	19.6
STEM 与计算机科学	16	16.5
教育与人文学科	7	7.2

输出格式: DOCX、XLSX、PPTX、PDF、Mark-down、图像和文本类交付物。

$$\text{score}(\mathcal{D}, \mathcal{T}) = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i} \in [0, 1]. \quad (2)$$

4 实验

4.1 实验设置

我们在 StartupBench 上评估 9 个代表性模型，覆盖闭源和开源模型家族：

- **闭源模型**：GPT-5.6-sol [OpenAI \[2026\]](#)、GPT-5.5 [OpenAI \[2026\]](#)、Gemini-3.1-Pro [Google Cloud \[2026\]](#)、Seed-2.1-Pro [ByteDance Seed \[2026\]](#)、Qwen-3.6-Max [Qwen Team \[2026\]](#)。
- **开源模型**：DeepSeek-V4-Pro [DeepSeek-AI \[2026\]](#)、Kimi-K3 [Team et al. \[2026\]](#)、Kimi-K2.6 [Moonshot AI \[2026\]](#)、GLM-5.1 [Zeng et al. \[2026\]](#)。

为提高结果的可靠性，我们对每个模型开展 3 次独立运行，并报告任务分数的 95% bootstrap 置信区间；置信区间通过 10,000 次重采样计算。所有模型均在同一 Nanobot 框架中运行，工具配置完全相同，每项任务的交互步数上限为 200。对每项任务，智能体以任务特定的工作空间和输入请求初始化，其交付物从指定输出目录收集。依照上一节所述评估协议，裁判智能体根据任务说明、工作空间上下文和评分细则集合对这些交付物进行评估。

自动评估所用的裁判智能体也在相同的 Nanobot 框架下运行，以保证执行环境一致，其底层裁判模型为 GPT-5.5。除连续任务分数外，我们还报告**成功率**，即三次运行合并后成功完成的运行所占比例。若一项任务的最终分数不低于 90，则视为成功；否则计为失败。




图 3: StartupBench 排行榜。

4.2 主要结果

在通用智能体框架下，**初创企业任务远未饱和**。尽管最强的 Kimi-K3 和 GPT-5.6-sol 分别取得 73.67% 和 73.61% 的平均分，但在严格的验收标准（分数 ≥ 90）下，没有任何模型能成功完成三分之一的基准任务。更广泛地看，大多数模型的平均分大致位于 55 至 75 之间，说明当前智能体一般能够在解决现实专业 workflow 方面取得可观进展。然而，高平均分并不必然转化为高任务完成率。Kimi 系列尤其明显：Kimi-K3 的总体平均分最高，但成功率低于 GPT-5.6-sol；类似地，Kimi-K2.6 的平均分高于 Qwen-3.6-Max，成功率却更低。这些差异表明，某些模型虽能满足相当一部分任务要求，却仍无法完整交付。总体而言，所有模型的成功率都明显低于平均分。这说明主要瓶颈已不再是执行 workflow 的大部分环节，而是能否稳定生成达到直接专业使用标准的产物。

这一差距有两项重要含义。第一，它有助于解释为何专门化垂直智能体仍在许多经过市场验证的工作流中具有实际价值，因为这些场景必须稳定达到专业标准。第二，它说明基础模型的下一个前沿并非只是在执行专业任务，而是可靠地产出无需进一步核验或修改、用户即可采用的工作成果。我们将在第 4.4.2 节进一步研究这一差距的根本原因。

不同专业领域的性能差异显著。表 3 表明，当前通用智能体在各种现实 workflow 中的能力并不均衡。在六个领域中，商业始终最容易：所有模型的平均分都高于 60，跨模型平均成功率也明显高于其他任何领域。相比之下，金融最具挑战，其最低平均分为 54.48%。商业与金融之间的巨大差距表明，与需要持续定量推理、跨文档一致性和多步核验的工作流相比，当前模型处理结构化程度较高、相对标准化的任务更为可靠。

结果还揭示出显著的领域专长差异。尽管 Kimi-K3 与 GPT-5.6-sol 的总体平均分几乎相同（73.67 对 73.61），两者的强项却大不相同。按成功率看，Kimi-K3 在医疗和商业领域表现最佳，GPT-5.6-sol 在金融、STEM 和教育领域领先，而 GPT-5.5 在法律领域保持最强。平均分也呈现相似格局：Kimi-K3 在医疗、商业、金融和教育领域领先，GPT-5.6-sol 则在法律和 STEM 领域领先。因

此，即使在最强模型中，也没有单一智能体能够在所有专业领域始终占优。这些结果说明，当前通用智能体仍存在显著的领域依赖型差异；要提升端到端任务执行在异构专业工作流之间的稳健性和迁移能力，仍有很大改进空间。

4.3 所提出评估框架的有效性

为验证评估框架的可靠性，我们把它的判断与专家标注进行比较。我们对全部任务抽取两个代表性模型的输出，并请领域专家使用预定义评分细则独立评估每个提交结果。在细则层面，自动评估器与专家判断的总体一致率达到 **92.78%**。我们还通过比较最终成功标签，考查这些局部一致是否能转化为一致的任务级决策；当提交结果的聚合分数达到 90 时，即视为成功。自动评估与专家评估在 **92.84%** 的成功决策上保持一致。值得注意的是，尽管细则标签和成功标签的分布差异很大，两种层面的高一致率仍非常接近，这表明观察到的一致性并非只是标签不平衡造成的假象。

我们还进一步研究了逐条独立评估评分细则的必要性。在一项消融实验中，我们不再为每条细则分配一个裁判智能体，而是直接把完整模型输出连同全部细则列表交给单个裁判智能体，要求它在一次端到端推理中为所有细则打分。该替代方案使与人类专家的一致率下降到 83%。更重要的是，整体式设置在实践中的稳定性明显更差。裁判智能体必须同时进行长上下文推理、在众多评估标准之间维持一致，并最终生成覆盖所有细则分数的结构化输出，因而经常出现输出格式错误或格式不完整等失败，不得不重复执行。平均而言，每次评估要运行两次以上，才能得到有效结果。相比之下，我们的逐细则评估把考查过程分解为一组相互独立的轻量裁判任务，既明显提升了与人类专家的一致性，也显著改善了执行稳健性。

4.4 失败模式分析

4.4.1 结果层面失败分析

不同评分细则维度上的能力差异。图 4 进一步按评分细则维度拆解模型性能。总体上，当前模型在结构与完整性、信息整合，尤其是输出与呈现维度上始终取得较高分，说明它们通常能够把异构信息组织成结构良好、视觉上精致的交付物。相比之下，领域特定合规性是所有被评模型最困难的维度，计算精度也明显弱于其他维度。这说明，现代基础模型虽然能生成外观看似完整且专业的产物，但要可靠满足领域特定法规、业务惯例和数值正确性要求，仍是现实部署的一项主要障碍。

最强的两个模型 GPT-5.6-sol 与 Kimi-K3 几乎在所有评分细则维度上都优于其他系统，而非只依赖某一项专门能力。它们最大的优势出现在结构与完整性、计算精度、信息整合和输出与呈现方面，体现出更强的端到

端 workflow 执行和产物构建能力。即便如此，这两个领先模型的最低分仍落在领域特定合规性上，表明遵守专业标准和领域特定要求即使对最先进系统而言仍是首要瓶颈。

模型常常满足外围要求，却遗漏最重要的要求。表 4

报告了三个重要性层级上经过任务归一化的评分细则满足率。跨模型平均后，满足率从辅助细则的 **68.67%** 下降到重要细则的 **65.89%**，再降至核心细则的 **63.45%**；9 个模型中有 8 个呈现相同的总体趋势。需要强调的是，这些层级反映每项要求对成功完成任务的贡献，而非其预期难度。该模式揭示了当前智能体的一种典型失败：它们往往能够满足辅助性或表层要求，却会在决定任务能否真正成功完成的核心要求上失手。换言之，明显的表面进展可能来自完成任务中不太关键的部分，而关键遗漏仍会使最终交付物无法实际使用。

图 5 展示了模型难以满足任务完成核心要求的典型案例。在这项机械工艺任务中，模型经常完成工作簿的外围要求，却未能完成核心技术操作：从工程图中准确提取尺寸、根据所给文档核验规格，以及把发现的差异与相应整改措施关联起来。即使许多辅助要求已经完成，这些失败仍使所得工作簿无法实现其主要用途。

输出格式不合规。部分失败源于模型没有使用任务明确要求的文件类型生成交付物。与前文讨论的大多数失败模式不同，这项要求既不涉及复杂推理，也不需要领域知识，而且可以根据文件扩展名确定性地验证。尽管如此，在 56 项明确规定输出格式的任务上，没有任何模型达到完全合规（表 5），合规率介于 97.6% 与 86.3% 之间。大多数违规可归入两种反复出现的模式：生成错误的文件类型（例如以 `.md/.txt` 代替要求的 `.pdf`），以及遗漏部分请求的交付物（例如要求同时生成 `.xlsx` 和 `.docx`，却只生成其中一种）。这些错误表明，即使是基本的交付物层面约束，对当前基础模型而言仍是不可忽视的失败来源。

4.4.2 行为层面失败分析

复杂指令遵循。复杂的现实工作流通常会对最终交付物提出大量约束，包括结构组织、计算逻辑、格式和可执行正确性。尽管任务描述明确列出这些要求，当前模型仍经常只做到部分合规：它们满足最显眼的要求，却忽略其他同样关键的约束。因此，生成的产物经粗略检查似乎大体完整，却不满足直接使用所需的全部验收标准。该行为表明，模型往往在优化“看起来正确”的输出，而非确保每一条支配最终交付物的指令都得到忠实执行。

图 6 展示了一个代表性案例。该任务要求根据多个源工作表生成完整的人力资源薪资工作簿，并满足多种结构、计算和格式约束。尽管模型生成的产物看起来大体完整，包括所有要求的工作表、公式、图表和仪表板



图 4: 不同评分细则维度上的表现。图中给出不同模型在 StartupBench 六个评分细则维度上的重要性加权通过率 (%)；数值越高，表示在相应评估维度上的表现越好。

布局，产物层面评估却发现仍有若干关键验收条件未满足。具体而言，下游验证所需的关键缓存值缺失，使这个外观精致的工作簿无法核验。该案例体现了常见的部分合规模式：模型满足最显眼的要求，却忽略不那么明显但同样不可或缺的交付物约束。

自我验证幻觉。我们还观察到，许多模型失败并非因为无法完成所需工作流，而是因为它们错误地假定“执行成功”等同于“交付成功”。模型在生成一个看似合理的产物后，常把预期的推理过程或已执行步骤总结为任务已经通过验证的证据，却不依据原始用户要求独立检查最终交付物。于是，单元格数值错误、标识符无法匹配、约束缺失或格式不一致等细微但关键的问题，即使在一个看似可信的输出中也不会被发现。该行为体现了一种自我验证幻觉：模型把对自身推理过程的信心误当成生成产物满足验收标准的证据。然而在现实办公工作流中，成功完成任务要求验证最终交付物本身，而不是只确认执行过程；因此，这种幻觉是部署关键型失败的常见来源。典型案例见附录 D.1。

领域专门知识。另一个主要失败来源是领域专门知识不足，这与领域特定合规性维度上相对较差的表现一致。与通用指令遵循错误不同，这些失败由不同专业领域独特的操作要求造成。模型往往能生成措辞流畅、格式专业的输出，却经常不能满足决定交付物是否真正可用的领域特定约束。因此，主要失败模式因领域而有显

著差异，反映出现实工作流对正确性、证据、精度和可操作性的不同要求。

从领域视角看，不同专业领域暴露出各异的失败特征。商业与管理任务主要考验产物正确性，特别是电子表格、仪表板、公式和结构化报告。金融任务强调来源归因、数值精度、估值假设和时间一致性，错误通常来自核对不足、数值自检不充分或会计惯例不一致。法律任务受到法律文书风格的约束相对较少，更受法律推理完整性和正确性的限制，包括引用缺失、事实覆盖不全、成文法依据不足，或事实与适用规则映射错误。医疗任务的平均分相对较高，但安全风险明显更大，因为用药时机、继续治疗标准或出院规划方面的错误会直接破坏临床可用性。STEM 与计算机科学任务则要求精确的对象层面落地，即准确把握代码、工程图、图像、物料清单和系统组件之间的关系。最后，教育与人文学科任务更强调细粒度规则遵循，例如课程要求、学分配、文档组织和文本连贯性。领域专门知识不足所致失败的一个典型示例见附录 D.2。

4.5 智能体框架对初创企业任务的影响

4.5.1 通用智能体框架的影响

在主实验中，所有模型都在 Nanobot 智能体框架下评估。为考查观察到的性能是否主要由智能体框架选择而非底层模型决定，我们使用另外两个代表性通用智能体框架 Hermes Nous Research [2026] 和 Claude Code An-




图 5: StartupBench 中模型未通过核心评分细则、却通过辅助评分细则的一个代表性案例。

thropic 重新评估基准。所有框架均使用相同任务集和完全相同的评估协议，只有执行框架被替换。

如表 6 所示，更换通用框架只会造成很小的性能差异。在所有被评模型中，最佳与最差框架之间的平均差异仅为 1.79 分。GLM-5.1 几乎完全不受影响 (0.61 分)，即使 GPT-5.5 上观察到的最大差异也只有 2.68 分。更重要的是，三个框架下模型的相对排序保持不变。这些结果表明，StartupBench 基本不受通用智能体框架选择的影响。尽管不同框架采用不同的提示策略、工具接口和交互机制，单纯替换通用框架并不会显著改变端到端任务性能。因此，StartupBench 上观察到的性能差距主要反映底层基础模型的能力，而非某个特定框架的实现特征。

4.5.2 通用智能体与专门化智能体

为进一步理解智能体框架的作用，我们把通用智能体框架与 StartupBench 任务所源自的专门化初创企业智能体进行比较。与上一实验不同，这项比较对每个任务使用相应的生产级初创企业智能体；这些智能体已通过领域特定模型选择、提示策略、工具编排和工作流设计，针对其目标工作流进行专门优化。

表 7 汇总了通用与专门化智能体系统的比较。综合全部执行，通用智能体的平均分为 64.26，成功率为 19.74%，明显低于专门化智能体的 83.50 和 39.18%。由于专门化智能体明确针对目标领域进行设计和优化，我们还为通用智能体考虑了一个更强的 oracle 设置：对每个模型-任务组合，保留三次独立试验中的最佳结果。该 oracle 选择把平均分提高到 71.75、成功率提高到 28.06%，但仍明显落后于专门化智能体；平均分相差 11.75 分，成

功率相差 11.12 个百分点。因此，这一性能差距不能只用随机变化或偶发执行失败来解释：即使允许通用智能体多次尝试并按观测到的最佳结果评估，专门化智能体系统在这些任务上仍明显更有效。

结合前述失败模式分析，这些发现更完整地刻画了通用基础模型与专门化初创企业智能体之间尚存的差距。尽管当今基础模型在统一通用框架下仍无法完全取代领域专门化智能体，其短板集中在一组相对明确的能力上，包括复杂指令遵循、领域特定知识、专业操作惯例和长时程工作流执行。这表明，专门化系统目前观察到的优势未必需要根本不同的智能体架构，而可能反映当前通用模型尚未可靠掌握的能力。随着这些底层能力继续改进，通用智能体或将越来越多地完成有价值的专业端到端任务，而无需依赖领域特定的智能体框架设计。




表 3: StartupBench 模型性能，取三次独立运行的平均值。上半部分：按重要性加权的单任务平均分（0-100）；下半部分：成功率，即三次运行合并后分数 ≥ 90 的样本比例（%）。各列**最佳值加粗**，次佳值加下划线。

模型	总体	医疗	金融	法律	商业	STEM	教育
平均分							
Kimi-K3	73.67	80.03	62.38	69.45	83.90	68.34	77.71
GPT-5.6-sol	<u>73.61</u>	<u>79.32</u>	61.66	73.53	77.61	74.77	<u>73.94</u>
GPT-5.5	72.79	78.59	<u>62.09</u>	<u>71.75</u>	<u>79.59</u>	<u>72.14</u>	68.32
Seed-2.1-Pro	67.19	73.15	57.26	61.35	77.83	65.61	62.91
Kimi-K2.6	59.95	67.70	51.17	54.62	71.91	51.38	58.60
GLM-5.1	60.79	65.66	51.22	50.20	78.53	52.18	66.50
Qwen-3.6-Max	59.46	66.51	52.45	50.33	75.03	48.83	59.26
DeepSeek-V4-Pro	61.11	69.42	51.11	54.53	73.69	54.89	57.03
Gemini-3.1-Pro	49.73	54.05	41.00	43.49	61.18	45.88	51.23
成功率 (≥ 90)							
Kimi-K3	<u>29.55</u>	34.92	20.37	20.83	52.63	16.67	<u>23.81</u>
GPT-5.6-sol	31.27	<u>33.33</u>	27.78	<u>22.92</u>	38.60	33.33	28.57
GPT-5.5	26.80	30.16	<u>22.22</u>	25.00	38.60	<u>22.92</u>	9.52
Seed-2.1-Pro	22.34	19.05	16.67	14.58	<u>45.61</u>	20.83	4.76
Kimi-K2.6	13.06	15.87	14.81	6.25	24.56	4.17	4.76
GLM-5.1	16.49	12.70	16.67	8.33	36.84	8.33	9.52
Qwen-3.6-Max	15.12	11.11	16.67	10.42	33.33	6.25	4.76
DeepSeek-V4-Pro	16.49	20.63	16.67	8.33	29.82	10.42	0.00
Gemini-3.1-Pro	6.53	6.35	11.11	6.25	8.77	0.00	4.76

表 4: 不同重要性层级上经过任务归一化的评分细则满足率(%)。对每个模型-任务-试验组合, 我们先计算各重要性层级内的满足率, 再在任务和试验之间求平均。

模型	辅助	重要	核心
Kimi-K3	77.89	75.12	73.40
GPT-5.6-sol	77.59	74.47	73.07
GPT-5.5	75.12	75.09	72.07
Seed-2.1-Pro	70.83	69.85	65.77
Kimi-K2.6	66.64	63.56	57.82
GLM-5.1	64.58	61.40	60.68
Qwen-3.6-Max	65.39	62.17	58.08
DeepSeek-V4-Pro	66.50	62.97	60.05
Gemini-3.1-Pro	53.48	48.41	50.13
平均	68.67	65.89	63.45

表 5: 56 项含明确输出文件要求细则的 StartupBench 任务上的输出格式合规率。模型按合规率排序。

模型	合规率 (%)
Kimi-K3	97.6
Seed-2.1-Pro	95.2
GPT-5.6-sol	94.6
Qwen-3.6-Max	94.6
DeepSeek-V4-Pro	94.0
GPT-5.5	93.5
Kimi-K2.6	92.9
Gemini-3.1-Pro	86.9
GLM-5.1	86.3

表 6: 不同通用智能体框架下的性能。对每个模型, 我们报告三个通用框架下的平均分, 以及框架间性能极差(最大值减最小值)。

模型	Hermes	Claude Code	Nanobot	极差
GPT-5.5	71.00	70.11	72.79	2.68
GLM-5.1	60.20	60.18	60.79	0.61
Qwen-3.6-Max	59.10	57.38	59.46	2.08
平均	63.43	62.56	64.35	1.79

表 7: 通用智能体系统与专门化智能体系统的比较。Oracle General 表示对每个模型的全部试验取最高分后所得平均值。

智能体系统	平均分	成功率
通用 (全部运行平均)	64.26	19.74
通用 (Oracle)	71.75	28.06
专门化智能体	83.50	39.18

5 结论

我们提出 **StartupBench**，用于评估模型在源自经过市场验证的人工智能原生产品和现实用户需求的端到端专业工作流上的表现。我们对跨越多个领域的多项任务开展评估，揭示了“在专业工作上取得有意义的进展”与“生成完全满足实际验收标准的交付物”之间的显著差距。该差距主要由复杂指令遵循、领域专门知识、专业惯例和长时程 workflow 执行方面的局限造成。通过把评估植根于用户已经希望委派给人工智能的工作流，StartupBench 为衡量智能体的实际能力提供了一项现实尺度，并指出未来改进的具体方向。我们希望 StartupBench 能支持模型和智能体的发展，使其不仅能够完成有价值的专业工作，还能可靠地交付可供直接使用的结果。

6 贡献

项目负责人

Liya Zhu, Xin Ma, Tao Liu, Haodong Wang, Ge Zhang

核心贡献者

Jingzhe Ding, Qingshui Gu, Yongjie Zhong, Jinxiang Meng, Yuan Gao, Yunqiu Zhou, Hao Zhu, Jifeng He, Yongzhi Liao, Xinyi Zhang, Chaoxin Li, Yi Zhu, Xi Lin, Duju Zeng, Xiang Gao, Wen Zhang, Yunyang Wang, Duo Wang

贡献者

Huan Zhou, Zuo Wang, Jin Chen, Kaiyuan Zhang, Chuqian Yu, Tianhao Yu, Longxiang Liu, Jianbo Xue, Huimin Che, Jiahao Wang

资助委员会

Yujia Qin, Jiaheng Liu

通讯作者

Ge Zhang (gezhang@umich.edu)

Shen Yan (sheny@bytedance.com)

Xiaolong Chang (changxiaolong@bytedance.com)

Wenhao Huang (huang.wenhao@bytedance.com)

参考文献

- Anthropic. Claude code. <https://github.com/anthropics/claude-code>. GitHub repository.
- ByteDance Seed. Seed2.1 model card: Agentic intelligence for productivity. Technical report, ByteDance, 2026. URL https://lf3-static.bytednsdoc.com/obj/eden-cn/lapzild-tss/ljhwZthlaukjlkulzlp/seed2.1/Seed2_1_Model_Card.pdf.
- DeepSeek-AI. Deepseek-v4: Towards highly efficient million-token context intelligence, 2026. URL <https://huggingface.co/collections/deepseek-ai/deepseek-v4>. Technical Report.
- Alexandre Drouin, Maxime Gasse, Massimo Caccia, Issam H Laradji, Manuel Del Verme, Tom Marty, Léo Boisvert, Megh Thakkar, Quentin Cappart, David Vazquez, et al. Workarena: How capable are web agents at solving common knowledge work tasks?, 2024. URL <https://arxiv.org/abs/2403.07718>.
- Xeron Du, Yifan Yao, Kaijing Ma, Bingli Wang, Tianyu Zheng, Minghao Liu, Yiming Liang, Xiaolong Jin, Zhenlin Wei, Chujie Zheng, et al. Supergpqa: Scaling llm evaluation across 285 graduate disciplines. *Advances in Neural Information Processing Systems*, 38, 2026.
- Google Cloud. Gemini 3.1 Pro Model Card, 4 2026. URL <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-1-pro?hl=zh-cn>.
- Xiaomeng Hu, Yinger Zhang, Fei Huang, Jianhong Tu, Yang Su, Lianghao Deng, Yuxuan Liu, Yantao Liu, Dayiheng Liu, and Tsung-Yi Ho. Occubench: Evaluating ai agents on real-world professional tasks via language environment simulation, 2026. URL <https://arxiv.org/abs/2604.10866>.
- Seungone Kim, Jay Shin, Joel Jang, Shayne Longpre, Hwaran Lee, Sangdoo Yun, Ryan Shin, Sungdong Kim, James Thorne, Minjoon Seo, et al. Prometheus: Inducing fine-grained evaluation capability in language models. In *International Conference on Learning Representations*, 2024.
- Fangyu Lei, Jinxiang Meng, Yiming Huang, Junjie Zhao, Yitong Zhang, Jianwen Luo, Xin Zou, Ruiyi Yang, Wenbo Shi, Yan Gao, et al. Dacomp: Benchmarking data agents across the full data intelligence lifecycle. *arXiv preprint arXiv:2512.04324*, 2025.
- Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, et al. Agentbench: Evaluating llms as agents. In *International Conference on Learning Representations*, 2024.
- Jinxiang Meng, Shaoping Huang, Fangyu Lei, Jingyu Guo, Haoxiang Liu, Jiahao Su, Sihan Wang, Yao Wang, Enrui Wang, Ye Yang, et al. Dv-world: Benchmarking data visualization agents in real-world scenarios. *arXiv preprint arXiv:2604.25914*, 2026.
- Grégoire Mialon, Clémentine Fourrier, Thomas Wolf, Yann LeCun, and Thomas Scialom. Gaia: a benchmark for general ai assistants. In *International Conference on Learning Representations*, 2024.
- Moonshot AI. Kimi K2.6: Advancing open-source coding. <https://www.kimi.com/blog/kimi-k2-6>, 2026. Accessed: 2026-06-02.
- Nous Research. Hermes agent: The ai agent that learns from you. <https://github.com/hermes-agent-org/hermes>, 2026. GitHub repository.
- OpenAI. Gpt-5.6 system card. Technical report, OpenAI, 7 2026. URL <https://deploymentsafety.openai.com/gpt-5-6/gpt-5-6.pdf>.
- OpenAI. Introducing gpt-5.5, 4 2026. URL <https://openai.com/index/introducing-gpt-5-5/>. System Card: <https://deploymentsafety.openai.com/gpt-5-5/gpt-5-5.pdf>.
- Krista Opsahl-Ong, Arnav Singhvi, Jasmine Collins, Ivan Zhou, Cindy Wang, Ashutosh Baheti, Owen Oertell, Jacob Portes, Sam Havens, Erich Elsen, et al. Officeqa pro: An enterprise benchmark for end-to-end grounded reasoning. *arXiv preprint arXiv:2603.08655*, 2026.
- Tejal Patwardhan, Rachel Dias, Elizabeth Proehl, Grace Kim, Michele Wang, Olivia Watkins, Simón Posada Fishman, Marwan Aljubei, Phoebe Thacker, Laurance Fauconnet, et al. Gdpval: Evaluating ai model performance on real-world economically valuable tasks. *arXiv preprint arXiv:2510.04374*, 2025.
- Long Phan, Alice Gatti, Ziwen Han, Nathaniel Li, Josephina Hu, Hugh Zhang, Chen Bo Calvin Zhang, Mohamed Shaaban, John Ling, Sean Shi, et al. Humanity’s last exam. *arXiv preprint arXiv:2501.14249*, 2025.

- Qwen Team. Qwen3.6-Max-Preview: Smarter, sharper, still evolving, April 2026. URL <https://qwen.ai/blog?id=qwen3.6-max-preview>.
- Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools. *Advances in neural information processing systems*, 36: 68539–68551, 2023.
- Wentao Shi, Yu Wang, Yuyang Zhao, Yuxin Chen, Fuli Feng, Xueyuan Hao, Xi Su, Qi Gu, Hui Su, Xunliang Cai, et al. Aj-bench: Benchmarking agent-as-a-judge for environment-aware evaluation. *arXiv preprint arXiv:2604.18240*, 2026.
- Yiyou Sun, Xinyang Han, Weichen Zhang, Yuanbo Pang, Tianyu Wang, Yuhan Cao, Yixiao Huang, Chris Duroiu, Haoyun Zhang, Jeffrey Lin, et al. Agents’ last exam. *arXiv preprint arXiv:2606.05405*, 2026.
- Zirui Tang, Xuanhe Zhou, Yumou Liu, Linchun Li, Yukai Wu, Weizheng Wang, Hongzhang Huang, Wei Zhou, Jun Zhou, Jiachen Song, et al. Workspace-bench 1.0: Benchmarking ai agents on workspace tasks with large-scale file dependencies. *arXiv preprint arXiv:2605.03596*, 2026.
- Kimi Team, Tongtong Bai, Yifan Bai, Yiping Bao, Jianfeng Cai, Xinyuan Cai, Peizhou Cao, Yuxuan Cao, Ziwei Chai, Y Charles, et al. Kimi k3: Open frontier intelligence. *arXiv preprint arXiv:2607.24653*, 2026.
- Yubo Wang, Xueguang Ma, Ge Zhang, Yuansheng Ni, Abhranil Chandra, Shiguang Guo, Weiming Ren, Aaran Arulraj, Xuan He, Ziyang Jiang, et al. Mmlu-pro: A more robust and challenging multi-task language understanding benchmark. *Advances in Neural Information Processing Systems*, 37:95266–95290, 2024.
- Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh Jing Hua, Zhoujun Cheng, Dongchan Shin, Fangyu Lei, Yitao Liu, Yiheng Xu, Shuyan Zhou, Silvio Savarese, Caiming Xiong, Victor Zhong, and Tao Yu. OSWorld: Benchmarking multimodal agents for open-ended tasks in real computer environments. In *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2024.
- Frank Fangzheng Xu, Yufan Song, Boxuan Li, Yuxuan Tang, Kritanjali Jain, Mengxue Bao, Zora Wang, Xuhui Zhou, Zhitong Guo, Murong Cao, et al. Theagentcompany: benchmarking llm agents on consequential real world tasks. *Advances in Neural Information Processing Systems*, 38, 2026.
- Qianyu Yang, Yang Liu, Jiaqi Li, Jun Bai, Hao Chen, Kaiyuan Chen, Tiliang Duan, Jiayun Dong, Xiaobo Hu, Zixia Jia, et al. Onemillion-bench: How far are language agents from human experts? *arXiv preprint arXiv:2603.07980*, 2026.
- Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. In *11th International Conference on Learning Representations, ICLR 2023*, 2023.
- Runyang You, Hongru Cai, Caiqi Zhang, Qiancheng Xu, Meng Liu, Tiezheng Yu, Yongqi Li, and Wenjie Li. Agent-as-a-judge. *arXiv preprint arXiv:2601.05111*, 2026.
- Aohan Zeng, Xin Lv, Zhenyu Hou, Zhengxiao Du, Qinkai Zheng, Bin Chen, Da Yin, Chendi Ge, Chenghua Huang, Chengxing Xie, et al. Glm-5: from vibe coding to agentic engineering. *arXiv preprint arXiv:2602.15763*, 2026.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, et al. Judging llm-as-a-judge with mt-bench and chatbot arena. *Advances in neural information processing systems*, 36:46595–46623, 2023.
- Shuyan Zhou, Frank F Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, et al. Webarena: A realistic web environment for building autonomous agents. In *International Conference on Learning Representations*, 2024.
- Liya Zhu, Jingzhe Ding, Jian Zhang, Jianbo Xue, Shihao Liang, Ge Zhang, Yi Zhu, Duju Zeng, Xiang Gao, Qingshui Gu, Mailun Gao, Huimin Che, Yan Zhao, Peiheng Zhou, Haojun Wang, Chaobo Xian, Lili Le, Chi Wu, Yiwei Liu, Shengda Long, Jiale Yang, Fangzhi Xu, Sijin Wu, Haodong Duan, Chao He, Zhaojian Li, Minchao Wang, Huan Zhou, Jiani Hou, Chuqian Yu, Weiran Shi, Hongwan Gao, Jiamin Chen, Guanhong Chen, Tingqin Luo, Kaiyuan Zhang, Zhixin Yao, Qing Hua, Yuhao Jiang, Jin Chen, Pu Chen, Zhenyu Hu, Xingyu Li, Zhengxuan Jiang, Meng Cao, Tianfeng Long, Haozhe Wang, Mingzhang Wang, Yichen Zhang, Yiming Dai, Chenchen Zhang, Jiaying Wang, Xinying Liu, Xingzu Liu, Lingling Zhang, Xinjie Chen, Yujia Qin, Wangchunshu Zhou, Zhiyong Wu, Yang Liu, Jiaheng Liu, Lei Zhang, Shen Yan, Wenhao

Huang, Zaiyuan Wang, and Xiaolong Chang. Workflow-gym: Towards long-horizon evaluation of computer-use agentic tasks in real-world professional fields, 2026. URL <https://arxiv.org/abs/2606.11042>.

Mingchen Zhuge, Changsheng Zhao, Dylan R. Ashley, Wenyi Wang, Dmitrii Khizbullin, Yunyang Xiong, Zechun Liu, Ernie Chang, Raghuraman Krishnamoorthi, Yandong Tian, Yangyang Shi, Vikas Chandra, and Jürgen Schmidhuber. Agent-as-a-judge: Evaluate agents with agents. In *Forty-second International Conference on Machine Learning*, 2025.

A *StartupBench* 任务标注教程

A.1 任务构建

一项 startup 任务可定义为三元组 $\mathcal{T} = (q, \mathcal{E}, \mathcal{R})$ 。专家必须提供任务的全部要素：

- **输入请求：**请求 q 是对任务的自然语言表述，规定启动任务的用户指令。输入请求源自标注者工作的真实场景，应反映现实用户意图，包括任务背景、隐含约束和预期交付物。
- **任务工作空间：**环境 $\mathcal{E}$ 表示提供给智能体的完整工作空间，包括多模态源文件，以及完成任务所需的其他资源和交互设置。任务工作空间为智能体提供自包含的执行环境。每个工作空间都包含完成任务所需的全部输入产物（例如文件、数据集或结构化资源），并确保智能体能够获得足够的输入信息来解决问题。该设计既能在受控条件下进行可复现评估，也保留了现实工作流结构。
- **评估细则：**评分细则 $\mathcal{R} = \{(p_i, w_i)\}_{i=1}^n$ 是一张核对表，其中每一项都包含自然语言评分点 p_i 和正的重要性权重 w_i ；权重反映该项对成功完成任务的重要程度。评估细则定义了一组用于考查任务完成质量的细粒度标准。由于现实工作流复杂且涉及多个方面，每项任务均使用覆盖不同维度的多条评分细则进行评估。我们把 *StartupBench* 的全部评分细则分为 6 个维度和 3 个重要性层级，详见附录 C。

这些组成部分共同保留了现实智能体工作流的结构，同时支持系统、客观的评估。任务可能要求信息综合、约束遵循、结构化生成，或领域特定的推理与判断。

A.2 交叉验证

为保证数据质量的可靠性，在构建过程中，每项任务至少由另一位具有相关专业经验的领域专家独立审查。审查者并非只关注标注一致性，而是从多个互补视角验证任务的真实性和正确性。

- **任务真实性。**审查者核验任务描述和配套工作空间的真实性，包括检查输入请求是否反映现实用户要求、全部所给材料是否事实正确，以及是否不存在领域知识错误。
- **工作流忠实度。**审查者考查任务是否忠实代表相应职业中的现实工作流。偏离实际工作程序或不能反映真实岗位职责的任务会被修订或舍弃。
- **评分细则有效性。**审查者检查评估细则，确保被考查能力对目标工作流有意义、各条细则清晰且无歧义，其相对权重也能合理反映任务优先级。

表 8: 领域专家背景汇总。职业经验指受访者报告的、在相应或密切相关领域中的经验年数。

专家统计	数值
领域专家人数	57
职业经验中位数	5 年
职业经验 ≥ 3 年的专家	68.4%
职业经验 ≥ 6 年的专家	42.1%
职业经验 ≥ 10 年的专家	24.6%
<i>StartupBench</i> 领域覆盖	6 / 6

- **真实答案验证。**审查者使用最终评分细则评估参考解答（真实答案），以验证该解答。真实答案交付物必须取得满分。如果发现参考解答与评估标准不一致，则同时修订解答和评分细则，直至二者相互一致。

B 领域专家背景

我们招募了 57 位领域专家，支持任务构建和交叉验证。专家团队覆盖 *StartupBench* 全部 6 个领域，并拥有多样的专业背景，包括临床医学、法律、投资与量化金融、软件开发与人工智能、工程、商业管理与咨询，以及教育与人文学科。我们根据专家报告的专长领域和职业经验分配任务，以确保任务构建和审查由熟悉相应专业领域的人员完成。

表 8 汇总了专家团队的职业经验。其中位职业经验为 5 年。在 57 位专家中，68.4% 拥有至少 3 年职业经验，42.1% 拥有至少 6 年职业经验，24.6% 拥有至少 10 年职业经验。这些背景为把访谈得到的用户场景转化为可复现基准任务，以及在交叉验证期间评估任务的真实性、正确性和评估标准，提供了实践领域知识。所有专家均根据任务构建和审查的实际工作量获得合理报酬。

C *StartupBench* 评分细则

评分细则维度。为在异构现实任务之间实现一致评估，我们按照主要考查能力，把全部评估细则组织为六个高层类别。这些类别并不绑定特定应用领域，而是刻画办公任务中反复出现的交付物质量共性维度，包括正确性、完整性、数据处理、专业推理、工程质量和呈现质量。这套分类既维持了跨任务类型的统一评估框架，又能使模型优缺点分析更易解释。

- **结构与完整性。**评估是否按照正确组织、文件结构和必需组成部分，完整生成了要求的交付物，以及其总体完整程度。
- **计算精度。**评估数值结果、逻辑推理、公式执行、事实一致性和其他客观计算的正确性。
- **信息整合。**评估数据清洗、变换、聚合、统计分析、

特征工程、建模和其他结构化数据处理工作流。

- **领域特定合规性。**评估输出是否满足领域特定的专业要求，包括业务逻辑、金融原则、法律推理、医疗实践、教育标准和其他专家知识。
- **工程与格式。**评估实现质量、编码规范、电子表格工程、文档格式、可复现性、稳健性、命名规范，以及对技术规格的遵守情况。
- **输出与呈现。**评估视觉呈现和沟通质量，包括图表、布局、格式、可读性、报告组织，以及最终交付物的总体可用性。

表 9 汇总了 StartupBench 全部 2,453 条评分细则的分布。计算精度是最大的细则类别，占 38.9%，反映了生成客观正确的工作成果的重要性。结构与完整性和领域特定合规性合计再占 42.8%，表明要成功完成现实办公工作流，不仅需要正确计算，还需要完整的交付物和专业领域推理。

表 9: StartupBench 评分细则类别分布。

类别	占比
结构与完整性	27.31%
计算精度	38.89%
信息整合	9.46%
领域特定合规性	15.49%
工程与格式	6.20%
输出与呈现	2.65%
总计	100.00%

评分细则重要性层级。为体现不同要求对成功完成任务的重要程度差异，我们把每条评分细则划分到三个重要性层级之一。**核心**细则刻画直接决定主要用户需求是否得到满足的要求；违反这些要求会严重损害最终交付物的正确性、可靠性、安全性或可用性。**重要**细则代表高质量完成任务的关键要求，满足与否会实质影响交付物总体质量，但单独违反其中一条不一定导致交付物不可用。**辅助**细则刻画层级较低的要求；遗漏它们主要影响细节、用户体验、视觉吸引力或精致程度，而不是交付物的基本可用性。我们分别为核心、重要和辅助细则赋予 5、3 和 1 的权重，并在把细则级判断聚合为任务分数时使用这些权重。图 7 展示了一个含不同层级评分细则的典型任务案例。

在所有任务中，核心、重要和辅助细则的权重占比平均分别为 59.10%、34.33% 和 6.57%，从而确保任务分数主要由会实质影响任务成功完成的要求决定。

D 行为层面失败模式示例

D.1 自我验证幻觉

图 8 展示了一个代表性案例。任务要求模型筛选出所有 11 级成员，模拟路线签到直至每位成员达到 12 级阈值，并生成满足一组精确数值和格式约束的 Excel 工作簿。生成的工作簿看似大体完整，包含所需工作表、成员记录和输出列，因而模型断定任务已经成功完成。然而，产物层面检查发现了多项会影响验收的关键错误，包括有效点数数值不正确以及成员姓名不匹配。根本问题并非模型不能执行要求的计算，而是它从未核验自己生成的产物。模型反而把成功的执行摘要当成最终交付物已经得到验证的证据。于是，局部却对用户至关重要的错误未被发现，体现出一种自我验证幻觉：模型的信心来自推理过程，而不是根据原始任务要求独立检查已完成的产物。

D.2 领域特定失败

图 9 展示了一个由领域特定临床可操作性不足导致的代表性失败案例。模型生成了一份格式良好、看似符合临床专业标准的多学科治疗计划，却违反了多项安全关键型治疗约束。该失败并非源于写作质量不佳，而是源于模型无法把医学知识转化为可操作且临床可靠的决策。




图 7：一项任务中跨越三个层级的评分细则代表性示例。核心细则考查解决投资问题所必需的金融推理和计算；重要细则评估辅助分析的正确性与完整性；辅助细则则关注呈现质量和额外的定量支持。




图 8: 自我验证幻觉的代表性示例。模型生成了一个看似合理的工作簿，并根据执行过程断定任务已经完成；但产物层面的抽查揭示出最终交付物中影响验收的关键错误，表明模型把进度摘要误作真正的验证，没有根据原始任务要求检验生成的产物。

