

Step-GUI 技术报告

GELab-Team, StepFun

Abstract

多模态大语言模型的快速发展，为 GUI 自动化带来了前所未有的机会；但一个基础问题仍未解决：如何在保证标注可靠性的同时，高效获得高质量训练数据？本文提出以**校准式步骤奖励系统**（Calibrated Step Reward System, CSRS）为核心的自进化训练流水线。该系统通过轨迹级校准，将模型生成的执行轨迹转化为可靠训练信号，以 10–100 倍更低的成本实现超过 90% 的标注准确率。

基于这一流水线，我们训练了 Step-GUI 系列 GUI 专家模型（4B/8B）。其中 Step-GUI-8B 在多项 GUI 基准上取得了领先结果，包括 AndroidWorld 80.2%、OSWorld 48.5%、ScreenSpot-Pro 62.6%，并在我们提出的 AndroidDaily 上达到静态任务 89.91%、端到端任务 52.50% 的表现，同时保持较强的通用多模态能力。

随着 GUI 智能体能力增强，真实部署还面临两个现实问题：异构设备之间缺乏统一接口，以及敏感屏幕内容带来的隐私风险。为此，我们提出 **GUI-MCP**，这是首个面向 GUI 自动化的 Model Context Protocol。它采用分层设计，将底层原子操作与本地 GUI 专家模型支持的高层任务委派结合起来，从而在保证隐私的前提下实现高效执行。

最后，我们提出 **AndroidDaily**，这是一个基于真实移动端日常使用模式构建的评测基准，包含 3146 个静态动作样本与 235 个端到端任务。该基准更贴近日常高频移动场景，可用于评估 GUI 智能体在真实数字生活中的实用性。总体而言，本文从数据构建、模型训练、部署接口到真实评测，系统性推进了实用 GUI 智能体的发展。

1 引言

大语言模型（LLM）的出现极大提升了机器在自然语言理解与生成方面的能力，而近来的多模态大语言模型进一步把这种能力扩展到了视觉感知与动作规划 (Bai et al., 2025a; Comanici et al., 2025; OpenAI, 2025a; Anthropic, 2025c; Guo et al., 2025b)。这为 GUI 自动化奠定了基础：模型不仅能够理解复杂界面，还能够推理出合适的交互步骤，从而成为真正可用的图形界面智能体。

围绕 GUI 智能体，研究社区已经在数据采集、模型训练和任务评测上取得显著进展。已有工作探索了 GUI 交互数据的获取方法 (Gao et al., 2024; Rawles et al., 2023; Liu et al., 2025b; Wang et al., 2025c)，并提出了多种具备实际能力的 GUI 模型 (Qin et al., 2025; Wang et al., 2025a; Ye et al., 2025; Zeng et al., 2025)。然而，一个关键瓶颈始终存在：如何高效获得高质量的轨迹和知识数据，以持续提升 GUI 智能体在目标领域中的能力？传统人工标注不仅昂贵，而且容易受主观因素影响，难以支撑大规模迭代。

为解决这一问题，本文提出以 **Calibrated Step Reward System**（CSRS）为核心的自进化训练流水线。与依赖模型自反思、后验过滤或单轮可验证任务的数据生成方法不同 (Zelikman et al., 2022; Madaan et al., 2023; Jung et al., 2023; Gulcehre et al., 2023)，CSRS 面向多步 GUI 执行场景，把模型生成的步骤级推理锚定到轨迹级结果信号上，这些结果信号可以来自自动验证脚本，也可以来自人工标注。通过这种方式，CSRS 能在可扩展的前提下显著提高轨迹标注质量，并将生成轨迹进一步提炼为训练所需的知识数据。

在这套流水线上，我们训练了 **Step-GUI** 系列模型（4B 和 8B），其骨干来自 Qwen3-VL。Step-GUI-8B 在多个 GUI 基准上达到领先水平：AndroidWorld 80.2%，OSWorld 48.5%，ScreenShot-Pro 62.6%，并在本文提出的 AndroidDaily 上获得静态任务 89.91%、端到端任务 52.50% 的结果。与此同时，4B 版本已经具备较强的本地部署能力，可运行在消费级硬件上，适合隐私敏感场景。

当 GUI 智能体逐渐具备更强的理解与执行能力后，又会出现两个更现实的部署问题：一是不同设备和平台之间缺乏统一的通信接口，二是屏幕截图和设备状态往往包含大量敏感信息。为此，




Figure 1: 跨异构 GUI 基准的整体性能概览。Step-GUI-8B 在多项 grounding 与端到端任务上达到领先水平。

我们提出 **GUI-MCP**，即面向 GUI 自动化的图形界面模型上下文协议。它通过分层双层设计统一设备控制接口，在低层提供原子级操作，在高层支持把任务直接委派给本地 GUI 专家模型，从而让主模型聚焦高层规划，同时把实际界面执行尽可能留在本地设备上，以实现更好的隐私保护。

除了训练和部署，真实可用的 GUI 智能体还需要更贴近现实的评测。现有工作要么偏重静态界面 grounding (Cheng et al., 2024; Wu et al., 2024; Li et al., 2025c,b; Burns et al., 2022; Rastogi et al., 2021; Zhang et al., 2024; Liu et al., 2024)，要么虽然支持交互式执行 (Rawles et al., 2024; Xie et al., 2024)，但对高频中文移动应用场景覆盖不足。针对这一空白，我们提出 **AndroidDaily**。该基准不追求最大化应用数量，而是聚焦出行、购物、社交、娱乐和本地服务等高频真实场景，并采用静态动作预测与端到端执行相结合的双层评测方式，更能反映 GUI 智能体在日常数字生活中的实际可用性。

总体来看，本文的贡献体现在四个方面：

- 提出自进化训练流水线与 CSRS，以大幅降低标注成本并持续提升模型能力。
- 训练出 Step-GUI 系列模型，在多个 GUI 基准上达到领先或有竞争力的结果，同时保留较强通用能力。
- 提出 GUI-MCP，为 GUI 自动化提供统一、可扩展且隐私友好的协议接口。
- 提出 AndroidDaily，建立更贴近日常移动使用场景的 GUI 评测基准。

这些工作共同覆盖了 GUI 智能体从训练数据、模型构建、部署接口到真实评测的完整链条，为实用型 GUI 智能体奠定了基础。

2 Step-GUI

2.1 数据构建思路

我们希望构建的不是一个只会执行固定 GUI 指令的狭义策略模型，而是一个同时保留**通用多模态能力**、具备丰富世界知识、并拥有**强 agentic 能力**的视觉语言基础模型。为此，Step-GUI 的训练数据分为中训练（mid-train）与冷启动（cold-start）两类阶段。

中训练数据。 中训练的目标是为模型建立 GUI 智能体所需的基础能力，包括：保留通用视觉与语言理解、掌握细粒度视觉 grounding、理解轨迹格式与动作协议、形成从自然语言指令到可执行动作的初步映射。我们因此混合两大类数据：

- **通用多模态与知识数据**：用于保持语言流畅性、世界知识与通用视觉理解。
- **Agent 导向数据**：包括动作对齐数据、轨迹数据和跨平台环境数据，使模型熟悉 Android、Windows、macOS、Ubuntu 等系统中的操作模式。

冷启动数据。 在已有基础能力上，冷启动阶段主要用于**注入缺失知识并校正执行行为**。我们观察到，很多 GUI 失败并非源于缺少操作轨迹，而是源于知识盲区，例如不了解某应用页面结构、服务语义或任务规则。因此，冷启动阶段会根据轨迹执行错误反推出缺失知识，并将其重写成面向模型的问答或视觉问答样本，同时保留一部分轨迹数据用于稳定动作格式与执行习惯。

2.2 CSRS：校准式步骤奖励系统

GUI 任务通常是长轨迹、多步骤、稀疏奖励的执行过程，简单依赖模型自我评价会带来严重幻觉与错误归因。CSRS 的核心思想是：**不直接相信模型生成的步骤级解释，而是用轨迹级结果信号去校准步骤级数据**。

CSRS 主要由以下部分组成：

- **轨迹级验证**：通过自动评测脚本或人工结果标注判断整条任务轨迹是否成功。
- **步骤级知识提炼**：对成功轨迹中的关键步骤、决策依据和环境模式做结构化抽取，转化成更可靠的训练样本。
- **渐进式训练闭环**：模型不断生成新轨迹，系统不断校准、过滤和回流高质量数据，从而形成自进化循环。

与传统逐步标注相比，CSRS 通过“轨迹成功性”这一更高置信度的信号，显著降低了步骤标注成本，同时也让模型能从真实执行结果中学习更稳定的 GUI 推理模式。

2.3 训练机制

Step-GUI 使用三阶段的渐进式训练策略，把**新探索**与**知识过滤**两条数据流结合起来，不断提升模型能力。训练过程中还引入了强化学习式优化，用于提升长程任务中的规划与执行质量。

半在线探索。 长程 GUI 任务的奖励往往极其稀疏，因此单纯依赖随机探索难以有效学习。本文采用 **Semi-Online** 策略：对于原本未能完成任务的 rollout，系统在第二轮执行时向模型注入有限的 ground-truth 提示，使模型能够接触到更高质量的成功轨迹。这些“带回溯的成功经验”会进一步转化为高价值训练样本。

稳定性增强。 为了让 RL 训练更稳定，文中还引入了若干增强策略，包括动态探索范围、基于重要性采样的样本复用，以及对 clipping 后梯度完全消失问题的修正。其目标是在不过度牺牲稳定性的前提下，保留对低概率但有价值动作的学习能力，避免模型过早塌缩到局部最优。

2.4 模型定位

Step-GUI 的目标并不是仅在某一个 GUI 基准上刷分，而是形成一类可扩展的 GUI 专家模型。4B 版本强调**本地部署与隐私友好**，适合设备侧执行；8B 版本则在 grounding、长程任务完成率和多模态综合能力之间取得更优平衡。实验表明，这种设计既提高了 GUI 专项能力，也没有明显损害模型在 OCR、图表理解、一般视觉问答等任务上的表现。

3 GUI-MCP：面向安全 LLM-设备交互的高效协议

尽管 LLM 已经展现出很强的推理与规划能力，但 GUI 自动化在实际落地时仍然缺少一个统一、标准化的接口层。现有方案往往高度依赖具体平台和工程实现，导致不同模型、不同设备之间难以复用。为此，本文提出 **GUI-MCP** (Graphical User Interface - Model Context Protocol)，它是第一个专门面向 GUI 操作任务设计的 MCP 实现。

GUI-MCP 的目标是让 LLM 能通过统一协议控制 Ubuntu、macOS、Windows、Android 和 iOS 等多种设备，从而把 GUI 自动化从“为每个平台单独定制”转变为“在统一接口上调度异构设备能力”。




Figure 2: GUI-MCP 的整体架构。它由低层 MCP 与高层 MCP 两部分组成，同时兼顾执行效率与隐私保护。

3.1 体系结构

GUI-MCP 采用分层设计，分为 **低层 MCP** 与 **高层 MCP**。

低层 MCP。 低层 MCP 主要面向原子操作，提供细粒度设备控制接口，包括：

- 设备管理，如 `get_device_list()`；
- 状态感知，如 `get_screenshot()`；
- 基本交互动作，如点击、双击、滑动、长按、拖拽、输入文本与热键等。

类别	操作
点击	<code>click</code> , <code>double_click</code> , <code>triple_click</code>
手势	<code>swipe</code> , <code>long_press</code>
鼠标	<code>move_to</code> , <code>drag_to</code>
输入	<code>input_text</code> , <code>hotkey</code>
应用	<code>awake</code>

Table 1: 低层 MCP 暴露的典型原子操作。

这一层给予主模型最大的控制灵活性，适合需要逐步规划、依赖上下文确认、或超出本地专家模型能力边界的场景。

高层 MCP。 高层 MCP 则面向完整任务执行，例如 `execute_task(task_description)`。用户或主 LLM 只需要提供自然语言任务描述，系统就会调用本地 GUI 专家模型（如 Step-GUI-4B）自动完成整段 GUI 操作。这样做的好处是，主模型不再需要为每一个简单界面动作都参与推理和 API 交互。

3.2 设计优势

执行效率。 分层设计允许系统按任务复杂度灵活切换控制模式：对于简单且封闭的 GUI 操作，可以直接交给本地高层 MCP 完成；对于复杂、多轮、存在歧义或需要外部推理的任务，则使用




Figure 3: AndroidDaily 静态基准的动作分类。它覆盖 Android 自动化中的八类核心动作，并支持多解标注。

低层 MCP，让主模型保留更强控制力。这样可以显著降低主模型的推理成本与 API 调用次数。

隐私保护。 GUI 场景中的截图和界面状态通常包含个人信息、支付信息、位置、联系人等隐私内容。GUI-MCP 提供了**高隐私模式**：

- 外部云端模型无法直接看到原始截图；
- 本地图像与敏感状态先由本地 GUI 模型解析；
- 对外仅输出完成任务所需的语义摘要，而不是原始像素内容。

这一设计使得系统既能利用云端大模型的高层推理能力，又能尽量把敏感视觉数据留在设备本地处理，从而在可用性与隐私之间取得较好平衡。

可扩展性。 由于 GUI-MCP 把设备能力抽象成统一协议，未来无论是新增应用、平台，还是接入不同能力级别的本地 GUI 专家模型，都可以在同一协议层上扩展，而不需要重写整套 LLM 交互逻辑。

4 AndroidDaily：面向日常生活 Agent 任务的动态基准

尽管 AndroidWorld 等基准已经推动了 Android GUI 智能体评测的发展，但现有基准与真实高频日常移动使用之间仍然存在明显差距。很多任务更偏向生产力或技术演示场景，而不一定是用户每天真正高频执行的事情。AndroidDaily 的设计目标正是填补这一空白。

与按应用目录选题不同，AndroidDaily 基于真实移动端使用频率与下载统计来选择任务场景。它重点覆盖出行、购物、社交媒体、娱乐和本地服务等高频应用场景，优先纳入外卖下单、打车、短视频浏览、移动支付等真实影响强、操作复杂度高、且与现实服务深度绑定的任务。

AndroidDaily 采用双层评测设计，以平衡评测效率与真实性。

静态基准 (3146 个动作)。 静态基准提供任务描述与逐步截图，要求模型预测当前界面上的下一步动作。它覆盖 AWAKE、CLICK、COMPLETE、INFO、LONGPRESS、SLIDE、TYPE 和 WAIT 八类动作。每个动作都带有精确参数，且显式支持多解 ground truth，例如同一个目标可能可通过多个 UI 区域完成。该设置适合高效迭代模型，因为不需要复杂的在线环境。

端到端基准 (235 个任务)。 端到端基准要求智能体在真实应用环境中完成整项任务，并通过 LLM-based judge 判定是否成功。这种设置工程成本更高，但更接近真实世界使用。任务主要分布在五类日常场景中：*Transportation*、*Shopping*、*Social Media*、*Entertainment* 与 *Local Services*。

除场景类别之外，AndroidDaily 还从多个维度标注任务属性，包括认知操作类型（检索、筛选、分析等）、结构复杂度（原子任务、组合任务、带条件/循环任务）以及指令歧义等级。这样




Figure 4: AndroidDaily 端到端任务的场景分布。该基准覆盖五类日常高频场景，并给出代表性任务示例。

的多维组织方式有助于精确分析模型的强项与失败模式，也让这个基准比传统“纯动作匹配”式评测更具诊断价值。

5 实验

5.1 实验设置

Grounding 基准。 我们在五个 GUI grounding 基准上评估模型的元素感知与定位能力，包括 ScreenSpot-Pro、ScreenSpot-v2、OSWorld-G、MMBench-GUI-L2 与 VisualWebBench (Li et al., 2025c; Wu et al., 2024; Wang et al., 2025d; Liu et al., 2024)。

桌面与手机任务。 OSWorld (Xie et al., 2024) 提供 369 个真实桌面任务，覆盖多种桌面软件；AndroidWorld (Rawles et al., 2024) 提供 116 个手机任务，运行在真实 Android 模拟环境中；AndroidDaily 则补充了更贴近高频中文移动应用场景的评测。

通用多模态基准。 为了验证 Step-GUI 并未因 GUI 专项训练而失去通用能力，我们还在 OCR、图表理解、数学视觉推理和一般多模态理解基准上进行测试。

对比方法。 基线覆盖了当前主流基础模型与 GUI 专项模型，包括 Claude、OpenAI CUA、Gemini、UI-TARS、InternVL、MobileRL、AutoGLM、Qwen 系列与 GUI-Owl 等 (Anthropic, 2025b,a; OpenAI, 2025b; Google, 2025; Qin et al., 2025; Wang et al., 2025a,b; Xu et al., 2025; Z.ai, 2025a,b; Bai et al., 2025b; Ye et al., 2025; Bai et al., 2025a)。

5.2 主要结果

GUI grounding。 Step-GUI 在多个 grounding 基准上表现稳定且强劲。尤其是 Step-GUI-8B，在 ScreenSpot-Pro 上达到 62.6，在 OSWorld-G 上达到 70.0，在 MMBench-GUI-L2 上达到 85.6，并在 VisualWebBench 上保持非常有竞争力的表现。相比同规模或更大规模的基础模型，Step-GUI 在 GUI 元素理解和定位方面展现出显著优势。

端到端 GUI 任务。 在 AndroidWorld 与 OSWorld 这类需要多步规划和稳定执行的基准上，Step-GUI-8B 取得了有竞争力甚至领先的成绩。论文尤其强调，虽然 8B 模型尺寸不大，但在真实 GUI 环境中的表现已经足以和许多更大模型正面竞争，而 4B 版本也能在资源受限场景中保持相当强的能力。

Table 2: 多个 GUI grounding 基准上的表现。粗体为最优，带下划线为次优。

模型	ScreenSpot-Pro	ScreenSpot-v2	OSWorld-G	MMBench-GUI-L2	VisualWebBench
OpenAI CUA	23.4	87.9	36.4	-	-
UI-TARS-1.5	<u>61.6</u>	94.2	-	-	-
SeedVL-1.5	60.9	95.2	-	<u>84.4</u>	87.3
GUI-Owl-32B	58.0	93.2	58.0	83.0	-
Qwen3-VL-4B-Instruct	59.5	94.0	58.2	-	-
Qwen3-VL-8B-Instruct	54.6	94.4	58.2	-	-
Qwen3-30B-A3B-Instruct	60.5	94.7	61.0	79.7	79.7
Step-GUI-4B	60.0	93.6	<u>66.9</u>	84.0	90.7
Step-GUI-8B	62.6	<u>95.1</u>	70.0	85.6	<u>89.7</u>

Table 3: 主流多模态基准上的代表性结果。

Benchmark	Qwen3-VL-8B	Qwen3-VL-30B-A3B	Step-GUI-4B	Step-GUI-8B
V*	86.4	86.4	79.1	89.0
PhyX	28.3	31.1	33.0	41.9
OmniOCR	78.7	74.4	73.6	77.1
OCRBench	89.7	90.8	84.6	88.0
LogicVista	52.3	58.2	52.1	53.7
CharXiv_DQ	83.0	85.5	84.1	86.3
SimpleVQA	50.2	52.7	48.1	50.8

AndroidDaily。 在 AndroidDaily 静态动作预测上，Step-GUI-8B 达到 89.91%，明显高于多项已有方法；在端到端任务上达到 52.50%，与当前强基线差距较小。进一步分析表明，模型在查询类任务上表现最好，而分析类和组合类任务依旧是最具挑战的部分。值得注意的是，Step-GUI-8B 在高歧义任务上的表现优于部分强基线，这说明它对不完整指令的鲁棒性更强。

通用多模态能力。 GUI 专项训练并没有显著损害模型的一般多模态能力。Step-GUI-8B 在 V*、PhyX、CharXiv、OmniOCR 等任务上保持了很强的性能，相比基础版 Qwen3-VL-8B-Instruct 仍有多处提升。这一点非常关键，因为真实部署中，GUI 智能体往往需要同时处理 OCR、文档理解、图表推理和一般视觉问答，而非只执行固定 UI 动作。

5.3 详细分析

自进化训练的收益。 论文跟踪了 Step-GUI-8B 在六轮自进化训练中的表现，结果显示模型在 AndroidWorld 上出现了明显的“阶段跃迁”，在 OSWorld 上则呈现更平稳的持续增长。这说明 CSRS 既能在模型达到一定能力阈值后快速吸收高质量成功轨迹，也能通过拒绝采样与知识回流持续修正困难场景中的失败模式。

RLVR 训练稳定性。 从奖励曲线、KL 变化、困惑度比例以及重要性采样方差等指标来看，训练过程保持了相对平稳的上升趋势，没有出现明显的奖励欺骗或发散。尤其是联合奖励和各子能力奖励的同步上升，说明模型的改进并不是偶然投机，而是来自 GUI grounding、桌面操作和手机操作等多项能力的共同提升。

探索与熵。 基础 GRPO 训练会让策略熵快速下降，虽然有助于 exploitation，但也会提高模式坍塌风险。引入梯度保持机制后，这种趋势更明显；而 Semi-Online 策略通过对失败轨迹注入少量真实提示，有效恢复了策略熵，帮助模型维持更健康的探索水平。




Figure 5: Step-GUI-8B 在六轮自进化训练中的性能演化。




Figure 6: RLVR 训练过程中的奖励动态。整体曲线平滑上升，说明训练收敛稳定。

6 相关工作

6.1 语言模型推理与自改进

Chain-of-thought (CoT) 提示证明了显式中间推理步骤对复杂问题求解的重要性 (Wei et al., 2022)。在此基础上, Synthetic Prompting、STaR、Tree of Thoughts、Quiet-STaR 等方法进一步探索了如何自动生成、搜索和利用推理轨迹 (Shao et al., 2023; Zelikman et al., 2022; Yao et al., 2023; Zelikman et al., 2024)。与此同时, 自一致性、自验证、自反思和基于检索的纠错机制也被广泛用于提升推理可靠性 (Wang et al., 2022; Weng et al., 2023; Madaan et al., 2023; Li et al., 2025a; Niu et al., 2024; Zheng et al., 2023)。

不过, 这些方法大多面向单轮推理或可直接验证的任务; 对于 GUI 这种长轨迹、多步执行、环境状态持续变化的场景, 单纯依赖模型自我解释并不足够可靠。CSRS 的贡献就在于把步骤级 reasoning 放到轨迹级成功信号之下进行校准, 从而让“自改进”真正适用于 GUI 智能体。

6.2 GUI 智能体

近期大量工作开始系统研究 GUI 智能体的数据、训练和架构设计, 包括 UI-TARS、OpenCUA、GUI-Owl、UITron、Mobile-Agent-v3 等 (Qin et al., 2025; Wang et al., 2025a,c; Ye et al., 2025; Zeng




Figure 7: 离策略修正与稳定性诊断结果。多项指标显示训练策略与 rollout 策略保持较高同步。




Figure 8: 不同训练策略下策略熵的演化。Semi-Online 策略显著改善了探索水平。

et al., 2025)。与此同时，Claude、Seed、Qwen 等通用基础模型也开始原生支持 GUI 场景 (Anthropic, 2025c; Guo et al., 2025a; Bai et al., 2025a)。

大多数 GUI 智能体遵循 ReAct 范式：观察、推理、再行动 (Yao et al., 2022)。最近的方法则进一步引入多智能体协作、分层规划以及视觉与代码混合控制 (Liu et al., 2025a; Song et al., 2025; Zhang et al., 2025; Agashe et al., 2025)。Step-GUI 的不同之处在于：它不仅关注模型架构和执行流程，还围绕“如何稳定、低成本地构造高质量训练数据”建立了完整闭环。

6.3 GUI 评测基准

GUI 评测大致可以分成两类。一类是静态基准，例如 ScreenSpot、ScreenSpot-v2、ScreenSpot-Pro、FuncPred、MoTIF、RefExp、LlamaTouch 和 VisualWebBench 等，主要考察元素定位和动作预测 (Cheng et al., 2024; Wu et al., 2024; Li et al., 2025c,b; Burns et al., 2022; Rastogi et al., 2021; Zhang et al., 2024; Liu et al., 2024)。另一类是交互式基准，例如 AndroidWorld 与 OSWorld，它们允许智能体在更真实的系统环境中执行完整任务 (Rawles et al., 2024; Xie et al., 2024)。

AndroidDaily 与这些工作互补：它更强调真实日常高频移动使用场景，特别是中文移动生态中的出行、购物与本地生活任务，因此能更直接反映 GUI 智能体走向真实部署时的能力边界。

7 结论

本文从数据、部署和评测三个层面系统推进了实用 GUI 智能体的发展。我们提出 CSRS 与自进化训练流水线，以更低成本构建高质量 GUI 轨迹与知识数据；基于此训练的 Step-GUI 系列模型在多个 GUI 基准上取得了领先或有竞争力的表现，并保留了较强的通用多模态能力。

在部署层面，我们提出 GUI-MCP，为 LLM 与异构设备之间的交互提供了统一、分层且注重隐私的协议；在评测层面，我们提出 AndroidDaily，把 GUI 智能体的评价进一步拉近到真实移动

日常使用场景。整体而言，这些工作缩小了 GUI 智能体“研究原型”和“可靠日常助手”之间的距离。

References

- S. Agashe, K. Wong, V. Tu, J. Yang, A. Li, and X. E. Wang. Agent s2: A compositional generalist-specialist framework for computer use agents. *arXiv preprint arXiv:2504.00906*, 2025.
- Anthropic. Claude sonnet 4.5. <https://www.anthropic.com/claude/sonnet>, 2025a.
- Anthropic. Claude 4. <https://www.anthropic.com/news/claude-4>, 2025b.
- Anthropic. Introducing claude opus 4.5. <https://www.anthropic.com/news/claude-opus-4-5>, 2025c. Accessed: March 19, 2026.
- S. Bai, Y. Cai, R. Chen, K. Chen, X. Chen, Z. Cheng, L. Deng, W. Ding, C. Gao, C. Ge, W. Ge, Z. Guo, Q. Huang, J. Huang, F. Huang, B. Hui, S. Jiang, Z. Li, M. Li, M. Li, K. Li, Z. Lin, J. Lin, X. Liu, J. Liu, C. Liu, Y. Liu, D. Liu, S. Liu, D. Lu, R. Luo, C. Lv, R. Men, L. Meng, X. Ren, X. Ren, S. Song, Y. Sun, J. Tang, J. Tu, J. Wan, P. Wang, P. Wang, Q. Wang, Y. Wang, T. Xie, Y. Xu, H. Xu, J. Xu, Z. Yang, M. Yang, J. Yang, A. Yang, B. Yu, F. Zhang, H. Zhang, X. Zhang, B. Zheng, H. Zhong, J. Zhou, F. Zhou, J. Zhou, Y. Zhu, and K. Zhu. Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*, 2025a.
- S. Bai, K. Chen, X. Liu, J. Wang, W. Ge, S. Song, K. Dang, P. Wang, S. Wang, J. Tang, et al. Qwen2. 5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025b.
- A. Burns, D. Arsan, S. Agrawal, R. Kumar, K. Saenko, and B. A. Plummer. A dataset for interactive vision-language navigation with unknown command feasibility. In *European Conference on Computer Vision*, pages 312–328. Springer, 2022.
- K. Cheng, Q. Sun, Y. Chu, F. Xu, Y. Li, J. Zhang, and Z. Wu. Seeclick: Harnessing gui grounding for advanced visual gui agents. *arXiv preprint arXiv:2401.10935*, 2024.
- G. Comanici, E. Bieber, M. Schaekermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen, et al. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. *arXiv preprint arXiv:2507.06261*, 2025.
- L. Gao, L. Zhang, S. Wang, S. Wang, Y. Li, and M. Xu. Mobileviews: A large-scale mobile gui dataset. *arXiv preprint arXiv:2409.14337*, 2024.
- Google. Introducing the gemini 2.5 computer use model. <https://blog.google/technology/google-deepmind/gemini-computer-use-model>, 2025.
- C. Gulcehre, T. L. Paine, S. Srinivasan, K. Konyushkova, L. Weerts, A. Sharma, A. Siddhant, A. Ahern, M. Wang, C. Gu, et al. Reinforced self-training (rest) for language modeling. *arXiv preprint arXiv:2308.08998*, 2023.
- D. Guo, F. Wu, F. Zhu, F. Leng, G. Shi, H. Chen, H. Fan, J. Wang, J. Jiang, J. Wang, et al. Seed1. 5-vl technical report. *arXiv preprint arXiv:2505.07062*, 2025a.
- D. Guo, F. Wu, F. Zhu, F. Leng, G. Shi, H. Chen, H. Fan, J. Wang, J. Jiang, J. Wang, et al. Seed1. 5-vl technical report. *arXiv preprint arXiv:2505.07062*, 2025b.
- J. Jung, P. West, L. Jiang, F. Brahman, X. Lu, J. Fisher, T. Sorensen, and Y. Choi. Impossible distillation: from low-quality model to high-quality dataset & model for summarization and paraphrasing. *arXiv preprint arXiv:2305.16635*, 2023.

- F. Li, P. Fang, Z. Shi, A. Khan, F. Wang, D. Feng, W. Wang, X. Zhang, and Y. Cui. Cot-rag: Integrating chain of thought and retrieval-augmented generation to enhance reasoning in large language models. *arXiv preprint arXiv:2504.13534*, 2025a.
- H. Li, J. Chen, J. Su, Y. Chen, Q. Li, and Z. Zhang. Autogui: Scaling gui grounding with automatic functionality annotations from llms. *arXiv preprint arXiv:2502.01977*, 2025b.
- K. Li, Z. Meng, H. Lin, Z. Luo, Y. Tian, J. Ma, Z. Huang, and T.-S. Chua. Screenspot-pro: Gui grounding for professional high-resolution computer use. In *Proceedings of the 33rd ACM International Conference on Multimedia*, pages 8778–8786, 2025c.
- H. Liu, X. Zhang, H. Xu, Y. Wanyan, J. Wang, M. Yan, J. Zhang, C. Yuan, C. Xu, W. Hu, et al. Pc-agent: A hierarchical multi-agent collaboration framework for complex task automation on pc. *arXiv preprint arXiv:2502.14282*, 2025a.
- J. Liu, Y. Song, B. Y. Lin, W. Lam, G. Neubig, Y. Li, and X. Yue. Visualwebbench: How far have multimodal llms evolved in web page understanding and grounding? *arXiv preprint arXiv:2404.05955*, 2024.
- Z. Liu, J. Xie, Z. Ding, Z. Li, B. Yang, Z. Wu, X. Wang, Q. Sun, S. Liu, W. Wang, et al. Scalecua: Scaling open-source computer use agents with cross-platform data. *arXiv preprint arXiv:2509.15221*, 2025b.
- A. Madaan, N. Tandon, P. Gupta, S. Hallinan, L. Gao, S. Wiegrefe, U. Alon, N. Dziri, S. Prabhume, Y. Yang, et al. Self-refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems*, 36:46534–46594, 2023.
- M. Niu, H. Li, J. Shi, H. Haddadi, and F. Mo. Mitigating hallucinations in large language models via self-refinement-enhanced knowledge retrieval. *arXiv preprint arXiv:2405.06545*, 2024.
- OpenAI. Gpt-5 system card. 2025a.
- OpenAI. Openai o3 operator. <https://openai.com/index/o3-o4-mini-system-card-addendum-operator-o3/>, 2025b.
- Y. Qin, Y. Ye, J. Fang, H. Wang, S. Liang, S. Tian, J. Zhang, J. Li, Y. Li, S. Huang, et al. Ui-tars: Pioneering automated gui interaction with native agents. *arXiv preprint arXiv:2501.12326*, 2025.
- A. K. Rastogi, B. A. y Arcas, C. Bai, J. J. Chen, S. K. Sunkara, X. Zang, and Y. Xu. Uibert: Learning generic multimodal representations for ui understanding. 2021.
- C. Rawles, A. Li, D. Rodriguez, O. Riva, and T. Lillicrap. Androidinthewild: A large-scale dataset for android device control. In *Advances in Neural Information Processing Systems*, 36:59708–59728, 2023.
- C. Rawles, S. Clinckemallie, Y. Chang, J. Waltz, G. Lau, M. Fair, A. Li, W. Bishop, W. Li, F. Campbell-Ajala, et al. Androidworld: A dynamic benchmarking environment for autonomous agents. *arXiv preprint arXiv:2405.14573*, 2024.
- Z. Shao, Y. Gong, Y. Shen, M. Huang, N. Duan, and W. Chen. Synthetic prompting: Generating chain-of-thought demonstrations for large language models. In *International conference on machine learning*, pages 30706–30775. PMLR, 2023.
- L. Song, Y. Dai, V. Prabhu, J. Zhang, T. Shi, L. Li, J. Li, S. Savarese, Z. Chen, J. Zhao, et al. Coact-1: Computer-using agents with coding as actions. *arXiv preprint arXiv:2508.03923*, 2025.
- H. Wang, H. Zou, H. Song, J. Feng, J. Fang, J. Lu, L. Liu, Q. Luo, S. Liang, S. Huang, et al. Ui-tars-2 technical report: Advancing gui agent with multi-turn reinforcement learning. *arXiv preprint arXiv:2509.02544*, 2025a.

- W. Wang, Z. Gao, L. Gu, H. Pu, L. Cui, X. Wei, Z. Liu, L. Jing, S. Ye, J. Shao, et al. Internvl3. 5: Advancing open-source multimodal models in versatility, reasoning, and efficiency. *arXiv preprint arXiv:2508.18265*, 2025b.
- X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022.
- X. Wang, B. Wang, D. Lu, J. Yang, T. Xie, J. Wang, J. Deng, X. Guo, Y. Xu, C. H. Wu, et al. Opencua: Open foundations for computer-use agents. *arXiv preprint arXiv:2508.09123*, 2025c.
- X. Wang, Z. Wu, J. Xie, Z. Ding, B. Yang, Z. Li, Z. Liu, Q. Li, X. Dong, Z. Chen, et al. Mmbench-gui: Hierarchical multi-platform evaluation framework for gui agents. *arXiv preprint arXiv:2507.19478*, 2025d.
- J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, D. Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- Y. Weng, M. Zhu, F. Xia, B. Li, S. He, S. Liu, B. Sun, K. Liu, and J. Zhao. Large language models are better reasoners with self-verification. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 2550–2575, 2023.
- Z. Wu, Z. Wu, F. Xu, Y. Wang, Q. Sun, C. Jia, K. Cheng, Z. Ding, L. Chen, P. P. Liang, et al. Os-atlas: A foundation action model for generalist gui agents. *arXiv preprint arXiv:2410.23218*, 2024.
- T. Xie, D. Zhang, J. Chen, X. Li, S. Zhao, R. Cao, T. J. Hua, Z. Cheng, D. Shin, F. Lei, et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments. In *Advances in Neural Information Processing Systems*, 37:52040–52094, 2024.
- Y. Xu, X. Liu, X. Liu, J. Fu, H. Zhang, B. Jing, S. Zhang, Y. Wang, W. Zhao, and Y. Dong. Mobilerl: Online agentic reinforcement learning for mobile gui agents. *arXiv preprint arXiv:2509.18119*, 2025.
- S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. R. Narasimhan, and Y. Cao. React: Synergizing reasoning and acting in language models. In *The eleventh international conference on learning representations*, 2022.
- S. Yao, D. Yu, J. Zhao, I. Shafran, T. Griffiths, Y. Cao, and K. Narasimhan. Tree of thoughts: Deliberate problem solving with large language models. *Advances in neural information processing systems*, 36: 11809–11822, 2023.
- J. Ye, X. Zhang, H. Xu, H. Liu, J. Wang, Z. Zhu, Z. Zheng, F. Gao, J. Cao, Z. Lu, et al. Mobile-agent-v3: Fundamental agents for gui automation. *arXiv preprint arXiv:2508.15144*, 2025.
- Z.ai. Autoglm goes open source. <https://autoglm.z.ai/blog>, 2025a.
- Z.ai. Introducing the gemini 2.5 computer use model. <https://z.ai/blog/glm-4.6v>, 2025b.
- E. Zelikman, Y. Wu, J. Mu, and N. Goodman. Star: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems*, 35:15476–15488, 2022.
- E. Zelikman, G. Harik, Y. Shao, V. Jayasiri, N. Haber, and N. D. Goodman. Quiet-star: Language models can teach themselves to think before speaking. *arXiv preprint arXiv:2403.09629*, 2024.
- Z. Zeng, J. Huang, L. Zheng, W. Han, Y. Zhong, L. Chen, L. Yang, Y. Chu, Y. He, and L. Ma. Uitrone: Foundational gui agent with advanced perception and planning. *arXiv preprint arXiv:2508.21767*, 2025.
- C. Zhang, H. Huang, C. Ni, J. Mu, S. Qin, S. He, L. Wang, F. Yang, P. Zhao, C. Du, et al. Ufo2: The desktop agentos. *arXiv preprint arXiv:2504.14603*, 2025.

- L. Zhang, S. Wang, X. Jia, Z. Zheng, Y. Yan, L. Gao, Y. Li, and M. Xu. Llamatouch: A faithful and scalable testbed for mobile ui task automation. In *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology*, pages 1–13, 2024.
- G. Zheng, B. Yang, J. Tang, H.-Y. Zhou, and S. Yang. Ddcot: Duty-distinct chain-of-thought prompting for multimodal reasoning in language models. *Advances in Neural Information Processing Systems*, 36: 5168–5191, 2023.